博士学位论文

（学术学位论文）

基于强化学习的反作用轮无人自行车平衡控制研究

RESEARCH ON REINFORCEMENT LEARNING-BASED BALANCING CONTROL FOR REACTION WHEEL UNMANNED BICYCLES

朱先进

哈尔滨工业大学

2023 年 11 月

中国知网 https://www.cnki.net

国内图书分类号：TP242.6
国际图书分类号：681.5

学校代码：10213
密级：公开

博士学位论文

基于强化学习的反作用轮无人自行车平衡控制研究

博士研究生：朱先进

导　　师：刘宇教授

申请学位：工学博士

学　　科：机械工程

所在单位：机电工程学院

答辩日期：2023 年 11 月

授予学位单位：哈尔滨工业大学

中国知网　https://www.cnki.net

Classified Index: TP242.6
U.D.C: 681.5

Dissertation for the Doctoral Degree in Engineering

RESEARCH ON REINFORCEMENT LEARNING-BASED BALANCING CONTROL FOR REACTION WHEEL UNMANNED BICYCLES

Candidate: Xianjin Zhu
Supervisor: Prof. Yu Liu
Academic Degree Applied for: Doctor of Engineering
Specialty: Mechanical Engineering
Affiliation: School of Mechatronics Engineering
Date of Defense: November, 2023
Degree-Conferring-Institution: Harbin Institute of Technology

中国知网 https://www.cnki.net

摘 要

无人系统的研究在国防科技和工业生产领域具有极其重要的意义。无人自行车因其狭长的车身设计及前后单轮结构，相较于其他无人系统展现出较高的载重与自重比以及良好的灵活性，在野外侦察、边境巡逻、灾害救援等领域具有广泛的应用潜力。实现高性能的平衡控制始终是无人自行车系统研发中的核心技术挑战和科学难题。特别是在崎岖路面及建模误差、外部扰动等不确定性因素下，无人自行车的欠驱动特性和横向不稳定性加剧了高性能平衡控制算法设计的难度。根据对崎岖路面下不同平衡方式的对比分析，本研究以反作用轮无人自行车为研究对象，针对现有平衡控制算法的不足，开展基于强化学习的无人自行车平衡控制算法研究，分析离线强化学习在无人自行车平衡控制中存在的不足，提出串并联在线强化学习的自平衡滑模控制方案，并实现强化学习在线训练的稳定性保障和安全性保障，具有重要的研究价值和广阔的应用前景。

研制反作用轮无人自行车样机，采用等效重力场方法及内外环系统框架，构建反作用轮无人自行车的横滚角误差跟踪模型。同时，建立仿真与实物测试环境，设计平衡控制算法的测试评估任务。此外，构建基于动力学模型的离线强化学习域随机化训练环境，并设计基于近端策略优化算法的无人自行车平衡控制器，随后在上述仿真环境中进行相关测试。

为了进一步提升反作用轮无人自行车的平衡控制性能，并赋予其平衡控制器在线自适应优化的能力，本文提出一种串并联在线强化学习的自平衡滑模控制算法。该算法能够降低强化学习对在线交互样本量的需求，克服滑模控制匹配条件的限制，并弥补自适应滑模控制仅能调整趋近律参数的局限性。仿真和实验结果表明，该算法不仅增强了平衡控制的鲁棒性，还显著提升了平衡控制的整体性能。

针对强化学习在线训练中缺乏稳定性保障的问题，本研究提出鲁棒自适应动态规划稳定性保障的无人自行车平衡控制算法，旨在增强强化学习在线训练的鲁棒性与稳定性。该算法通过利用在线交互数据的滚动求和，替代哈密顿函数在线求解过程中对系统模型的依赖。此外，为了抑制在线学习中探索噪声的影响，本文在已知滑模控制器参数可调范围的假设下，提出输出饱和约束，从而进一步提升在线学习过程的鲁棒性。同时，对该算法在线学习过程的稳定性进行深入分析。仿真与实验结果表明，该算法显著提高了实验的完成度，增强了反作用轮无人自行车平衡控制在线学习的鲁棒性。

最后，从系统不确定性的概率预测角度出发，提出概率安全保障的在线强化学习无人自行车平衡控制算法。该算法利用滑动窗口高斯过程回归对系统状态的

中国知网 https://www.cnki.net

不确定性进行实时预测，并据此构建高斯控制障碍函数，以实现在线强化学习中的概率安全约束。此外，设计在线强化学习探索噪声匹配机制，以减轻探索噪声对训练过程的负面影响。仿真和实验验证了该算法的有效性。

关键词：反作用轮无人自行车；平衡控制；强化学习；滑模控制；自适应动态规划；控制障碍函数；高斯过程回归

中国知网 https://www.cnki.net

Abstract

The investigation of unmanned systems holds considerable importance within the domains of national defense science and technology, as well as industrial production. Unmanned bicycles, characterized by their elongated design and single-wheel structure at both the front and rear, exhibit a superior load-weight ratio and enhanced flexibility compared to other unmanned systems. This unique configuration affords them significant potential for diverse applications, including field reconnaissance, border patrol, and disaster relief. A primary technical challenge in the advancement of unmanned bicycle systems is the achievement of high-performance balance control. This challenge is exacerbated by various uncertainties, such as uneven terrain, modeling inaccuracies, and external disturbances, which contribute to the underactuation characteristics and lateral instability of unmanned bicycles. This study focuses on the reaction wheel unmanned bicycle as the subject of research, addressing the limitations of existing balance control algorithms. It critically examines the deficiencies of offline reinforcement learning in the context of unmanned bicycle balance control and proposes a self-balancing sliding mode control scheme that utilizes series-parallel online reinforcement learning. This approach ensures the stability and security of the online reinforcement learning training process, thereby offering significant research value and promising application prospects.

A prototype of the reaction wheel unmanned bicycle has been developed, and a roll angle error tracking model for this vehicle was established utilizing the equivalent gravity field method alongside an inner and outer ring system framework. Concurrently, both simulation and real-world testing environments were created, and a testing and evaluation protocol for the balance control algorithm was formulated. Furthermore, an offline reinforcement learning domain randomized training environment, grounded in a dynamic model, was constructed. A balance controller for the unmanned bicycle, based on a near-end strategy optimization algorithm, was subsequently designed, followed by relevant testing conducted within the aforementioned simulation environment.

To enhance the balance control performance of reaction wheel unmanned bicycles and to equip the balance controller with capabilities for online adaptive optimization, this paper proposes a novel algorithm that integrates series and parallel online reinforcement learning with self-balancing sliding mode control. This algorithm effectively reduces the necessity for a large sample size of online interactions, addresses the matching conditions

中国知网 https://www.cnki.net

associated with sliding mode control, and mitigates the limitation of adaptive sliding mode control, which is restricted to adjusting only the parameters of the reaching law. Both simulation and experimental results demonstrate that the proposed algorithm not only improves the robustness of the balance control system but also significantly elevates the overall performance of the balance control mechanism.

In addressing the issue of stability assurance in online training for reinforcement learning, this study introduces a robust adaptive dynamic programming algorithm designed to guarantee stability in the context of unmanned bicycle balance control. The primary objective of this algorithm is to enhance the robustness and stability of online training in reinforcement learning. By employing a rolling summation of online interactive data, the algorithm mitigates the reliance on system models during the resolution of the online Hamiltonian function. Furthermore, to counteract the effects of exploration noise inherent in online learning, the study proposes an output saturation constraint, predicated on the assumption that the parameters of the sliding mode controller are adjustable, thereby further bolstering the robustness of the online learning process. A comprehensive analysis of the stability of the algorithm's online learning process is also conducted. Simulation and experimental results demonstrate that the proposed algorithm significantly improves experimental outcomes and enhances the robustness of online learning in the balance control of reaction wheel unmanned bicycles.

In conclusion, a probabilistic online reinforcement learning algorithm for balance control in unmanned bicycles is introduced, focusing on the probabilistic prediction of system uncertainty. This algorithm employs sliding window Gaussian process regression to facilitate real-time predictions of system state uncertainty and constructs a Gaussian control barrier function to implement probabilistic safety constraints within the online reinforcement learning framework. Furthermore, a mechanism for matching exploration noise during online reinforcement learning is developed to mitigate the adverse effects of exploration noise on the training process. Both simulations and experimental results substantiate the efficacy of the proposed algorithm.

Keywords: Reaction Wheel Unmanned Bicycle, Balancing Control, Reinforcement Learning, Sliding Mode Control, Adaptive Dynamic Programming, Control Barrier Function, Gaussian Process Regression

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 课题背景及研究目的和意义.....1
1.1.1 课题来源.....1
1.1.2 研究目的及意义.....1
1.2 无人自行车平衡方式及传统控制研究现状.....2
1.3 强化学习及其在无人自行车平衡控制上的研究现状.....8
1.3.1 强化学习概述及在机器人运动控制中的应用.....8
1.3.2 强化学习应用于无人自行车的平衡控制.....16
1.4 当前研究存在的问题.....17
1.5 本文主要研究内容.....18
第 2 章 反作用轮无人自行车系统设计及离线强化学习平衡控制....20
2.1 引言.....20
2.2 反作用轮无人自行车样机设计及实验场景搭建.....20
2.2.1 反作用轮无人自行车样机设计.....20
2.2.2 反作用轮无人自行车实验场景搭建.....24
2.3 反作用轮无人自行车动力学建模及仿真场景设计.....25
2.3.1 反作用轮无人自行车动力学建模.....25
2.3.2 反作用轮无人自行车仿真场景设计.....35
2.4 基于离线强化学习的反作用轮无人自行车平衡控制.....40
2.4.1 强化学习问题的数学模型.....40
2.4.2 离线强化学习的策略迁移.....42
2.4.3 基于近端策略优化算法的无人自行车平衡控制.....43
2.5 离线强化学习无人自行车平衡控制仿真测试.....47
2.6 本章小结.....50
第 3 章 基于串并联在线强化学习的无人自行车自平衡滑模控制....51
3.1 引言.....51
3.2 反作用轮无人自行车自平衡滑模控制.....51
3.3 双延迟深度确定性策略梯度算法.....56
3.4 强化学习与滑模控制的串并联结合.....59
3.4.1 串联强化学习对滑模控制在线调参.....59
3.4.2 并联强化学习对滑模控制在线补偿.....61
3.4.3 串并联强化学习对滑模控制调参和补偿.....62
3.5 串并联在线强化学习无人自行车平衡控制仿真测试.....63
3.5.1 定性对比分析.....63

中国知网 https://www.cnki.net

3.5.2 定量对比分析.....70
3.6 串并联在线强化学习无人自行车平衡控制实物实验.....73
3.7 本章小结.....79
第 4 章 鲁棒自适应动态规划稳定性保障的无人自行车平衡控制.....81
4.1 引言.....81
4.2 问题描述.....81
4.3 鲁棒在线自学习反作用轮无人自行车平衡控制.....83
4.3.1 鲁棒在线自学习平衡控制.....83
4.3.2 鲁棒在线自学习算法的稳定性分析.....86
4.4 鲁棒在线自学习无人自行车平衡控制仿真测试.....87
4.5 鲁棒在线自学习无人自行车平衡控制实物实验.....92
4.6 本章小结.....95
第 5 章 概率安全保障的在线强化学习无人自行车平衡控制.....97
5.1 引言.....97
5.2 问题描述.....97
5.3 无人自行车概率安全保障的在线强化学习平衡控制算法.....98
5.3.1 高斯过程回归.....99
5.3.2 探索噪声匹配机制.....101
5.3.3 高斯控制障碍函数.....103
5.4 概率安全保障下的无人自行车平衡控制仿真测试.....105
5.4.1 反作用轮无人自行车高斯过程回归仿真测试.....105
5.4.2 高斯障碍函数仿真测试.....108
5.4.3 反作用轮无人自行车安全在线强化学习仿真测试.....111
5.5 概率安全保障下的无人自行车平衡控制实物实验.....113
5.6 本章小结.....116
结论.....117
参考文献.....119
附录 A 在线强化学习与滑模结合的仿真测试结果.....131

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 课题背景及研究目的和意义

1.1.1 课题来源

本课题来源于国家自然科学基金“面向越野环境的单轨两轮机器人大机动运动控制方法研究”（62073183）和“单轨双轮机器人的主动漂移控制方法研究”（62203252）。

1.1.2 研究目的及意义

近年来，无人系统的研究在国防科技和工业生产领域取得了突破性进展，显著推动了我国军事现代化和产业结构的优化升级。无人自行车以其结构简单、轻便灵活的特点，能够轻松穿越山地、丘陵等复杂地形，因此在野外侦察、边境巡逻、灾害救援等关键任务中扮演着至关重要的角色。实现高性能的平衡控制始终是无人自行车系统研发中的核心技术挑战和科学难题。开发先进的无人自行车平衡控制系统，已成为我国新一代装备研发和智能交通领域亟待解决的瓶颈问题。

在当前的无人自行车平衡控制研究领域，传统控制方法因其理论框架的严谨性与实施的便捷性而受到工程界的广泛青睐。并将反作用轮作为平衡辅助机构引入到无人自行车系统。尽管如此，这些传统控制方法由于对精确模型的依赖性，在面临崎岖地形及系统的不确定性时，显示出其在鲁棒性方面的局限性，无法有效适应环境的变化，从而难以实现理想的平衡控制效果。鉴于传统控制方法难以满足无人自行车在复杂环境下的平衡控制需求，研究强鲁棒性和高适应能力的无人自行车平衡控制策略具有重要的理论意义和实际应用价值。

另一方面，强化学习作为一种基于数据驱动的学习算法，通过与环境交互学习来优化策略，展现了其自主学习特性和环境适应能力。该方法能够有效应对崎岖地形及不确定性下无人自行车平衡控制中的难以获得精确系统动态模型的问题，并为平衡控制提供在线优化能力，有利于提高系统的鲁棒性和适应性，为解决复杂环境下的平衡控制问题提供了新的思路和技术途径。因此，从工程应用角度而言，将强化学习引入无人自行车的平衡控制有望克服传统控制方法在应对复杂动态环境、处理非线性控制问题以及适应模型不确定性方面的局限性；从理论研究角度而言，开展强化学习在无人自行车平衡控制领域的研究与应用是学术界关注的焦点问题，也是无人自行车平衡控制技术发展的必然趋势。

中国知网 https://www.cnki.net

然而，受限于强化学习算法在训练收敛速度和实际应用中的泛化能力，以及无人自行车系统本身的非线性、欠驱动和横向不稳定性特点，制约了强化学习在无人自行车平衡控制领域的应用。当前基于强化学习的无人自行车平衡控制研究尚处于理论探索和仿真验证阶段，较少关注强化学习算法在无人自行车平衡控制中的实际应用。

正是在这样的背景下，本论文将强化学习算法引入反作用轮无人自行车的平衡控制领域，充分发挥强化学习的自适应能力，提出一种具有学习能力的平衡控制算法。揭示强化学习在无人自行车平衡控制中的自学习机理，利用传统控制与强化学习的结合实现平衡控制的在线学习能力，提升强化学习在线学习过程的鲁棒性，解决强化学习训练过程缺乏安全性保障的问题，对推动强化学习算法在无人自行车平衡控制中的实用化进程、促进无人自行车系统的稳定性和安全性具有一定的指导意义。

1.2 无人自行车平衡方式及传统控制研究现状

无人自行车的平衡控制算法可以根据其是否具备探索优化能力，划分为传统控制方法与基于强化学习的控制方法。为深入探讨无人自行车平衡控制算法的最新研究进展，本节将对不同的无人自行车平衡方式及基于传统控制方法的无人自行车平衡控制研究现状进行系统梳理。其中，无人自行车的平衡方式可以分为两类：一类是依赖车把转动实现平衡的传统自行车形式；另一类则是通过搭载辅助装置来维持平衡，例如力矩陀螺、质量摆和反作用轮等装置。

（1）转向平衡方式的无人自行车

仅依赖于车把实现无人自行车的自我稳定，指的是在特定的车速范围内，无人自行车能够抵抗一定程度的侧向扰动并保持平衡。关于自行车自平衡机制的解释存在三种主要观点：第一种观点由 Appell 提出，认为自行车的自平衡源于前轮向车体倾斜方向的转动，从而使得运动中的自行车的离心力抵消了重力造成的倾覆影响[1]；第二种观点由 Sommerfeld 提出，强调车轮旋转所产生的陀螺效应在自行车自稳定性中的重要性[2]；第三种观点由 Grammel 提出，认为脚轮效应在自平衡中起着主要作用[3]。1970 年，Jones 在自行车前轮上方安装了一个反向旋转的辅助轮，以消除陀螺效应。实验结果表明，该自行车仍然具备自稳定性，如图1-1 (a) 所示[4]。2011 年，Kooijman 等人设计了一种特殊的无脚轮效应的自行车 “TBS”，如图1-1 (b) 所示，并通过反向辅助轮消除了陀螺效应，结果显示该自行车在一定车速下仍能保持自平衡。因此，Kooijman 认为脚轮效应和陀螺效应并非自行车自稳定的主要因素[5]。然而，刘延柱指出，尽管 Kooijman 设计的自行车具有负拖曳

中国知网 https://www.cnki.net

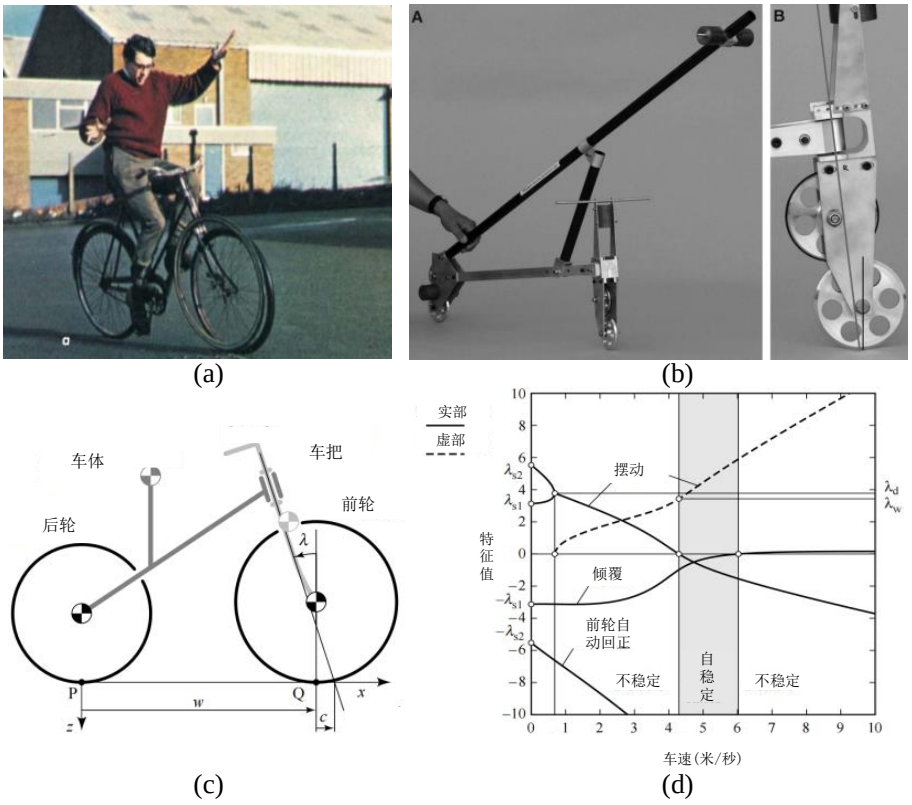


图 1-1 自行车的平衡特性

Fig.1-1 Balance characteristics of bicycles

距，但由于其重心高度显著高于普通自行车，导致前轮的侧向摩擦力作用超过了法向支撑力，从而使脚轮效应依然存在[6]。

该类无人自行车的定量分析，最早可以追溯到 1898 年。Whipple 通过建立恒定车速下的无人自行车线性微分方程，并利用劳斯判据对其稳定性进行了深入分析。该模型在后续的研究中得到了广泛应用，并被称为 “Carvallo-Whipple” 自行车，如图1-1 (c) 所示[7]。1988 年，康奈尔大学的 Hand 等将无人自行车视为一个多刚体系统，采用牛顿-欧拉刚体动力学方法和拉格朗日方法，详细推导了无人自行车的多体模型，分析了在特定车速下，仅依靠车把转向的无人自行车所具备的自稳定特性[8]。2007 年，Meijaard 通过非线性动力学仿真模拟验证了 “Carvallo-Whipple” 自行车线性方程的准确性，并计算了方程特征值、自行车横滚角、车速这三者与自稳定性之间的关系，如图1-1 (d) 所示[9]。2020 年，北京大学刘才山团队针对经典的 Whipple 自行车构型，系统回顾了自行车动力学研究中的相关问题，并对自行车的相对平衡点和稳定性进行了深入分析[10]。

1995 年，Getz 利用无人自行车约束的对称性，将无人自行车的质量集中于一点，推导了基于约束拉格朗日的无人自行车动力学模型，并在此基础上设计了用于跟踪无人自行车横滚角轨迹的控制策略，实现了仅依靠车把转向的无人自行车

中国知网 https://www.cnki.net

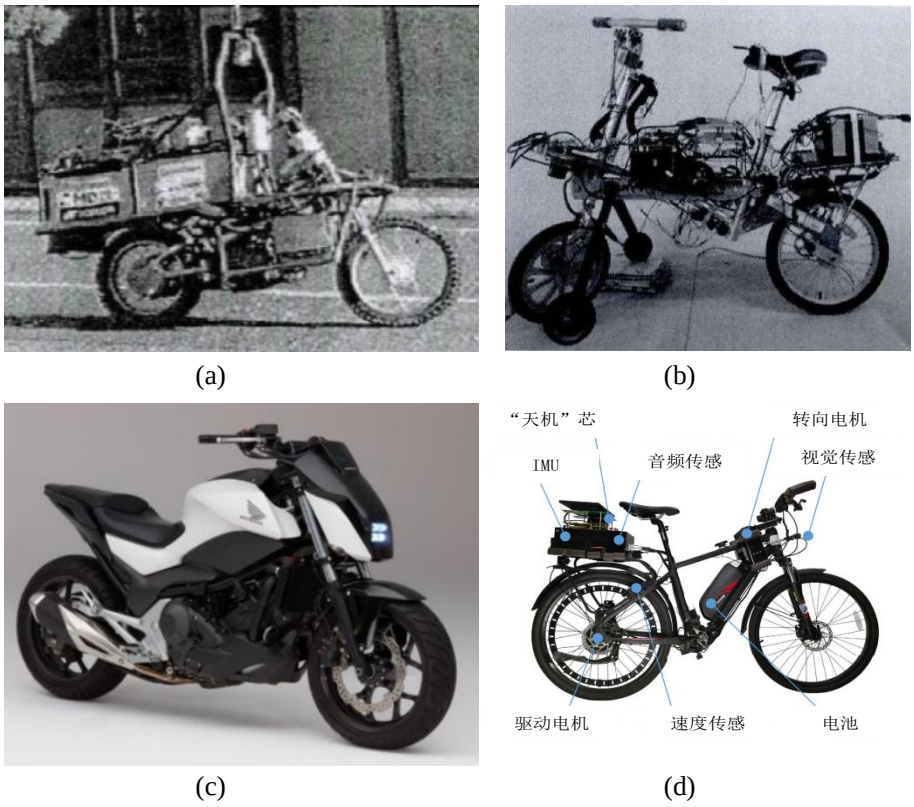


图 1-2 仅依靠车把平衡的无人自行车

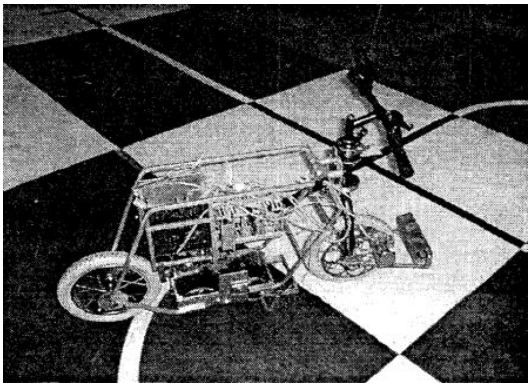
Fig. 1-2 Unmanned bicycles balanced only based on handlebars

在保持平衡的同时实现轨迹跟踪[11]。2006 年，Yi 等人在 Getz[11] 动力学模型基础上，进一步考虑了转把几何特性对无人自行车质心位置及轨迹跟踪控制和平衡控制的影响，设计了非线性控制器使得系统在保持平衡的同时实现轨迹跟踪，其开发的无人自行车平台，如图1-2 (a) 所示[12]。2011 年，黄用华研制了前轮驱动、依靠车把转向平衡的无人自行车，如图1-2 (b) 所示。基于部分反馈线性化原理，设计了 90° 车把转角和 45° 车把转角下定车运动以及原地回转运动平衡控制器[13,14]。本田在 CES ASIA 2017 展览中，展出了其创新产品 Honda Riding Assist，如图1-2 (c) 所示。通过前叉倾角的主动改变实现拖曳距的调整，从而实现了无前向速度下，仅通过转动车把的无人摩托平衡控制。本田将无人摩托等效为一个双质点系统，并为其设计了分段 PID 控制器。这一技术展示了该领域的新进展[15]。如图1-2 (d) 所示，清华大学赵明国团队在 2019 年，设计了反馈与前馈相结合的无人自行车转向平衡控制器，同时实现其平衡控制和路径跟踪[16]。之后又提出了纯追踪算法与模型预测控制结合的改进模型预测控制。并将类脑芯片用于无人自行车的导航、避障中[17]。

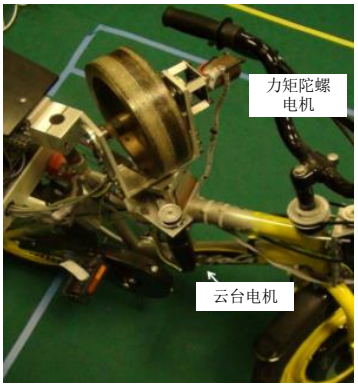
（2）陀螺机构平衡方式的无人自行车

1998 年，Beznos 等学者构建了一种配备双力矩陀螺的无人自行车，如图1-3

中国知网 https://www.cnki.net



(a)



(b)



(c)

图 1-3 搭载力矩陀螺的无人自行车
Fig. 1-3 Unmanned bicycles based on moment gyros

(a) 所示。该研究通过两个反向旋转的陀螺来抵消重力引起的倾覆力矩，并验证了其在直线及曲线运动中的平衡控制效果[18]。2012 年，新加坡国立大学的 Lam 研发了一款基于单个力矩陀螺作为平衡机构的无人自行车，如图1-3 (b) 所示。该研究利用拉格朗日方程建立了无人自行车的动力学模型，并设计了 PID 控制器。同时，研究还分析了系统的稳定性，并通过实验验证了在静止和行驶状态下的平衡控制效果[19]。2019 年，国立台北工业大学的 Chen 等开展了一项关于自行车主动稳定辅助系统的研究。该研究利用陀螺效应，设计了一种双力矩陀螺系统，以实现无人自行车的平衡控制，如图1-3 (c) 所示。研究团队通过拉格朗日方程推导了系统的动力学模型，并在仿真环境中验证了其平衡控制和操纵性能[20]。2021 年，清华大学的陈章团队也对搭载双力矩陀螺的无人自行车进行了相关研究[21]。

此外，日本研究人员 Igarashi 和 Yamakita 在 2015 年开展了一项关于带有飞轮平衡器的无人自行车的研究，如图1-4所示。他们采用模型预测控制方法，在仿真环境中验证了带有飞轮平衡器的无人自行车在平衡控制能力和高机动性能方面的表现，包括前轮离地和车体急转向操作[22]。这项研究为无人自行车的高机动运动提供了新思路。

中国知网 https://www.cnki.net

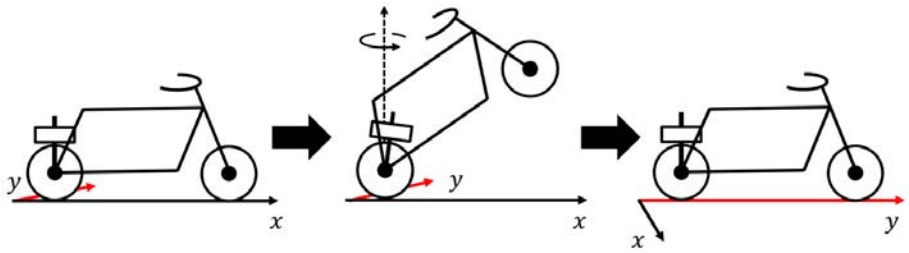
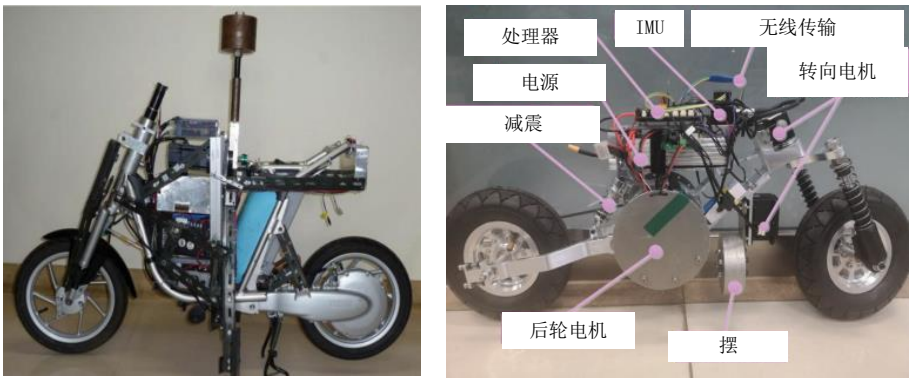


图 1-4 Yusuke 研制的无人自行车
Fig.1-4 The unmanned bicycle constructed by Yusuke

（3）质量摆平衡方式的无人自行车

1998 年，南非的 Yavin 设计了一种依赖于转动杆的无人自行车。Yavin 通过拉格朗日方程建立了该无人自行车的动力学模型，并基于输入输出反馈进行了线性化研究，以探讨无人自行车在低速运动下的轨迹跟踪与平衡控制[23]。2009 年，Keo 等人设计了一种配备平衡质量调节器的无人自行车，并推导出带有辅助平衡器的自行车简化模型，如图1-5 (a)。该研究建立了以转把和辅助平衡器扭矩作为输入的平衡控制器，以实现自行车的稳定性，并通过特征多项式对闭环系统进行了稳定性分析，从而实现了无人自行车的轨迹跟踪与平衡控制[24,25]。2021 年，清华大学的陈章团队提出了一种基于动态逆技术的反步控制器，成功实现了带质量摆的无人自行车的平衡控制与轨迹跟踪控制图1-5 (b)[26]。



(a) (b)

图 1-5 搭载质量摆的无人自行车
Fig.1-5 Unmanned bicycles based on balancers

（4）反作用轮平衡方式的无人自行车

2005 年，日本 Murata 公司研发了一款名为“Murata Boy”的智能自行车。如图1-6 (a) 所示，该自行车通过对反作用轮的控制，实现了在静止和运动状态下的平衡控制[27]。2015 年，Kanjanawanishkul 对搭载反作用轮的无人自行车进行了研究，比较了线性二次规划、线性模型预测和非线性模型预测三种控制方法的效果，如图1-6 (b) 所示[28]。2020 年，腾讯公司 Robotics X 实验室探讨了反作用轮无人自

中国知网 https://www.cnki.net

行车的静态平衡控制稳定性问题[29]。随后，研究团队建立了一个能够同时描述静态和动态特性的数学模型，并采用基于增益规划的控制方法对其平衡控制进行了深入研究，所搭建的无人自行车如图1-6 (c) 所示[30]。2021 年，杭州电子科技大学的 Chen 等人将自适应积分终端滑模控制应用于带有反作用轮的无人自行车，实现了鲁棒性平衡控制，其实验样机如图1-6 (d) 所示[31]。

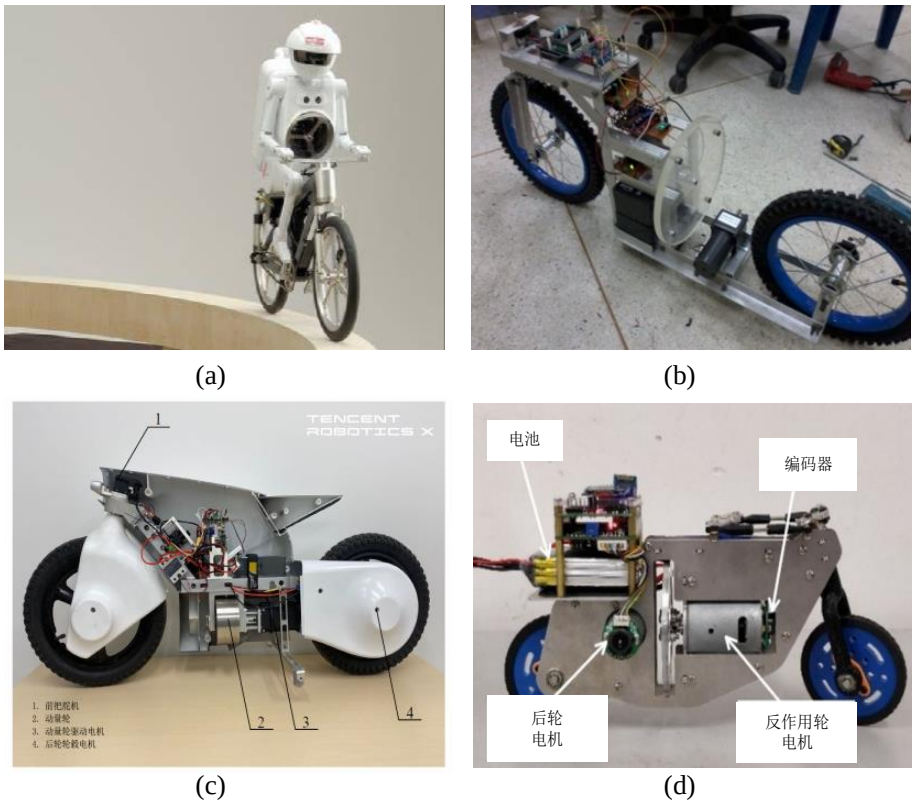


图 1-6 搭载反作用轮的无人自行车
Fig. 1-6 Unmanned bicycles based on reaction wheels

根据本文对控制任务的需求，仅依赖车把转向方式来实现无人自行车的平衡控制并不符合要求。这是因为该方法通常需要推导前叉倾角与无人自行车横滚角之间的关系，而在曲面路面上行驶时，路面的不规则性会导致前叉倾角的变化，从而显著增加控制器设计的复杂性。此外，该方法中路径跟踪控制与平衡控制相互影响，不利于实现崎岖路面下对路径的精确跟踪。采用陀螺机构的平衡方式，利用陀螺效应在一定程度上可以增强无人自行车的抗扰能力。然而，路面的不规则性可能会对高速旋转和大惯量的力矩陀螺系统造成冲击。此外，陀螺系统通常具有较大的自重，这不利于无人自行车的轻便灵活性。质量摆的方式则要求质量摆在重量上占据无人自行车整体重量的较大比例，因此对驱动电机的输入力矩和响应速度提出了较高的要求。相比之下，反作用轮的方式在控制精度和响应速度的要

中国知网 https://www.cnki.net

求上低于质量摆，同时在系统额外重量增加和复杂性方面也低于陀螺方式。此外，在控制算法的实现上，相较于仅依靠车把的方式，反作用轮在曲面路面上的应用更为简便。

（5）传统控制在反作用轮无人自行车平衡控制中的应用

现有关于反作用轮无人自行车的平衡控制研究可分为线性控制、非线性控制和智能控制三大类。在线性控制方面，研究者通常采用系统平衡点附近的局部线性化方法来实现反作用轮无人自行车的平衡控制，常见的控制策略包括比例-积分-微分控制（PID）[19] 和线性二次调节器（LQR）[28,32]。尽管线性控制方法相对简单且易于实现，但其在非线性系统中的控制性能受到限制，并且需要进行精细的参数调整。无人自行车在运动过程中受到多种内部和外部不确定性因素的影响，例如传感器测量误差和关节摩擦等，这使得控制器需要频繁调整参数以维持其平衡控制性能。为应对更为复杂的无人自行车平衡控制需求并提升非线性系统的控制性能，部分学者开始研究非线性控制方法在反作用轮无人自行车平衡控制中的应用。例如，文献 [12] 中提出了一种结合低通滤波算法的滑模控制器，其在系统扰动下展现出比线性控制更强的鲁棒性。此外，针对平坦地形下的反作用轮无人自行车，文献 [31] 中提出了一种自适应滑模控制器，设计了一种单调自适应律以调整控制部分的增益。文献 [28] 还设计了线性模型预测控制和非线性模型预测控制的反作用轮无人自行车平衡控制器，通过模型预测和滚动优化在仿真中表现出良好的抗扰能力。模糊控制作为一种基于模糊逻辑的控制方法，其优点在于能够根据环境和任务自动调整控制策略，具有较强的鲁棒性，尤其适用于复杂和不确定的环境。然而，模糊规则的制定过程往往较为繁琐。为应对脉冲扰动和系统不确定性，文献 [33] 中为反作用轮无人自行车设计了模糊滑模控制器。尽管该方法在一定程度上取得了成效，但其模糊规则的制定过程仍需进一步简化。

1.3 强化学习及其在无人自行车平衡控制上的研究现状

本节内容分为两个部分。第一部分综述强化学习的发展历程、重要概念及其相关算法。首先，回顾强化学习的研究进程，指出其可分为三个阶段。接着，对当前主要的强化学习算法进行分类和说明，并描述强化学习在机器人运动控制中的主要应用方式。此外，重点介绍与本文研究密切相关的在线自适应动态规划算法。最后，对安全强化学习的发展进行简要概述。第二部分则聚焦于强化学习在无人自行车平衡控制领域的研究现状。

1.3.1 强化学习概述及在机器人运动控制中的应用

（1）强化学习的研究历程

中国知网 https://www.cnki.net

强化学习的研究历程可大致划分为三个阶段。第一阶段始于 20 世纪 80 年代，持续至 2000 年。在这一阶段，强化学习经历了早期的探索与发展。20 世纪 80 年代，强化学习在继承动物心理学的试错学习理论的基础上，结合基于值函数和动态规划的最优控制问题的研究，逐渐演变为一门独立的学科。1987 年，Williams 提出了策略梯度方法的开创性研究，利用蒙特卡洛采样来估计策略的梯度，并通过梯度上升法更新策略参数，这一方法成为强化学习中最早的策略梯度方法[33,34]。1988 年，Sutton 将动态规划与蒙特卡洛算法相结合，提出了时序差分算法，通过利用当前状态与下一个状态的估计值来更新值函数，从而逐步学习最优策略[35]。策略梯度算法与时序差分算法为强化学习的发展奠定了理论基础。1992 年，Watkins 在其博士论文中提出了 Off-policy 的 Q-Learning 算法，该算法使用 Q 值函数来表示在某一状态下执行特定动作所可能获得的累积奖励估计值，并通过不断更新 Q 值函数来逼近最优策略的值函数[36]。Q-Learning 算法的提出是强化学习发展的一个重要里程碑。1994 年，Rummery 和 Niranjan 提出了 Q-Learning 的 On-policy 变种，称为 SARSA 算法[37]。

第二阶段涵盖了 2000 年至 2010 年，在此期间强化学习方法经历了一系列显著的改进，并开始在控制、游戏及机器人等领域得到应用。2000 年，为了克服策略梯度算法所面临的高方差问题以及值函数估计中的高偏差问题，提出了 Actor-Critic 算法（AC）[38]，该算法将策略梯度与值函数估计相结合，为强化学习提供了一种更加稳定和高效的学习机制。Actor-Critic 的提出是强化学习领域的又一个重要里程碑。随着计算能力的提升和算法的不断进步，强化学习在机器人运动控制、电子游戏等领域得到了广泛的研究[39–41]。AlphaGo 的胜利被视为强化学习发展过程中的一个重要事件，充分展示了其在复杂决策问题中的潜力。

第三阶段涵盖了 2010 年至 2020 年，这一时期见证了强化学习的迅速发展，尤其是多种函数逼近方法的引入，包括神经网络，从而推动了强化学习算法的重大突破。2013 年，DeepMind 团队将深度神经网络与 Q-Learning 算法相结合，提出了深度 Q 网络算法（Deep Q-Networks，DQN）[42]。该算法利用深度神经网络来表示值函数，使得强化学习在处理高维和复杂输入空间（如图像输入）时表现出色。DQN 算法在一系列 Atari 游戏中展现了超越人类的表现，并于 2015 年登上了《Nature》期刊的封面。2015 年，Schulman 等人提出了信任区域策略优化算法（Trust Region Policy Optimization，TRPO），旨在解决策略梯度算法中的不稳定性和样本效率问题。该算法基于 Kullback-Leibler 散度对新旧策略的差异进行估计，并对策略更新的幅度进行约束，从而提高了策略更新的稳定性[43]。为了解决 DQN 算法仅能处理离散动作输出的局限性，2016 年，Lillicrap 等人提出了结合了 Actor-critic 结构

中国知网 https://www.cnki.net

的深度确定性策略梯度算法（Deep Deterministic Policy Gradient，DDPG）。该算法引入了两个神经网络，分别用于估计策略和值函数，并通过深度神经网络实现模型的表示与逼近。为了优化学习过程，DDPG 算法还引入了经验回放机制，以存储和随机采样历史经验数据，从而减少时间相关性，平稳采样分布，提高学习效率和稳定性[44]。这一算法在强化学习领域的应用为解决连续动作空间问题提供了重要的思路，并为实现更高效的智能控制奠定了基础。2017 年，Schulman 提出了 TRPO 算法的简化版本——近端策略优化（Proximal Policy Optimization，PPO）算法，通过广义优势估计和剪切技巧，避免了策略的不稳定性，同时提高了样本效率[45]。由于其稳定性和高效性，PPO 已成为当前强化学习中广泛应用的算法之一。2018 年，Scott Fujimoto、Herke van Hoof 和 David Meger 针对 DDPG 中存在的策略评估误差，提出了基于双评论家网络和延迟策略更新的双延迟深度确定性策略梯度（Twin Delayed DDPG，TD3）算法，使其在处理连续动作空间问题时表现更加稳定，收敛速度更快，并且相较于传统的 DDPG 算法具有更优的性能[46]。该算法在机械臂控制等实际应用中取得了显著成功，成为强化学习领域的重要算法之一。同年，Tuomas Haarnoja 等人将最大熵原理引入 Actor-critic 框架，提出了 SAC 算法（Soft Actor-Critic），通过最大化策略的熵（即策略的不确定性），增强了策略的探索性，使得 SAC 算法在训练过程中能够更主动地探索状态-动作空间[47]。

（2）强化学习算法分类

一般而言，强化学习算法可以分为基于模型和无模型两种类型。这一分类依据智能体是否通过访问或学习环境模型来预测状态转移和奖励。根据相关综述文献 [48]，常见的强化学习算法分类如图1-7所示。

基于模型的强化学习算法可以根据模型的来源分为已知模型和估计模型两类。已知模型指的是在强化学习过程中，智能体在与环境进行交互之前，已经掌握了环境的动态模型。这使得智能体能够利用该模型进行有效的规划与决策。已知模型的强化学习算法包括自适应动态规划（Adaptive Dynamic Programming，ADP）[49] 和模型预测控制（Model Predictive Control，MPC）[50] 等方法。相对而言，估计模型则是指智能体在进行规划和决策时，并未事先建立模型，而是通过与环境的交互数据进行拟合而获得。例如，PILCO 算法（Probabilistic Inference for Learning Control）[51] 结合了高斯过程模型与概率推断方法，以学习系统的动力学模型并实现最优控制。

无模型强化学习可以进一步细分为基于策略估计的方法和基于值函数的方法。基于策略估计的强化学习算法属于策略优化的范畴，其中策略梯度算法是其具体实现之一。该算法的核心思想在于通过直接优化策略参数来实现策略优化的目标。策略估计算法旨在直接估计或近似当前的最优策略，因此其优化和更新过程依赖

中国知网 https://www.cnki.net

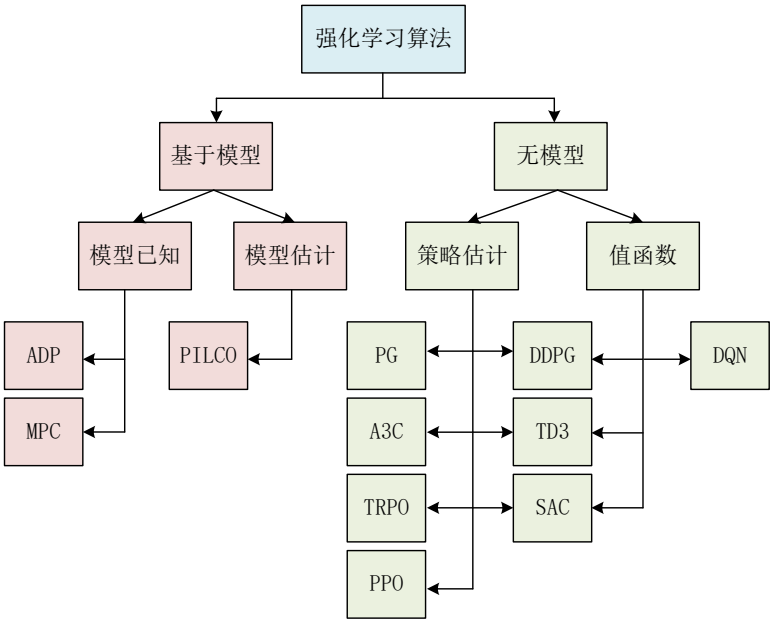


图 1-7 常用强化学习算法分类

Fig. 1-7 Classification of commonly used reinforcement learning algorithms

于从环境中采集的轨迹数据。常见的策略梯度算法包括 PPO（Proximal Policy Optimization）。另一方面，值函数方法通常通过引入时间差分误差，依据当前估计的值函数与后续状态的实际奖励及其估计值之间的差异进行更新。在值函数或状态值函数的基础上，采用贪婪策略等方法选择动作。目前，常用的值函数方法包括 TD3（Twin Delayed Deep Deterministic Policy Gradient）和 SAC（Soft Actor-Critic）。

此外，强化学习可以根据其实现方式分为三类：时序差分（Temporal-difference，TD）[52]、策略梯度（Policy Gradient，PG）[53] 以及演员-评论家（Actor-critic，AC）[54]。

时间差分算法（TD）通过评估状态值函数或状态动作值函数，进而对策略进行改进。TD 算法融合了蒙特卡洛方法与动态规划的理念，是强化学习核心思想的经典实现之一，典型的例子便是 Q 学习算法。Q 学习算法是一种基于状态动作值函数的迭代学习方法，其在计算目标函数时选择能够最大化下一状态动作值的动作。在有限状态空间的理论框架下，可以证明 Q 学习能够获得最优值函数。然而，当应用于大规模状态空间时，Q 学习往往只能找到最优状态动作值函数的近似解。这一限制制约了 TD 算法在连续状态空间和连续动作空间中的应用。

策略梯度算法（PG）通过学习一个参数化策略来选择动作，从而避免了显式构建状态-动作值函数的过程，这使其在处理连续状态空间和动作空间时表现更为优越。然而，由于策略梯度在计算中依赖于当前策略生成的轨迹，即每次交互所产生的数据样本仅能用于当前策略的更新，因此 PG 算法的数据利用效率较低。尤其是在环境随机性较大的情况下，策略梯度的估计往往会出现较高的方差，从而影响策略的收敛性。

中国知网 https://www.cnki.net

演员-评论家算法（AC）有两个主要组成部分：Actor 和 Critic。Actor 负责将状态映射为动作，而 Critic 则负责对状态的累积回报进行估计。Actor 与 Critic 的结合使得该算法在学习过程中同时具备探索与利用的能力，从而能够更有效地利用已有数据进行训练与优化，显著提升了采样效率。

（3）强化学习在机器人运动控制中的应用

强化学习算法的发展，如深度确定性策略梯度（DDPG）、双重延迟深度确定性策略梯度（TD3）和近端策略优化（PPO），已成为相关研究的重要里程碑。这些算法的出现为强化学习奠定了坚实的基础，使研究人员能够更深入地探讨其在各个应用领域的潜力。由于强化学习在机器人运动控制中通常需要大量的交互样本，而实际机器人不可避免地受到机械系统疲劳和损坏等因素的影响，因此，强化学习在机器人运动控制中的应用主要可以分为两类。

第一类方法是基于 Sim-to-Real 的离线强化学习策略迁移，通常涉及在构建域随机化的仿真环境中对强化学习智能体进行训练，随后将其迁移并部署到实际物理系统中。2019 年，OpenAI 团队通过强化学习实现了基于视觉的物体重定位灵巧手的操控策略[55]。该团队采用域随机化的方法，在仿真环境中随机调整系统的多项物理属性（例如摩擦系数和物体外观）进行训练。尽管强化学习智能体的训练完全在仿真环境中进行，但他们成功地将策略迁移至实际机器人上。该机器人展现出与人类操作行为相似的指间运动、多指协调以及在物体翻转过程中对重力的利用，如图1-8所示。2020 年，苏黎世联邦理工大学通过系统辨识与域随机化方法，结合课程学习和特征编码技术，成功将仿真环境中训练得到的四足机器人行走策略迁移至四足机器人样机，并在一系列复杂地形中进行了测试，如图1-9所示[56]。

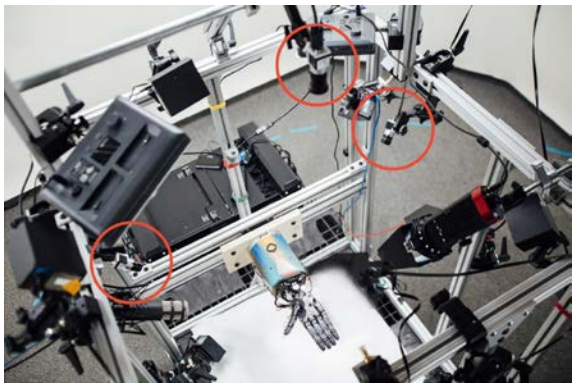


图 1-8 基于视觉输入的灵巧手

Fig.1-8 Dexteric hand based on visual input

第二类研究涉及在线强化学习与传统控制方法的结合。这类方法有助于降低强化学习对交互样本数量的依赖，并充分利用其在线优化的能力。2018 年，西门

中国知网 https://www.cnki.net



图 1-9 基于强化学习的四足机器人
Fig. 1-9 Quadruped robot based on reinforcement learning

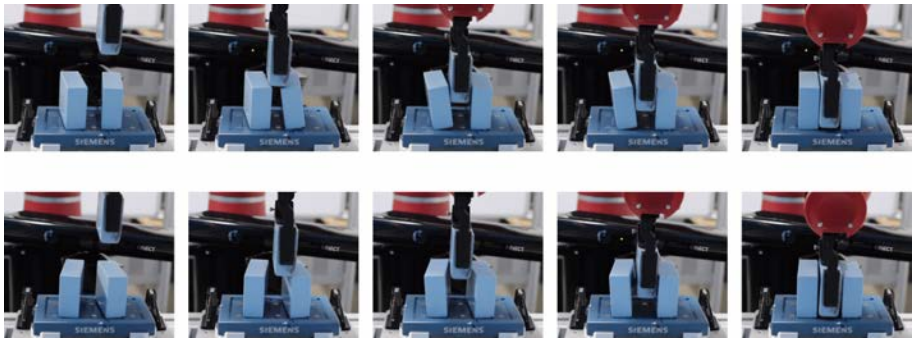


图 1-10 残差强化学习在组装任务中的实验结果
Fig. 1-10 Experimental results of residual reinforcement learning on the assembly task

子公司、加州大学伯克利分校与汉堡大学联合探讨了强化学习在机器人控制领域的应用。研究指出，尽管传统控制方法已有效解决多种机器人控制问题，但现代制造业中涉及接触和摩擦等难以建模的问题，常常导致控制器的不稳定性，从而影响制造精度。强化学习通过与环境的交互，能够有效应对机器人在摩擦和接触问题上所面临的建模困难。该研究提出了一种残差强化学习算法，将控制问题分解为传统反馈控制与残差强化学习两部分，最终的控制策略是这两种信号的叠加。通过在真实环境中训练机器人，该研究成功执行了包括接触和不稳定因素的物体组装任务，如图1-10所示[57]。2019 年，日本广岛大学的 Guan 等人提出了一种基于强化学习的自适应 PID 控制器。该方法展示了如何利用强化学习进行 PID 控制的在线优化。在所提出的方案中，采用径向基函数（Radial Basis Function，RBF）来表示 Actor 策略函数和 Critic 价值函数，并基于时序差分误差性能指标及梯度下降法对 PID 参数进行更新。最终，通过在非线性系统中的数值模拟，验证了该方案的鲁棒性及其对控制性能的优化效果[58]。

此外，从控制器中智能体的数量来看，前述研究均属于单智能体强化学习的范畴。近年来，多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）在机器人运动控制领域取得了显著进展[59]。多智能体强化学习作为强化学习的重要分

中国知网 https://www.cnki.net

支，旨在探讨在复杂环境中多个智能体在协作、竞争和交互过程中的学习与决策机制。常见的多智能体强化学习算法包括集中训练分布式执行（Centralized Training Decentralized Execution）和分层强化学习（Hierarchical RL）。

在 2021 年，斯坦福大学的研究团队提出了一种基于多智能体强化学习的人机协作方法，如图1-11所示。该团队通过人机协作示范学习了人机之间的合作策略，使得机器人助手能够适应人类的多样化行为，并在任务执行过程中灵活应对人类合作者策略的变化。研究团队通过共同优化人类与机器人策略，达成了高效的学习过程[60]。在 2022 年，比勒费尔德大学的研究人员探讨了分布式和分层控制在多足机器人运动控制中的应用。自然界中的多足动物在运动时展现出分层和分散式的控制方式，这一现象激发了将这些生物设计原则引入机器人控制系统的思考。该研究旨在探讨分散和分层控制对多足机器人的益处，并提出了一种新颖的分散分层架构以控制模拟多足机器人[61]。



图 1-11 基于多智能体强化学习的人机物体交接

Fig.1-11 The transition of human-computer objects based on multi-agents reinforcement learning

（4）在线自适应动态规划

动态规划[62] 是由美国学者理查德 · 贝尔曼提出的一种优化决策过程的方法，它与苏联学者列昂季 · 庞特里亚金所创立的极小值原理共同构成了最优控制理论的两大基石。该方法最初应用于时间离散问题，即多级决策过程。随后基于哈密顿-雅可比理论扩展至连续动态系统。然而，针对复杂非线性系统，动态规划方法面临着“维数灾难”的重大挑战。

为了解决动态规划中存在的“维数灾难”问题，研究者们提出了自适应动态规划方法[63,64]。该方法位于机器学习领域的强化学习算法与控制领域的自适应控制技术之间，利用神经网络的逼近能力，将传统动态规划的逆向求解转变为正向过程，从而显著减少了计算和存储的需求。自适应动态规划的原理如图1-12所示，主要由三个部分组成：动态系统、评价网络和执行网络。评价网络和执行网络的结构与强化学习中的 Actor-critic 算法相似，评价网络用于逼近最优性能指标，对当前控制决策进行评估，并指导执行网络进行下一步策略的更新。执行网络则相

中国知网 https://www.cnki.net

当于基于神经网络的控制器，其目标是逼近最优控制策略。两个网络之间通过信息反馈与传递，持续对当前策略进行评估与更新，最终实现各自的目标。自适应动态规划通常被视为一种基于模型的强化学习方法，其与无模型强化学习方法的主要区别在于，自适应动态规划能够提供理论上的稳定性和收敛性保障。

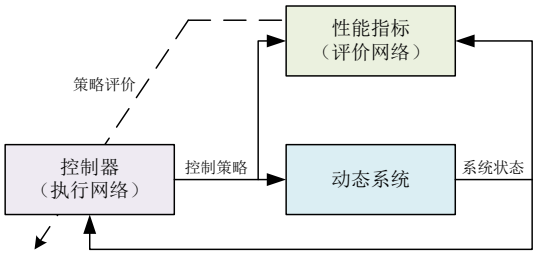


图 1-12 自适应动态规划原理图

Fig.1-12 Schematic diagram of adaptive dynamic programming

关于在线自适应动态规划算法的研究最早出现在文献[65]中，涉及实时在线学习最优控制哈密顿雅可比方程的解。该方法可以实时逼近最优代价和最优控制策略，同时保证闭环系统的稳定性。该研究证明了系统对最优控制器的收敛性，并确保了系统的稳定性，但未考虑标称模型与实际系统之间的差异。为了在系统不确定性下更好地在线利用自适应动态规划算法，现有研究主要形成了两类：一是在线拟合采样数据，用拟合得到的模型代替标称模型，进行自适应动态规划问题的求解[49]；二是直接利用采样数据的积分，求解自适应动态规划问题，而不需要显式依赖系统模型，例如积分强化学习[66]和鲁棒自适应动态规划[67]。

在线自适应动态规划通常需要满足初始控制策略能够使闭环系统稳定这一假设条件。因此，在线自适应动态规划与传统控制的结合逐渐引起关注。文献[68]在无人自行车的平衡控制中，研究了线性控制器与自适应动态规划的结合，但其自适应动态规划算法为基于标称模型的离线形式。文献[69]在无人驾驶汽车的轨迹跟踪问题中，研究了滑模控制器与自适应动态规划算法的结合。然而，即使初始控制策略能够使闭环系统稳定，在动态扰动等系统不确定性影响下，在线自适应动态规划也难以始终保证系统的稳定性。

（5）安全强化学习

尽管强化学习在围棋、视频游戏、导航和推荐系统等多个领域取得了显著成就，但在机器人运动控制领域，许多强化学习算法仍然难以直接应用于真实的物理环境。这主要是因为在模拟环境中，智能体可以通过不断的试错与环境进行交互，从而学习到最优策略。然而，考虑到安全性，许多现实世界的应用要求限制智能体的随机探索行为。因此，安全问题成为强化学习从模拟环境向现实环境转化的重要挑战。

中国知网 https://www.cnki.net

安全强化学习（Safe RL）的概念最早在文献 [70] 中被提出。安全强化学习旨在学习一种最大化预期回报的策略，同时确保或促进满足某些安全约束。在过去十年中，该领域得到了广泛的研究，并主要发展出两种类型的方法[71]。第一类方法是通过修改优化训练过程来实现安全性，包括约束强化学习[72]、基于 Lyapunov 的强化学习[73,74] 和安全策略迭代[75] 等；第二类方法则是在控制输出上添加安全层，例如屏蔽控制器[76,77]、备用控制器[78] 和控制障碍函数法（Control Barrier Functions, CBFs）。总体而言，修改优化训练过程的方法仅能在模拟到现实的框架内提供安全保障，因为它们依赖于多集训练模式。而在第二类方法中，使用备用控制器的策略在许多应用场景中并不易于实现。控制障碍函数作为类 Lyapunov 函数的扩展，旨在将定义于状态空间的安全约束映射至控制输入。这一方法是实现安全在线强化学习的少数可行方法之一。

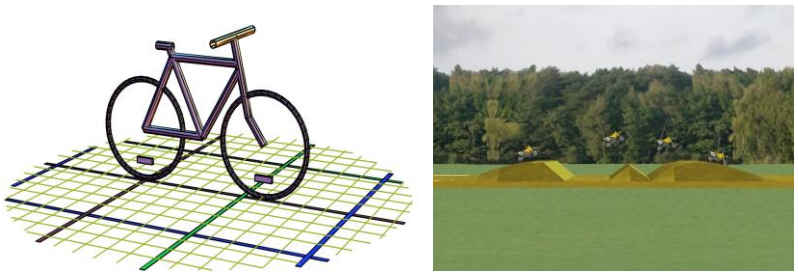
控制障碍函数（CBFs）在确保安全关键系统的安全性方面展现出了显著的有效性，尤其是在自动驾驶车辆[79]、双足机器人[80] 和四旋翼飞行器[81] 等领域。然而，CBFs 的一个主要局限性在于其对动态系统精确数学模型的依赖。这一特性带来了显著的挑战，因为动态系统通常面临模型不确定性和未知扰动，从而使得构建准确的系统模型变得困难。为了解决 CBFs 中存在的问题，文献 [82] 中提出了一种自适应 CBF，通过在线更新系统模型参数的估计值来实现。在另一项研究 [83] 中，设计了一种基于滑模变量的 CBF，以增强其鲁棒性。此外，文献 [84] 还展示了模型预测控制（MPC）与 CBF 结合的有效性。由于高斯过程回归（GPR）能够提供状态预测的概率性保证，CBF 与 GPR 的结合也得到了广泛的研究。其中一项研究 [81] 探讨了基于高斯核函数构建 CBF 的有效性，而另一项研究 [85] 则利用 GPR 在线更新系统模型的预测。此外，还有研究考虑了基于 GPR 的障碍函数更新[86]，但该研究未考虑预测方差的影响。尽管上述方法探讨了 GPR 与 CBF 的集成，但大多数现有研究仅关注了动态不确定性对安全约束的单一影响。

1.3.2 强化学习应用于无人自行车的平衡控制

目前，基于强化学习的无人自行车平衡控制研究中，鲜有针对反作用轮的无人自行车进行探讨，研究主要集中在依赖车把转向以实现平衡的无人自行车上。1998 年，Randløv 在其推导的忽略二阶交叉项的无人自行车简化动力学模型中，验证了强化学习算法 SARSA 能够有效完成平衡控制与驶向固定目标点的复合任务。然而，该算法仅能处理离散的状态输入和输出，且训练效率较低[87]。2000 年，Randløv 受到儿童使用辅助轮学习骑自行车的启发，提出通过训练一个改变物理特性的简单问题来辅助学习原始复杂问题的思路[88]。这一理念与后来的迁移学习概念相似。

中国知网 https://www.cnki.net

Randløv 将此方法应用于前述任务及数值模型，依然使用 SARSA 算法，通过在训练过程中逐步提高辅助轮的离地高度，显著提升了学习效率。2004 年，Cook 在 Getz 建立的自行车动力学模型基础上，引入神经网络进行自行车运动控制，实现了无人自行车的路径跟踪，如图1-13 (a) 所示[89]。2017 年，Tuyen 在 Randløv 的简化模型基础上，研究了无人自行车的平衡控制及绕圈等任务，其不同之处在于采用了能够处理连续状态和动作的 DDPG 算法[90]。2019 年，Choi 认为仅依靠车把转向的无人自行车在固定速度下难以兼顾平衡与跟踪，因此对 Randløv 的自行车模型进行了扩展，增加了对踏板力矩的控制[91]。2021 年，Zheng 针对无人自行车在冲坡飞跃多阶段过程中的姿态控制问题进行了研究，通过合理配置奖励函数，在 Bikesim 仿真软件中验证了 DDPG 算法解决该问题的可行性，如图1-13 (b) 所示[92]。



(a) (b)

图 1-13 基于强化学习的无人自行车

Fig.1-13 Unmanned bicycles based on reinforcement learning

1.4 当前研究存在的问题

通过对现有文献的综合分析，可以发现反作用轮在无人自行车的平衡控制，尤其是在复杂地形中的应用，展现出优于其他平衡方式的潜力。尽管传统的反作用轮无人自行车平衡控制方法在平坦路面上取得了一定的成效，但这些方法通常依赖于精确的动力学模型，或在控制性能与鲁棒性之间进行权衡，这突显了平衡控制在线自学习能力的重要性。为了开发出能够在复杂地形和系统不确定性下自主学习、鲁棒且安全的反作用轮无人自行车平衡控制器，当前在线强化学习研究需要在以下几个方面进行改进：

（1）强化学习难以直接用于在线优化反作用轮无人自行车的平衡控制。

目前，反作用无人自行车的平衡控制主要依赖于传统控制方法，这些方法受到动力学模型的准确性和控制器结构的限制，从而影响了其鲁棒性和控制性能。强化学习通过与环境的交互，能够实现平衡控制器的在线优化。然而，强化学习通

中国知网 https://www.cnki.net

常需要大量的交互数据，并且由于反作用无人自行车在横向上的不稳定性，直接应用强化学习进行其平衡控制的在线优化面临一定的挑战。

（2）系统不确定性下在线强化学习的稳定性分析。

在系统不确定性下，在线强化学习的稳定性保障仍然面临挑战。特别是在外部扰动的影响下，策略的在线学习可能会出现较大的波动和较慢的收敛速度。尽管在线自适应动态规划结合了强化学习与最优控制的优势，能够为在线学习过程提供稳定性分析，但其对精确系统模型的依赖限制了其在系统不确定性环境中的应用。此外，系统不确定性的存在也会对在线学习的稳定性产生显著影响。

（3）系统不确定性下在线强化学习的安全性保障。

在系统存在不确定性的情况下，确保在线强化学习在反作用轮无人自行车平衡控制中的安全性仍然是一个未得到充分解决的课题。尽管将控制障碍函数与高斯过程回归相结合为安全性保障提供了新的视角，但现有研究较少同时考虑动态扰动对安全约束和障碍函数的综合影响。

1.5 本文主要研究内容

为应对崎岖地形及系统不确定性对反作用轮无人自行车平衡控制的影响，本研究旨在开发一种基于强化学习的平衡控制器，该控制器具备在线自学习能力，并确保在线学习过程的鲁棒性与安全性。具体而言，为了解决无人自行车平衡控制性能在线优化的问题，提出一种基于串并联在线强化学习的自平衡滑模控制算法。为进一步保障强化学习在线训练的稳定性，提出一种鲁棒自适应动态规划稳定性保障的无人自行车平衡控制算法。最后，为确保强化学习在线训练的安全性，提出一种基于概率安全保障的在线强化学习无人自行车平衡控制算法。论文的组织结构如图1-14所示，主要章节内容如下：

（1）第二章设计反作用轮无人自行车样机，并构建相应的实验环境，为后续平衡控制算法的验证提供必要的平台。在此基础上，推导反作用轮无人自行车的横滚角跟踪误差模型，该模型为后续控制器的设计与分析奠定理论基础。此外，建立反作用轮无人自行车的仿真测试场景，为算法的评估与比较提供有效的反馈机制。最后，设计基于近端策略优化的离线强化学习反作用轮无人自行车平衡控制器，包括构建其域随机化训练环境以及对策略迁移的效果进行测试。

（2）第三章提出基于串并联在线强化学习的无人自行车自平衡滑模控制方法。系统性地构建多种在线强化学习与滑模控制相结合的策略，包括单智能体强化学习与滑模控制的串联结合（在线调参）及并联结合（在线补偿），以及多智能体强化学习与滑模控制的结合（同时在线调参和补偿）。上述算法用于实现反作用轮无

中国知网 https://www.cnki.net

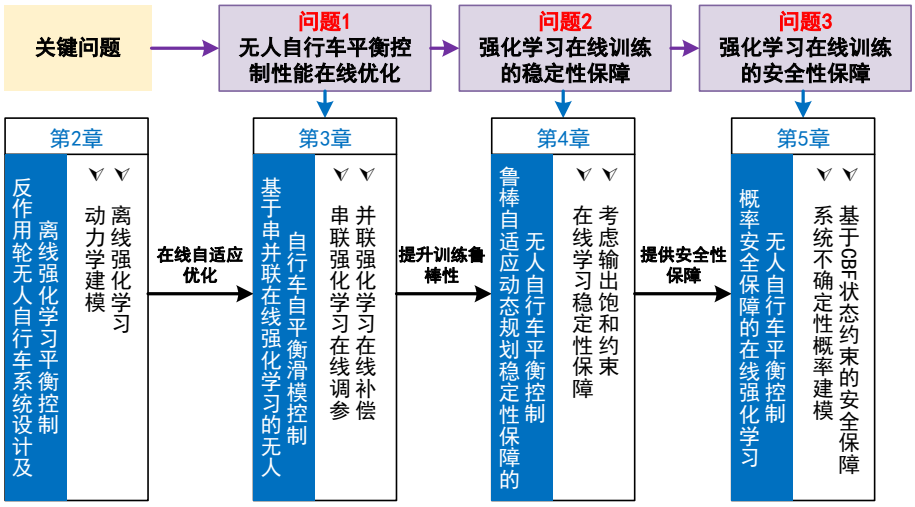


图 1-14 论文架构

Fig. 1-14 Organization of the dissertation

人自行车平衡控制器的在线优化，有利于提升平衡控制的鲁棒性和控制性能。在仿真测试和实物实验中，串并联在线强化学习的平衡控制在测试任务的完成情况和横滚角跟踪误差方面显著优于离线强化学习和传统的滑模控制算法。

（3）第四章提出鲁棒自适应动态规划在无人自行车平衡控制中的稳定性保障问题。目前，在线自适应动态规划的研究通常依赖于系统的标称模型进行梯度预测，这在面对系统不确定性时存在一定的局限性。本章在第三章在线强化学习与滑模控制结合的基础上，假设控制器参数调节范围已知，得到系统输出饱和约束；利用哈密顿函数的滚动积分，降低自适应动态规划求解中对精确系统模型的依赖。此外，本章给出强化学习在线训练过程的稳定性分析，并通过仿真和实验验证该算法的有效性。

（4）第五章提出在无人自行车平衡控制中概率安全保障的在线强化学习算法。基于系统不确定性符合高斯分布的假设，利用高斯过程回归对系统不确定性进行拟合和预测，本章提出基于高斯过程预测的高斯控制障碍函数和在线学习探索噪声匹配机制，通过综合考虑不确定性对系统安全性及在线学习过程的影响，进一步提升反作用轮无人自行车在线学习的安全性。

中国知网 https://www.cnki.net

第 2 章 反作用轮无人自行车系统设计及离线强化学习平衡控制

2.1 引言

反作用轮无人自行车的动力学模型对于构建离线强化学习的训练环境具有重要意义。目前，反作用轮无人自行车的动力学建模研究主要集中在平坦路面条件下，而对崎岖路面条件下的动力学模型研究相对较少。这一研究局限性显著制约了无人自行车在崎岖路面环境中应用的潜力。本章首先设计反作用轮无人自行车样机，并详细描述实验及仿真测试场景的构建过程。接着，提出一种基于等效重力场的处理方法，该方法将俯仰角转换为等效重力加速度，从而简化崎岖路面条件下反作用轮无人自行车的动力学建模问题。在此基础上，构建 Stanley 路径跟随算法，该算法能够根据目标路径点计算出车把转角的指令。在已知后轮速度和计算出的车把转角的情况下，通过无人自行车的拉格朗日方程推导出外环动力学模型，并确定横滚角的平衡点。随后，将横滚角平衡点引入内环等效反作用轮摆模型中，最终建立反作用轮无人自行车的横滚角跟踪误差模型。

此外，鉴于离线强化学习在算法部署方面的优势，本章构建一个域随机化的训练环境，并设计一种基于近端策略优化的离线强化学习反作用轮无人自行车平衡控制算法。最后，通过仿真测试对该算法在反作用轮无人自行车平衡控制问题中的局限性进行分析。

2.2 反作用轮无人自行车样机设计及实验场景搭建

本研究探讨的反作用轮无人自行车样机设计面临的主要挑战在于如何高效配置有限的硬件资源，以满足无人自行车在后续章节中所涉及的强化学习算法及其神经网络梯度计算等方面的计算密集型需求，同时确保能够以一定的输出频率和实时性进行数据输出。

2.2.1 反作用轮无人自行车样机设计

（1）样机机电系统设计

本文从紧凑性和轻量化的视角出发，设计了一种反作用轮无人自行车，如图2-1所示，并构建了相应的样机，如图2-2所示，其主要参数汇总于表2-1中。该样机主要由前轮、车把、车架、反作用轮及后轮等组成。样机设有三个主动控制关节，

中国知网 https://www.cnki.net

分别为车把转角控制、后轮速度控制以及反作用轮的力矩控制。车把转角控制与循迹模块相结合，实现样机对预定路径的跟随；后轮速度控制指令则直接由上位机发出；反作用轮的力矩控制指令通过平衡控制算法，基于 MPU6050 获取的无人自行车横滚角度、角速度、车把转角及后轮转速等信息进行计算得出。

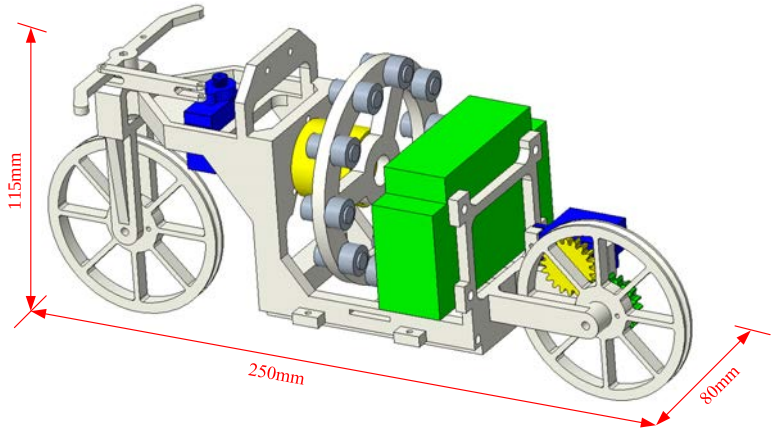


图 2-1 反作用轮无人自行车三维模型

Fig. 2-1 The 3D model of the unmanned bicycle with reaction wheel

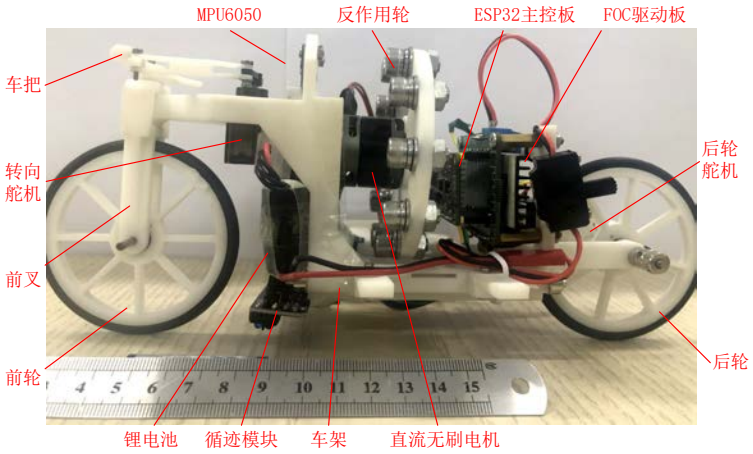


图 2-2 反作用轮无人自行车样机

Fig. 2-2 Prototype of the unmanned bicycle with reaction wheel

为了便于后续对基于强化学习的反作用轮无人自行车平衡控制算法进行对比分析，本文所设计的样机需同时满足平衡控制算法的实时性要求及强化学习算法的运算密集性需求。为此，本文采取以下方案：将计算开销较大的强化学习算法部署在上位机上，以减轻无人自行车样机的计算负担；而实时性要求较高的运算则部署在无人自行车样机的处理器上；样机与上位机通过低延迟 UDP 无线传输协议进行通信，以实现数据和指令的交换。

在转向机构的设计中，由于常规的非直立车把形式在崎岖路面上存在以下问

中国知网 https://www.cnki.net

表 2-1 反作用轮无人自行车样机参数
Table 2-1 The parameters of the unmanned bicycle with reaction wheel

类别	指标	参数
机械参数	质量	430g
	包络尺寸	250mm*115mm*80mm
	轮径	70mm
	轮距	185mm
动力参数	转把	±20° 0.16Nm
	后轮	30RPM 0.2Nm
	反作用轮	2000RPM 0.72Nm
	电池	12V 450mAh
硬件参数	主控芯片	ESP32 双核 240Mhz
性能参数	最大速度	0.11m/s
	最大爬坡角度	24°

题：首先，非直立车把会导致车把转角与拖曳距共同作用产生显著的横滚力矩，从而使自行车系统的动力学模型更加复杂；其次，自行车前轮与地面接触点的相对变化会导致非直立车把自行车的拖曳距不断变化，进而使该部分动力学模型的准确建立变得更加困难。因此，本文采用直立车把形式，以削弱崎岖地形下车把转动与拖曳距之间的耦合作用对平衡控制的影响。

本文使用单圈 SG90 微型舵机实现车把转角的位置控制，该舵机在控制精度、额定扭矩、工作电压、尺寸及重量方面均能较好地满足样机的需求。SG90 舵机通过脉宽调制（PWM）直接控制舵机的转动角度，硬件和控制实现相对简单。在其工作电压下，SG90 的扭矩为 0.16Nm。

在姿态传感器的选择上，本文选用六轴惯性测量单元 MPU6050，以获取无人自行车的姿态角和俯仰角的角度值及角速度值。MPU6050 通常与卡尔曼滤波结合使用，以获得实时准确的姿态数据。与其他惯性测量单元相比，MPU6050 在体积、重量和功耗方面具有显著优势。

为便于平衡控制算法的部署，本文在反作用轮驱动电机的选择上，采用了直流无刷电机及 FOC 矢量控制算法，以实现对反作用轮的力矩控制。具体而言，选用了 BGM2208 直流无刷电机驱动反作用轮。该无刷电机重量仅为 40 克，在无负载情况下转速可达 2000RPM，额定扭矩为 0.06(Nm/V)，能够满足样机平衡控制的需求。

在后轮驱动方面，本研究采用多圈的 SG90 微型舵机。与单圈的 SG90 微型舵机不同，多圈的 SG90 微型舵机中脉宽调制（PWM）直接控制其转动速度而不是转动角度，其最高转速可以达到 30RPM，最大扭矩为 0.2Nm。在重力加速度为 9.81m/s² 且不考虑轮地之间的滑移时，无人自行车最大能够爬坡的角度约为 24°。

中国知网 https://www.cnki.net

在样机处理器的选择上，本文选用乐鑫 ESP32 作为主控芯片。乐鑫 ESP32 为双核 240MHz 处理器，相较于常用的 STM32F1 系列、STM32F4 系列及 Arduino 系列嵌入式芯片，其运算频率更高，适合满足本文对无人自行车传感数据处理、直流无刷电机矢量控制解算及无线通信等实时计算的需求。乐鑫 ESP32 集成的 Wi-Fi 模块能够方便地实现无人自行车与上位机之间的通信。此外，乐鑫 ESP32 还具有丰富的外设接口，能够满足样机对多种类型数据输入输出的要求。

最后，在样机的结构组件设计中，本文采用了 3D 打印技术制造车架、轮毂等部件，并在局部区域使用金属连接件以提升无人自行车样机的刚度。车轮和转把等转动副则选用金属转轴及深沟球轴承，以降低转动摩擦。

（2）样机控制系统组成

反作用轮无人自行车样机控制系统的主要组成部分及其相互关系如图2-3所示。为了同时满足平衡控制的实时性需求以及强化学习神经网络的梯度计算等计算密集型任务，该控制系统被划分为样机部分和上位机部分。样机部分负责执行对实时性要求较高的运算，而上位机部分则承担计算量较大的强化学习运算，并通过上位机软件的用户界面设置后轮转速等。

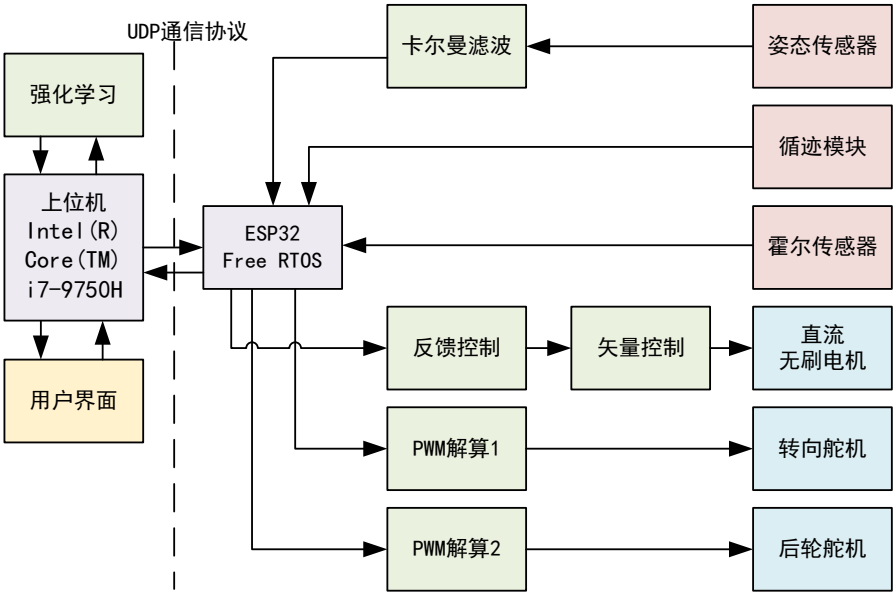


图 2-3 无人自行车控制系统及关键组成要素关系

Fig. 2-3 The control system and key components of the unmanned bicycle

在样机部分，ESP32 芯片上采用了 FreeRTOS 实时操作系统，以实现芯片计算资源的调度、硬件资源的管理及多线程的协同工作，从而确保系统能够同时处理姿态信息、控制算法以及在直流无刷电机 FOC 下的实时性和稳定性。此外，ESP32 芯片对 MPU6050 采集的数据进行了卡尔曼滤波处理，并读取霍尔传感器信息以解

中国知网 https://www.cnki.net

算 FOC 矢量控制，生成直流无刷电机的三相电压信号。在转向和后轮驱动方面，ESP32 芯片实时解算上位机指令的 PWM 信号。

在上位机方面，使用了一台搭载 Intel(R) Core(TM) i7-9750H CPU 的电脑，并通过 QT 软件开发了上位机操作程序。所开发的上位机操作程序的用户界面如图2-4所示，图中右框展示了反作用轮无人自行车状态量随时间的变化。该上位机操作程序设计了 Wi-Fi 连接设置功能、平衡控制算法选择功能、滑模控制参数在线调节功能、车把及后轮控制指令的设置与发送功能，以及数据存储功能等。

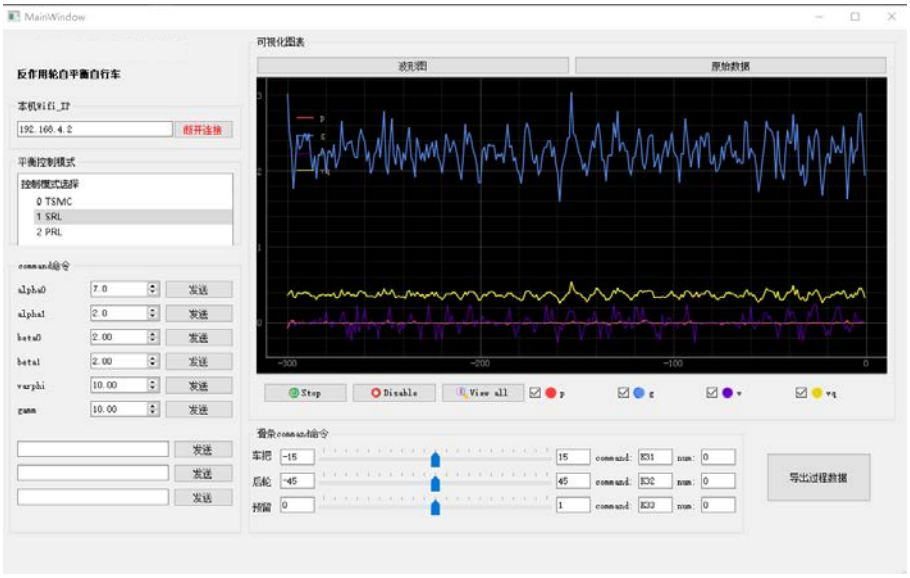


图 2-4 上位机用户界面
Fig.2-4 User interface

2.2.2 反作用轮无人自行车实验场景搭建

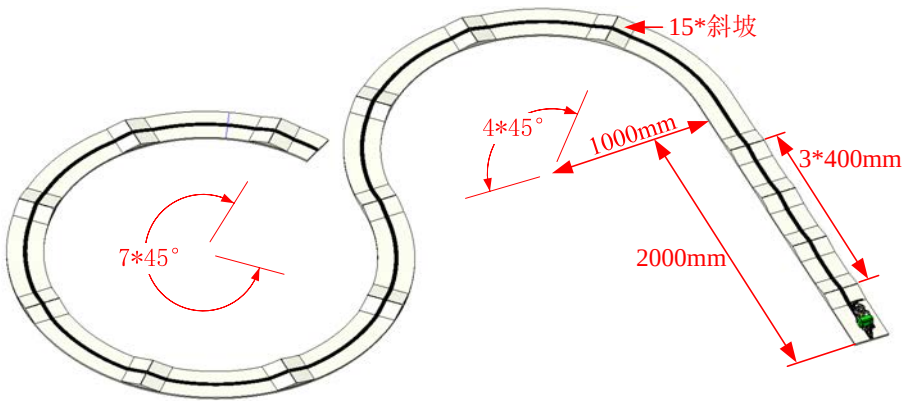


图 2-5 曲面路面三维模型
Fig.2-5 The model of curved pavement

由于无人自行车样机的车架部分与地面的最小间隙为 20mm，因此在实验设

中国知网 https://www.cnki.net

计中，曲面路面的凸起部分高度不得超过该值。实验中所设计的复合路径跟随曲面路面如图2-5所示，由 2000mm 长的直线路径与半径为 1000mm 的 “8 字” 路径组合而成，路径中设有 15 处斜坡，斜坡的倾斜角度均约为 10°。

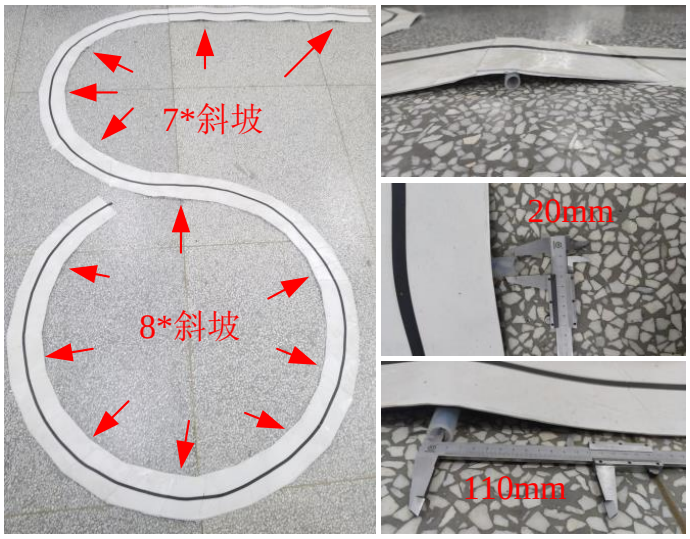


图 2-6 曲面路面实物场景

Fig. 2-6 The real scene of curved pavement

所搭建的实际实验场景如图2-6所示，路面中心贴有黑色循迹线，以实现无人自行车的路径跟随。由于无人自行车样机所采用的红外循迹模块在小车行驶过程中仅能提供关于循迹线位置的开关量信号，因此在实验中，车把的控制指令是根据循迹模块的开关量生成的，具体包括 0° 和 ±15° 三个转把角度指令。

2.3 反作用轮无人自行车动力学建模及仿真场景设计

2.3.1 反作用轮无人自行车动力学建模

目前，机器人动力学建模的方法主要包括牛顿-欧拉法[93] 和拉格朗日方程法[94] 等。牛顿-欧拉法通过对系统的受力和运动进行分析，建立各变量之间的运动关系。然而，该方法的局限性在于需要求解大量的微分方程，这在实际应用中可能会导致计算上的困难。相比之下，拉格朗日方程法基于拉格朗日原理，通过最小化机器人系统的作用量来推导运动方程。这种方法适用于由质点构成的受约束机械系统，其建模过程不需要考虑未知约束，而是专注于系统的能量和广义力。

本文采用拉格朗日方程法建立反作用轮无人自行车的动力学模型。反作用轮无人自行车的示意图见图2-7，由后轮 (R)、车架 (B)、反作用轮 (W)、车把 (H) 和前轮 (F) 五个部分组成。图2-7中 G 为反作用轮无人自行车系统的质心，G_1 和 G_2 分别为除反作用轮外系统的质心和反作用轮的质心，相关符号及其含义见表2-2。

中国知网 https://www.cnki.net

动力学建模的步骤及每一步之间的关联关系如图2-8所示。首先，提出无人自行车系统建模的相关假设。接着，通过等效重力场的处理方法，将曲面路面上无人自行车的俯仰角转换为等效的重力加速度。在此基础上，建立反作用轮无人自行车动力学模型的内外环形式，其中外环通过基于约束的拉格朗日方程确定无人自行车系统的平衡点，内环则基于反作用轮摆模型对该平衡点进行跟踪。同时，采用 Stanley 算法生成给定路径下的车把转角指令。最后，得到路径跟随过程中横滚角平衡点跟踪误差的动力学模型。

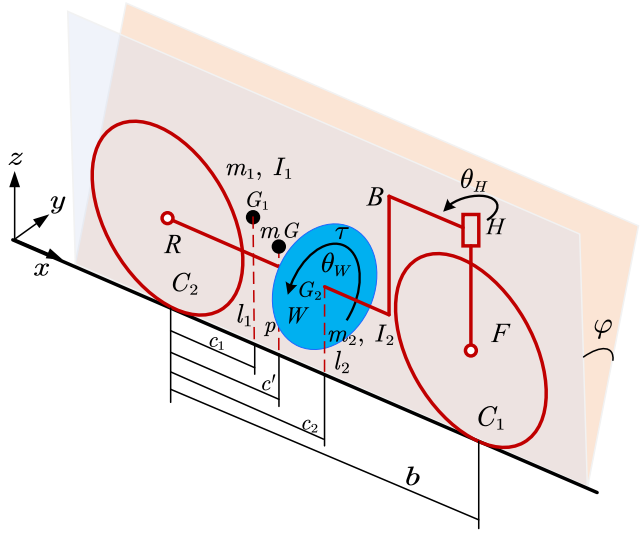


图 2-7 反作用轮无人自行车示意图

Fig.2-7 The unmanned bicycle based on reaction wheel

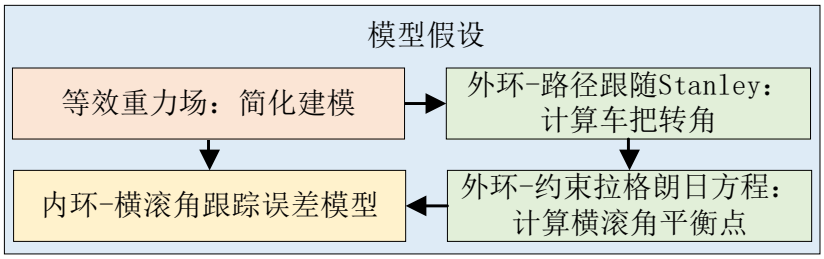


图 2-8 反作用轮无人自行车动力学建模

Fig.2-8 The dynamics modeling of unmanned bicycle based on reaction wheel

（1）模型假设

假设 1：在本研究中，假设无人自行车的前后轮宽度可以忽略不计，即前后轮与地面之间的接触点被视为点接触。同时，在车轮滚动过程中，不考虑其纵向滑移、横向滑移及脱离路面的情况。该假设在无人自行车相关研究中被广泛采用[11,12,16]，旨在简化轮胎轮廓、轮胎形变等因素对无人自行车动力学分析的影响。

假设 2：无人自行车的五个组成部分均关于车架所在的平面呈对称分布，即五

中国知网 https://www.cnki.net

表 2-2 反作用轮无人自行车符号含义
Table2-2 The notations of the unmanned bicycle with reaction wheel

符号	单位	含义
b	m	前后轮轴心在水平面上投影点 C_1 和 C_2 的距离
p，c'	m	质心 G 的高度及到 C_2 的水平距离
c_1，c_2	m	质心 G_1 和 G_2 在水平面上的投影到 C_2 的距离
l_1，l_2	m	质心 G_1 和 G_2 的高度
m	kg	反作用轮无人自行车系统的质量
m_1，m_2	kg	除反作用轮外部分和反作用轮的质量
I_1	$\mathrm{kg\cdot m^2}$	除反作用轮外部分相对于 C_1C_2 连线的转动惯量
I_2	$\mathrm{kg\cdot m^2}$	反作用轮相对于其回转轴线的转动惯量
φ	rad	反作用无人自行车相对于铅垂面的横滚角
θ_W	rad	反作用轮相对于车架的角度
θ_H	rad	车把转角
τ	Nm	平衡控制力矩

个组成部分的质心位于同一平面内；当无人自行车行驶于水平路面时，车把的回转轴线与路面垂直，并且位于该平面内。此假设有助于进一步简化无人自行车动力学模型的推导过程。

假设 3：本研究中，假设无人自行车在曲面路面行驶时，俯仰角的变化相对平缓。因此，后续分析中仅考虑俯仰角变化对系统动力学的影响，而不考虑俯仰角的高阶导数影响。

假设 4：无人自行车的后轮采用速度伺服控制，反作用轮采用力矩控制，车把则采用位置伺服控制。这意味着在动力学建模中可以忽略车把的转动惯量，从而可以忽略车把绕转轴的动能。该假设与 Getz 的研究[11] 及赵的工作[16] 一致，并与本文设计的无人自行车样机中车把和后轮的实际控制方式相符。

由于反作用轮的位置和速度对无人自行车系统的运动并不产生直接影响，因此在曲面路面上进行无人自行车的动力学建模时，可以将其分为内环和外环两个部分：外环为非完整约束的无人自行车模型，内环为反作用轮摆模型。

（2）等效重力场

在机器人系统的动力学建模与控制领域，等效重力场是一种常见且直观的处理方式。等效重力场是指在非惯性参考系中，为了描述物体在非水平面上运动所受的合力而引入的一种虚拟重力加速度。文献 [95] 基于等效重力场原理，对斜面上双足机器人无源行走的关节力矩进行了深入分析，并在等效水平面双足机器人行走控制中取得了显著成效。此外，文献 [96] 在研究多边形机器人在崎岖路面上的自主运动规划问题时，也采用了等效重力场的处理方法。

为简化无人自行车在曲面路面上的动力学建模，本文采用等效重力场的方法，

中国知网 https://www.cnki.net

将无人自行车的俯仰角转化为虚拟重力加速度矢量。如图2-9所示，η 表示俯仰角，θ_{yaw} 表示偏航角，ϕ 为前轮平面接地线与前后轮接地点连线之间的夹角。无人自行车系统被视为与地面存在两个接触点的等效质点系统，则系统所受的重力 $F_g = mg$ 可以转化为 $F_{g'} = mg\cos(\eta)$，$F_{h''} = mg\sin(\eta)$ 和 $M_{h''} = pmg\sin(\eta)$，其中 $F_{h''}$ 和 $M_{h''}$ 均位于车架所在的平面内。

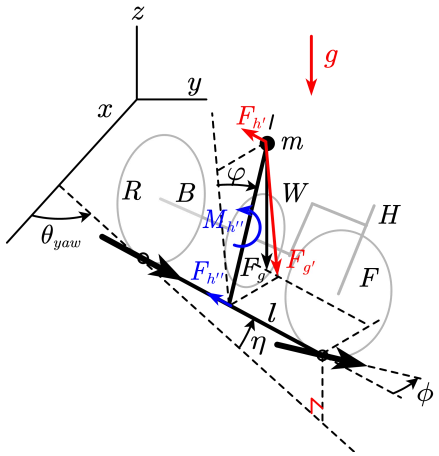


图 2-9 无人自行车等效重力处理

Fig.2-9 Equivalent gravity treatment of the unmanned bicycle

根据假设 4，本文讨论的无人自行车系统以后轮速度为输入进行伺服控制，并假设后轮输入力矩足够大。在假设 1 的前提下，无人自行车系统的前后轮始终与地面保持接触，因此可以忽略 $F_{h''}$ 和 $M_{h''}$ 对系统动力学的影响。在此情况下，曲面路面上的无人自行车可以通过等效重力加速度的形式 $g' = g\cos(\eta)$ 进行简化。

（3）路径跟随

路径跟随是指车辆或自主移动系统沿预先设定路径进行移动。在路径跟随控制中，通常需要在确保系统稳定性和跟踪精度的前提下，适应不同形状和复杂程度的路径。常见的路径跟随控制算法主要包括基于误差反馈控制的算法和基于预测模型控制的算法。基于误差反馈控制的算法通过计算期望路径与实际路径之间的偏差，调整控制器输出，以使系统能够跟随期望路径。典型的方法包括比例积分微分控制、纯追踪算法和 Stanley 算法。基于预测模型的算法则是通过构建车辆运动、路面条件及环境因素下的系统预测模型，推测未来几秒内车辆的位置和速度，从而计算出车辆应前往的目标点。

文献 [50, 97] 对常见的路径跟随控制算法进行了分析。尽管模型预测控制能够考虑机器人与环境之间的实时变化，并通过最优控制算法优化机器人状态轨迹及控制器输出，从而提高路径跟随的精度和鲁棒性，但其实施过程不仅需要复杂的参数调节，同时也伴随着较大的计算负担。Stanley 算法作为一种常用的路径跟随

中国知网 https://www.cnki.net

控制算法，其基本思想是利用机器人横向误差和航向角误差作为反馈信号，通过比例控制调整机器人的转向运动，从而实现沿预设路径的行驶。与模型预测控制相比，Stanley 算法在实现上更为简便，运算量小、响应速度快，并且其横向跟踪误差与角度跟踪误差均能指数收敛于零。此外，Stanley 算法已在众多无人系统的路径跟随实践中得到了验证，特别是在那些难以获取精确系统模型的崎岖路面环境下的无人驾驶应用中[98]。

本研究采用 Stanley 算法作为无人自行车的路径跟随控制算法。图2-10和公式(2-1) 给出了基于 Stanley 算法的转向角计算。图2-10中 c_x 和 c_y 表示离前轮接地点最近的目标路径点的 x 坐标和 y 坐标。

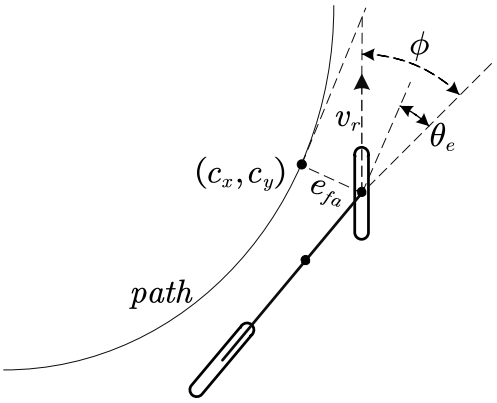


图 2-10 基于 Stanley 算法的路径跟随
Fig. 2-10 Path Following Control based on Stanley algorithm

基于 Stanley 算法的车把转向 $\phi(t)$ 的控制指令表达式如下：

$$\phi(t) = \theta_e(t) + \arctan\frac{k_\phi e_{fa}(t)}{v_r(t)} \tag{2-1}$$

式中 θ_e———路径跟随的航向角误差（rad）；

e_{fa}———路径跟随的横向误差（m）；

v_r———前轮速度（m/s）；

$k_\phi > 0$———控制器可调增益系数（无量纲常数）。

根据公式 (2-1) 可得，$\sin(\phi - \theta_e) = \frac{k_\phi e_{fa}/v_r}{\sqrt{1+\left(k_\phi e_{fa}/v_r\right)^2}}$，代入到 $\dot{e}_{fa} = -v_r \sin(\phi - \theta_e)$ 中，可得路径跟随的横向误差变化率

$$\dot{e}_{fa}(t) = -\frac{k_\phi e_{fa}(t)}{\sqrt{1+\left(\frac{k_\phi e_{fa}(t)}{v_r(t)}\right)^2}} \tag{2-2}$$

当 $\left|e_{fa}\right| \ll \left|\frac{v_r}{k_\phi}\right|$ 时，

中国知网 https://www.cnki.net

$$\dot{e}_{fa}(t) \approx -k_{\phi} e_{fa}(t) \tag{2-3}$$

可得，

$$e_{fa}(t) \approx e_{fa}(0) \cdot \exp\left(-k_{\phi} t\right) \tag{2-4}$$

因此，无人自行车路径跟随的横向误差指数收敛于 $e_{fa}(t) = 0$。

（4）横滚角平衡点

图2-11为等效重力处理后的无人自行车系统示意图。x 和 y 表示后轮接地点在惯性系 $Oxyz$ 中的坐标。无人自行车车架所在平面与 $Oxyz$ 中水平面的交线形成了前后轮与地面之间的接触线，该接触线绕 z 轴的旋转与 Ox 的夹角为航向角 θ_{yaw}，逆时针方向为正方向。无人自行车的对称平面与垂直平面之间的夹角称为横滚角 φ，图2-11中为横滚角的负方向。由于本文中无人自行车采用了直立的车把，因而转向角 ϕ 近似等于车把转角 θ_H。为了简化后续动力学模型的推导，定义转向角变量 $\sigma := \tan(\phi)/b$。利用上述变量构成系统广义坐标的一个完备集，表示为 $\left[x\ y\ \theta_{yaw}\ \varphi\ \sigma\right]$。

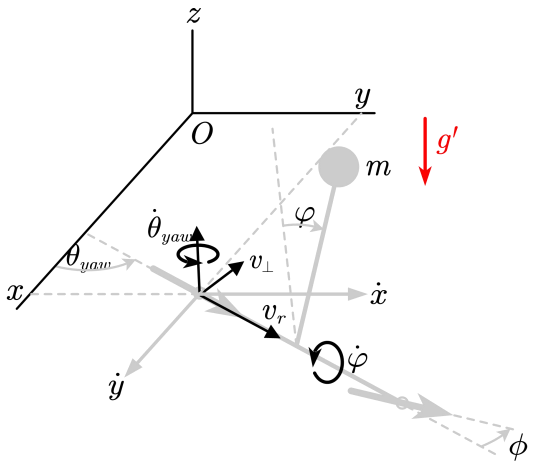


图 2-11 等效重力处理后的无人自行车示意图

Fig.2-11 Illustration of the unmanned bicycle after equivalent gravity treatment

为了便于后续对非完整约束进行处理，接下来给出广义速度的变换。定义 $v_{\perp}$ 为后轮速度在水平面内沿前后轮连线垂直方向的分量，而 v_r 则表示后轮速度在前后轮连线上的分量。由此，后轮接地点的速度可以表示为：

$$\begin{bmatrix} \dot{x} \\ \dot{y} \end{bmatrix} = \begin{bmatrix} \cos\left(\theta_{yaw}\right) & -\sin\left(\theta_{yaw}\right) \\ \sin\left(\theta_{yaw}\right) & \cos\left(\theta_{yaw}\right) \end{bmatrix} \begin{bmatrix} v_r \\ v_{\perp} \end{bmatrix} \tag{2-5}$$

无人自行车系统的广义速度的完备集可以表示为 $\left[\dot{v}_r\ \dot{v}_{\perp}\ \dot{\theta}_{yaw}\ \dot{\varphi}\ \dot{\sigma}\right]$。

中国知网 https://www.cnki.net

系统的拉格朗日函数 L 由质点 m 的动能与势能构成，见公式 (2-6)。为简化表达，公式中用 s_φ 表示 $\sin(\varphi)$，c_φ 表示 $\cos(\varphi)$。

$$L = -mg'pc_\varphi + \frac{m}{2}\left(\left(v_r + ps_\varphi\dot{\theta}_{yaw}\right)^2 + \left(v_\perp - l_1\dot{\varphi}c_\varphi + c'\dot{\theta}_{yaw}\right)^2 + \left(-p\dot{\varphi}s_\alpha\right)^2\right) \tag{2-6}$$

将广义速度分为两部分：$\dot{r} = [\dot{\varphi}, \dot{v}_r, \dot{\sigma}]^T$ 和 $\dot{s} = \left[\dot{\theta}_{yaw}, \dot{v}_\perp\right]^T$。

在假设 1 中，前后轮纯滚动无侧滑的条件下，非完整约束可以表示为：

$$\dot{s} + A(r,s)\,\dot{r} = 0 \tag{2-7}$$

其中，

$$A(r,s) = \begin{bmatrix} 0 & -\sigma & 0 \\ 0 & 0 & 0 \end{bmatrix} \tag{2-8}$$

在任意时刻如果 $\dot{r}$ 已知，则可以通过对 $\dot{\sigma}$ 进行积分获得 σ，进而推导出 $\dot{s}$。这一过程与文献[99] 中对 Base 速度和 Fiber 速度的描述相一致，满足基于约束的拉格朗日方程的应用条件。

接下来，将 $\dot{\theta}_{yaw} = \sigma v_r$ 和 $v_\perp = 0$ 代入公式 (2-6)，可以得到基于约束的拉格朗日方程如公式 (2-9) 所示：

$$L_c = -mg'pc_\varphi + \frac{m}{2}\left(\left(v_r + ps_\varphi\sigma\upsilon_r\right)^2 + p^2s_\varphi^2\dot{\alpha}^2 + \left(c'\sigma v_r - pc_\varphi\dot{\alpha}\right)^2\right) \tag{2-9}$$

基于文献 [7] 中推导的约束拉格朗日方程形式，可以得到公式 (2-10)：

$$\frac{d}{dt}\frac{\partial L_c}{\partial \dot{r}^i} - \frac{\partial L_c}{\partial r^i} + A_i^k\frac{\partial L_c}{\partial s^k} = -\frac{\partial L}{\partial \dot{s}^l}C_{ij}^l\dot{r}^j + \tau^i \tag{2-10}$$

其中，τ^i 为第 i 个广义坐标对应的广义力，C_{ij}^l 的定义为：

$$C_{ij}^l = \left(\frac{\partial A_i^l}{\partial r^j} - \frac{\partial A_j^l}{\partial r^i} + A_i^k\frac{\partial A_j^l}{\partial s^k} - A_j^k\frac{\partial A_i^l}{\partial s^k}\right) \tag{2-11}$$

并且有：

$$A_i^k\frac{\partial A_j^l}{\partial s^k} \equiv \sum_{k=1}^{m} A_i^k\frac{\partial A_j^l}{\partial s^k} \tag{2-12}$$

由此可得，当 $i = 1$ 时，对应的广义力为反作用轮对车体的反作用力矩 τ，则其表达式如下：

$$\begin{aligned} mp^2\ddot{\varphi} - mcp\sigma\dot{v}_rc_\varphi = mg'ps_\varphi - \\ mc'p\sigma v_rs_\varphi + mpc_\varphi\sigma\upsilon_r^2\left(1 + ps_\varphi\sigma\right) + mc'pc_\varphi v_r\dot{\sigma} + \tau \end{aligned} \tag{2-13}$$

中国知网 https://www.cnki.net

将广义速度 $\left[\dot{v}_r\ \dot{v}_\perp\ \dot{\theta}_{yaw}\ \dot{\varphi}\ \dot{\sigma}\right]$ 和反作用轮输入力矩 τ 都设为零，则可以得到无人自行车系统外环横滚角平衡点 φ_d 的隐式表达式如下：

$$0 = (g' - c'\sigma v_r)\tan(\varphi_d) + c'\sigma v_r^2 + p(c'\sigma)^2 v_r^2 \sin(\varphi_d) \tag{2-14}$$

（5）横滚角跟踪误差模型

为构建反作用轮无人自行车的横滚角跟踪误差模型，本文将无人自行车系统的内环等效为反作用轮摆，如图2-12所示。该系统主要由两个部分构成：后轮、车架、车把及前轮合并成的整体（单元 P），以及被视为另一独立部分的反作用轮（单元 W）。在前文中已经采用了等效重力对无人自行车的俯仰角进行了处理，即本节中等效反作用轮摆系统仅考虑如下两个转动自由度：单元 P 围绕点 o 具有一个转动自由度（对应于原无人自行车系统的横滚角变化）；单元 W 围绕点 o_2 具有另一个转动自由度。

设定系统的惯性坐标系为图2-12中的 $oxyz$，其中坐标原点位于等效反作用轮摆单元 P 的回转中心，x 轴沿无人自行车与地面接触线的方向，y 轴沿改接触性的垂线方向，z 轴沿铅垂方向。在单元 P 和单元 W 的质心处分别建立随动坐标系 $o_1x_1y_1z_1$ 和 $o_2x_2y_2z_2$。

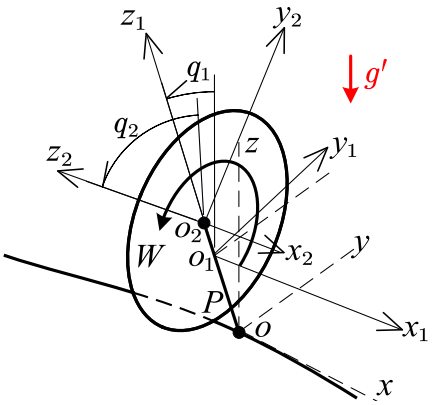


图 2-12 反作用轮摆

Fig.2-12 Reaction wheel pendulum

定义广义坐标 q_1 为单元 P 绕 x_1 轴相对于 x 轴的转角，q_2 为单元 W 绕 x_2 轴相对于 x 轴的转角。单元 P 和单元 W 的质量如前文所述分别为 m_1 和 m_2，单元 P 绕 x_1 轴的转动惯量为 I_1，单元 W 绕 x_2 轴的转动惯量为 I_2，点 o_1 与点 o 之间的距离为 l_1，点 o_2 与点 o 之间的距离为 l_2。为便于后续拉格朗日方程的推导，定义以下变量：$\bar{m} = m_1 l_1 + m_2 l_2$，$J = m_1 l_1^2 + m_2 l_2^2 + I_1 + I_2$。

反作用轮摆系统的拉格朗日函数 L_r 可表示为：

$$L_r = \frac{1}{2} J \dot{q}_1^2 + \frac{1}{2} I_2 \dot{q}_2^2 - \bar{m} g' (\cos(q_1) - 1) \tag{2-15}$$

中国知网 https://www.cnki.net

拉格朗日方程的表达式如下：

$$\frac{d}{dt}\left(\frac{\partial L_r}{\partial \dot{r}^i}\right)-\frac{\partial L_r}{\partial r^i}=\tau^i, i=1,\cdots,n \tag{2-16}$$

对拉格朗日函数进行偏导数运算可得：

$$\begin{cases}\frac{\partial L_r}{\partial q_1}=\bar{m}g'\sin(q_1)\\ \frac{\partial L_r}{\partial \dot{q}_1}=J\dot{q}_1+I_2\dot{q}_2\\ \frac{\partial L_r}{\partial q_2}=0\\ \frac{\partial L_r}{\partial \dot{q}_2}=I_2\dot{q}_2\end{cases} \tag{2-17}$$

则反作用轮无人自行车内环动力学模型为：

$$\begin{aligned}J\ddot{q}_1+I_2\ddot{q}_2-\bar{m}g'\sin(q_1)&=d_1\\ I_2\ddot{q}_1+I_2\ddot{q}_2&=\tau+d_2\end{aligned} \tag{2-18}$$

式中 d_1———表示非匹配扰动（如未建模的轮地接触、阵风及地形引起的扰动等）（Nm）；

d_2———表示匹配扰动（如反作用轮转轴的干摩擦等）（Nm）。

为便于后续控制器的设计与理论分析，提出假设 5：扰动 d_1、$\dot{d}_1$、$\ddot{d}_1$、$\dddot{d}_1$ 及 d_2 都有界。

当反作用轮无人自行车的后轮速度 v_r 和待跟随的路径已知时，可以根据公式 (2-1) 计算出车把转向角 ϕ 的控制指令。将后轮速度和车把转向角代入无人自行车系统外环平衡点公式 (2-14)，可得横滚角平衡点 φ_d。定义横滚角跟踪误差 $e=q_{1d}-q_1$，其中 $q_{1d}=\varphi_d$。将 $e=q_{1d}-q_1$ 代入内环反作用轮摆动力学模型公式 (2-18)，并通过低通滤波器对 $\dot{q}_{1d}$ 进行估计。可以推导出反作用轮无人自行车系统横滚角跟踪误差的动力学模型：

$$\begin{aligned}-J\ddot{e}+J\ddot{q}_{1d}+I_2\ddot{q}_2-\bar{m}g'\sin(q_{1d}-e)&=d_1\\ -I_2\ddot{e}+I_2\ddot{q}_{1d}+I_2\ddot{q}_2&=\tau+d_2\end{aligned} \tag{2-19}$$

为便于利用系统已知的动力学信息，将无人自行车系统的物理参数分为标称部分和不确定部分，具体如下：

$$\begin{aligned}\Delta J=|J_t-J_0|<\overline{\Delta J}\\ \Delta I_2=|I_{2t}-I_{20}|<\overline{\Delta I_2}\\ \Delta M=|M_t-M_0|<\overline{\Delta M}, M=\bar{m}g'\end{aligned} \tag{2-20}$$

中国知网 https://www.cnki.net

式中 J_t，I_{2t}，M_t———物理参数的真值（$\mathrm{kg\cdot m^2}$，$\mathrm{kg\cdot m^2}$，Nm）；

J_0，I_{20}，M_0———物理参数的标称值（$\mathrm{kg\cdot m^2}$，$\mathrm{kg\cdot m^2}$，Nm）；

ΔJ，ΔI_2，ΔM———物理参数的不确定部分（$\mathrm{kg\cdot m^2}$，$\mathrm{kg\cdot m^2}$，Nm）；

$\overline{\Delta J}$，$\overline{\Delta I_2}$，$\overline{\Delta M}$———物理参数不确定部分上界（$\mathrm{kg\cdot m^2}$，$\mathrm{kg\cdot m^2}$，Nm）。

公式 (2-19) 可表述为：

$$\begin{aligned} -J_0\ddot{e}+J_0\ddot{q}_{1d}+I_{20}\ddot{q}_2-M_0\sin\left(q_{1d}-e\right)&=d_{l1}\\ -I_{20}\ddot{e}+I_{20}\ddot{q}_{1d}+I_{20}\ddot{q}_2&=\tau+d_{l2}\end{aligned} \tag{2-21}$$

其中，$d_{l1}=d_1+\Delta M\sin\left(q_{1d}-e\right)+\Delta J\ddot{e}-\Delta J\ddot{q}_{1d}-\Delta I_2\ddot{q}_2$，$d_{l2}=d_2+\Delta I_2\ddot{e}-\Delta I_2\ddot{q}_{1d}-\Delta I_2\ddot{q}_2$。

根据文献 [100, 101] 中的 Olfati-Saber 变换，状态变量可定义为：

$$\begin{aligned} x_1&=-J_0\dot{e}+J_0\dot{q}_{1d}+I_{20}\dot{q}_2\\ x_2&=M_0\sin\left(q_{1d}-e\right)-M_0\sin\left(q_{1d}\right)\\ x_3&=M_0\cos\left(q_{1d}-e\right)\left(\dot{q}_{1d}-\dot{e}\right)-M_0\cos\left(q_{1d}\right)\left(\dot{q}_{1d}\right)\end{aligned} \tag{2-22}$$

状态方程可以表示为如下级联形式：

$$\begin{aligned} \dot{x}_1&=x_2+M_0\sin\left(q_{1d}\right)+d_{l1}\\ \dot{x}_2&=x_3\\ \dot{x}_3&=u+\frac{1}{J_0-I_{20}}M_0\cos\left(q_{1d}-e\right)\left(d_{l1}-d_{l2}\right)\end{aligned} \tag{2-23}$$

其中，

$$\begin{aligned} u=-\frac{M_0}{J_0-I_{20}}\cos\left(q_{1d}-e\right)\tau+\frac{1}{J_0-I_{20}}\left(M_0^2\sin\left(q_{1d}-e\right)\cos\left(q_{1d}-e\right)\right)-\\ M_0\sin\left(q_{1d}-e\right)\left(\dot{q}_{1d}-\dot{e}\right)^2+M_0\sin\left(q_{1d}\right)\left(\dot{q}_{1d}\right)^2-M_0\cos\left(q_{1d}\right)\ddot{q}_{1d}\end{aligned} \tag{2-24}$$

因此，可以得到反作用轮无人自行车平衡控制力矩 τ 关于 u 的函数为：

$$\tau=\frac{u-F_2}{F_1} \tag{2-25}$$

其中，

$$\begin{aligned} F_1&=-\frac{M_0}{J_0-I_{20}}\cos\left(q_{1d}-e\right)\\ F_2&=\frac{1}{J_0-I_{20}}\left(M_0^2\sin\left(q_{1d}-e\right)\cos\left(q_{1d}-e\right)\right)-M_0\sin\left(q_{1d}-e\right)\left(\dot{q}_{1d}-\dot{e}\right)^2+\\ &\quad M_0\sin\left(q_{1d}\right)\left(\dot{q}_{1d}\right)^2-M_0\cos\left(q_{1d}\right)\ddot{q}_{1d}\end{aligned} \tag{2-26}$$

在公式 (2-23) 中，由于 $M_0\sin\left(q_{1d}\right)\leqslant M_0$，$\left|\frac{1}{J_0-I_{20}}M_0\cos\left(q_{1d}-e\right)\right|\leqslant\frac{1}{J_0-I_{20}}M_0$，且

中国知网 https://www.cnki.net

M_0 和 $\frac{1}{J_0-I_{20}}M_0$ 都为常数。

状态方程可以进一步化简为：

$$\begin{aligned}\dot{x}_1 &= x_2 + d_1' \\ \dot{x}_2 &= x_3 \\ \dot{x}_3 &= u + d_2'\end{aligned} \tag{2-27}$$

其中，$d_1' = M_0 \sin(q_{1d}) + d_{l1}$，$d_2' = \frac{1}{J_0-I_{20}}M_0 \cos(q_{1d} - e)(d_{l1} - d_{l2})$。

根据假设 5，可以得到 d_1'、$\dot{d}_1'$、$\ddot{d}_1'$、$\dddot{d}_1'$ 和 d_2' 均为有界量，设定 $L_i(i = 1, \cdots, 5)$ 为常数，$L_1 > |d_1'|$，$L_2 > |\dot{d}_1'|$，$L_3 > |\ddot{d}_1'|$，$L_4 > |\dddot{d}_1'|$ 以及 $L_5 > |d_2'|$。

2.3.2 反作用轮无人自行车仿真场景设计

在机器人运动控制领域，通过在动力学仿真软件中对机器人系统模型的动态变化进行模拟，可以有效评估控制器的性能。常见的动力学仿真软件包括美国 MSC Software 公司开发的 MSC.ADAMS、美国 MathWorks 公司开发的 Simscape Multibody、韩国 FunctionBay 公司开发的 RecurDyn 以及德国 Dassault Systemes 开发的 Simpack 等。其中，Simscape Multibody 为机器人系统提供了一个可视化的、多体系统动力学仿真环境。该软件能够快速构建多种机械系统及部组件模型，包括刚体、柔性体、连杆、齿轮、传动机构和驱动装置等。在 Simscape Multibody 中，多体系统被建模为由刚体、关节和力（力矩）组成的物理系统，并提供多种数值计算方法以求解多体系统的运动状态和受力情况，例如隐式欧拉法和变步长积分法，从而确保仿真的精度和速度。此外，Simscape Multibody 的另一个显著优势在于其能够与 MathWorks 的其他产品（如 MATLAB/Simulink）方便地集成使用，这使其在机器人运动控制领域得到了广泛的应用。

本节构建基于 Simscape Multibody 的崎岖路面及反作用轮无人自行车的仿真测试环境，并介绍无人自行车的组成、崎岖路面的构造、轮地接触设置以及仿真测试的相关设置。

（1）无人自行车

本文在 Simscape Multibody 仿真环境中构建的反作用轮无人自行车，如图2-13所示。与前文所述一致，该反作用轮无人自行车由后轮 (R)、车架 (B)、反作用轮 (W)、车把 (H) 和前轮 (F) 五个组成部分构成，其中车把 H 被简化为图示车架 B 前端的竖直轴线。

该无人自行车设有三个主动的回转副（车把的转动、反作用轮的转动和后轮的转动）和一个被动的回转副（前轮的转动）。主要几何参数，$p = 0.1\text{m}$，$c' = 0.15\text{m}$，$b = 0.3\text{m}$。

中国知网 https://www.cnki.net

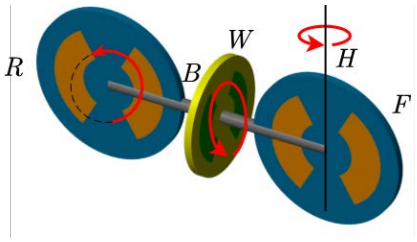


图 2-13 仿真环境中的无人自行车

Fig.2-13 The unmanned bicycle in a simulation environment

假定无人自行车各部分的质量都是均匀分布，在设定无人自行车的车体质量、反作用轮质量和车轮质量后，可以通过 Simscape Multibody 对反作用轮无人自行车的其他物理参数进行计算，可以得到：$J_t = 0.033\text{kg}\cdot\text{m}^2$，$I_{2t} = 0.004\text{kg}\cdot\text{m}^2$，$M_t = 0.2742g'\text{Nm}$。

（2）崎岖路面

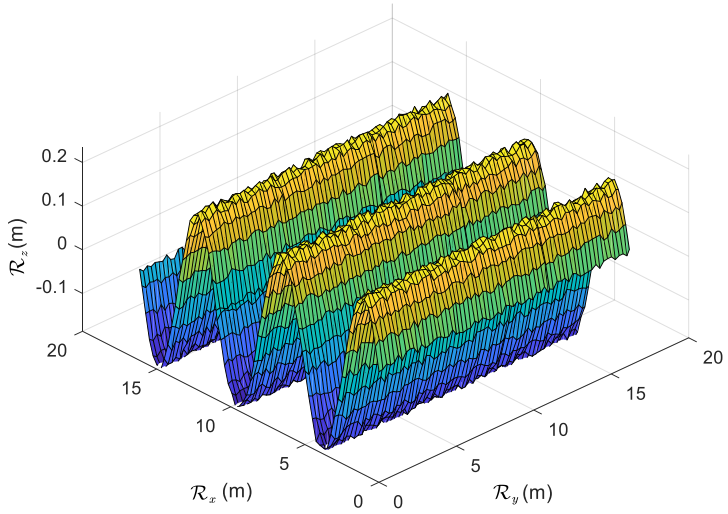


图 2-14 曲面路面

Fig.2-14 Curved surface pavement

在 Simscape Multibody 仿真环境中，所构建的崎岖路面如图2-14所示，为叠加了白噪声的正弦曲面。白噪声用于模拟地面的颠簸，为反作用轮无人自行车的平衡控制引入扰动。正弦曲面用于模拟崎岖路面，其高度值 $\mathcal{R}_z$ 是关于坐标 $\mathcal{R}_x$ 和 $\mathcal{R}_y$ 的函数，其表达式如下：

$$\mathcal{R}_z\left(\mathcal{R}_x,\mathcal{R}_y\right) = K_1\sin\left(K_2\left(\mathcal{R}_x\right)\cdot\mathcal{R}_x\right) + K_3\left(\mathcal{R}_x,\mathcal{R}_y\right) \tag{2-28}$$

其中，无量纲常数 K_1 为给定的曲面高度系数。$K_2\left(\mathcal{R}_x\right) = 0.8 + 0.4\gamma_1\left(\mathcal{R}_x\right)$ 为由 $\mathcal{R}_x$ 作为随机种子生成的无量纲随机数，$0 < \gamma_1\left(\mathcal{R}_x\right) < 1$。$K_2\left(\mathcal{R}_x\right)$ 的引入，使得正弦曲面路面的每个波峰与相邻波谷的距离在一定范围内变化。该范围如果设置不当，

中国知网 https://www.cnki.net

极可能导致无人自行车无法正常通行。$K_3\left(\mathcal{R}_x,\mathcal{R}_y\right)=0.1K_1\cdot\gamma_2\left(\mathcal{R}_x,\mathcal{R}_y\right)$，$\gamma_2$ 表示由 $\mathcal{R}_x$ 和 $\mathcal{R}_y$ 生成的随机数，$0<\gamma_2\left(\mathcal{R}_x,\mathcal{R}_y\right)<1$。图2-14截取了 $K_1=0.2$ 时，所生成的崎岖路面。

（3）轮地接触模型

Simscape Multibody 在处理轮地接触时，将接触力分为基于碰撞的法向接触正压力和基于速度的切向摩擦力。如图2-15所示，碰撞的法向接触正压力 F_c 主要由无量纲的接触刚度系数 k_r 和最大阻尼系数 c_{max} 进行调节，其数学表达式如下：

$$F_c=\max\left(0,k_r x_d^e-\operatorname{step}\left(x_d,0,0,d,c_{\max}\right)\dot{x}_d\right) \tag{2-29}$$

式中 x_d———嵌入深度（m）；

e———力指数（无量纲常数）；

d———最大阻尼对应的嵌入深度（m）。

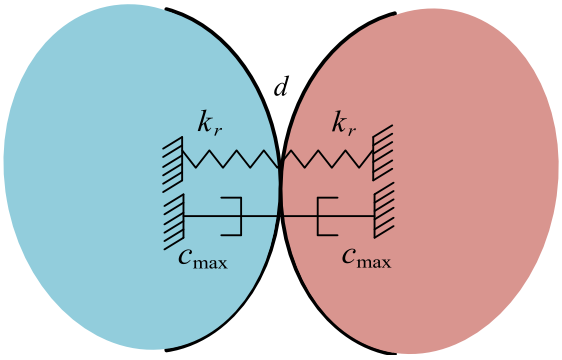


图 2-15 轮地接触模型

Fig.2-15 Wheel-ground contact model

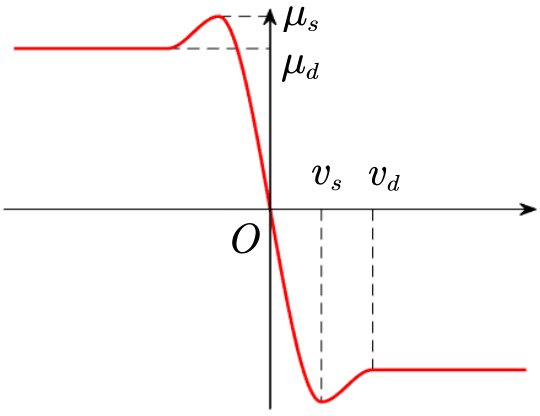


图 2-16 摩擦模型

Fig.2-16 Friction model

基于速度的摩擦模型是一种常用的切向接触力计算方法，如图2-16所示，其表达式如下：

中国知网 https://www.cnki.net

$$\mu(v_\tau)=\begin{cases}-\text{sign}(v_\tau)\,\mu_d & |v_\tau|>v_d\\ \text{sign}(v_\tau)\,\text{step}(|v_\tau|,v_s,-\mu_s,v_d,-\mu_d) & v_s<|v_\tau|\leqslant v_d\\ -\text{step}(v_\tau,-v_s,-\mu_s,v_s,\mu_s) & -v_s\leqslant v_\tau\leqslant v_s\end{cases} \tag{2-30}$$

式中 v_τ———接触点的切向速度（m/s）；

v_s，v_d———黏滞过渡速度和滑移过渡速度（m/s）；

μ_s，μ_d———动静摩擦系数（无量纲常数）。

在公式 (2-29) 和公式 (2-30) 中，阶跃函数的定义为：

$$\text{step}(x_d,d_0,h_0,d_1,h_1)=\begin{cases}h_0 & x_d\leqslant d_0\\ h_0-a\cdot\Delta^2(3-2\Delta) & d_0<x_d<d_1\\ h_1 & x_d\geqslant d_1\end{cases} \tag{2-31}$$

其中，$a=h_0-h_1$，$\Delta=(x_d-d_0)/(d_1-d_0)$。

在本研究中，路面与机器人轮胎的接触部分材质均设为橡胶，根据现有研究[102] 对相关碰撞参数进行设置。轮地接触部分与前述推导的动力学模型之间的差异可以被视为建模误差对反作用轮无人自行车平衡控制所产生的影响。

（4）仿真测试任务设计

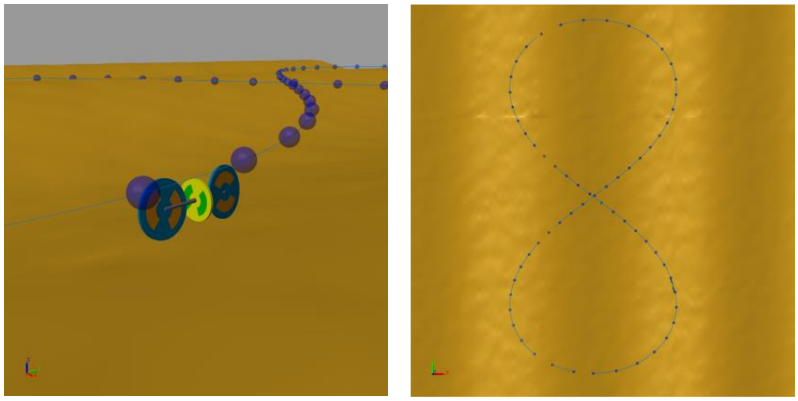
为充分评估反作用轮无人自行车平衡控制器的性能，本文设计了两类平衡控制任务。任务 1 为直线路径跟随过程中的平衡控制，任务 2 为“8 字”路径跟随过程中的平衡控制，如图2-17所示。图2-17 (a) 展示了无人自行车在曲面路面上对“8 字”形路径的跟随，图2-17 (b) 为仿真环境中“8 字”形目标路径的俯视图。该“8 字”形目标路径由公式 (2-32) 生成：

$$\begin{cases}\mathcal{T}_x=6\cos(j)/\left(1+\sin^2(j)\right)\\ \mathcal{T}_y=8\sin(j)\cos j/\left(1+\sin^2(j)\right)\end{cases} \tag{2-32}$$

其中，$\mathcal{T}_x$ 和 $\mathcal{T}_y$ 为目标路径点的坐标，单位为米；j 为区间 $[0,2\pi]$ 以 0.1 为步长生成的无量纲序列。

在仿真测试任务中，根据不同的地面高度系数 K_1 和不同的无人自行车后轮速度 v_r 组合形成三个测试场景，如表2-3所示。当 $v_r=10$rad/s 时，无人自行车绕“8 字”路径一圈约需 50 秒。因此，设置每个仿真测试任务的时长为 50 秒。当无人自行车的横滚角超过 0.5rad 时，仿真测试提前结束。仿真中实际采用的物理参数如表2-4中所示真值。随后，通过从 $[0.8,1.2]$ 的均匀分布中抽取三个随机数，得到 η_1，η_2，η_3。对无人自行车的物理参数进行处理，得到 $\hat{J}=\eta_1 J$，$\hat{I}_2=\eta_2 I_2$，$\hat{\bar{m}}=\eta_3\bar{m}$，以引入参数不确定性对控制器的影响，见表2-4中的参数 1、参数 2 和参数 3。

中国知网 https://www.cnki.net



(a) (b)

图 2-17 无人自行车仿真环境
Fig. 2-17 Simulation environment of the unmanned bicycle

表 2-3 仿真中的测试用例参数
Table 2-3 The parameters of test cases

	场景 1	场景 2	场景 3
K_1 高度系数 (m)	0.1	0.2	0.2
后轮转速 (rad/s)	10	10	20

表 2-4 无人自行车参数
Table 2-4 The parameters of the unmanned bicycle

	真值	参数 1	参数 2	参数 3
$J\ (\mathrm{kg}\cdot\mathrm{m}^2)$	0.033	0.0358	0.0368	0.0391
$I_2\ (\mathrm{kg}\cdot\mathrm{m}^2)$	0.004	0.0041	0.0035	0.0033
$\bar{m}\ (\mathrm{kg}\cdot\mathrm{m})$	0.2742	0.2609	0.2544	0.3267

此外，在所有测试案例中都添加了如图2-18所示的外部扰动，以模拟阵风等对无人自行车平衡控制的影响。扰动力矩幅值为 0.2Nm，每隔 10 秒施加一次，每次持续时间为 2 秒，正负交替。仿真测试中的控制器频率均设定为 100Hz，反作用轮的控制力矩限制在 $[-0.5\mathrm{Nm}, 0.5\mathrm{Nm}]$。通过上述设置，共构成了 18 个仿真测试任务，用于本文后续平衡控制算法的评估。

由于本文后续章节重点关注的是无人自行车在路径跟随过程中的平衡控制性能，因此需要先测试 Stanley 算法在路径跟随控制中的效果。图2-19展示了在传统滑模平衡控制算法下，无人自行车在场景 1、参数 1 中的目标跟随路径及其运行的实际路径。从图2-19可以看出，在任务 1 和任务 2 中，无外部扰动时 Stanley 算法的路径跟踪误差小于 2mm，而在有外部扰动时，路径跟踪误差增加后迅速减小，表明所采用的 Stanley 算法能够有效跟随目标路径。本文所有仿真测试中的路径跟随控制均采用该算法，后文将不再对此进行赘述。

中国知网 https://www.cnki.net

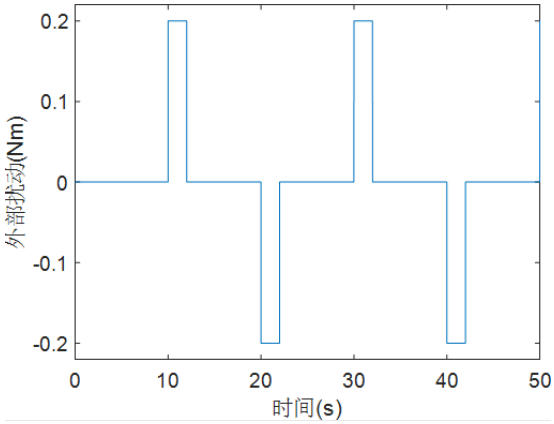


图 2-18 无人自行车的侧向扰动

Fig.2-18 Lateral disturbance of the unmanned bicycle

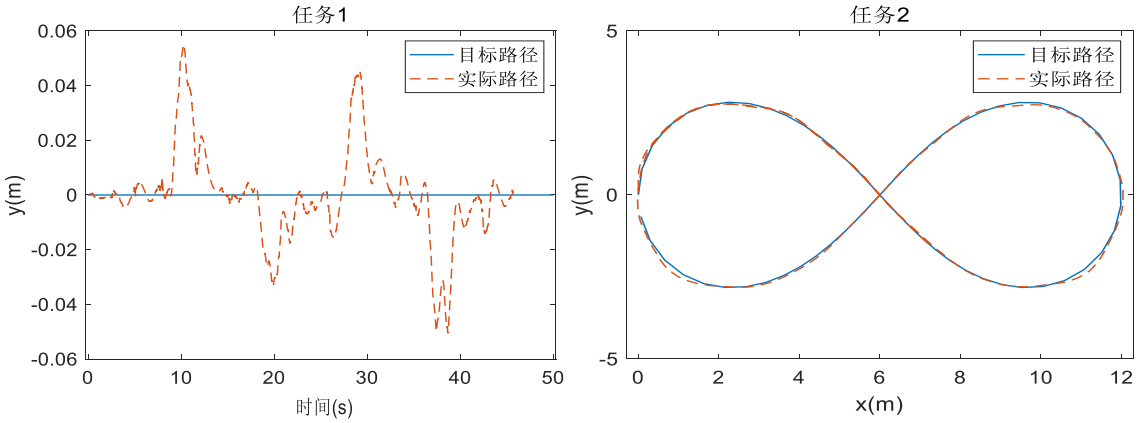


图 2-19 无人自行车的路径跟随控制

Fig.2-19 Path following control of the unmanned bicycle

2.4 基于离线强化学习的反作用轮无人自行车平衡控制

离线强化学习在反作用轮无人自行车的平衡控制中，主要面临训练环境与实际部署环境之间差异对控制性能的影响。域随机化方法通过在训练环境中引入大量随机化条件，以提升强化学习智能体的泛化能力。离线强化学习的优势在于其部署过程简便，在线计算需求较低，能够有效降低硬件负担和能耗。

本节首先概述本章所涉及的强化学习基本理论，包括强化学习问题的数学模型，以及离线强化学习与策略迁移的相关内容。接着，基于一种在性能和泛化能力上都较为优异的强化学习算法设计反作用轮无人自行车的平衡控制器，并作为后续章节中对比的基线。

2.4.1 强化学习问题的数学模型

在强化学习领域，通常用 s 表示状态，a 表示动作。为了与传统控制领域的符

中国知网 https://www.cnki.net

号保持一致，本文在后续的强化学习理论及反作用轮无人自行车平衡控制算法的理论推导中，用 $\boldsymbol{x}$ 替代 s 以表示系统状态，并用 u 替代 a 以表示控制策略的输出。

强化学习通过智能体与环境之间的持续交互，获取由状态和动作构成的数据样本，并基于这些数据样本不断优化策略，以实现累积奖励的最大化，其形式化描述如图2-20所示[52]。在智能体与环境交互的时间步 k，智能体依据环境的状态 $\boldsymbol{x}_k$，在策略 π 的指导下选择动作 u_k，通过执行该动作使环境从状态 $\boldsymbol{x}_k$ 转移至状态 $\boldsymbol{x}_{k+1}$，并向智能体反馈奖励信号 r_k。假设从时间步 $k=0$ 开始，执行 K 个时间步，则可以获得轨迹序列 $\tau=(\boldsymbol{x}_0,u_0,\boldsymbol{x}_1,u_1,\cdots,\boldsymbol{x}_K)$ 及其对应的回报序列 $r_0,r_1,r_2,\cdots,r_K$。在周期性交互的样本中，元组 $(\boldsymbol{x}_k,u_k,r_k,\boldsymbol{x}_{k+1})$ 构成了状态转移元组，表示从时间步 k 到 $k+1$ 的状态转移。以有限状态空间和有限动作空间为例，转移元组所形成的集合可以将强化学习问题抽象为马尔可夫决策过程：$\left(\mathcal{X},\mathcal{U},P^{u}_{\boldsymbol{x}\boldsymbol{x}'},R,\gamma,T\right)$，其中 $\mathcal{X}$ 表示状态集合，$\mathcal{U}$ 表示动作集合，状态转移概率 $P^{u}_{\boldsymbol{x}\boldsymbol{x}'}=P\left[\boldsymbol{x}'|\boldsymbol{x},u\right]$ 表示在状态 $\boldsymbol{x}$ 下采取动作 u 时转移到状态 $\boldsymbol{x}'$ 的概率，$R=\sum\gamma^k r_k$ 表示折扣累计回报，用于评估强化学习策略，r_k 为单步奖励，γ 为用于计算累积回报的折扣因子。可以看出，回报函数是对奖励的加权求和，且权重随着时间步的增加而逐渐衰减。此外，强化学习算法的应用通常要求被控对象满足以下假设：所涉及的被控系统具备马尔可夫性，即时刻 $k+1$ 的系统状态 $\boldsymbol{x}_{k+1}$ 仅由时刻 k 的状态 $\boldsymbol{x}_k$ 和动作 u_k 决定，而与其他历史时刻的状态和动作无关。

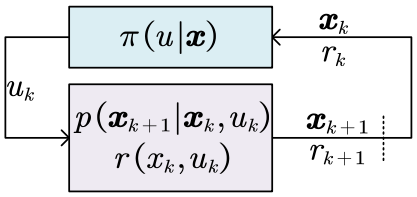


图 2-20 强化学习的形式化描述

Fig.2-20 A formal description of reinforcement learning

一般而言，由于环境通常具有一定的随机性，状态价值表示累积回报的期望值，如公式 (2-33)。强化学习的目标是寻找最优策略 $\pi(u|\boldsymbol{x})$，以最大化该期望值。

$$V_\pi(\boldsymbol{x})=E_\pi\left[\sum_{k=0}^{\infty}\gamma^k R_k(\boldsymbol{x})\right] \tag{2-33}$$

相应地，状态动作值函数的定义为，在状态 $\boldsymbol{x}$ 下，依据策略 π 采取动作 u 所能获得的累积回报的期望：

$$Q(\boldsymbol{x},u)=E\left[\sum_{k=0}^{\infty}\gamma^k R_k(\boldsymbol{x},u)\right] \tag{2-34}$$

中国知网 https://www.cnki.net

最优状态值函数 $V^*(\boldsymbol{x})$ 表示在所有策略中所能达到的最大值函数，而最优状态动作值函数 $Q^*(\boldsymbol{x},u)$ 则表示在所有策略中所能达到的最大状态动作值函数。根据相关定义，可以推导出最优状态值函数和最优状态动作值函数的贝尔曼方程：

$$\begin{aligned} V^*(\boldsymbol{x}) &= \max_u Q^*(\boldsymbol{x},u) \\ Q^*(\boldsymbol{x},u) &= R_{\boldsymbol{x}}^u + \gamma \sum P_{\boldsymbol{x}\boldsymbol{x}'|u} V^*(\boldsymbol{x}') \end{aligned} \tag{2-35}$$

因此，强化学习问题转化为基于交互采样数据的控制策略优化问题。

2.4.2 离线强化学习的策略迁移

在真实世界中，机器人策略交互的数据收集面临诸多限制，包括数据获取效率低下和安全性问题。因此，强化学习方法通常依赖于虚拟机器人模型进行训练。在模拟环境中，可以通过大规模生成样本数据和多样化的模拟场景来探索不同的决策空间。训练完成后，强化学习算法所获得的策略会被迁移至实际的机器人系统，这一过程被称为离线强化学习的策略迁移。

为了更有效地实现离线强化学习的策略迁移，通常需要克服模拟环境与真实环境之间的差异，这方面的研究被称为 Sim-to-Real[103]。Sim-to-Real 的主要方法包括系统辨识、域随机化[104] 和域自适应[105] 等。系统辨识旨在通过建立更为精确的环境模型来缩小模拟环境与真实环境之间的差距；域随机化则通过高度随机化的模拟来覆盖真实环境数据的分布；而域自适应方法则通过研究源域与目标域特征空间的统一，利用来自不同源域的数据来提升模型在目标域上的性能。相较于系统辨识和域自适应，域随机化是一种常用且实现相对简单的方法，它不需要额外的专业领域知识和精细的模型参数辨识。仅通过在训练过程中引入多样性和随机性，域随机化就能够帮助强化学习智能体适应不同的环境和条件，从而提高模型差异下控制策略的泛化能力。

设计离线强化学习的反作用轮无人自行车平衡控制，面临的另外一个问题是强化学习算法的选择。接下来对当前应用最广的强化学习 PPO 算法和 TD3 算法进行对比说明。从算法类型上区分，PPO 算法属于 On-policy 的强化学习算法，TD3 算法属于 Off-policy 的强化学习算法。On-policy 与 Off-policy 是根据行为策略与目标策略是否为同一个策略进行划分的。为便于对这两类算法的区别进行说明，介绍行为策略（Behavior Policy）和目标策略（Target Policy）的概念。行为策略是指用于与环境交互以生成数据的策略，即在训练过程中所做的决策；而目标策略则是在行为策略生成的数据基础上进行优化更新的策略。在强化学习的训练过程中，当行为策略与目标策略为同一策略时，该训练过程所涉及的强化学习方法被

中国知网 https://www.cnki.net

称为 On-policy 强化学习[106]；而当行为策略与目标策略不属于同一策略时，则称为 Off-policy 强化学习[107]。

一般而言，On-policy 强化学习算法的主要特征在于其行为策略与目标策略的一致性。这一特性确保了在更新过程中所使用的数据与当前策略之间存在紧密的关联，从而有助于减少策略评估的偏差，并提升强化学习策略的泛化能力，因此更适合于离线强化学习中的策略迁移。然而，由于 On-policy 算法通常需要舍弃与旧策略相关的历史数据，这可能导致其数据的有效利用率低于 Off-policy 方法。相对而言，Off-policy 方法允许行为策略与目标策略存在差异，这意味着可以利用一个策略生成的交互数据来更新另一个策略。尽管某些 Off-policy 算法可能因策略差异而面临更大的方差和收敛速度问题，但通过将历史交互数据存储在经验池（replay buffer）中，Off-policy 算法能够重复利用这些数据，从而提高样本效率，因此通常更适用于需要高效利用数据的在线强化学习场景。

2.4.3 基于近端策略优化算法的无人自行车平衡控制

近端策略优化算法（PPO）是对策略梯度算法的一种改进，属于 On-policy 算法。该算法在实现过程中结合了演员-评论家（Actor-Critic）算法框架，以对状态值进行估计。PPO 算法的核心在于采用了广义优势估计（GAE)[108] 和信任域（Trust Region)[109] 方法，从而增强了算法的适应性和训练的稳定性，使其成为当前最先进且应用最广泛的强化学习算法之一。自 2017 年由 OpenAI 提出以来，PPO 算法已被广泛应用于解决各种控制问题和智能博弈任务，并被 OpenAI 称为强化学习应用的首选算法。

（1）广义优势估计与信任域方法

广义优势估计（GAE）是一种在强化学习领域中被广泛应用的回报估计技术。其主要目标是近似计算策略梯度和优势函数，以支持强化学习智能体的训练过程。在强化学习的框架下，GAE 旨在为每个状态-动作对估算优势函数，该函数用于评估某一特定动作相对于当前策略的优劣。通过对优势函数的有效估计，可以获得更为精确的策略梯度估计，从而提升训练效果。GAE 的引入有助于降低样本中的随机性和噪声影响，使得策略梯度的估计更加稳定和准确。具体而言，GAE 通过将未来奖励的折现值与当前奖励的价值进行比较，计算出一个差异值，即广义优势估计。该差异值可用于更新策略梯度以及计算价值函数的损失。

考虑 K 个单步估计量加权的 GAE 广义优势估计 $\hat{A}_k$，见公式 (2-36)：

$$\begin{aligned} \delta_k &= r_k + \gamma V_\pi\left(\boldsymbol{x}_{k+1}\right) - V_\pi\left(\boldsymbol{x}_k\right) \\ \hat{A}_k &= \delta_k + (\gamma\lambda)\,\delta_{k+1} + (\gamma\lambda)^2\,\delta_{k+2} + \cdots + (\gamma\lambda)^{K-k+1}\,\delta_{K-1} \end{aligned} \tag{2-36}$$

中国知网 https://www.cnki.net

式中　　δ_k———单步时序差分（无量纲变量）；

$\lambda \in [0,1]$———GAE 光滑因子（无量纲常数）。

信任域（Trust Region）是一种常见的优化算法，旨在确保策略更新的稳定性与收敛性。信任域方法的核心目标是限制策略更新的幅度，以确保每次迭代中的策略改进均在一个可信的范围内进行。该可信范围被称为信任域。通过设定信任域的约束，可以有效防止策略的剧烈变化，从而避免在训练过程中出现不稳定或不可预测的情况。

以 PPO 算法为例，其信任域通过引入一个额外的损失函数项来实现。该损失函数项由 KL 散度[110] 对当前策略与旧策略之间的差异进行评估。通过最小化这一额外的损失函数，并依据信任域的约束来确定策略更新的步长，避免过大的策略变动。这种方式有助于实现策略的平滑调整和渐进更新，从而提升训练的稳定性与收敛性。信任域的更新目标是最大化式 (2-37) 的值。

$$L^{CLIP}(\theta)=\hat{\mathbb{E}}_t\left[-min\left(\frac{\pi_\theta(u_k|\boldsymbol{x}_k)}{\pi_{\theta old}(u_k|\boldsymbol{x}_k)}\hat{A}_k, clip\left(\frac{\pi_\theta(u_k|\boldsymbol{x}_k)}{\pi_{\theta old}(u_k|\boldsymbol{x}_k)}, 1-\varepsilon, 1+\varepsilon\right)\hat{A}_k\right)\right] \tag{2-37}$$

式中　$\pi_{\theta old}(u_k|\boldsymbol{x}_k)$———旧策略及状态 $\boldsymbol{x}_k$ 下选动作 u_k 的概率（无量纲变量）；

ε———单次参数更新幅度的限制（无量纲常数）。

（2）域随机化训练环境

为了得到离线 PPO 算法的无人自行车平衡控制器，需要利用反作用轮无人自行车反馈线性化后的离散形式生成域随机化环境对智能体进行训练。

经过反馈线性化处理后，反作用轮无人自行车的横滚角跟踪误差模型公式 (2-27) 可表示为如下状态空间方程：

$$\begin{aligned}\dot{\boldsymbol{x}} &= A_c\boldsymbol{x}+B_cu\\ y &= C_c\boldsymbol{x}\end{aligned} \tag{2-38}$$

其中，状态向量 $\boldsymbol{x}$，矩阵 A_c、B_c 和 C_c 分别为：

$$\boldsymbol{x}=\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix},\quad A_c=\begin{bmatrix}0&1&0\\0&0&1\\0&0&0\end{bmatrix},\quad B_c=\begin{bmatrix}0\\0\\1\end{bmatrix},\quad C_c=\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}$$

以时间间隔 T_s 对上述方程进行离散化处理，可以得到：

$$\boldsymbol{x}(k+1)=A_d\boldsymbol{x}(k)+B_du(k) \tag{2-39}$$

域随机化是指在训练过程中对环境的动态过程添加随机化因素，以使得所训练的策略能够有效覆盖现实环境与模拟环境之间的差距，从而降低认知不确定性

中国知网　https://www.cnki.net

和随机性对策略迁移的影响，使得训练得到的智能体能够直接应用于现实环境。本文采用公式 (2-40) 作为强化学习智能体的域随机化训练环境：

$$\boldsymbol{x}(k+1)=A_d\boldsymbol{x}(k)+B_du(k)+D(k) \tag{2-40}$$

其中，$D(k)=\left[d_{r1}\ d_{r2}\ d_{r3}\right]^{\mathrm{T}}$，$d_{ri}\sim\mathcal{N}\left(0,\sigma_i^2\right)$，$i=1,2,3$。

（3）PPO 算法智能体及其训练步骤

以下首先对 PPO 算法的奖励函数、策略网络（Actor Net.）和评价网络（Critic Net.）进行介绍，随后给出 PPO 算法的主要步骤。

反作用轮无人自行车平衡控制问题的强化学习奖励函数设计如公式 (2-41) 所示，其目的在于使状态量和控制器输出 $\bar{X}(k)=[x_1(k),x_2(k),x_3(k),u(k)]^{\mathrm{T}}$ 趋近于零，即使得自行车横滚角趋于平衡点。

$$r(k)=\begin{cases}0 & r(k)<0,\\ 1-\bar{X}(k)^{\mathrm{T}}\phi\bar{X}(k) & 0<r(k)<1\\ 1 & r(k)>1\end{cases} \tag{2-41}$$

式中 $\phi=\mathrm{diag}(a_1,a_2,a_3,a_4)$，$a_i>0$（$i=1,2,3,4$）———权重因子（无量纲常数）。

Actor Net. 的构建如图2-21所示，策略的输出 $u\sim N\left(m(x,\theta_1),\sigma^2(x,\theta_2)\right)$，其中 θ_1 表示策略网络均值部分神经网络的权值和偏差；θ_2 表示策略网络方差部分神经网络的权值和偏差。定义 $\theta=[\theta_1,\theta_2]^{\mathrm{T}}$ 为策略网络中所有可学习参数的集合。Actor Net 的功能是将状态 $\boldsymbol{x}(k)$ 映射至输出动作 $u(k)$，可简化表示为 $u(k)\sim\pi_\theta(\boldsymbol{x}(k))$。图2-21中 Fully Connected (i) 表示具有 i 个神经元的全连接层网络，Relu、Tanh 和 Softplus 表示非线性激活函数。

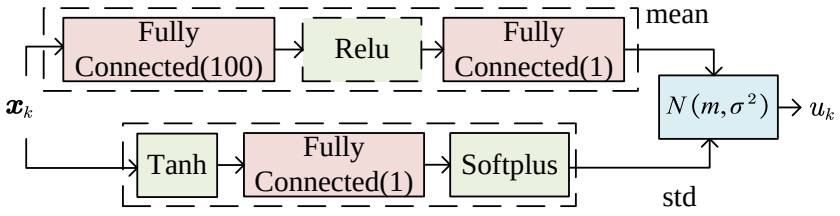


图 2-21 PPO 算法中的 Actor Net.

Fig. 2-21 Actor Net. in PPO algorithm

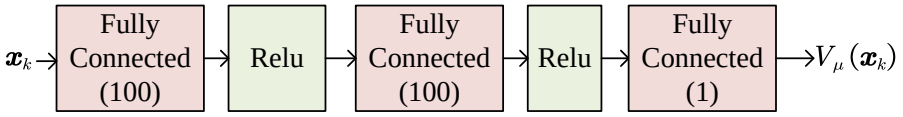


图 2-22 PPO 算法中的 Critic Net.

Fig. 2-22 Critic Net. in PPO algorithm

中国知网 https://www.cnki.net

Critic Net. 是基于神经网络的状态值函数逼近器，其作用是将状态 $\boldsymbol{x}(k)$ 映射到标量值 $V_\mu(\boldsymbol{x}(k))$，其中 μ 代表该神经网络中可学习的参数。该标量值 $V_\mu(\boldsymbol{x}(k))$ 反映了智能体在特定状态下对后续状态轨迹的累积回报的期望值。本文所构建的 PPO 算法中，Critic Net 如图2-22所示。

PPO 算法流程如图2-23所示，相关的伪代码见表2-5，主要包括三个步骤：

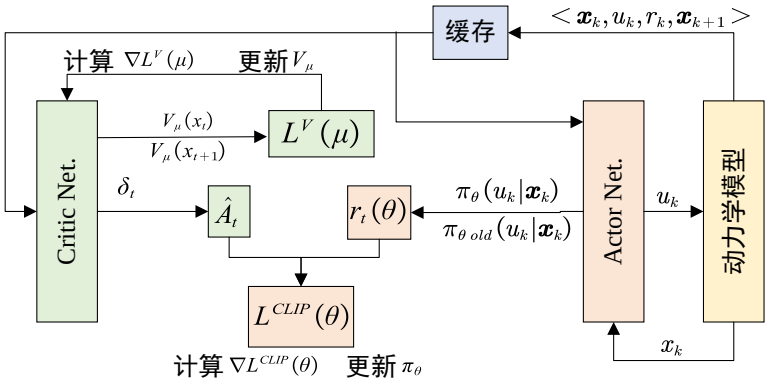


图 2-23 PPO 算法

Fig.2-23 PPO algorithm

第一步，采集反作用轮无人自行车的原始状态 $\boldsymbol{q}_k$，通过公式 (2-22) 得到状态 $\boldsymbol{x}_k$。利用 Actor Net. 生成动作 $u(k) \sim \pi_\theta(\boldsymbol{x}(k))$，然后通过公式 (2-25) 计算出控制器的实际输出 τ。通过域随机化环境对反作用轮无人自行车的状态进行递推。将 $\Omega_t = \{\boldsymbol{x}_t, u_t, r_{t+1}, \boldsymbol{x}_{t+1}\}$ 作为一个元组进行存储，并计算单步奖励值 $r(k)$。

第二步，基于 N 个时间步的交互，构建序列 $\Omega = \{\Omega_k, \Omega_{k+1}, \ldots, \Omega_{k+N}\}$。通过公式 (2-36) 计算时序差分误差（TD-error）及广义优势估计（GAE），其中 γ 和 λ 均取 0.95。最小化损失函数 L^V 对 Critic Net. 中的 μ 进行更新，见公式 (2-42)：

$$\begin{aligned} L^V(\mu) &= \frac{1}{M}\sum_{i=1}^{M} {A_i}^2 \\ \mu' &= \mu - \eta_\mu \nabla L^V(\mu) \end{aligned} \tag{2-42}$$

式中 η_μ———Critic 网络的学习率，本文取 0.001（无量纲常数）；

μ'———更新后的 Critic Net. 参数（无量纲变量）。

第三步，通过最小化 L^{CLIP} 更新 Actor Net. 的参数 θ，见公式 (2-43)：

$$\begin{aligned} L^{CLIP}(\theta) = \frac{1}{M}\sum_{k=1}^{M}\Bigg[& -\min\left(\frac{\pi_\theta(u_k|\boldsymbol{x}_k)}{\pi_{\theta old}(u_k|\boldsymbol{x}_k)}\hat{A}_k, clip\left(\frac{\pi_\theta(u_k|\boldsymbol{x}_k)}{\pi_{\theta old}(u_k|\boldsymbol{x}_k)}, 1-\varepsilon, 1+\varepsilon\right)\hat{A}_k\right) \\ & +\omega H(\theta, \boldsymbol{x}_k) \Bigg] \\ H(\theta, \boldsymbol{x}_k) &= \frac{1}{2}\ln\left(2\pi \cdot e \cdot {\sigma_k}^2\right) \\ \theta' &= \theta - \eta_\theta \nabla L^{CLIP}(\theta) \end{aligned} \tag{2-43}$$

中国知网 https://www.cnki.net

其中，$H(\theta, \boldsymbol{x}_k)$ 表示策略熵，用于鼓励智能体的探索行为；$\pi_{\theta old}(u_k|\boldsymbol{x}_k)$ 为参数 θ 更新前在状态 $\boldsymbol{x}_k$ 下选择动作 u_k 的概率；$\pi_\theta(u_k|\boldsymbol{x}_k)$ 为参数 θ 更新后在状态 $\boldsymbol{x}_k$ 下选择动作 u_k 的概率；θ' 为更新后的 Actor Net. 参数。

在反作用轮无人自行车的平衡控制中，PPO 算法的主要超参数及其设置如下，$\varepsilon = 0.2$ 为单次参数更新幅度的限制；$\omega = 0.02$ 为熵损失项的系数；$\eta_\theta = 0.001$ 为 Actor Net. 的学习率；$M = 3$ 为更新频率。

表 2-5 PPO 算法伪代码

Table2-5 Pseudo code of PPO algorithm

PPO 算法
初始化 Actor Net 的参数 θ 和 Critic Net 的参数 μ 循环： 　循环 $k = 1, 2, \cdots, M$ 　　在域随机化环境中利用策略 $\pi_{\theta old}$ 交互 N 个时间步 　　计算 GAE，$\hat{A}_{k+1}$，$\hat{A}_{k+2}$，$\cdots$，$\hat{A}_{k+N}$ 　　最小化损失函数 L^{CLIP}，$\theta_{old} \leftarrow \theta$ 　直到横滚角大于 0.5rad 或达到最大时间步数 直到达到最大更新次数或者收敛条件，终止循环

2.5 离线强化学习无人自行车平衡控制仿真测试

本节首先对基于 PPO 算法的无人自行车平衡控制智能体在域随机化环境中进行训练，训练结果如图2-24所示。图中蓝线表示累积奖励随训练局次的变化，红线则为以长度为 100 的滑动窗口计算的累积奖励平均值。可以看到该训练在 3000 局后达到最大奖励。

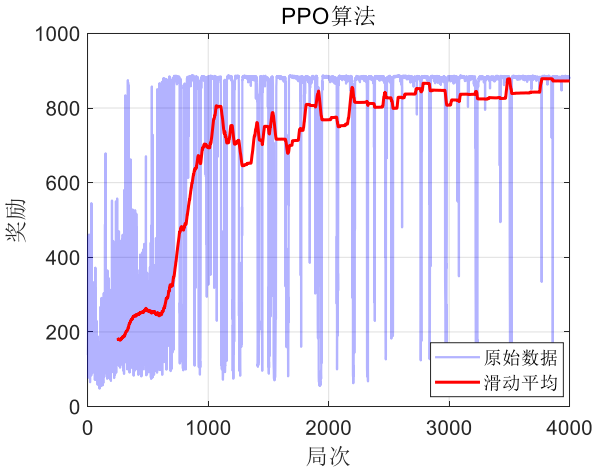
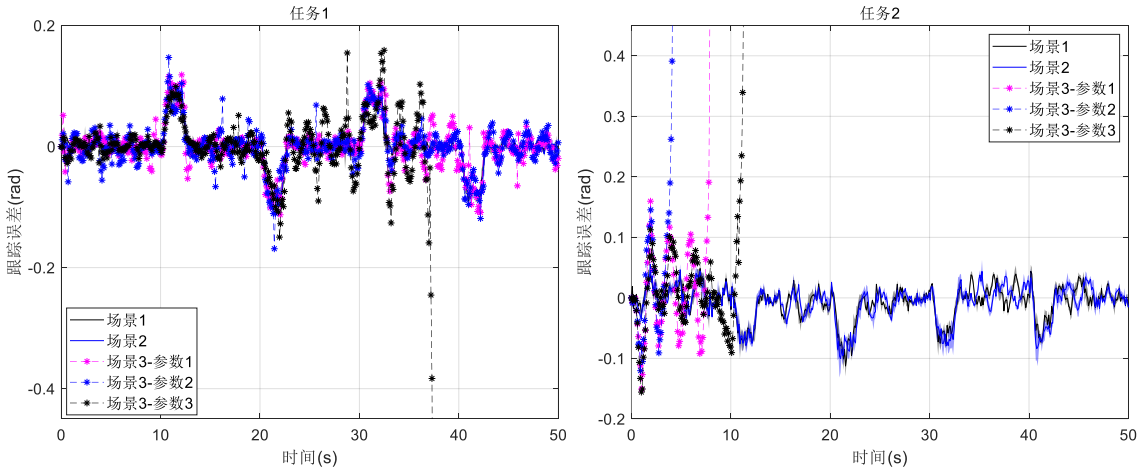


图 2-24 PPO 算法的训练过程

Fig.2-24 Training process of PPO algorithm

中国知网 https://www.cnki.net

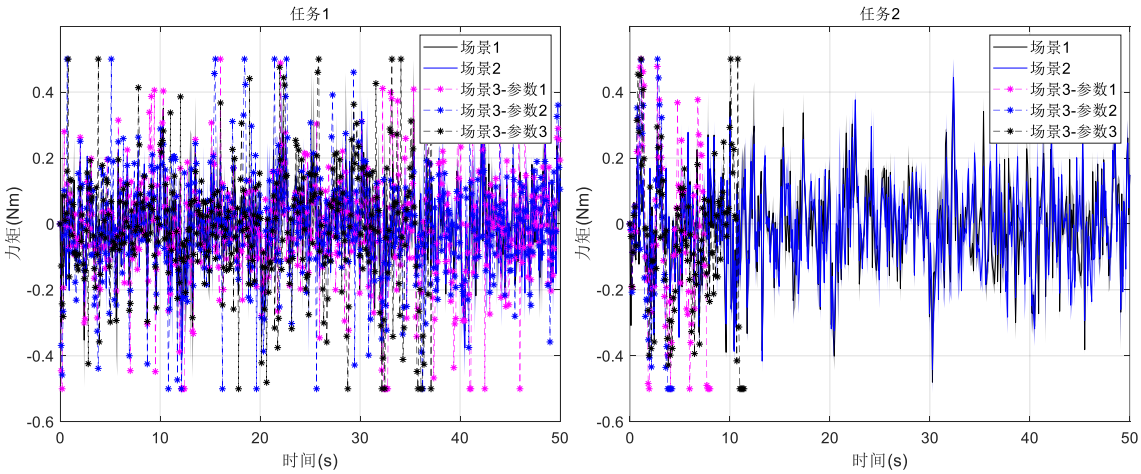
随后，在仿真环境中对上述训练得到的强化学习智能体进行测试。仿真测试任务中反作用轮无人自行车的横滚角如图2-25所示，反作用轮控制力矩如图2-26所示。对于不同参数下均能完成仿真测试任务的情况，图2-25中用实线代表三个参数下的测试结果的均值，而半透明区域则表示相应任务和场景下跟踪误差的标准差。对于不同参数下未完成仿真测试任务的情况，则直接绘制其对应的横滚角跟踪误差曲线。



(a) (b)

图 2-25 PPO 算法测试的跟踪误差

Fig. 2-25 Tracking error of PPO algorithm test



(a) (b)

图 2-26 PPO 算法测试的输出力矩

Fig. 2-26 Output torque of PPO algorithm test

仿真测试的完成情况见表2-6，从中可以观察到 18 个仿真测试任务已成功完成了 14 个，显示出良好的控制效果。未能完成的仿真测试任务主要集中在场景 3，即地形高度系数 $K_1 = 0.2$，后轮转速为 $v_r = 20\text{rad/s}$。从仿真完成情况，可以看出

中国知网 https://www.cnki.net

本章所设计的离线强化学习平衡控制器在应对所设定的仿真测试任务时存在一定的提升空间。

表 2-6 仿真测试完成情况 (秒)
Table2-6 Simulation test completion status(s)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1	-	-	-	-	-	-	-	-	37.36
2	-	-	-	-	-	-	7.98	4.15	11.32

横滚角跟踪误差的最大值见表2-7，平均值为 0.117rad。横滚角跟踪误差的均方值见表2-8，平均值为 $1.02 \times 10^{-3}\text{rad}^2$。控制力矩绝对值的累加见表2-9，平均值为 $5.59 \times 10^{2}\text{Nm}$。

在本文后续的反作用轮无人自行车平衡控制算法的比较中，将继续采用仿真完成情况、横滚角跟踪误差的最大值、横滚角跟踪误差的均方值以及控制力矩绝对值的累加作为评估指标，用于衡量不同算法在反作用轮无人自行车平衡控制中的性能。

表 2-7 跟踪误差最大值 (10^{-1}rad)
Table2-7 Simulation test completion status(s)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1	1.12	1.01	1.00	1.14	1.09	1.11	1.31	1.47	-
2	1.25	1.22	0.96	1.20	1.31	1.14	-	-	-

表 2-8 跟踪误差的均方值 (10^{-3}rad^2)
Table2-8 Simulation test completion status(s)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1	0.998	1.00	0.911	1.00	1.00	0.881	1.40	1.30	-
2	0.917	0.904	0.832	1.100	1.100	0.943	-	-	-

表 2-9 控制力矩绝对值的累加 (10^{2}Nm)
Table2-9 Simulation test completion status(s)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1	5.12	5.29	4.93	5.01	5.37	4.71	6.52	6.85	-
2	5.69	5.88	5.43	5.72	6.23	5.44	-	-	-

中国知网 https://www.cnki.net

2.6 本章小结

本章研制了反作用轮无人自行车样机，推导了横滚角跟踪误差模型。设计了18个仿真测试任务，构建了离线强化学习的域随机化训练环境，建立了基于近端策略优化算法的离线强化学习无人自行车平衡控制算法。对离线强化学习平衡控制算法在反作用轮无人自行车仿真中的表现进行了测试，仿真测试中，该策略成功完成了18个仿真测试任务中的14个，表明本文设计的离线强化学习反作用轮无人自行车平衡控制器具有一定的抗扰及应对系统不确定性的能力。同时，计算了相关的评估指标。本章为后续研究奠定了基础，并提供了控制算法比较的基准。

中国知网 https://www.cnki.net

第 3 章 基于串并联在线强化学习的无人自行车自平衡滑模控制

3.1 引言

第二章设计了基于策略迁移的离线强化学习反作用轮无人自行车平衡控制算法。尽管该算法在仿真测试中展现出一定的抗干扰能力和对系统不确定性的鲁棒性，但由于其缺乏在线学习能力，不能很好地应对崎岖路面与系统不确定性的影响，因此其仅完成了部分仿真测试任务。本章提出基于串并联在线强化学习的无人自行车自平衡滑模控制算法，旨在赋予平衡控制器在线学习能力，增强平衡控制器的鲁棒性并提升其平衡控制性能。

由于反作用轮无人自行车存在横向不稳定性，并且强化学习通常需要大量的交互数据才能有效地进行训练，因此必须为强化学习在反作用轮无人自行车平衡控制中的在线应用提供一个初始可用的控制器。考虑到滑模控制具有结构简单和鲁棒性强等优点，本章对在线强化学习与滑模控制相结合的反作用轮无人自行车平衡控制进行研究。

尽管已有研究考虑过在线强化学习与传统控制的结合，包括：1）强化学习在线调整传统控制器参数，本文称之为强化学习与传统控制的串联；2）强化学习对传统控制器输出进行补偿，本文称之为强化学习与传统控制的并联。然而，目前对同时考虑在线调参和在线补偿的研究相对匮乏，且现有研究鲜有关注在线强化学习与滑模控制结合在反作用轮无人自行车平衡控制中的应用。

3.2 反作用轮无人自行车自平衡滑模控制

滑模变结构控制作为一种经典的鲁棒控制算法，经过数十年的研究与发展，已成为控制领域的重要分支之一。滑模控制的主要特征在于能够使系统在特定条件下沿预定状态轨迹进行小幅度、高频的上下运动，这一现象被称为滑模运动。该模态与系统的参数及外部扰动无关，从而使得处于滑模运动的系统展现出良好的鲁棒性。

本节首先构建基于终端滑模控制的反作用轮无人自行车平衡控制器。同时，考虑到滑模控制的不变性仅适用于匹配不确定性[111]；而本研究中反作用轮无人自行车系统模型 (2-27) 的不确定性和扰动并不符合滑模控制所要求的匹配条件。因此，本节进一步设计了高阶滑模观测器进行扰动补偿，用于本章后续与强化学习在线

中国知网 https://www.cnki.net

补偿算法进行比较。此外，本节还将引入近期自适应滑模控制（Adaptive Global Fast Terminal Sliding-Mode Control, ATSMC）的相关研究成果[31]，以便于本章后续与强化学习在线调节滑模控制器参数进行比较。

（1）终端滑模平衡控制

本节设计基于全局快速终端滑模控制（Global Fast Terminal Sliding-Mode Control, TSMC）的反作用轮无人自行车的平衡控制器。全局快速终端滑模控制不同于传统的滑模控制技术，其结合了线性滑模控制的快速性与快速终端滑模控制的优势。通过在滑模超平面的设计中引入非线性函数，例如 $s = \dot{x} + \alpha x + \beta x^{q/p} = 0$，其中 $x \in R^1$ 为状态变量，α 和 $\beta > 0$，p 与 q（$p > q$）为正奇数，这一设计确保了系统在远离零点时能够保持线性滑模的快速性，而在接近平衡状态时则由快速终端吸引子决定其收敛速度，从而实现系统状态的快速收敛。此外，全局快速终端滑模控制律为连续形式，有助于消除传统滑模控制中的抖振现象。

构建反作用轮无人自行车系统的快速滑动模态表示为[112,113]：

$$\begin{aligned} s_0 &= x_1 \\ s_1 &= \dot{s}_0 + \alpha_0 s_0 + \beta_0 {s_0}^{q_0/p_0} \\ s_2 &= \dot{s}_1 + \alpha_1 s_1 + \beta_1 {s_1}^{q_1/p_1} \end{aligned} \tag{3-1}$$

式中 $\alpha_i > 0, \beta_i > 0 (i = 0, 1)$———滑模面系数（无量纲）；

$q_i < p_i$ 为正奇数 $(i = 0, 1)$———滑模阶数（无量纲）；

在公式 (3-1) 中，为确保 $s_i^{q_i/p_i}$ 在实数域内有意义，公式 (3-1) 及后文中分数次幂表达式都可以替换为 $\text{sign}(s_i)|s_i|^{q_i/p_i}$，sign 为符号函数。

根据文献 [114]，等效控制律 u_{eq} 和趋近控制律 u_r 设计如下，

$$\begin{aligned} u_{eq} &= \alpha_0 \ddot{s}_0 + \beta_0 \frac{d^2}{dt^2} s_0^{q_0/p_0} + \alpha_1 \dot{s}_1 + \beta_1 \frac{d}{dt} s_1^{q_1/p_1} \\ u_r &= \varphi s_2 + \vartheta s_2^{q_2/p_2} \end{aligned} \tag{3-2}$$

式中 $\varphi > 0$，$\vartheta > 0$———趋近律参数（无量纲）；

$q_2 < p_2$，为正奇数———滑模阶数（无量纲）；

终端滑模控制器的输出为，

$$u_{tsmc} = -\left(u_{eq} + u_r\right) \tag{3-3}$$

接下来，对 TSMC 的稳定性进行分析。根据公式 (3-1)，可得：

$$\dot{s}_2 = \dddot{s}_0 + \alpha_0 \ddot{s}_0 + \beta_0 \frac{d^2}{dt^2} s_0^{q_0/p_0} + \alpha_1 \dot{s}_1 + \beta_1 \frac{d}{dt} s_1^{q_1/p_1} \tag{3-4}$$

中国知网 https://www.cnki.net

将控制律式 (3-2) 代入上式得，

$$\dot{s}_2 = -\varphi s_2 - \vartheta s_2^{q_2/p_2} \tag{3-5}$$

基于李雅普诺夫稳定性定理，定义李雅普诺夫函数 $L_V = \frac{1}{2}s_2^2$，可得

$$\dot{L}_V = s_2\dot{s}_2 = -\varphi s_2^2 - \vartheta \left|s_2\right|^{(p_2+q_2)/p_2} \tag{3-6}$$

所以 $\dot{L}_V \leq 0$，系统稳定。当 $\dot{L}_V \equiv 0$ 时，$s_2 \equiv 0$，根据 Lasalle 不变性原理，$t \to \infty$ 时，$s_2 \to 0$。

（2）带有观测器的终端滑模平衡控制

目前，基于滑模控制器的非匹配不确定性处理方法主要可分为三类。第一类方法基于经典控制设计工具，如 Riccati 方法、LMI 方法和自适应方法，对含有非匹配不确定性的系统进行稳定性分析。这类方法通常要求非匹配不确定性满足范数有界的条件，然而这一假设在许多实际工程应用中并不适用[115,116]。第二类方法是积分滑模控制，通过高频切换增益迫使系统状态到达积分滑模面，并趋向目标平衡点。与第一类方法相比，积分滑模控制方法更为简洁和实用，并在一些包含非匹配不确定性的系统控制中取得了良好的效果。然而，积分滑模控制也不可避免地给系统带来了不利影响，如过大的超调量和较长的上升时间[117,118]。第三类方法则是将滑模控制与扰动观测相结合，该方法不仅适用于匹配不确定性的处理，也在非匹配不确定性处理中得到了广泛研究[119,120]。此外，由于第一类和第二类方法在处理非匹配不确定性时往往以牺牲系统控制性能为代价，因此第三类方法在相关研究中表现出了更好的控制性能[121]。

本节采用高阶滑模观测器，通过反馈机制对系统状态及扰动进行观测。高阶滑模观测器的设计不依赖于生成扰动的具体数学模型，也无需对其作用进行直接测量。基于前文推导的无人自行车横滚角误差模型以及相关文献[121,122]，设计了公式 (3-7) 的高阶滑模观测器以估计非匹配扰动 d_1'，并结合其估计值 $\hat{d}_1'$ 构建终端滑模控制器。下文中将该算法称为 OTSMC。

定义 $\Phi(t) = x_1(t) - x_1(0) - \int_0^t x_2(s)\,ds$，构建高阶滑模观测器 (Higher Order Sliding Mode Observer，HOSMO) 如下，

$$\begin{cases} \dot{\eta}_0 = -k_1 L^{\frac{1}{5}} \left|\eta_0 - \Phi\right|^{\frac{4}{5}} sign\left(\eta_0 - \Phi\right) + \eta_1 \\ \dot{\eta}_1 = -k_2 L^{\frac{2}{5}} \left|\eta_0 - \Phi\right|^{\frac{3}{5}} sign\left(\eta_0 - \Phi\right) + \eta_2 \\ \dot{\eta}_2 = -k_3 L^{\frac{3}{5}} \left|\eta_0 - \Phi\right|^{\frac{2}{5}} sign\left(\eta_0 - \Phi\right) + \eta_3 \\ \dot{\eta}_3 = -k_4 L^{\frac{4}{5}} \left|\eta_0 - \Phi\right|^{\frac{1}{5}} sign\left(\eta_0 - \Phi\right) + \eta_4 \\ \dot{\eta}_4 = -k_5 L sign\left(\eta_0 - \Phi\right) \end{cases} \tag{3-7}$$

中国知网 https://www.cnki.net

由前文中反作用无人自行车动力学模型推导及假设 5 可知，$L > L_4$。则存在 $T(\eta_0(0) - \Phi(0)) > 0$，使得 $\forall t \geq T$ 时，$\eta_0 \equiv \Phi, \eta_1 \equiv d_1', \eta_2 \equiv \dot{d}_1', \eta_3 \equiv \ddot{d}_1'$。

取 $\hat{d}_1' = \eta_1$，$\hat{\dot{d}}_1' = \eta_2$，$\hat{\ddot{d}}_1' = \eta_3$，设计具有递归结构的快速滑动模态表示为：

$$\begin{aligned} s_0 &= x_1 \\ s_1 &= \hat{s}_0 + \alpha_0 s_0 + \beta_0 s_0^{q_0/p_0} \\ s_2 &= \hat{\dot{s}}_1 + \alpha_1 s_1 + \beta_1 s_1^{q_1/p_1} \end{aligned} \tag{3-8}$$

设计其控制律为：

$$\begin{aligned} u_{oeq} &= \alpha_0 \hat{\dot{s}}_0 + \beta_0 \frac{d^2}{dt^2} s_0^{q_0/p_0} + \alpha_1 \hat{\dot{s}}_1 + \beta_1 \frac{d}{dt} s_1^{q_1/p_1} \\ u_{or} &= \varphi s_2 + \vartheta s_2^{q_2/p_2} \\ u_{otsmc} &= -\left(u_{oeq} + u_{or}\right) - \hat{\ddot{d}}_1' \end{aligned} \tag{3-9}$$

对其稳定性进行分析，

$$\dot{s}_2 = \hat{\ddot{s}}_0 + \alpha_0 \hat{\dot{s}}_0 + \beta_0 \frac{d^2}{dt^2} s_0^{q_0/p_0} + \alpha_1 \hat{\dot{s}}_1 + \beta_1 \frac{d}{dt} s_1^{q_1/p_1} \tag{3-10}$$

将公式 (3-9) 代入上式可得，

$$\dot{s}_2 = u_{otsmc} + \ddot{d}_1' + d_2' + \alpha_0 \ddot{s}_0 + \beta_0 \frac{d^2}{dt^2} s_0^{q_0/p_0} + \alpha_1 \dot{s}_1 + \beta_1 \frac{d}{dt} s_1^{q_1/p_1} \tag{3-11}$$

进一步化简可得，

$$\dot{s}_2 = -\varphi s_2 - \vartheta s_2^{q_2/p_2} + d_2' = -\varphi s_2 - \left(\vartheta - \frac{d_2'}{s_2^{q_2/p_2}}\right) s_2^{q_2/p_2} = -\varphi s_2 - \vartheta' s_2^{q_2/p_2} \tag{3-12}$$

其中，$\vartheta' = \vartheta - \frac{d_2'}{s_2^{q_2/p_2}}$。由假设 5 可知，$L_5 > \left|d_2'\right|$。

基于李雅普诺夫稳定性定理，定义李雅普诺夫函数 $L_V = \frac{1}{2} s_2^2$，由 $\vartheta > \frac{L_4}{\left|s_2^{q_2/p_2}\right|}$ 可得 $\vartheta' > 0$，则

$$\dot{L}_V = s_2 \dot{s}_2 = -\varphi s_2^2 - \vartheta' s_2^{(p_2+q_2)/p_2} \tag{3-13}$$

公式 (3-13) 的证明与公式 (3-6) 相同。

（3）自适应终端滑模平衡控制

自适应终端滑模控制是终端滑模控制与自适应控制的有机结合，其核心理念是在传统滑模控制过程中引入自适应律，通过系统的响应特性构建滑模函数，从而提升系统的鲁棒性和跟踪性能。与传统滑模控制相比，自适应滑模控制通常表现出更优异的控制性能。下文中将构建的自适应终端滑模平衡控制记为 ATSMC。

参考文献 [31, 123]，给出自适应趋近控制律如公式 (3-14) 所示，

中国知网 https://www.cnki.net

$$u_{ar} = (\gamma_0 + \gamma_1 |s_1| + \gamma_2 |\dot{s}_1|)\, sign(s_2) + \varepsilon |s_1|^a\, sign(s_2) + k |s_2|^{b \cdot sign(|s_2|-1)}\, s_2 \quad (3\text{-}14)$$

式中 $\varepsilon > 0$，$k > 0$，$0 < a < 1$，$0 < b < 1$———趋近控制律参数（无量纲）；

$\xi > 0$，$\eta_0 > 0$，$\eta_1 > 0$，$\eta_2 > 0$———自适应律参数（无量纲）；

其中，γ_0，γ_1，γ_2 由公式 (3-15) 自适应律进行更新，

$$\dot{\gamma}_0 = \begin{cases} \eta_0 |s_2|, |s_2| > \xi \\ 0, |s_2| \leqslant \xi \end{cases}, \dot{\gamma}_1 = \begin{cases} \eta_1 |s_1| |s_2|, |s_2| > \xi \\ 0, |s_2| \leqslant \xi \end{cases}, \dot{\gamma}_2 = \begin{cases} \eta_2 |\dot{s}_1| |s_2|, |s_2| > \xi \\ 0, |s_2| \leqslant \xi \end{cases} \quad (3\text{-}15)$$

因此，ATSMC 的控制律为：

$$u_{atsmc} = -\left(u_{eq} + u_{ar}\right) \quad (3\text{-}16)$$

接下来，对 ATSMC 的稳定性进行分析：

假设存在三个正数 $\bar{\gamma}_i$，使得 $\gamma_i < \bar{\gamma}_i\ (i = 0, 1, 2)$，定义李雅普诺夫函数为，

$$L_V = \frac{1}{2} s_2^2 + \frac{1}{2} \mu_0 (\gamma_0 - \bar{\gamma}_0)^2 + \frac{1}{2} \mu_1 (\gamma_1 - \bar{\gamma}_1)^2 + \frac{1}{2} \mu_2 (\gamma_2 - \bar{\gamma}_2)^2 \quad (3\text{-}17)$$

则可得，

$$\dot{L}_V = -s_2 u_r + \mu_0 (\gamma_0 - \bar{\gamma}_0) \dot{\gamma}_0 + \mu_1 (\gamma_1 - \bar{\gamma}_1) \dot{\gamma}_1 + \mu_2 (\gamma_2 - \bar{\gamma}_2) \dot{\gamma}_2 \quad (3\text{-}18)$$

将公式 (3-15) 代入可得，

$$\begin{aligned} \dot{L}_V = & -s_2 \left[(\gamma_0 + \gamma_1 |s_1| + \gamma_2 |\dot{s}_1|)\, sign(s_2) + \varepsilon |s_1|^a\, sign(s_2) + k |s_2|^{b \cdot sign(|s_2|-1)}\, s_2\right] + \\ & \mu_0 (\gamma_0 - \bar{\gamma}_0) \dot{\gamma}_0 + \mu_1 (\gamma_1 - \bar{\gamma}_1) \dot{\gamma}_1 + \mu_2 (\gamma_2 - \bar{\gamma}_2) \dot{\gamma}_2 \\ \leqslant & -(\gamma_0 + \gamma_1 |s_1| + \gamma_2 |\dot{s}_1|) |s_2| + \mu_0 \eta_0 (\gamma_0 - \bar{\gamma}_0) |s_2| + \\ & \mu_1 (\gamma_1 - \bar{\gamma}_1) \eta_1 |s_1| |s_2| + \mu_2 (\gamma_2 - \bar{\gamma}_2) \eta_2 |\dot{s}_1| |s_2| + \\ & (\bar{\gamma}_0 + \bar{\gamma}_1 |s_1| + \bar{\gamma}_2 |\dot{s}_1|) |s_2| - (\bar{\gamma}_0 + \bar{\gamma}_1 |s_1| + \bar{\gamma}_2 |\dot{s}_1|) |s_2| \\ \leqslant & -(\bar{\gamma}_0 + \bar{\gamma}_1 |s_1| + \bar{\gamma}_2 |\dot{s}_1|) |s_2| + (\mu_0 \eta_0 - 1) (\gamma_0 - \bar{\gamma}_0) |s_2| + \\ & (\mu_1 \eta_1 - 1) (\gamma_1 - \bar{\gamma}_1) |s_1| |s_2| + (\mu_2 \eta_2 - 1) (\gamma_2 - \bar{\gamma}_2) |\dot{s}_1| |s_2| \end{aligned} \quad (3\text{-}19)$$

定义，

$$\begin{cases} \epsilon_0 = \bar{\gamma}_0 + \bar{\gamma}_1 |s_1| + \bar{\gamma}_2 |\dot{s}_1| \\ \epsilon_1 = (\mu_0 \eta_0 - 1) |s_2| \\ \epsilon_2 = (\mu_1 \eta_1 - 1) |s_1| |s_2| \\ \epsilon_3 = (\mu_2 \eta_2 - 1) |\dot{s}_1| |s_2| \end{cases} \quad (3\text{-}20)$$

中国知网 https://www.cnki.net

通过选择满足条件 $\mu_i\eta_i > 1$ 的 μ_i，可以推导出 $\epsilon_i > 0$。

$$\begin{aligned}\dot{L}_V \leqslant & -\epsilon_0\sqrt{2}\frac{|s_2|}{\sqrt{2}} - \epsilon_1\sqrt{2\mu_0^{-1}}\sqrt{\frac{\mu_0}{2}}\left(\bar{\gamma}_1 - \gamma_1\right) - \\ & \epsilon_2\sqrt{2\mu_1^{-1}}\sqrt{\frac{\mu_1}{2}}\left(\bar{\gamma}_2 - \gamma_2\right) - \epsilon_3\sqrt{2\mu_2^{-1}}\sqrt{\frac{\mu_2}{2}}\left(\bar{\gamma}_3 - \gamma_3\right) \\ \leqslant & -\lambda\left(\frac{|s_2|}{\sqrt{2}} + \sqrt{\frac{\mu_0}{2}}\left|\bar{\gamma}_1 - \gamma_1\right| + \sqrt{\frac{\mu_1}{2}}\left|\bar{\gamma}_2 - \gamma_2\right| + \sqrt{\frac{\mu_2}{2}}\left|\bar{\gamma}_3 - \gamma_3\right|\right) \\ \leqslant & -\lambda L_V^{1/2}\end{aligned} \tag{3-21}$$

其中，$\lambda = \min\left\{\epsilon_0\sqrt{2}, \epsilon_1\sqrt{2\mu_0^{-1}}, \epsilon_2\sqrt{2\mu_1^{-1}}, \epsilon_3\sqrt{2\mu_2^{-1}}\right\}$。因此，系统的稳定性得到验证。

3.3 双延迟深度确定性策略梯度算法

双延迟深度确定性策略梯度算法（TD3）于 2018 年被提出，是对 DDPG 算法的重大改进，其属于无模型、Off-policy 的强化学习算法。TD3 算法通过引入重要性采样，解决了行为策略与目标策略不一致的问题，相较于第二章所采用的 PPO 算法，更加适合于强化学习的在线应用。此外，TD3 算法通过引入双 Q 网络和延迟更新机制，能够有效应对在线训练过程中受到的动作噪声和过估计误差的影响。

（1）双 Q 网络、延迟策略更新和重要性采样

为了提高强化学习的训练效率，DDPG 算法采用了确定性策略。然而，确定性策略的使用会导致行为策略网络生成的动作集中在局部区域，难以覆盖更多可能的动作。当行为策略网络产生的动作偏离实际最优动作时，目标 Q 值的估计会受到偏差的影响，进而导致 TD 误差的扩大。TD3 中的双 Q 网络通过使用两个独立的 Q 网络来降低 DDPG 中 Q 值过估计的倾向，从而提高算法的稳定性，其值网络的更新目标为两个值网络中输出的较小值。

在 DDPG 中，每个时间步都会交替更新策略网络和值网络。由于值函数网络的更新依赖于策略网络生成的动作，而策略网络的更新又依赖于值函数网络的估计，这种相互依赖关系可能导致两个网络之间的误差累积和相互干扰，从而使训练过程不够稳定。为了解决这一问题，TD3 算法引入了延迟策略更新机制。具体而言，TD3 算法将策略网络的更新频率降低至值函数网络的一半或更低，即对于每个值函数网络的多次更新步骤，仅执行一次策略网络的更新。通过减少策略网络的更新频率，可以有效降低策略网络与值函数网络之间的相互影响，从而更好地稳定训练过程，减少误差的累积和相互干扰，提高算法的收敛性和性能。

TD3 算法作为一种 Off-policy 算法，需要运用重要性采样[124] 来解决行为策略

中国知网 https://www.cnki.net

与目标策略不一致的问题。假设给定行为策略 ϱ 和目标策略 π，且 $\varrho \neq \pi$，要求估计 V_π。在覆盖性假设下，策略 π 下可选动作在策略 ϱ 中都有可能被选到。当初始状态为 s_t 时，在行为策略 ϱ 和目标策略 π 下得到相同轨迹的相对概率（重要性采样率）为：

$$\rho_{t:T-1} \doteq \frac{\prod_{k=t}^{T-1} \pi\left(u_k|\boldsymbol{x}_k\right) p\left(\boldsymbol{x}_{k+1}|\boldsymbol{x}_k, u_k\right)}{\prod_{k=t}^{T-1} \varrho\left(u_k|\boldsymbol{x}_k\right) p\left(\boldsymbol{x}_{k+1}|\boldsymbol{x}_k, u_k\right)} = \prod_{k=t}^{T-1} \frac{\pi\left(u_k|\boldsymbol{x}_k\right)}{\varrho\left(u_k|\boldsymbol{x}_k\right)} \tag{3-22}$$

从该式可以看出，重要性采样率与马尔可夫决策过程（MDP）无关，仅与行为策略 ϱ、目标策略 π 及该轨迹相关。基于值函数的相关定义可得状态 $\boldsymbol{x}$ 对应的值函数为 $\mathbb{E}\left[\rho_{t:T-1} G_t|\boldsymbol{x}_t\right] = v_\pi\left(\boldsymbol{x}\right)$。假设将不同局次的训练视为时间上连续的单局交互，$\eta\left(\boldsymbol{x}\right)$ 表示所有访问到状态 $\boldsymbol{x}$ 的集合，则 $v_\pi\left(\boldsymbol{x}\right)$ 的期望 $V\left(\boldsymbol{x}\right)$ 可以通过蒙特卡洛方法进行平均回报估计：

$$V\left(\boldsymbol{x}\right) \doteq \frac{\sum_{t\in\eta(\boldsymbol{x})} \rho_{t:T-1} G_t}{\left|\eta\left(\boldsymbol{x}\right)\right|} \tag{3-23}$$

（2）TD3 算法智能体及其训练步骤

TD3 算法的智能体构成通常涉及六个神经网络，分别为 Actor Net、Target Actor Net、Critic Net 1、Critic Net 2、Target Critic Net 1 和 Target Critic Net 2，其中 Actor Net 与 Target Actor Net 的结构相同，其余四个评价网络的结构也相同。

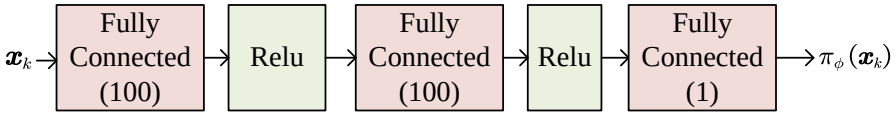


图 3-1 TD3 算法中的 Actor Net.
Fig.3-1 Actor Net. in TD3 algorithm

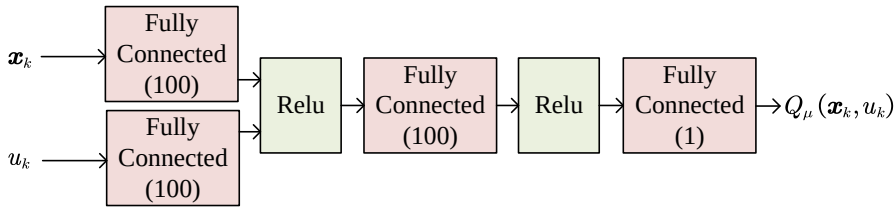


图 3-2 TD3 算法中的 Critic Net.
Fig.3-2 Critic Net. in TD3 algorithm

TD3 的策略网络 Actor Net 通常如图3-1所示。尽管 TD3 的策略网络输出为确定性值，但在与环境交互时，TD3 算法仍会在输出上叠加一个零均值、方差逐渐衰减的高斯噪声，以实现智能体对环境的探索。ϕ 表示 Actor Net 的网络参数。ϕ' 表示 Target Actor Net 的网络参数。TD3 的评价网络 Critic Net 如图3-2所示。ζ_i 表

中国知网 https://www.cnki.net

示第 i 个 Critic Net 的网络参数。ζ_i' 表示第 i 个 Target Critic Net 的网络参数。TD3 采用两个相同结构的神经网络来逼近状态动作值函数，而非 PPO 算法中的状态值函数。基于 TD3 算法的反作用轮无人自行车平衡控制器结构如图3-3所示，TD3 算法的伪代码见表3-1。

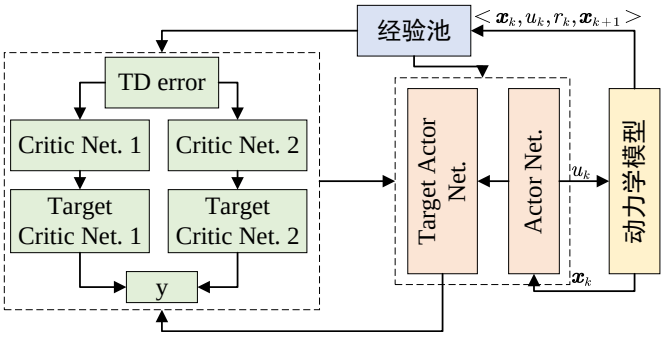


图 3-3 TD3 算法

Fig.3-3 TD3 algorithm

表 3-1 TD3 算法伪代码

Table3-1 Pseudo code of TD3 algorithm

TD3 算法
初始化 Critic Net. 1 参数 ζ_1，Critic Net. 2 参数 ζ_2，Actor Net. 参数 ϕ； 将 ζ_1，ζ_2 和 ϕ 分别赋值给 Target Critic Net. 1 参数 ζ_1'，Target Critic Net. 2 参数 ζ_2'，Target Actor Net. 参数 ϕ'；初始化经验池 $\mathcal{B}$； 循环： 　循环 $k = 1, 2, \cdots, K$ 　　在域随机化环境中利用策略 π_ϕ 进行交互，将数据元组存储在 $\mathcal{B}$ 中； 　　从 $\mathcal{B}$ 中采样 N 组数据，基于 Target Critic Net. 及 TD-error 更新参数 ζ_1 和 ζ_2； 　　间隔 D_1 时刻，基于 Critic Net. 1 更新 Actor Net. 参数 ϕ； 　　间隔 D_2 时刻，$\zeta_i' \leftarrow \tau\zeta_i + (1-\tau)\zeta_i'$，$\phi' \leftarrow \tau\phi + (1-\tau)\phi'$； 　直到横滚角大于 0.5rad 或达到最大时间步数； 直到达到最大更新次数或者收敛条件。

第一步，基于当前行为策略和状态得到动作，$u_k \sim \pi_\phi(\boldsymbol{x}_k) + \epsilon$，$\epsilon \sim \mathcal{N}(0, \sigma^2)$。执行动作 u_k 后，获得下一时刻状态 $\boldsymbol{x}_{k+1}$ 及奖励 r_k，并将元组 $\Omega = (\boldsymbol{x}_k, u_k, r_k, \boldsymbol{x}_{k+1})$ 存储在经验池 $\mathcal{B}$ 中。

第二步，从经验池中采样 N 组小批量数据，通过公式 (3-24) 对值函数神经网络参数 ζ_i 进行更新。

$$\begin{aligned} u &\sim \pi_{\phi'}(\boldsymbol{x}_{k+1}) + \epsilon \\ y &= r + \gamma \min_{i=1,2} Q_{\zeta_i}(\boldsymbol{x}', u) \\ \zeta_i &\leftarrow arg\min_{\zeta_i} N^{-1} \sum \left(y - Q_{\zeta_i}(\boldsymbol{x}, u)\right)^2 \end{aligned} \tag{3-24}$$

中国知网 https://www.cnki.net

第三步，每隔 D_1 步，通过最大化折扣累积奖励的期望值对策略网络的参数 ϕ 进行更新。

$$\nabla_{\phi} V(\phi) = N^{-1} \sum \nabla_{u} Q_{\zeta_1}(\boldsymbol{x}, u)|_{u=\pi_{\phi}(\boldsymbol{x})} \nabla_{\phi} \pi_{\phi}(\boldsymbol{x}) \tag{3-25}$$

第四步，每隔 D_2 步，根据公式 (3-26) 更新 Target Actor 网络和 Target Critic 网络的神经网络参数。

$$\begin{aligned} \zeta_i' &\leftarrow \lambda_1 \zeta_i + (1-\lambda_1)\zeta_i' \\ \phi' &\leftarrow \lambda_2 \phi + (1-\lambda_2)\phi' \end{aligned} \tag{3-26}$$

3.4 强化学习与滑模控制的串并联结合

滑模控制在应对不确定性时展现出的鲁棒性，通常是以牺牲控制性能为代价的，因此其鲁棒性与控制性能之间的权衡是一个仍未解决的问题。许多研究者致力于将滑模控制与其他控制方法相结合，以应对这一挑战，例如模糊控制[125]、自适应控制[126] 以及强化学习[127–129]。文献 [125] 提出了一种模糊滑模控制器以处理脉冲扰动和系统不确定性，但模糊规则的确立相对复杂。文献 [126] 提出了一种自适应滑模控制器，该控制器能够动态调整滑模控制器的参数以优化控制性能，但其仅能进行单调调整，可能导致系统增益过高，并引发抖振。

基于数据驱动的强化学习利用深度神经网络的强大表达能力[130]，通过从机器人系统与环境的交互数据中拟合状态空间与控制策略之间的复杂非线性关系，并借助强化学习的自主学习能力和延迟奖励处理能力来改进决策策略，从而为克服上述困难提供了可能性。将在线强化学习与滑模控制相结合，有助于克服两者各自的局限性，实现滑模控制与强化学习的优势互补。通过这种融合，强化学习能够减少对交互样本量的需求，实现在线学习优化，而滑模控制则能够在复杂和不确定的环境中通过在线优化实现更优的控制性能。因此，这种方法用于解决崎岖路面系统不确定性下反作用轮无人自行车的平衡控制问题，具有极大的潜力。

本节提出在线强化学习与滑模控制的串联结合（强化学习对滑模控制的在线调参）、并联结合（强化学习对滑模控制的在线补偿）以及串并联结合（强化学习对滑模控制的在线调参与补偿），以研究强化学习在反作用轮无人自行车平衡控制中的在线应用。

3.4.1 串联强化学习对滑模控制在线调参

本文将强化学习在线自适应调节滑模控制参数的算法记为 SRL（Serial Reinforcement Learning），该算法的核心是将滑模控制器嵌入到强化学习的策略网络中，

中国知网 https://www.cnki.net

并利用采集到的在线数据对其进行更新。该算法能够在线调节滑模控制器的趋近律参数和滑模面参数，相较于自适应滑模控制而言，弥补了其仅能调节趋近律参数的局限性。

首先，构建如图3-4所示的串联强化学习策略网络 TSMC Net，其输出服从正态分布 $u \sim N\left(u_{smc}\left(\theta_1,\theta_2\right),\sigma^2\left(\theta_3\right)\right)$，其中 $\sigma^2\left(x_t|\theta_3\right)=\log\left(1+e^{W_1^{\mathrm{T}}\tanh(x_t)+a}\right)$；$\theta_1 \triangleq [\alpha_0,\alpha_1,\beta_0,\beta_1]^{\mathrm{T}}$ 表示终端滑模控制中的滑模面参数，$\theta_2 \triangleq [\varphi,\vartheta]^{\mathrm{T}}$ 表示滑模控制中的趋近律参数，$\theta_3 \triangleq [W_1,a]^{\mathrm{T}}$ 表示 TSMC Net 方差部分的神经网络权重和偏置。TD3 算法构建的 SRL 中 Critic Net 如图3-5所示，标量值 $Q_\mu(\mathrm{x},u)$ 表示状态及策略下对累计奖励的期望。

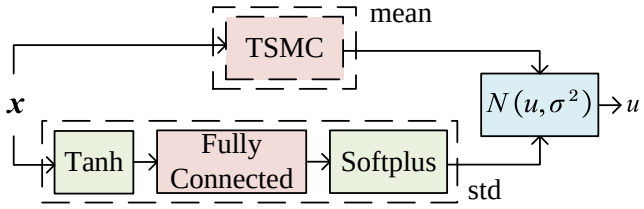


图 3-4 SRL 算法中的 TSMC Net.
Fig.3-4 TSMC Net. in SRL algorithm

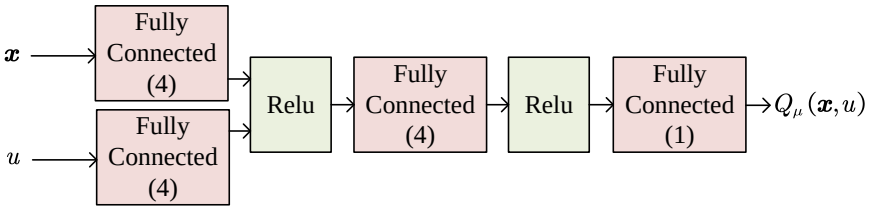


图 3-5 SRL 算法中的 Critic Net.
Fig.3-5 Critic Net. in SRL algorithm

为便于利用现有的神经网络梯度下降求解器对控制器的参数进行更新，将滑动模态表示为公式 (3-27)，

$$\begin{cases} s_1=\bar{\theta}_1^{\mathrm{T}}\left[s_0\ s_0^{q_0/p_0}\ 0\ 0\ \dot{s}_0\right]^{\mathrm{T}} \\ \dot{s}_1=\bar{\theta}_1^{\mathrm{T}}\left[\dot{s}_0\ (q_0/p_0)\ s_0^{q_0-p_0/p_0}\ 0\ 0\ \dot{s}_1\right]^{\mathrm{T}} \\ s_2=\bar{\theta}_1^{\mathrm{T}}\left[0\ 0\ s_1\ s_1^{q_1/p_1}\ \dot{s}_1\right]^{\mathrm{T}} \end{cases} \tag{3-27}$$

其中，$\bar{\theta}_1=[\theta_1\ 1]^{\mathrm{T}}$。

滑模控制器的神经网络表示，见公式 (3-28)，

$$u=\bar{\theta}_1^{\mathrm{T}}\left[\ddot{s}_0\ \frac{d^2}{dt^2}s_0^{q_0/p_0}\ \dot{s}_1\ \frac{d}{dt}s_1^{q_1/p_1}\ \theta_2^T\left[s_2\ s_2^{q_2/p_2}\right]\right]^{\mathrm{T}} \tag{3-28}$$

定义 $\bar{\theta}=[\theta_1\ \theta_2\ \theta_3]^{\mathrm{T}}$，则可以通过公式 (3-29) 对其进行更新，

中国知网 https://www.cnki.net

$$\bar{\theta} = \bar{\theta} - \gamma \frac{\partial}{\partial \bar{\theta}} J\left(\boldsymbol{x}, \tilde{u} | \bar{\theta}\right) \tag{3-29}$$

其中，$J\left(\boldsymbol{x}, \tilde{u} | \bar{\theta}\right) = \frac{1}{2} \left\| u_{\bar{\theta}}\left(\boldsymbol{x}\right) - \tilde{u} \right\|^2$ 为平方损失函数。

TD3 算法的其他超参数设置如下，Critic Net 的学习率 $\lambda_1 = 0.001$；Actor Net 的学习率 $\lambda_2 = 0.001$；折扣因子 $\gamma = 0.95$；从经验池中采样的数据量 $N = 256$；策略噪声方差 $\sigma^2 = 0.2$；更新间隔 $D_1 = 1$，$D_2 = 3$。

3.4.2 并联强化学习对滑模控制在线补偿

本小节构建了强化学习对滑模控制器输出的在线补偿，下文中记为 PRL（Parallel Reinforcement Learning），该算法的核心在于利用滑模控制提供基础的稳定性和鲁棒性，而利用强化学习的在线学习能力解决剩余未建模特性引入的不确定性。该算法有利于克服滑模控制匹配条件的约束。

文献 [57] 指出，传统反馈控制通过对机器人的运动学和动力学进行建模，能够有效解决多种机器人控制问题。然而，对于那些难以建模的特性，往往会导致控制器的“脆弱”和不准确。为了解决这一问题，可以将控制任务分解为由传统反馈控制处理的部分与由强化学习解决的残差部分，通过叠加这两种控制信号，有效减轻机器人运动控制中未建模特性的影响。

如图3-6所示，强化学习对滑模控制器输出的在线补偿，体现了强化学习算法与滑模控制 TSMC 的并联组合。具体而言，首先利用滑模控制生成初始控制输出。随后，根据系统实际反馈的状态，在强化学习奖励函数的框架下计算回报值。接着，强化学习智能体依据这些信息进行学习并优化输出补偿策略。智能体通过与环境的在线交互，逐步学习如何根据残差信息生成最优的输出补偿项，以优化系统控制性能。

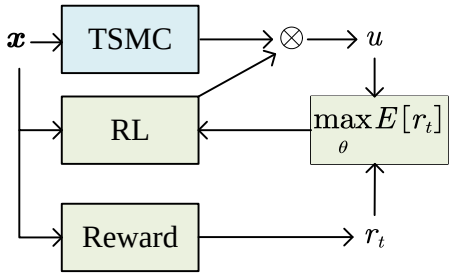


图 3-6 PRL 算法
Fig. 3-6 PRL algorithm

PRL 中智能体的策略网络和评价网络分别如图3-7和图3-8所示。PRL 中的奖励函数设置见公式 (2-41)。在 PRL 中，控制器的输出如公式 (3-30) 所示，由以下

中国知网 https://www.cnki.net

三部分组成：滑模控制、强化学习的 Actor Net 输出，以及用于在线强化学习探索的不断衰减的高斯噪声，σ 为高斯噪声方差。

$$u_{prl} = u_{tsmc} + \pi(\boldsymbol{x}) + \mathcal{N}(0, \sigma^2) \tag{3-30}$$

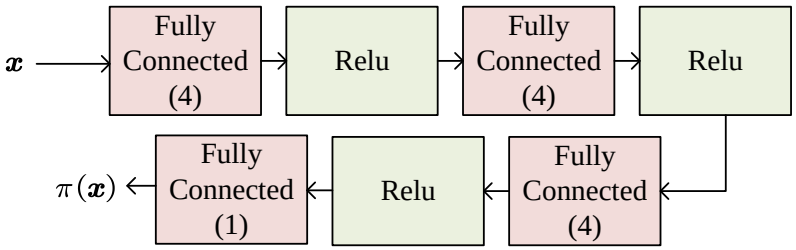


图 3-7 PRL 算法中的 Actor Net.
Fig.3-7 Actor Net. in PRL algorithm

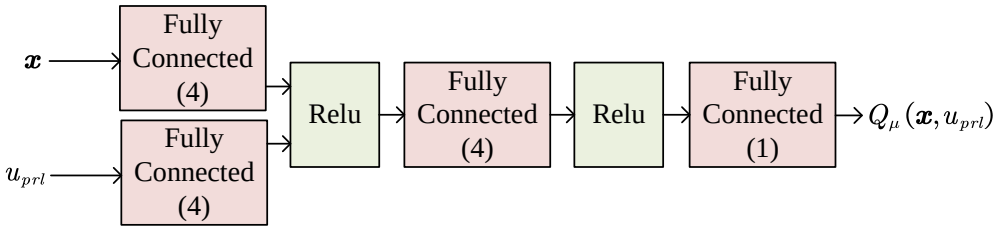


图 3-8 PRL 算法中的 Critic Net.
Fig.3-8 Critic Net. in PRL algorithm

3.4.3 串并联强化学习对滑模控制调参和补偿

根据本文绪论对研究现状的阐述，多智能体强化学习中的智能体结合方式可分为串联结合与并联结合。多智能体串联结合在强化学习领域通常被称为分层强化学习，其通过将复杂问题分解为多个层次，旨在学习一系列子技能的组合，以应对复杂的序列决策任务。然而，由于底层智能体的学习过程会对高层智能体的学习产生影响，导致该方法的收敛速度较慢，因此不适用于本章强化学习在线应用的需求。相较之下，多智能体的并联结合通过多个智能体之间的协作探索，有助于提高训练效率，并进一步增强在线强化学习的性能。

本小节提出一种多智能体强化学习与滑模控制结合的算法，该算法同时在线调节滑模控制器的参数并对控制输出进行在线补偿。如图3-9所示，RL1 和 RL2 分别表示强化学习智能体，其中 RL1 负责在线调节 TSMC 参数，形成 SRL；而 RL2 则对 SRL 的输出进行在线补偿，形成 PRL；两者共同构成 SPRL。该算法同时考虑了强化学习对滑模控制参数的自适应调节以及对输出的补偿，形成了 SRL 与 PRL 的多智能体强化学习并联结合。该算法有助于进一步克服 SRL 在处理非匹配扰动

中国知网 https://www.cnki.net

方面的局限性，同时也能提高 PRL 的在线训练效率，从而更有效地应对不确定性和外部扰动，提升控制系统的鲁棒性与控制性能。

SPRL 算法实现中涉及的奖励函数设置、神经网络设计等内容已在前述章节中 SRL 和 PRL 部分进行了详尽的阐述，在此不再重复说明。

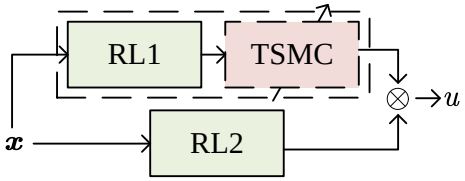


图 3-9 SPRL 算法
Fig.3-9 SPRL algorithm

3.5 串并联在线强化学习无人自行车平衡控制仿真测试

本节将在第二章所构建的反作用轮无人自行车仿真测试环境中，对前述设计的多种控制算法进行测试与比较分析。这些控制算法包括离线强化学习（PPO）、终端滑模控制（TSMC）、带扰动观测器的滑模控制（OTSMC）、自适应滑模控制（ATSMC）、单智能体在线强化学习与滑模控制的串联结合（SRL）、并联结合（PRL），以及多智能体在线强化学习与滑模控制的结合（SPRL）。

为便于对上述反作用轮无人自行车平衡控制算法进行对比与分析，本节将其分为四个组别进行比较。

1）第一组用于凸显串联强化学习在滑模控制在线调参方面相较于自适应滑模控制的优势，包含的控制器有 TSMC、ATSMC 和 SRL。

2）第二组用于验证并联强化学习在滑模控制在线补偿方面相较于带有扰动观测器的滑模控制的优势，包含的控制器有 TSMC、OTSMC 和 PRL。

3）第三组旨在揭示多智能体强化学习同时在线调参和补偿的有效性，包含的控制器有 TSMC、SRL、PRL 和 SPRL。

4）第四组用于展现在线强化学习相较于离线强化学习的优势，包含的控制器有 PPO、SRL、PRL 和 SPRL。

本节从仿真完成情况、最大横滚角跟踪误差、横滚角跟踪误差的均方根以及控制力矩绝对值的累积四个维度，对上述平衡控制器的性能进行对比分析。其中，仿真完成情况反映反作用轮无人自行车平衡控制器的鲁棒性，而最大横滚角跟踪误差、横滚角跟踪误差的均方根及控制力矩绝对值的累积则用于反映控制性能。

3.5.1 定性对比分析

（1）第一组（串联单智能体在线强化学习对滑模控制在线调参）

中国知网 https://www.cnki.net

在图3-10中，展示了任务 1、场景 1 和任务 2、场景 1 下，TSMC、ATSMC 和 SRL 的横滚角跟踪误差随时间变化的情况。图中实线代表三个随机种子下的跟踪误差均值，而半透明区域则表示系统不同物理参数下横滚角跟踪误差的标准差。在图3-10 (a) 中，可以看出 SRL 在经历了初始阶段（前 10 秒）的波动后，跟踪误差显著小于 TSMC。在图3-10 (b) 中，ATSMC 的跟踪误差幅值逐渐增大，SRL 的表现明显优于 TSMC 和 ATSMC。

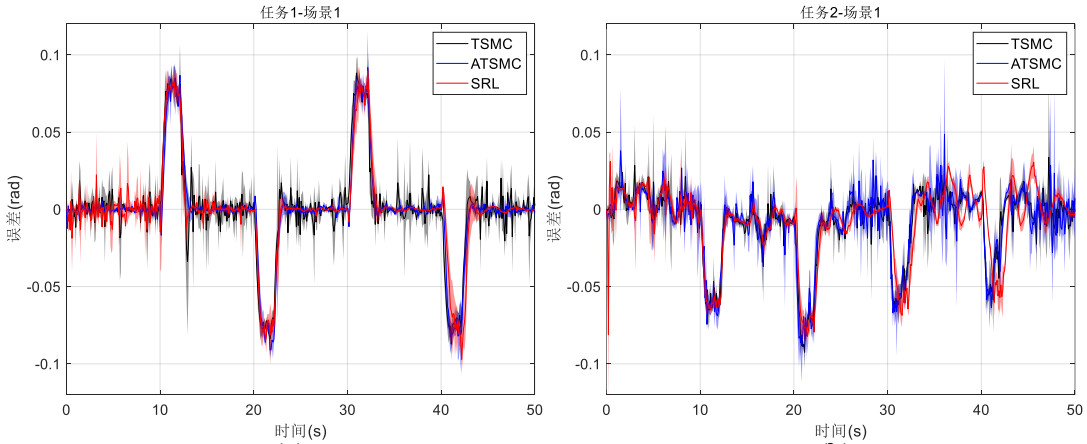


图 3-10 横滚角跟踪误差随时间的变化

Fig.3-10 Roll angle tracking error variation with time

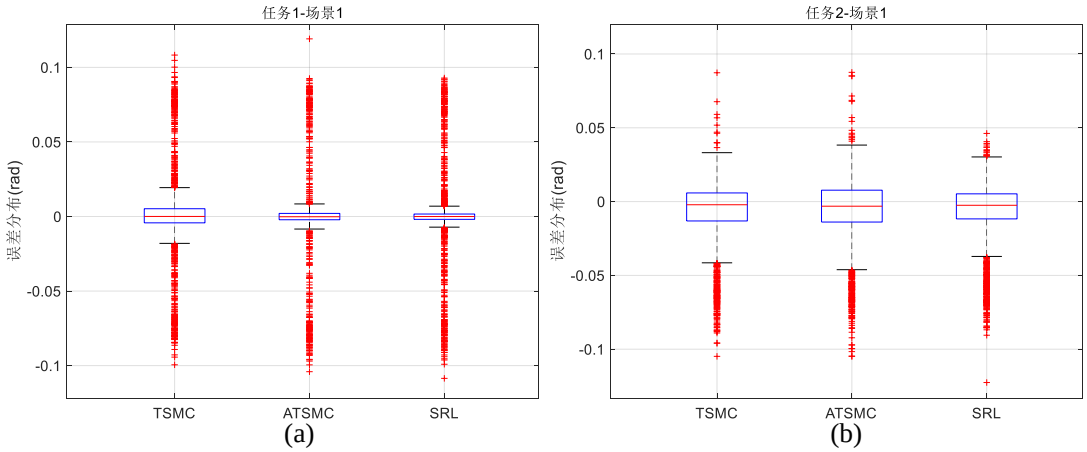


图 3-11 横滚角跟踪误差的分布

Fig.3-11 Roll angle tracking error distribution

为了更清晰地展示跟踪误差的分布情况，图3-11中呈现了误差分布的箱形图，其中箱体的上下水平线代表数据中位于原点附近的 50% 数据的范围，而箱体外的上边界和下边界则分别表示三四分位数和一四分位数。从图中可以看出，在任务 1 中，ATSMC 与 SRL 的跟踪误差分布相当；而在任务 2 中，SRL 明显优于其他两种平衡控制器。这一现象的原因在于任务 1 为相对简单的直线跟踪任务，而在任

中国知网 https://www.cnki.net

务 2 路径跟随任务中系统不确定性的影响更显著。ATSMC 在应对更为复杂的任务 2 时，平衡控制性能不如 SRL。

图3-12展示了 ATSMC 在任务 1、场景 1 和任务 2、场景 1 中的自适应参数变化。可以观察到，当有扰动出现时，ATSMC 的控制器参数单调增加。在任务 2 中，ATSMC 的滑模控制器趋近律参数不断单调增加，从而导致图3-10 (b) 中系统状态的波动加剧。

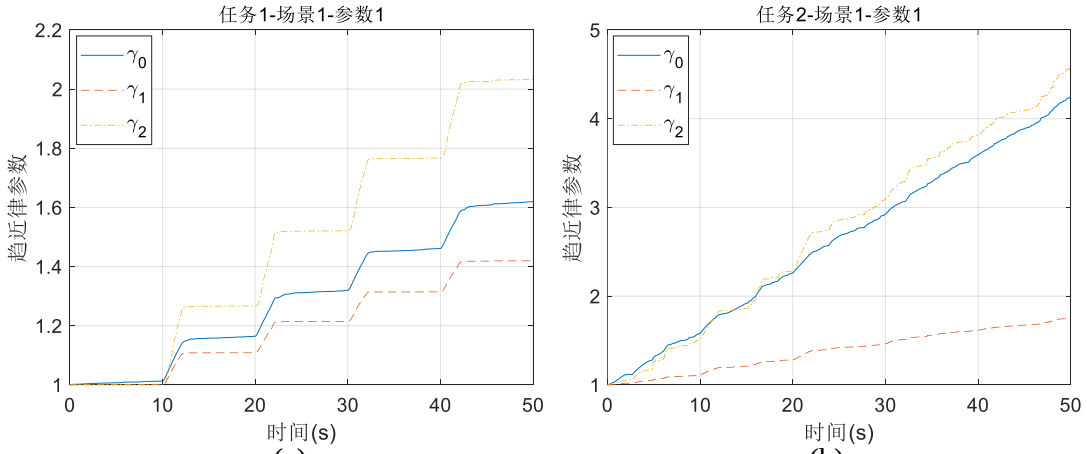


图 3-12 ATSMC 下滑模控制器参数随时间的变化

Fig.3-12 The variation of sliding mode controller parameters within ATSMC

本文提出的在线强化学习自适应调整滑模控制器参数的方法，不仅实现了对控制器趋近律和滑模面参数的调整，还在 Critic 评价网络的支持下实现了更优的调整策略。图3-13展示了 SRL 下滑模控制器参数的变化。从图3-13可以看出，SRL 下的滑模控制器参数则呈现出明显的下降趋势，并在外部扰动出现时急剧增大。

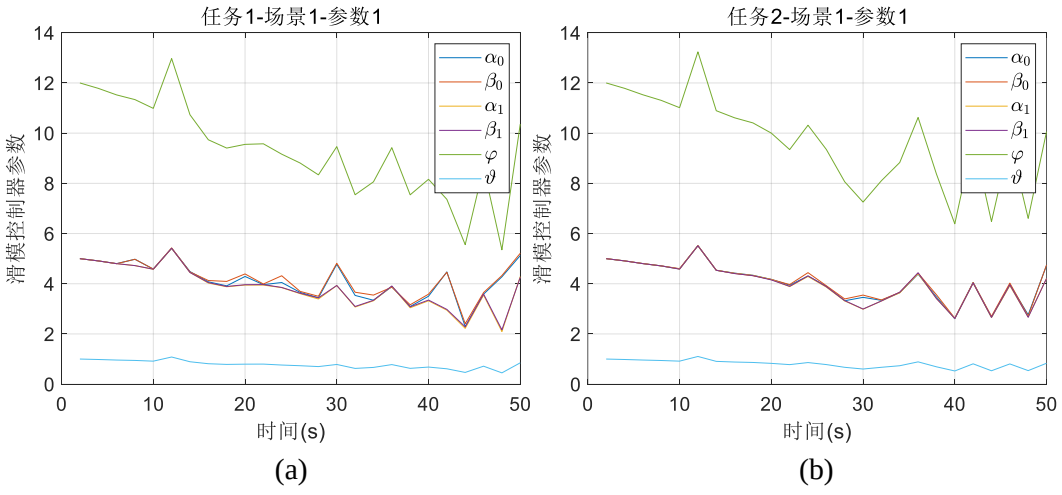


图 3-13 SRL 下滑模控制器参数随时间的变化

Fig.3-13 The variation of sliding mode controller parameters within SRL

中国知网 https://www.cnki.net

图3-14展示了 SRL 下任务 1、场景 1、参数 1 和任务 2、场景 1、参数 1 中的 Critic Loss。Critic Loss 通常用于反映基于 Actor-Critic 算法的强化学习的训练过程。本文采用的 TD3 算法属于 Actor-Critic 强化学习算法。从图3-14可以看到 SRL 中 Critic Loss 能够在较少的交互样本下快速收敛。并且 TD3 算法中双 Critic 网络的构造使得在阶跃扰动出现时，Critic Loss 受到的影响较小。

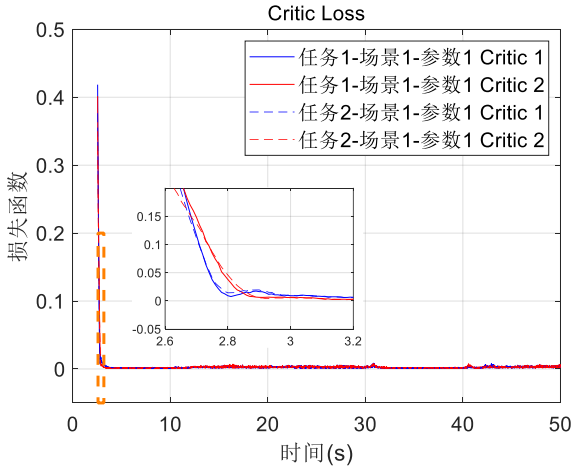


图 3-14 Critic loss 随时间的变化
Fig.3-14 Critic loss variation with time

（2）第二组（并联单智能体在线强化学习对滑模控制在线补偿）

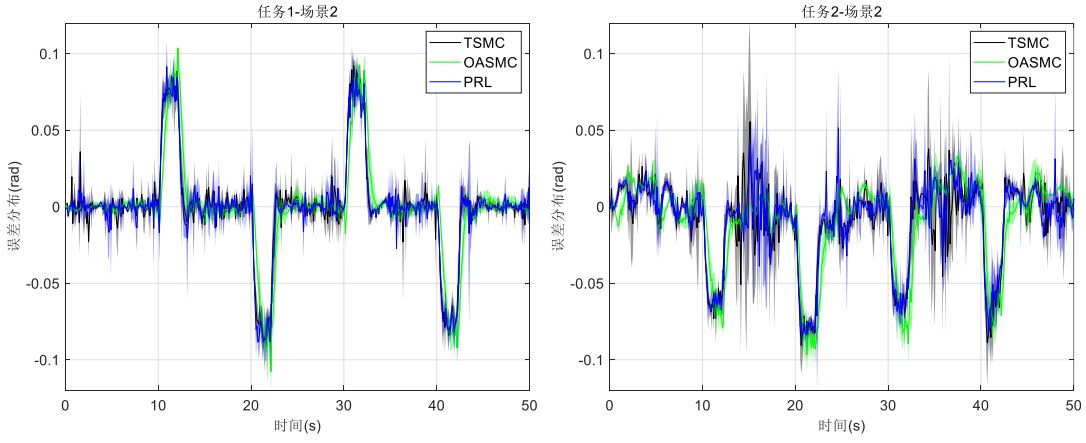


图 3-15 横滚角跟踪误差随时间的变化
Fig.3-15 Roll angle tracking error variation with time

在图3-15中，分别展示了任务 1、场景 2 和任务 2、场景 2 下，TSMC、OTSMC 与 PRL 的横滚角跟踪误差随时间变化的情况。图3-15 (a) 显示，蓝色曲线 PRL 的抖动幅度逐渐减小，表明强化学习在线学习的有效性。在图3-15 (b) 中，PRL 的抖动幅度持续减小，且在外部扰动施加时的跟踪误差最大值中 PRL 明显小于 OTSMC，进一步说明了在线强化学习的输出补偿是有效的。

中国知网 https://www.cnki.net

图3-16展示了相应测试场景下的误差分布图，支持了上述分析结果。在图3-16(a) 中，PRL 的误差分布与 OTSMC 相似、相较于 TSMC 更集中。在图3-16(b) 中，PRL 的误差分布显著小于 TSMC 算法；相较于 OTSMC，PRL 的误差分布更集中于原点。这表明在线强化学习的补偿机制能够有效提升控制器的性能。

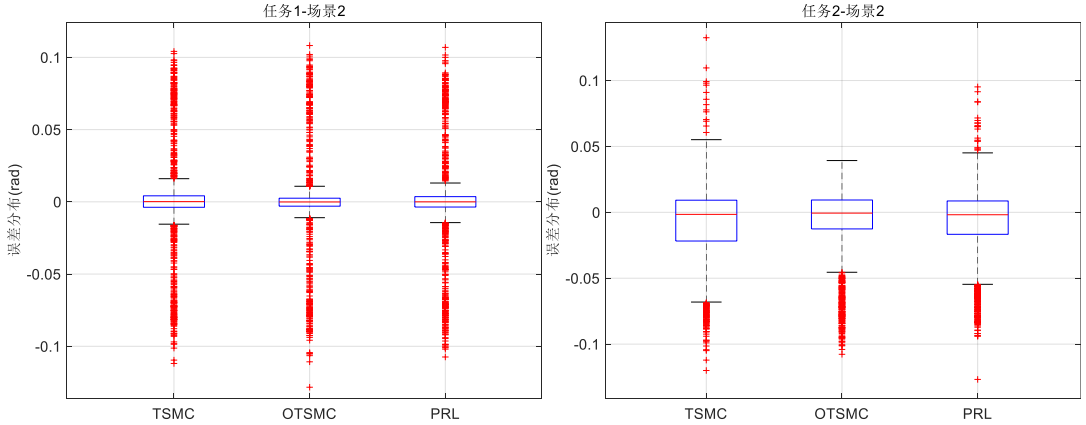


图 3-16 横滚角跟踪误差的分布

Fig.3-16 Roll angle tracking error distribution

图3-17展示了相应测试场景下 Critic loss 随时间变化的情况。可以观察到，虽然得益于 TD3 的双 Critic 网络结构形式，PRL 的 Critic loss 在阶跃扰动出现后，能够快速衰减。但相较于图3-14中 SRL 的 Critic loss 的快速收敛，PRL 的 Critic loss 收敛速度明显较慢，并且对阶跃扰动的影响更加敏感。

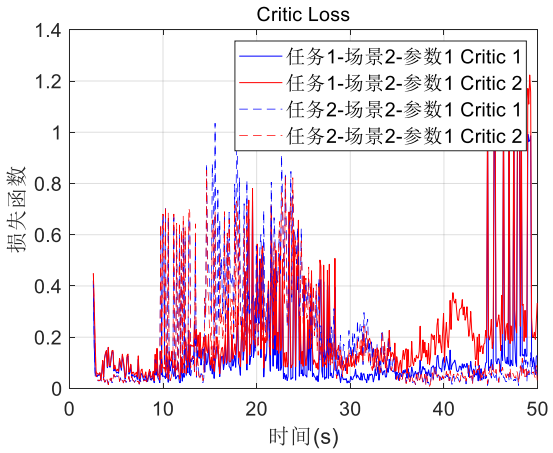


图 3-17 Critic loss 随时间的变化

Fig.3-17 Critic loss variation with time

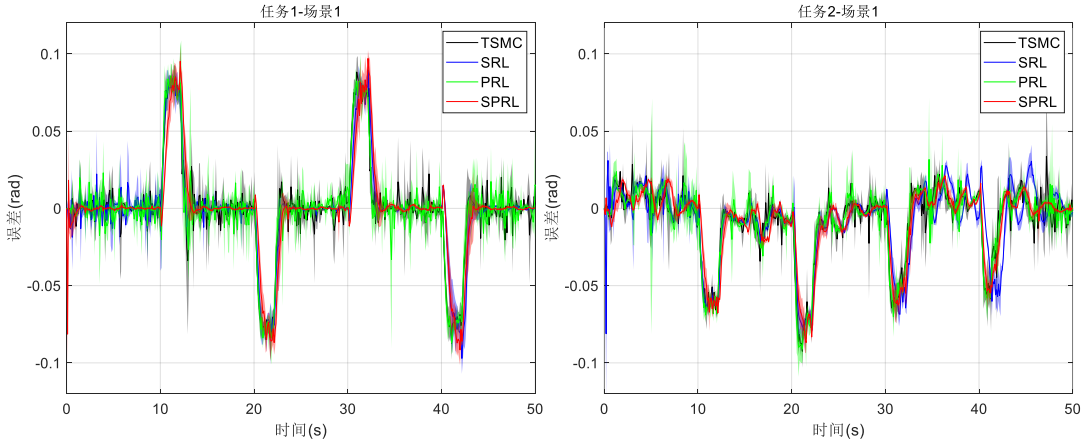
（3）第三组（多智能体强化学习同时在线调参和补偿）

通过对 SRL、PRL 及其组合形式 SPRL 的比较，能够展示到多智能体并联在

中国知网 https://www.cnki.net

线强化学习在控制效果上相较于其组成部分 SRL 和 PRL 的显著优势。此外，通过对 SRL 与 PRL 的比较，可以进一步明确二者在提升控制性能方面的差异。

图3-18中，展示了在任务 1、场景 2 及任务 2、场景 1 下，TSMC、SRL、PRL 和 SPRL 的横滚角跟踪误差随时间的变化情况。在图3-18 (a) 和图3-18 (b) 中，SRL 在初始阶段的抖动程度明显高于 PRL，这表明在线强化学习通过自适应调整滑模控制，相较于直接输出补偿，可能会对控制器的稳定性带来更大的风险。在图3-18中，SPRL 在整个仿真测试过程中，其跟踪误差的幅值及抖动程度始终显著低于 SRL 和 PRL，表明多智能体并联在线强化学习的控制效果优于其组成部分。此外，三种算法的控制性能均优于 TSMC，进一步说明了在线强化学习与滑模控制结合能够有效提升控制性能。



(a) (b)

图 3-18 横滚角跟踪误差随时间的变化

Fig. 3-18 Roll angle tracking error variation with time

图3-19展示了相应测试场景下的误差分布图。从图3-19箱形图的四分位线可以看出，SPRL 的跟踪误差分布相较于其他三种算法更加集中，说明 SPRL 的横滚角跟踪误差最小。其次，SRL 的跟踪误差分布相较于 PRL 更集中，说明在反作用轮无人自行车平衡控制中，串联在线调参取得了比并联在线补偿更好的控制效果。SPRL、SRL、PRL 都优于 TSMC，说明了强化学习在线应用能够优化平衡控制器的性能。

图3-20展示了 SPRL 训练过程中，其组成部分 SRL 和 PRL 的 Critic loss 收敛情况。通过与图3-20、图3-14 (b) 及图3-17 (a) 的对比，可以看出，多智能体强化学习的组成成分 SRL 和 PRL 中的 Critic loss 收敛速度明显快于单独使用 SRL 和 PRL 的情况，该现象支撑了前述分析的结论：SPRL 的平衡控制性能优于其组成成分 SRL 和 PRL。同时，也展现了多智能体强化学习同时在线调参与补偿算法在反作用轮无人自行车平衡控制问题中的有效性。

中国知网 https://www.cnki.net

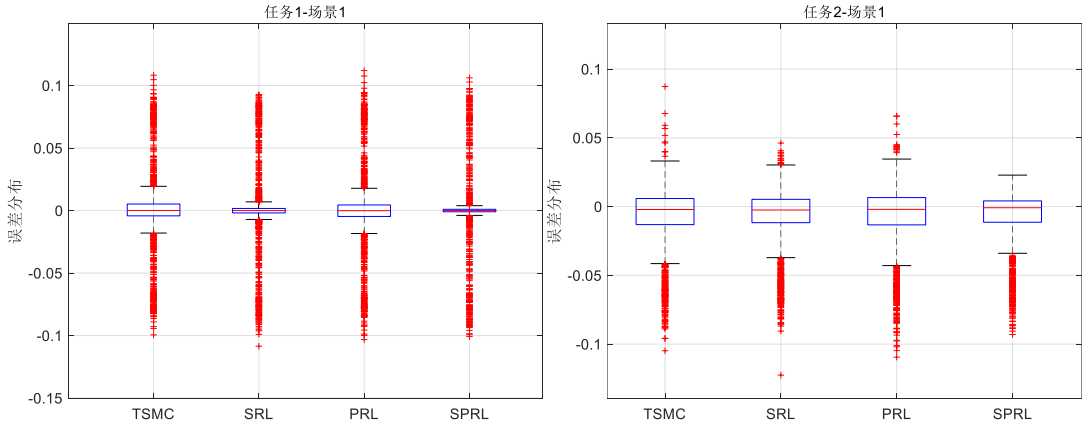


图 3-19 横滚角跟踪误差的分布

Fig.3-19 Roll angle tracking error distribution

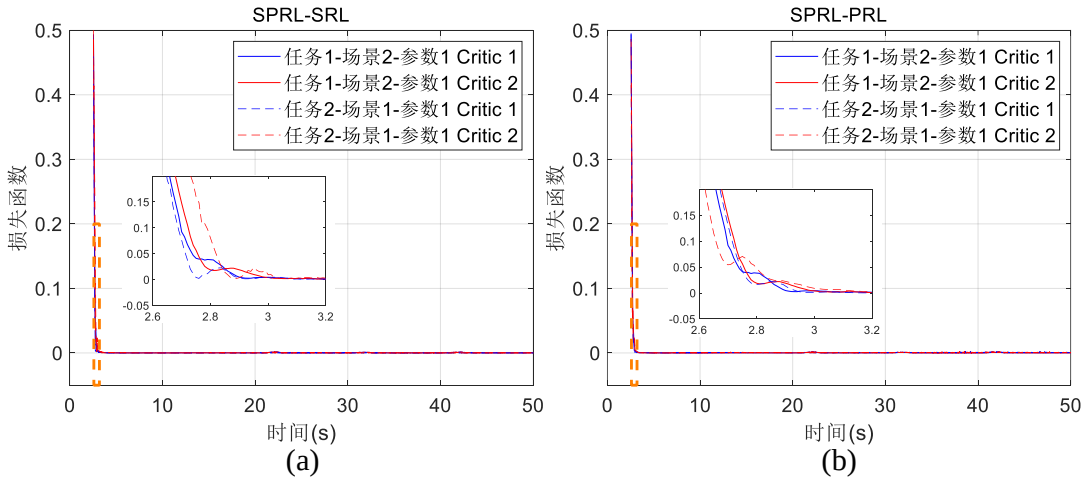


图 3-20 Critic loss 随时间的变化

Fig.3-20 Critic loss variation with time

（4）第四组（离线强化学习与在线强化学习）

图3-21展示了在任务 1、场景 1 以及任务 2、场景 1 下，PPO、SRL、PRL 和 SPRL 的横滚角跟踪误差随时间变化的情况。SPRL 的跟踪误差曲线中半透明区域明显比其他三种算法更窄，说明对于不同的系统物理参数，SPRL 的控制性能差异小，表明 SPRL 受系统不确定性的影响小。而 SPRL 相较于其他三种算法，其横滚角跟踪误差相较于原点的抖动幅度更小，说明其抗扰能力更强。此外，SRL 相较于 PRL 和 PPO 也能够得到类似结论。并且从图中可以看到，SRL 和 PRL 的抖动幅度随着时间增长，呈现出不断减小的趋势。

图3-22为上述四种算法下的反作用轮无人自行车横滚角跟踪误差的分布图。从图3-22(a) 的四分位线可以看出，SPRL 相较于 SRL 的误差分布更集中，SRL 相较于 PRL 的误差分布更集中，PRL 略优于 PPO 算法。图3-22(b) 中可以观察到相同结

中国知网 https://www.cnki.net

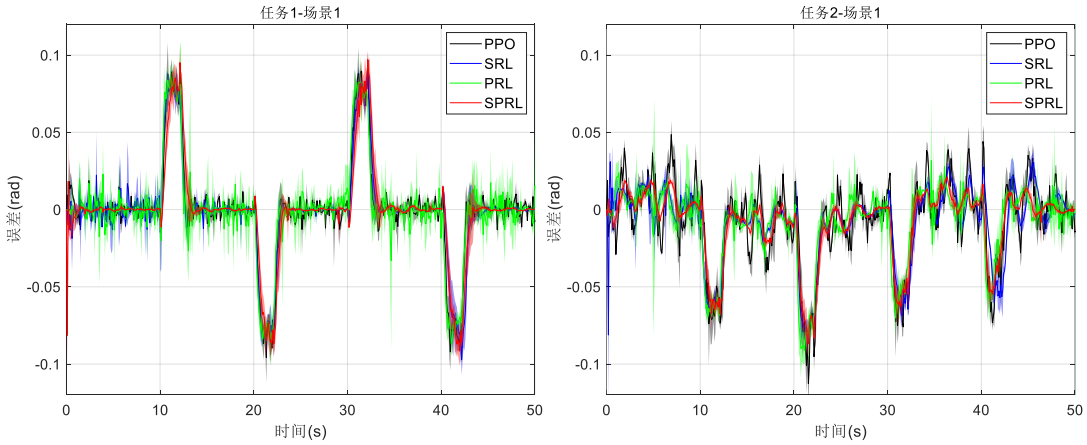


图 3-21 横滚角跟踪误差随时间的变化

Fig.3-21 Roll angle tracking error variation with time

论。从误差分布图3-22的分析得到的结论与跟踪误差曲线图3-21的分析结论一致，都表明在线强化学习能够获得比离线强化学习更优的控制性能。

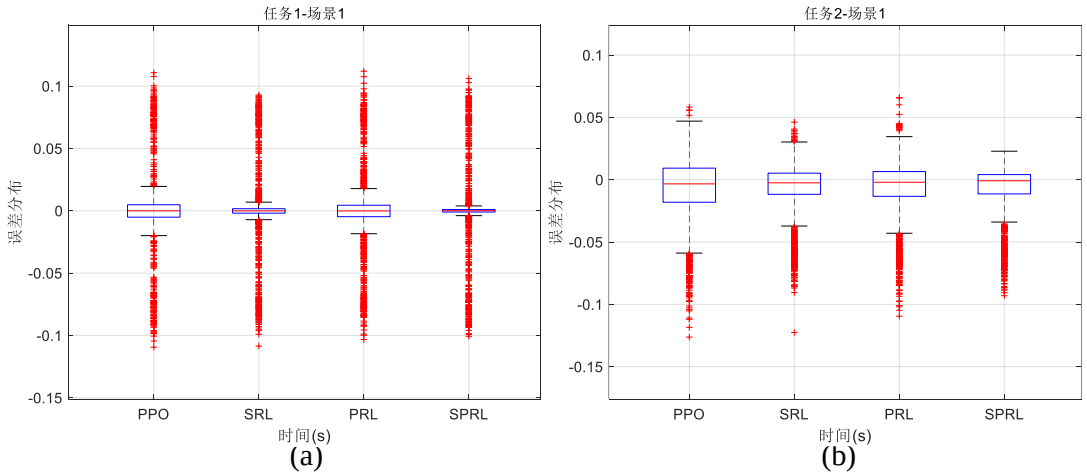


图 3-22 横滚角跟踪误差的分布

Fig.3-22 Roll angle tracking error distribution

3.5.2 定量对比分析

本小节从四个维度对上述反作用轮无人自行车平衡控制算法的仿真测试结果进行定量的对比分析，具体包括仿真完成情况、最大横滚角跟踪误差、横滚角跟踪误差的均方根值以及控制力矩绝对值的累积。

表3-2展示了上述 7 种算法在场景 3 中的仿真测试任务完成情况。从表3-2可以看出，SPRL、SRL 和 PRL 的仿真完成情况显著优于 PPO、TSMC、ATSMC 和 OTSMC 算法，说明在线强化学习显著提升了无人自行车平衡控制器的鲁棒性。此外，在任务 2、参数 1 和参数 3 的 TSMC 与 SRL 比较中，SRL 明显早于 TSMC 发

中国知网 https://www.cnki.net

生倒地现象。这一现象在 PRL 中也有所体现。其原因可能与在线强化学习初期较大的探索噪声导致的剧烈抖动有关，说明为在线强化学习与滑模控制结合时在线学习过程提供稳定性分析和安全性保障的必要性。

表 3-2 场景 3 的仿真测试完成情况 (s)
Table3-2 Simulation test completion status of case 3(s)

算法	任务 1			任务 2		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
PPO	-	-	37.36	7.98	4.15	11.32
TSMC	40.4	10.3	22.6	33.1	8.38	10.3
ATSMC	-	-	-	9.01	8.20	3.74
OTSMC	-	12.6	-	-	11.1	-
SRL	-	-	22.7	1.32	8.08	1.26
PRL	-	-	-	10.6	43.1	30.9
SPRL	-	-	-	45.6	-	-

表3-3对不同平衡控制算法的仿真测试完成情况进行了统计和打分。对于表现最佳的算法，给予 7 分；对于完成情况相同的算法，则赋予相同的分数，并依次递减。后续其他指标的统计中，也采用该方式。从表3-3可以看出，本章所提出的 SPRL 算法完成了 18 个仿真测试任务中的 17 个，表现最佳。SRL 和 PRL 相较于 PPO 和 TSMC 也有提升。表3-3更直观地呈现了在线强化学习对反作用轮自行车平衡控制鲁棒性的提升。

表 3-3 仿真测试完成情况的统计
Table3-3 Statistics on the completion of simulation tests

算法	PPO	TSMC	ATSMC	OTSMC	SRL	PRL	SPRL
统计	14	12	15	16	14	15	17
得分	4	3	5	6	4	5	7

表3-4、表3-5和表3-6分别列出了横滚角跟踪误差绝对值的最大值、横滚角跟踪误差的均方值以及输出力矩绝对值的累积值的统计情况。表3-4、表3-5和表3-6均以 PPO 算法为基准，依据公式 (3-31) 计算不同算法相对于基准算法 PPO 性能提升的百分比，

$$\xi_{alg} = \frac{1}{i}\sum \frac{\varepsilon_{ppo} - \varepsilon_{alg}}{\varepsilon_{ppo}} \tag{3-31}$$

其中 i 表示对应算法下仿真测试完成的个数，ε_{ppo} 表示 PPO 算法下该指标对应的值，ε_{alg} 表示对比算法下该指标对应的值。计算的原始数据见附录 A。

从表图3-23及表3-4、表3-5、表3-6和表3-7可以看到：1）SPRL 算法完成了 18

中国知网 https://www.cnki.net

表 3-4 最大跟踪误差的统计
Table 3-4 Statistics on the maximum tracking error

算法	PPO	TSMC	ATSMC	OTSMC	SRL	PRL	SPRL
均值	0.117	0.118	0.134	0.0893	0.109	0.130	0.117
统计	0.00%	-0.85%	-14.5%	32.7%	6.84%	-11.1%	0.00%
得分	5	4	2	7	6	3	5

表 3-5 跟踪误差均方值的统计
Table 3-5 Statistics on the mean square of tracking error

算法	PPO	TSMC	ATSMC	OTSMC	SRL	PRL	SPRL
均值	1.02	0.928	0.949	0.983	0.911	1.05	0.859
统计	0.00%	9.02%	6.96%	3.63%	10.69%	-2.94%	15.78%
得分	2	5	4	3	6	1	7

表 3-6 控制器输出力矩绝对值累计值的统计
Table 3-6 Statistics on the accumulation of absolute control moment

算法	PPO	TSMC	ATSMC	OTSMC	SRL	PRL	SPRL
均值	5.59	7.61	5.78	0.60	4.15	1.66	3.02
统计	0.00%	-36.14%	-3.40%	89.27%	25.76%	70.30%	45.98%
得分	3	1	2	7	4	6	5

个仿真测试任务中的 17 个，并且相较于 PPO 算法，其横滚角跟踪误差的均方值减少了 15.78%，控制器输出力矩绝对值累计减少了 45.98%，优于其他对比算法；2）SRL 相较于 PPO 的横滚角跟踪误差均方值减少了 10.69%，PRL 相较于 PPO 多完成了一个仿真测试任务，且 SRL 和 PRL 相较于 PPO 控制器输出力矩绝对值累计分别减少了 25.76% 和 70.30%。说明了本章所提出的在线强化学习算法，特别是同时在线调参数与补偿的 SPRL 算法，通过为平衡控制器引入在线学习能力，有效提升了反作用轮无人自行车的平衡控制性能。

为了更直观地呈现上述算法在不同评估维度上的表现，图3-23由上述算法在四个评估维度上的得分绘制得到，其中，Num 表示仿真任务完成次数，RMS 表示跟踪误差均方根值，MAX 表示最大跟踪误差，SUM 为控制器输出的累计值。通过该图可以清晰地观察到不同算法在各个维度上的优劣。

1）SRL 引入在线学习能力，自适应调节滑模控制器的趋近律参数和滑模面参数，弥补了传统自适应滑模仅能调整趋近律参数的局限性，在四个评估维度上都优于 PPO、TSMC 和 ATSMC 算法。

2）PRL 对控制器输出进行在线补偿，克服滑模控制匹配条件的约束，在仿真测试任务完成情况和控制器累计输出方面优于 PPO 和 TSMC 算法。但是由于强化

中国知网 https://www.cnki.net

学习的探索噪声直接叠加在控制输出上，且 PRL 的训练样本需求大于 SRL，因此其跟踪误差均方值和最大跟踪误差略大于 PPO 算法和 TSMC 算法，且大于 SRL。

3）SPRL 结合了 SRL 和 PRL 的优势，同时在线调参和补偿，且其多智能体的协同探索学习削弱了 PRL 训练样本需求大的影响，使得该算法在在仿真测试任务完全情况方面和跟踪误差均方值方面，显著优于上述其他算法。SPRL 在最大跟踪误差及控制器输出累计方面略大于 OTSMC 算法，其主要是受到在于强化学习在线探索噪声的影响。

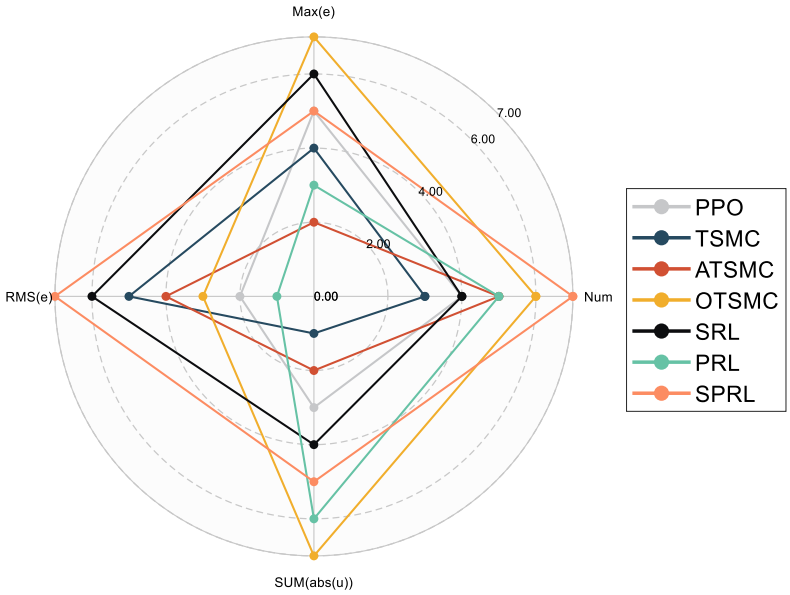


图 3-23 算法对比的雷达图

Fig. 3-23 Radar chart of the algorithm comparison

3.6 串并联在线强化学习无人自行车平衡控制实物实验

（1）平衡控制算法部署

考虑到无人自行车的平衡控制对控制输出的实时性和频率具有较高的要求，而在线强化学习算法通常伴随较大的计算开销，且嵌入式芯片的计算能力相对有限，难以同时满足这些需求。本文第二章对该问题的处理进行了简要介绍。将对实时性要求较高的数据处理及输出频率要求较高的滑模控制算法部署在 ESP32 芯片上，而将计算开销较大的在线强化学习神经网络的梯度计算等任务部署在上位机中。上位机与 ESP32 芯片通过 Wi-Fi 模块及 UDP 协议进行数据传输。尽管 UDP 协议在网络质量不佳时可能会出现连接中断和数据丢失的现象，但相较于 TCP 协议，其具有更高的传输速度和更低的延迟，更适合本文算法部署的需求。

在 TSMC、SRL、PRL 和 SPRL 控制算法的部署过程中，ESP32 芯片向上位机

中国知网 https://www.cnki.net

传输的数据为无人自行车样机的状态信息，表示为 $\boldsymbol{q}=\left[q_1\ \dot{q}_1\ \dot{q}_2\right]^{\mathrm{T}}$。与此同时，上位机向 ESP32 芯片发送的数据包为元组 $\left[\boldsymbol{\theta}^{\mathrm{T}}\ \zeta\right]^{\mathrm{T}}$，其中 $\boldsymbol{\theta}=\left[\alpha_0\ \beta_0\ \alpha_1\ \beta_1\ \varphi\ \vartheta\right]^{\mathrm{T}}$ 为滑模控制器的参数，ζ 为强化学习对滑模控制输出的在线补偿量。无人自行车样机的实际控制输出为 $u_{\boldsymbol{\theta}}(\boldsymbol{q})+\zeta$。在样机执行 TSMC 算法时，上位机发送的元组为常值 $\left[\boldsymbol{\theta}_0^{\mathrm{T}}\ 0\right]^{\mathrm{T}}$，其中 $\boldsymbol{\theta}_0$ 为滑模控制器的初始值，此时既不对 ESP32 中的滑模控制器参数进行更新，也不对其输出进行补偿。类似地，当样机运行 SRL 算法时，上位机发送的元组为 $\left[\boldsymbol{\theta}^{\mathrm{T}}\ 0\right]^{\mathrm{T}}$，此时 $\boldsymbol{\theta}$ 由强化学习算法在奖励函数的指导下不断更新。在样机执行 PRL 算法时，上位机发送的元组为 $\left[\boldsymbol{\theta}_0^{\mathrm{T}}\ \zeta\right]^{\mathrm{T}}$，此时输出补偿量不断更新，滑模控制器参数保持不变。在 SPRL 算法中，上位机发送的元组为 $\left[\boldsymbol{\theta}^{\mathrm{T}}\ \zeta\right]^{\mathrm{T}}$。这种设置有助于避免上位机与 ESP32 之间的通信负担导致的控制器性能差异。实验中，TSMC 控制器的参数初始值为 $\boldsymbol{\theta}_0=\left[7.0\ 2.0\ 2.0\ 2.0\ 10.0\ 10.0\right]^{\mathrm{T}}$。在 SRL、PRL 和 SPRL 算法中，主要超参数的设置如下，γ 取 0.995，N 取 256，τ 取 0.01。在线强化学习采用的奖励函数如公式 (2-41) 所示, 其中 $\phi=\left[0.2\ 0.02\ 0\ 0.0002\right]$。

（2）零前向速度下的平衡控制实验

本节首先在零前向速度、平坦路面场景中对 PPO、TSMC、SRL、PRL 和 SPRL 算法的反作用轮无人自行车，在扰动 d_{gp} 为 1.0V 和 2.0V 时的平衡控制进行实验。图3-24展示了 SPRL 下无人自行车样机在扰动幅值为 2.0V 时，第 20 秒和第 65 秒的实验视频截图。

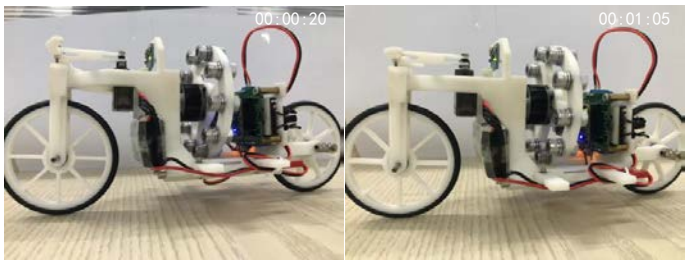


图 3-24 零前向速度下的样机实验

Fig.3-24 The prototype experiment at zero forward velocity

表3-7统计了相关的实验完成情况，其中“-”表示样机在 65 秒的实验中未发生提前倾倒现象，表中数值则表示倒地时间。从表中可以观察到，PPO 未能成功完成测试实验。这一结果的原因在于迁移策略的泛化能力不足以应对仿真训练环境与实验测试环境之间的差异，导致策略迁移控制性能的下降。此外，由于离线强化学习的策略是通过神经网络进行表示，其缺乏可解释性，使得手动调整神经网络参数变得困难。当扰动幅值为 1.0V 时，除 PPO 外的其他四种算法都成功完成了 65 秒的实验。当扰动幅值为 2.0V 时，只有 SRL 和 SPRL 完成了实验，说明

中国知网 https://www.cnki.net

SRL 和 SPRL 在无人自行车平衡控制，相较于 PPO 和 TSMC 展现出了更强的鲁棒性。当扰动幅值为 2.0V 时，PRL 在 12 秒时倒地，先于 TSMC 的 20 秒倒地，其原因可能在于强化学习探索噪声的影响。

表 3-7 实验完成情况

Table3-7 Experiments completion overview

算法	PPO	TSMC	SRL	PRL	SPRL
d_{gp} = 1.0	6s	-	-	-	-
d_{gp} = 2.0	5s	20s	-	12s	-

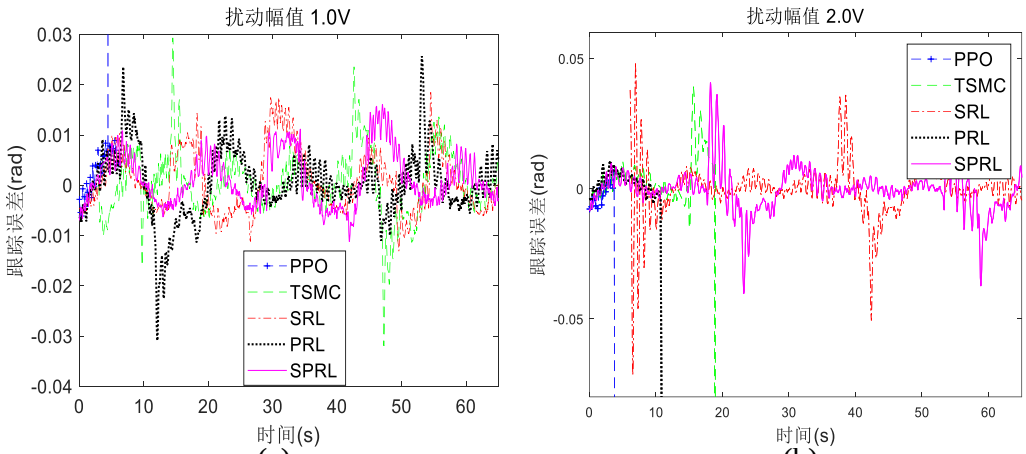


图 3-25 横滚角跟踪误差随时间的变化

Fig.3-25 Roll angle tracking error variation with time

图3-25描绘了 PPO、TSMC、SRL、PRL 和 SPRL 控制算法下无人自行车样机的横滚角跟踪误差随时间的变化情况。从图3-25 (a) 中可以明显看到，SRL、PRL 和 SPRL 的误差幅值呈现出逐渐减小的趋势，表明强化学习在线训练提升了平衡控制性能。图3-25 (b) 中也呈现出相同的趋势。此外，从跟踪误差的幅值来看，SPRL 显著小于其他对比算法。

图3-26绘制了实验中 TSMC、SRL、PRL 和 SPRL 算法下的跟踪误差分布情况。在图3-26 (a) 中，在线强化学习的 SRL、PRL 和 SPRL 在跟踪误差的最大值明显低于 TSMC，且 PRL、SPRL 的四分位线与 TSMC 相当，显示出在线强化学习对平衡控制有一定的优化效果。在图3-26 (b) 中，仅 SPRL 和 SRL 完成了实验，说明强化学习在线应用提升了平衡控制的抗扰能力；SPRL 在跟踪误差分布上明显优于 SRL，进一步说明了多智能体在线强化学习的有效性。

表3-8为横滚角跟踪误差均方值的统计结果，扰动幅值为 1.0V 时，以 TSMC 为基准呈现在线强化学习的优势；扰动幅值为 2.0V 时，以 SRL 为基准展示多智能体

中国知网 https://www.cnki.net

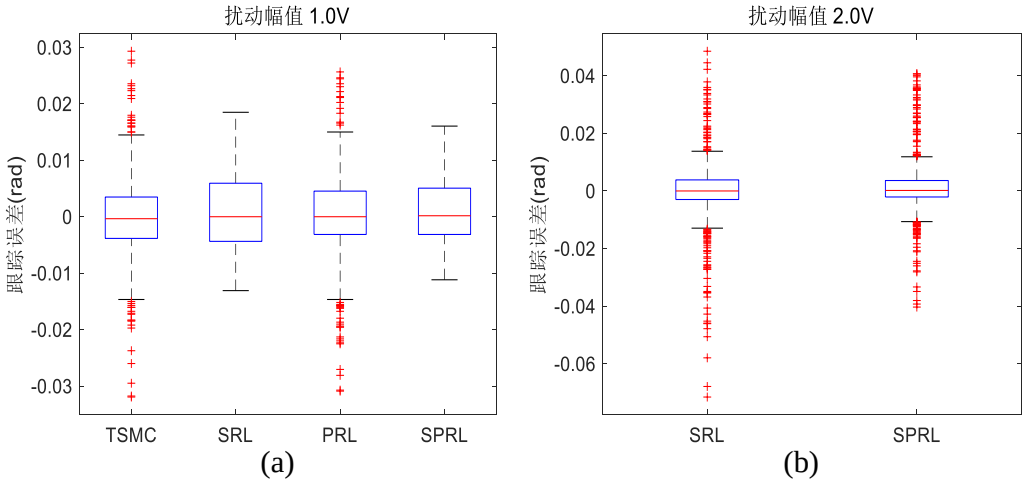


图 3-26 横滚角跟踪误差的分布

Fig.3-26 Roll angle tracking error distribution

强化学习同时在线调参和补偿的优势。当扰动幅值为 1.0V 时，SRL 相较于 TSMC 的跟踪误差均方值减少了 7.3%；SPRL 相较于 TSMC 减少了 30.2%；而在扰动幅值为 2.0V 时，SPRL 相较于 SRL 减少了 15.5%，展示了本章所提出的强化学习同时在线调参和补偿算法 SPRL 在反作用轮无人自行车平衡控制上的优势。

表 3-8 跟踪误差均方值 (10^{-4}rad^2)

Table3-8 Statistics on the mean square of tracking error(10^{-4}rad^2)

算法	PPO	TSMC	SRL	PRL	SPRL
$d_{gp}=1.0$	-	0.411	0.381	0.473	0.287
ξ_{TSMC}	-	-	7.3%	-15.1%	30.2%
$d_{gp}=2.0$	-	-	1.01	-	0.853
ξ_{SRL}	-	-	-	-	15.5%

（3）路径跟随下的平衡控制实验

与上一小节的实验相比，路径跟随下的平衡控制实验引入了车把的转动和地形的起伏。图3-27展示了在扰动幅值为 2.0V 时，SPRL 算法下反作用轮无人自行车样机实验的视频截图。



图 3-27 路径跟随下的样机实验

Fig.3-27 The path following prototype experiment

中国知网 https://www.cnki.net

表3-9统计了 TSMC、SRL、PRL 和 SPRL 算法下的实验完成情况。从表3-9可以看出，当扰动幅值为 0.0V 和 1.0V 时，四种算法均成功完成了 65 秒的实验。当扰动幅值为 2.0V 时，只有 SRL 和 SPRL 完成了实验，其中 TSMC 和 PRL 分别在 10 秒和 28 秒时倒地。这表明在路径跟随下的反作用轮无人自行车平衡控制实验中，SRL 和 SPRL 依旧具有较强的抗扰能力，进一步说明在线强化学习在提升平衡控制器鲁棒性方面的有效性。

表 3-9 实验完成情况

Fig.3-9 Experiments completion overview

算法	TSMC	SRL	PRL	SPRL
$d_{gp}=0.0$	-	-	-	-
$d_{gp}=1.0$	-	-	-	-
$d_{gp}=2.0$	10s	-	28s	-

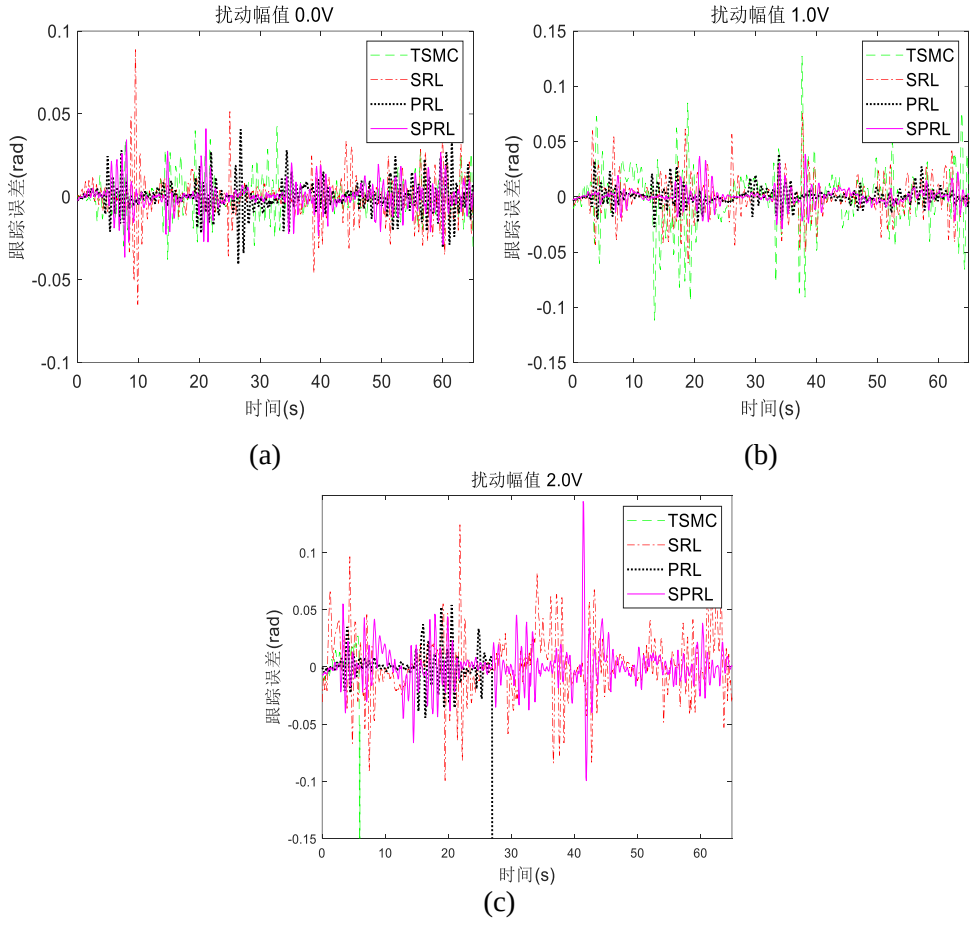


图 3-28 横滚角跟踪误差随时间的变化

Fig.3-28 Roll angle tracking error variation with time

图3-28描绘了不同扰动幅值下，TSMC、SRL、PRL 和 SPRL 控制算法下无人

中国知网 https://www.cnki.net

自行车样机的横滚角跟踪误差随时间的变化。在图3-28 (a) 中，从 0 秒到 10 秒，受强化学习训练初期探索噪声的影响，SRL 和 SPRL 的跟踪误差略大于 TSMC。随后，SPRL 的跟踪误差不断减少，最终小于 TSMC。在图3-28 (b) 中，实验阶段 30 秒到 65 秒，TSMC 的跟踪误差幅值显著高于 SRL、PRL 和 SPRL，显示出在线强化学习对平衡控制的优化作用。在图3-28 (c) 中，随着在线强化学习训练的进行，SPRL 的横滚角跟踪误差最终也显著小于 SRL。

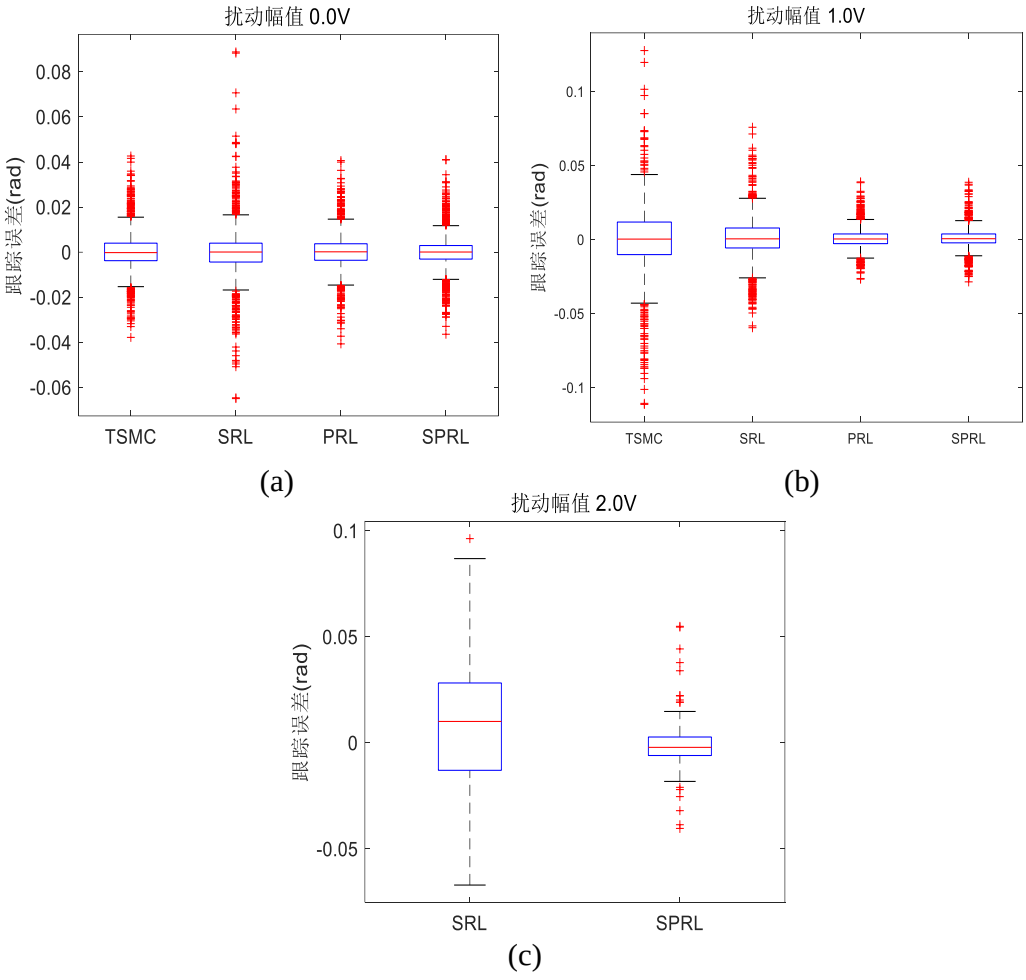


图 3-29 横滚角跟踪误差的分布

Fig. 3-29 Roll angle tracking error distribution

为了更清晰地呈现各控制算法在反作用轮无人自行车平衡控制中的差异，绘制如图3-29所示的箱线图。在图3-29 (a) 中，扰动幅值为 0.0V 时，SPRL 的跟踪误差最小，TSMC 和 PRL、SRL 相当；在图3-29 (b) 中，即扰动幅值为 1.0V 时，SPRL 和 PRL 表现最佳，SRL 次之，三者均优于 TSMC。在图3-29 (c) 中，扰动幅值为 2.0V 时，由于仅有 SRL 和 SPRL 完成实验，因此仅对这两者的误差分布进行比较，结果显示 SPRL 显著优于 SRL。该实验表明，在线强化学习与滑模控制结合应用

中国知网 https://www.cnki.net

于反作用轮无人自行车的平衡控制，相较于传统滑模控制，无论是抗扰能力还是控制精度都有有显著提升。并且同时在线调参和补偿的 SPRL 算法的平衡控制性能优于 SRL 和 PRL。

表 3-10 跟踪误差均方值 (10^{-4}rad^2)
Table3-10 Statistics on the mean square of tracking error(10^{-4}rad^2)

算法	TSMC	SRL	PRL	SPRL
$d_{gp}=0.0$	1.85	1.57	1.58	1.40
ξ_{TSMC}	-	15.1%	14.6%	24.3%
$d_{gp}=1.0$	3.12	2.67	2.51	2.31
ξ_{TSMC}	-	14.4%	19.5%	25.9%
$d_{gp}=2.0$	-	3.54	-	2.93
ξ_{SRL}	-	-	-	17.2%

表3-10统计了跟踪误差的均方值，扰动幅值为 0.0V 和 1.0V 时，以 TSMC 为基准呈现在线强化学习的优势；扰动幅值为 2.0V 时，以 SRL 为基准展示多智能体强化学习同时在线调参和补偿的优势。结果显示，在扰动幅值为 0.0V 和 1.0V 时，SRL 的跟踪误差均方值分别比 TSMC 减少了 15.1% 和 14.4%；PRL 的跟踪误差均方值分别比 TSMC 减少了 14.6% 和 19.5%；SPRL 的跟踪误差均方值分别比 TSMC 减少了 24.3% 和 25.9%。在扰动幅值为 2.0V 时，SPRL 的跟踪误差均方值相较于 SRL 减少了 17.2%。在扰动幅值为 0.0V 和 1.0V 时，SPRL 相较于 PRL 分别减少了 40.0% 和 24.7%。上述结论说明了在线强化学习有效提升了反作用轮无人自行车的平衡控制性能。

3.7 本章小结

为了解决反作用轮无人自行车平衡控制器的在线学习问题，本章提出了强化学习对滑模控制在线调参的 SRL 算法和在线补偿的 PRL 算法，解决了强化学习对交互样本量需求大的问题，赋予了反作用轮无人自行车平衡控制器的在线学习能力。随后，本章进一步提出了强化学习同时在线调节滑模控制参数以及进行输出补偿的 SPRL 算法，该算法不仅能够弥补自适应滑模控制仅能调整滑模趋近律参数的局限性，而且能够克服滑模控制匹配条件的约束。

本章在仿真测试和实物实验中，对 SPRL、SRL、PRL 和滑模控制 TSMC、自适应滑模控制、带观测补偿的滑模控制以及离线强化学习 PPO 算法进行了对比。首先，从仿真测试的对比分析来看：在任务完成情况方面，SPRL 完成了 18 个仿真测试中的 17 个、完成率约 94%，SRL、PRL、PPO 和 TSMC 分别完成了约 78%、83%、78% 和 67%，SPRL 在任务完成情况方面显著优于其他对比算法。在最大跟

中国知网 https://www.cnki.net

踪误差方面，SPRL 与 PPO 算法相当。在跟踪误差均方值和控制器累计输出方面，SPRL 相较于 PPO 分别减少了约 15% 和 45%。其次，在实物实验中，SPRL 完成了所有 6 个实验测试任务、完成率为 100%。而 PPO 算法泛化能力有限，未能完成任何一个实验测试任务。TSMC、SRL 和 PRL 分别完成了 80%、100% 和 80%。在实物实验的跟踪误差均方值方面，SPRL 相较于 TSMC、SRL 和 PRL 分别减少了约 20%、17% 和 32%。展现了本章所提出的基于串并联在线强化学习的无人自行车自平衡滑模控制算法在控制性能上的提升。

中国知网 https://www.cnki.net

第 4 章 鲁棒自适应动态规划稳定性保障的无人自行车平衡控制

4.1 引言

为了解决反作用轮无人自行车平衡控制的在线学习问题，第三章提出了基于串并联在线强化学习的自平衡滑模控制算法。该算法与离线强化学习的无人自行车平衡控制算法相比，不仅提高了测试任务的完成情况，还显著增强了平衡控制的性能。然而，该算法以无模型的强化学习算法（双延迟深度确定性策略梯度算法）为基础，无法为在线学习过程中的稳定性和收敛性提供充分的理论保障。这主要是因为无模型强化学习算法在动态环境中进行实时决策时，其策略更新的不确定性以及对环境模型认知的不完全性，可能导致学习过程的波动以及收敛性问题。

为此，本章提出鲁棒自适应动态规划稳定性保障的无人自行车平衡控制算法。该算法以基于模型的强化学习算法（自适应动态规划算法）为基础，引入鲁棒自适应动态规划机制，削弱自适应动态规划对精确系统模型的依赖，并在假设滑模控制器参数许用调节范围已知的前提下，构建输出饱和约束，从而确保在线学习过程的稳定性。本章旨在改进第三章提出的基于串并联在线强化学习的自平衡滑模控制算法，提升在线强化学习训练过程的鲁棒性。

4.2 问题描述

第三章中采用了一种无模型强化学习算法，即双延迟深度确定性策略梯度算法（TD3）。尽管 TD3 算法通过延迟策略更新来增强稳定性，并通过双 Q 网络的设计增强训练过程的鲁棒性，但其在线训练过程的稳定性主要依赖于超参数的设置，缺乏严格的稳定性理论证明。

相比之下，自适应动态规划算法（ADP）基于最优控制理论，能够通过闭环系统设计和参数自适应机制，确保系统在面对不确定性和外部干扰时仍保持一定的稳定性。此外，ADP 算法通常伴随李雅普诺夫稳定性证明，从而能够提供更强有力的理论稳定性保障。然而，自适应动态规划的训练过程通常对系统模型的准确性有较高要求，其用于反作用轮无人自行车的平衡控制存在一定的局限性。

本节构建基于传统自适应动态规划的反作用轮无人自行车平衡控制，并对其局限性进行分析。

将系统方程 (2-27) 改写为如下形式：

中国知网 https://www.cnki.net

$$\dot{\boldsymbol{x}} = A\boldsymbol{x} + Bu + D \tag{4-1}$$

其中，$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$，$A = \begin{bmatrix} 0\,1\,0 \\ 0\,0\,1 \\ 0\,0\,0 \end{bmatrix}$，$B = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$ 以及 $D = \begin{bmatrix} d_1' \\ 0 \\ d_2' \end{bmatrix}$。

定义 u_{adp} 为控制器输出中的自学习部分，则控制器的输出可以表示为：

$$u = u_{tsmc} + u_{adp} \tag{4-2}$$

其中，u_{tsmc} 见公式 (3-3)。

在最优控制理论中，值函数 V_c 通常也被称为代价函数，其定义如下：

$$V_c = \int_0^{\infty} \left(\boldsymbol{x}^{\mathrm{T}} Q \boldsymbol{x} + r \left(u_{tsmc} + u_{adp} \right)^2 \right) dt, \boldsymbol{x}\,(0) = \boldsymbol{x}_0 \tag{4-3}$$

其中，Q 为对称正定矩阵，r 为正常数。

对上式沿着系统轨线进行求导，可得如下 Hamilton 函数，

$$H = V_{cX}^{\mathrm{T}} \dot{\boldsymbol{x}} + \boldsymbol{x}^{\mathrm{T}} Q \boldsymbol{x} + r \left(u_{tsmc} + u_{adp} \right)^2 \tag{4-4}$$

其中，$V_{cX} = \partial V_c / \partial \boldsymbol{x}$。

自学习控制部分 u_{adp} 可以通过最小化值函数 V_c 来获得，定义 $V_c^* = \min_u (V_c)$，则最优值函数满足下式，

$$0 = H^* = \min_u \{H\} = V_{cX}^{*\mathrm{T}} \dot{\boldsymbol{x}} + \boldsymbol{x}^{\mathrm{T}} Q \boldsymbol{x} + r u^2 \tag{4-5}$$

其中，$V_{cX}^* = \partial V_c^* / \partial \boldsymbol{x}$。

假定上式的最小值存在且唯一，则可以令 $\partial H / \partial u_{adp} = 0$，得到 u_{adp}。

$$u_{adp}^* = arg \min_{u_{adp}} \{H\} = -\frac{1}{2r} V_{c\boldsymbol{x}}^{*\mathrm{T}} B - u_{tsmc} \tag{4-6}$$

将式 (4-6) 带入式 (4-5) 可得，

$$0 = V_{cX}^{*\mathrm{T}} \dot{\boldsymbol{x}} + \boldsymbol{x}^{\mathrm{T}} Q \boldsymbol{x} + r \left(-\frac{1}{2r} V_{c\boldsymbol{x}}^{*\mathrm{T}} B - u_{tsmc} \right)^2 \tag{4-7}$$

由于式 (4-7) 难以直接求解，因此通常采用文献 [35] 中的策略迭代算法，通过如下两步进行交替求解。

1）给定 $u^{(i)}$，求解 $V_c^{(i)}$，

$$\begin{aligned} 0 = V_{cX}^{(i)\mathrm{T}} \dot{\boldsymbol{x}} + \boldsymbol{x}^{\mathrm{T}} Q \boldsymbol{x} + r \left(u_{tsmc} + {u_{adp}}^{(i)} \right)^2 \\ V_c^{(i)}\,(0) = 0 \end{aligned} \tag{4-8}$$

2）更新控制策略，

中国知网 https://www.cnki.net

$$u_{adp}^{(i+1)} = -\frac{1}{2r}V_{c\boldsymbol{x}}^{(i)\mathrm{T}}B - u_{tsmc} \tag{4-9}$$

其中，$i = 1, 2, \cdots$ 表示迭代次数。当 $i \to \infty$ 时，$V_c \to V_c^*$，$u_{adp} \to u_{adp}^*$。

从式 (4-8) 可知，上述自适应动态规划问题的迭代求解需要精确的系统模型以提供 $\dot{\boldsymbol{x}}$ 的信息。而该信息在系统不确定性下的反作用轮无人自行车平衡控制问题中，不易获得。此外，在传统的自适应动态规划算法中，通常存在一个基本假设，即闭环系统本身具备稳定性。并且在自适应动态规划的优化过程中，该闭环系统的稳定性能够持续保持。这一假设条件在崎岖路面及系统不确定性下的反作用轮无人自行车平衡控制问题中可能难以满足。

4.3 鲁棒在线自学习反作用轮无人自行车平衡控制

4.3.1 鲁棒在线自学习平衡控制

由于在系统不确定性下的反作用轮无人自行车平衡控制问题中，难以为自适应动态规划的迭代优化过程式 (4-8) 提供精确的 $\dot{\boldsymbol{x}}$ 的信息。因此，本章引入鲁棒自适应动态规划机制[67]，通过对式 (4-8) 两端进行积分，得到不依赖于 $\dot{\boldsymbol{x}}$ 的优化求解形式，削弱系统不确定性对在线学习的影响。此外，给出滑模控制器参数可调节范围已知的假设，得到控制器的输出饱和约束。最后，在此基础上对反作用轮无人自行车平衡控制在线学习过程的稳定性进行分析。

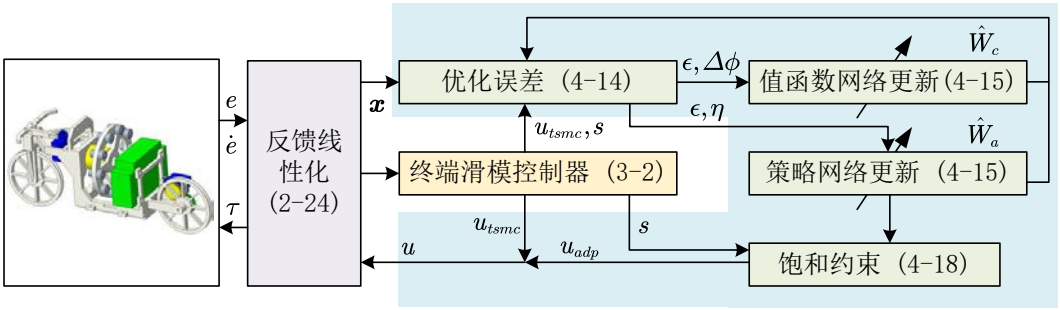


图 4-1 控制系统框图

Fig.4-1 Schematic of control system

本章所提出的鲁棒在线自学习平衡控制算法如图4-1所示，本文将其记为 RS-TSMC。RS-TSMC 与文献 [69] 中的 S-TSMC 及文献 [67] 中的 R-TSMC 之间的主要差异如下。首先，S-TSMC 的优化求解依赖于标称模型的 $\dot{\boldsymbol{x}}$ 信息，这在算法的在线应用中存在一定的局限性。本章采用鲁棒自适应动态规划的迭代形式以解决这一问题。其次，在 R-TSMC 的优化目标中仅涉及了 u_{adp}，而不是控制器的整体输出 u。相较之下，RS-TSMC 的优化则是针对控制器的整体输出 u 进行的。此外，

中国知网 https://www.cnki.net

R-TSMC 的优化求解并未考虑任何约束条件。S-TSMC 仅在稳定性证明中考虑了约束条件。RS-TSMC 用滑模控制参数许用调节范围已知的假设，替代了传统自适应动态规划中闭环系统始终稳定的假设，并将其用于实现控制器输出饱和约束。这种方式为处理系统不确定性提供了一种更加实用和鲁棒的方法。

（1）鲁棒自适应动态规划

假设给定输入 $u = u_{tsmc} + u_s$，u_s 为探索策略，则有，

$$\begin{aligned} \dot{V}_c^{(i)} &= V_{cx}^{(i)\mathrm{T}} \left(A\boldsymbol{x} + B\left(u_{tsmc} + {u_{adp}}^{(i)} \right) + B\left(u_s - {u_{adp}}^{(i)} \right) \right) \\ &= -2r\left(u_{tsmc} + u_{adp}^{(i+1)} \right)\left(u_s - {u_{adp}}^{(i)} \right) - \boldsymbol{x}^{\mathrm{T}} Q\boldsymbol{x} - r\left(u_{tsmc} + {u_{adp}}^{(i)} \right)^2 \end{aligned} \tag{4-10}$$

对上式在区间 T 上进行积分，

$$\begin{aligned} &V_c^{(i)}\left(\boldsymbol{x}_t\right) - V_c^{(i)}\left(\boldsymbol{x}_{t-T}\right) = \\ &-\int_{t-T}^{t} \left(2r\left(u_{tsmc} + u_{adp}^{(i+1)} \right)\left(u_s - {u_{adp}}^{(i)} \right) + \boldsymbol{x}^T Q\boldsymbol{x} + r\left(u_{tsmc} + {u_{adp}}^{(i)} \right)^2 \right) d\tau \end{aligned} \tag{4-11}$$

$V_c^{(i)}$ 与优化后的策略 $u_{adp}^{(i+1)}$ 可以通过上述公式进行求解。

接下来，采用 Actor-Critic 神经网络的形式来近似值函数网络和策略网络，并通过迭代方法求解网络参数。

值函数网络的定义如下：

$$\hat{V}_c^*\left(\boldsymbol{x}\right) = \hat{W}_c^{\mathrm{T}} \phi\left(\boldsymbol{x}\right) \tag{4-12}$$

策略网络的定义如下：

$$\hat{u}_{adp}^*\left(\boldsymbol{x}\right) = \hat{W}_a^{\mathrm{T}} \varphi\left(\boldsymbol{x}\right) \tag{4-13}$$

将值函数网络和策略网络代入式（4-18）可得，

$$\begin{aligned} &\epsilon\left(t\right) = \hat{W}_c^{\mathrm{T}}\left(\phi\left(\boldsymbol{x}_t\right) - \phi\left(\boldsymbol{x}_{t-T}\right)\right) + \\ &\int_{t-T}^{t} \left(2r\left(u_{tsmc} + \hat{W}_a^{\mathrm{T}}\varphi\left(\boldsymbol{x}\right)\right)\left(u_s - \hat{W}_a^{\mathrm{T}}\varphi\left(\boldsymbol{x}\right)\right) + \boldsymbol{x}^{\mathrm{T}} Q\boldsymbol{x} + r\left(u_{tsmc} + \hat{W}_a^{\mathrm{T}}\varphi\left(\boldsymbol{x}\right)\right)^2 \right) d\tau \end{aligned} \tag{4-14}$$

式中 $\epsilon\left(t\right)$———逼近误差；

采用梯度下降对值函数网络参数和策略网络参数进行更新，

$$\begin{aligned} \dot{\hat{W}}_c &= -\lambda_1 \frac{\phi\left(\boldsymbol{x}_t\right) - \phi\left(\boldsymbol{x}_{t-T}\right)}{m_s^2\left(t\right)} \epsilon\left(t\right) \\ \dot{\hat{W}}_a &= -\lambda_2 \frac{\eta\left(t\right)}{m_s^2\left(t\right)} \epsilon\left(t\right) \end{aligned} \tag{4-15}$$

其中，m_s 用于实现正则化。

中国知网 https://www.cnki.net

$$\begin{aligned} m_s &= \left(\phi\left(\boldsymbol{x}_t\right)-\phi\left(\boldsymbol{x}_{t-T}\right)\right)^{\mathrm{T}}\left(\phi\left(\boldsymbol{x}_t\right)-\phi\left(\boldsymbol{x}_{t-T}\right)\right)+\eta^{\mathrm{T}}\eta+1 \\ \eta\left(t\right) &= 2\int_{t-T}^{t}\left(\left(ru_s\right)\otimes\varphi\left(\boldsymbol{x}\right)\right)d\tau-\int_{t-T}^{t}\left(\varphi\left(\boldsymbol{x}\right)\otimes r\right)\otimes\varphi\left(\boldsymbol{x}\right)d\tau\mathbf{vec}\left(\hat{W}_a^{\mathrm{T}}\right) \end{aligned} \tag{4-16}$$

上式中，$\otimes$ 表示 Kronecker 积。

该求解方法能够利用交互采样数据进行计算，而不需要使用 $\dot{\boldsymbol{x}}$，因此避免了求解过程对精确系统模型的依赖，可以用于系统不确定性下的反作用轮无人自行车平衡控制。

（2）输出饱和约束

针对反作用轮无人自行车平衡控制问题，传统自适应动态规划所依赖的闭环系统始终稳定的假设在实际应用中难以实现。为此，本章基于初始可用的滑模控制器，提出滑模控制参数许用调节范围已知的假设。在此基础上，实现输出饱和约束直接作用于平衡控制的输出，从而为解决该控制问题提供更为切实可行的方案。

从公式 (3-1) 和公式 (3-2) 可知，第三章基于一种级联形式的全局快速终端滑模控制与强化学习的结合，提出了 SPRL。虽然 SPRL 同时在线调整滑模控制器的滑模面参数和趋近律参数，显著提高了平衡控制的鲁棒性和控制性能。但是从在线学习算法的稳定性分析角度来看，控制器参数需要基于滑模变量的收敛状态进行逐级调整。然而，在实际应用中，尤其是在面对崎岖路面和存在不确定性的反作用轮无人自行车平衡控制问题时，由于外部扰动和系统不确定性的持续影响，给出何时以及如何进行参数调整的逐级切换判定条件变得相对困难。因此，在 RS-TSMC 中，滑模控制参数已知许用调节范围的假设，仅涉及趋近律参数 φ 和 ϑ。

根据控制律式 (3-2) 和文献 [131] 可得，s_2 从任意初始状态 $s_2\left(0\right)\neq 0$ 收敛到平衡状态 $s_2=0$ 的时间为，

$$t_{s_2}=\frac{p_2}{\varphi\left(p_2-q_2\right)}ln\frac{\varphi s_2\left(0\right)^{\left(p_2-q_2\right)/p_2}+\vartheta}{\vartheta} \tag{4-17}$$

从公式 (4-17) 可以看到，参数 φ 和 ϑ 对滑模变量的趋近过程具有显著影响。较大的参数值能够缩短收敛所需的时间，并提升控制器对不确定性等因素的鲁棒性。然而，较大的控制器参数也会导致反作用轮无人自行车横滚角摆动的幅值增加，使控制器的性能变得更加保守。

因此，鉴于在线学习过程中存在的探索噪声及持续激励条件等因素，为进一步保障无人自行车平衡控制在线学习的稳定性，提出以下假设：假设存在集合 $\mathcal{K}$ 使得系统能够满足有限时间收敛条件，$\kappa\in\mathcal{K}=\left\{\kappa_{i\min}\leqslant\kappa_i\leqslant\kappa_{i\max}\right\}\left(i=1,2\right)$，参数 φ 和 ϑ 的时变调节量为 $\kappa=\left[\Delta\varphi,\Delta\vartheta\right]^{\mathrm{T}}$，则自学习部分的输出满足以下不等式：

$$\left[\kappa_{1\min},\kappa_{2\min}\right]\zeta_s<\left|u_{adp}\right|<\left[\kappa_{1\max},\kappa_{2\max}\right]\zeta_s \tag{4-18}$$

中国知网 https://www.cnki.net

其中，$\zeta_s = \left[s_2, s_2^{q_2/p_2}\right]^{\mathrm{T}}$。公式 (4-18) 可以用于，在反作用轮无人自行车平衡控制的在线学习过程中，实施控制器输出的饱和约束。

本章所提出的 RS-TSMC 算法的伪代码见表4-1。

表 4-1 RS-TSMC 算法伪代码
Table4-1 Pseudo code of RS-TSMC algorithm

RS-TSMC 算法
初始化 $\hat{W}_c(0)$ 和 $\hat{W}_a(0)$ 循环: 采集状态，基于公式 (2-23) 和公式 (4-3) 计算 $V_c(t)$ 根据公式 (4-15)，计算 $\hat{W}_c(t)$ 和 $\hat{W}_a(t)$ 根据公式 (3-2)，计算 u_{tsmc} 利用公式 (4-13) 和公式 (4-18)，计算饱和约束下的 $\hat{u}_{adp}$ 通过公式 (2-25)，得到反作用轮控制力矩指令 τ

4.3.2 鲁棒在线自学习算法的稳定性分析

定义值函数网络和策略网络如公式 (4-19) 所示，

$$\begin{aligned} V_c^*(X) &= W_c^{\mathrm{T}}\phi(\boldsymbol{x}) + \varepsilon_c \\ u_{adp}^*(X) &= W_a^{\mathrm{T}}\varphi(\boldsymbol{x}) + \varepsilon_a \end{aligned} \tag{4-19}$$

式中 ε_c———值函数的逼近误差（无量纲）；

ε_a———策略网络逼近误差（无量纲）；

定义目标权重和当前权重的差值为 $\tilde{W}_c = W_c - \hat{W}_c$，策略网络目标权重和当前权重的差值为 $\tilde{W}_a = W_a - \hat{W}_a$，其中 W_c 和 W_a 表示目标权重，$\hat{W}_c$ 和 $\hat{W}_a$ 表示网络当前权重。

根据公式 (4-14) 可得，

$$\begin{aligned} &V_c^*(\boldsymbol{x}_t) - V_c^*(\boldsymbol{x}_{t-T}) = \\ &-\int_{t-T}^{t}\left(2r\left(u_{tsmc} + u_{adp}^*\right)\left(u_s - {u_{adp}}^*\right) + \boldsymbol{x}^{\mathrm{T}}Q\boldsymbol{x} + r\left(u_{tsmc} + {u_{adp}}^*\right)^2\right)d\tau \end{aligned} \tag{4-20}$$

将式 (4-19) 代入 (4-20) 可得，

$$\begin{aligned} &\left(W_c^{\mathrm{T}}\phi(\boldsymbol{x}_t) + \varepsilon_c(t)\right) - \left(W_c^{\mathrm{T}}\phi(\boldsymbol{x}_{t-T}) + \varepsilon_c(t-T)\right) = \\ &-\int_{t-T}^{t}\left(\begin{array}{c} 2r\left(u_{tsmc} + W_a^{\mathrm{T}}\varphi(\boldsymbol{x}) + \varepsilon_a\right)\left(u_s - W_a^{\mathrm{T}}\varphi(\boldsymbol{x}) - \varepsilon_a\right) + \\ \boldsymbol{x}^{\mathrm{T}}Q\boldsymbol{x} + r\left(u_{tsmc} + W_a^{\mathrm{T}}\varphi(\boldsymbol{x}) + \varepsilon_a\right)^2 \end{array}\right)d\tau \end{aligned} \tag{4-21}$$

将神经网络表达式 (4-16) 代入，可得关于逼近误差的函数，

中国知网 https://www.cnki.net

$$\begin{aligned}\epsilon(t) &= \left(W_c - \tilde{W}_c\right)\left(\phi(\boldsymbol{x}_t) - \phi(\boldsymbol{x}_{t-T})\right) + \\ \int_{t-T}^{t} &\left(\begin{array}{c} 2r\left(u_{tsmc} + \left(W_a - \tilde{W}_a\right)\varphi(\boldsymbol{x})\right) \\ \left(u_s - \left(W_a - \tilde{W}_a\right)\varphi(\boldsymbol{x})\right) + \boldsymbol{x}^{\mathrm{T}} Q \boldsymbol{x} + r\left(u_{tsmc} + \left(W_a - \tilde{W}_a\right)\varphi(\boldsymbol{x})\right)^2 \end{array} \right) d\tau \end{aligned} \tag{4-22}$$

式 (4-22) 与式 (4-21) 做差，

$$\epsilon(t) = -\left(\tilde{W}_c\left(\phi(\boldsymbol{x}_t) - \phi(\boldsymbol{x}_{t-T})\right) + \tilde{W}_a\eta(t) - \int_{t-T}^{t} rW_a\varphi(\boldsymbol{x})\,\tilde{W}_a\varphi(\boldsymbol{x})\,d\tau - \varepsilon_{HJB}\right) \tag{4-23}$$

其中，$\varepsilon_{HJB} = -\left[\varepsilon_c(t) - \varepsilon_c(t-T)\right] - \int_{t-T}^{t}\left(2r\varepsilon_a\left(u_s - W_a^{\mathrm{T}}\varphi(\boldsymbol{x})\right) - r\varepsilon_a^2\right)d\tau$。

定义 Lyapunov 函数 $L_y = \frac{1}{2\lambda_1}\tilde{W}_c^{\mathrm{T}}\tilde{W}_c + \frac{1}{2\lambda_2}\tilde{W}_a^{\mathrm{T}}\tilde{W}_a$，其导数为，

$$\begin{aligned}\dot{L}_y &= \frac{1}{\lambda_1}\tilde{W}_c^{\mathrm{T}}\dot{\tilde{W}}_c + \frac{1}{\lambda_2}\tilde{W}_a^{\mathrm{T}}\dot{\tilde{W}}_a \\ &= \frac{\epsilon(t)}{m_s^2(t)}\left(\tilde{W}_c\left(\phi(\boldsymbol{x}_t) - \phi(\boldsymbol{x}_{t-T})\right) + \tilde{W}_a\eta(t)\right) \\ &\leqslant -\left\|\frac{\rho(t)}{m_s(t)}\tilde{W}\right\|\left[\left\|\frac{\rho(t)}{m_s(t)}\tilde{W}\right\| - \left\|\frac{\varepsilon_H}{m_s(t)}\right\|\right]\end{aligned} \tag{4-24}$$

其中，$\rho(t) = \left[\phi^{\mathrm{T}}(\boldsymbol{x}_t) - \phi^{\mathrm{T}}(\boldsymbol{x}_{t-T}), \eta^{\mathrm{T}}(t)\right]^{\mathrm{T}}$，$\tilde{W} = \left[\tilde{W}_c^{\mathrm{T}}, \tilde{W}_a^{\mathrm{T}}\right]^{\mathrm{T}}$。

因此，$\dot{L}_y \leq 0$，当 $\left\|\frac{\rho(t)}{m_s(t)}\tilde{W}\right\| > \left\|\frac{\varepsilon_H}{m_s(t)}\right\|$，$\|m_s(t)\| > 1$。基于本章给出的滑模控制器参数可调范围已知的假设，可以得到网络权重有界，结合文献 [65] 的引理 2 可得，$\tilde{W}_c$ 和 $\tilde{W}_a$ 符合一致最终有界。

4.4 鲁棒在线自学习无人自行车平衡控制仿真测试

本节首先对比本章提出的 RS-TSMC 算法和第三章提出的 SPRL，以展现本章所提出的 RS-TSMC 算法在鲁棒性提升方面的优势。随后，对比 RS-TSMC 算法与近期相关研究中提出的 R-TSMC 算法和 S-TSMC 算法，以展示本章 RS-TSMC 中鲁棒自适应机制及输出饱和约束的有效性。

RS-TSMC 中值函数网络和策略网络的定义如下，

$$\begin{aligned}\phi(\boldsymbol{x}) &= \left[x_1^2, x_2^2, x_1x_2, x_1^4, x_2^4, x_1^2x_2^2\right]^T \\ \varphi(\boldsymbol{x}) &= \left[x_1, x_2, x_1^2, x_2^2, x_1x_2, x_1^4, x_2^4, x_1^2x_2^2\right]^T\end{aligned} \tag{4-25}$$

RS-TSMC 中相关参数设置如下，

$$\begin{aligned}Q = \mathrm{diag}\{1,1\}, r = 1 \\ \kappa_{1\max} = \kappa_{2\max} = 0.8, \kappa_{1\min} = \kappa_{2\min} = -0.8 \\ \lambda_1 = 0.2, \lambda_2 = 0.1\end{aligned} \tag{4-26}$$

中国知网 https://www.cnki.net

（1）对比 RS-TSMC 和 SPRL

为了展现本章所提出的 RS-TSMC 在线学习算法，相较于 SPRL 算法在崎岖路面及系统不确定性下反作用轮无人自行车平衡控制在线学习中的优势，本小节在第二章设计的 18 个仿真任务中对上述算法进行测试。

由于上述算法都能够完成除仿真测试场景 3 外的仿真测试任务，因此表4-2中仅列出场景 3 的仿真测试完成情况。从该表可以看出，RS-TSMC 完成了所有仿真测试任务，相较于 SPRL，进一步提升了平衡控制的鲁棒性。

表4-3和表4-4分别统计了仿真测试任务 1 和仿真测试任务 2 中，横滚角跟踪误差的均方值以及 RS-TSMC 相较于 SPRL 减少的百分比。在仿真测试任务 1 中，RS-TSMC 算法下，跟踪误差的均方根值相较于 SPRL 平均降低了 40.2%。这一结果验证了本章所提出的 RS-TSMC 算法的有效性。在仿真测试任务 2 中，RS-TSMC 方法使得跟踪误差的均方根值平均减少了 5.4%。这一降幅不及仿真测试任务 1 的表现，其可能是由于任务 2 中引入了路径跟随，导致崎岖路面和系统不确定性对平衡控制性能的影响更加显著。另一个可能的原因在于，人为设定的滑模控制器参数的许用调节范围可能较为保守，这对仿真测试任务 2 的影响更显著。在所有仿真测试任务中，RS-TSMC 相较于 SPRL 平均减少了 22.9%。

表 4-2 场景 3 的仿真测试完成情况 (s)

Table4-2 Simulation test completion status of case 3(s)

算法	任务 1			任务 2		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
SPRL	-	-	-	45.6	-	-
RS-TSMC	-	-	-	-	-	-

表 4-3 任务一中跟踪误差的 RMS($10^{-3}rad^2$)

Table4-3 RMS tracking error of task 1 ($10^{-3}rad^2$)

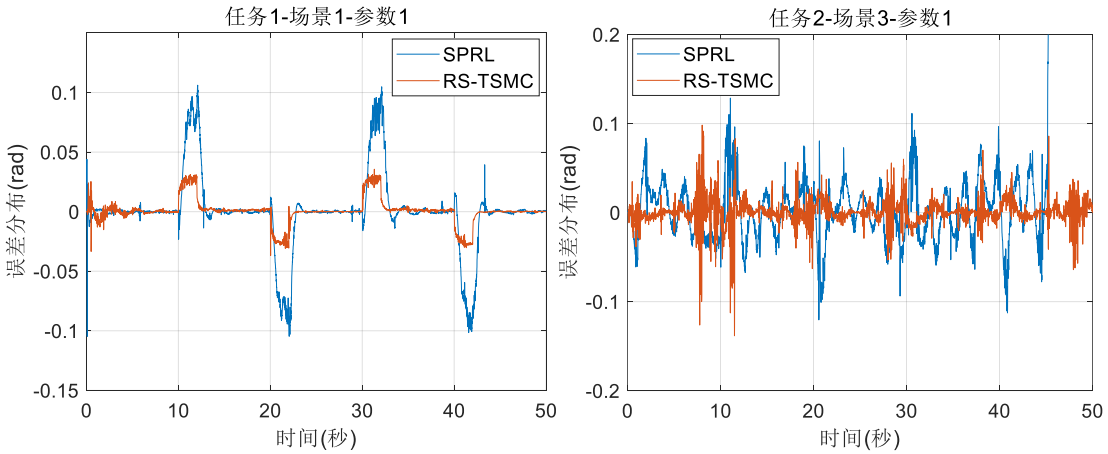
任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
SPRL	0.953	0.925	0.806	0.943	0.930	0.811	1.29	1.22	1.07
RS-TSMC	0.566	0.498	0.453	0.476	0.499	0.473	0.843	0.708	0.887
ξ	40.6%	46.2%	43.8%	49.5%	46.3%	41.7%	34.7%	41.9%	17.1%

图4-2绘制了任务 1、场景 1、参数 1 和任务 2、场景 3、参数 1 中，SPRL 和 RS-TSMC 的横滚角跟踪误差随时间的变化。图4-2(a) 中可以看出，在大约 5 秒后，RS-TSMC 的横滚角跟踪误差显著小于 SPRL。图4-2(b) 中，大约在 10s 后，RS-TSMC 的横滚角跟踪误差也小于 SPRL。说明 RS-TSMC 相较于 SPRL 进一步提高了反作用无人自行车的平衡控制效果。

中国知网 https://www.cnki.net

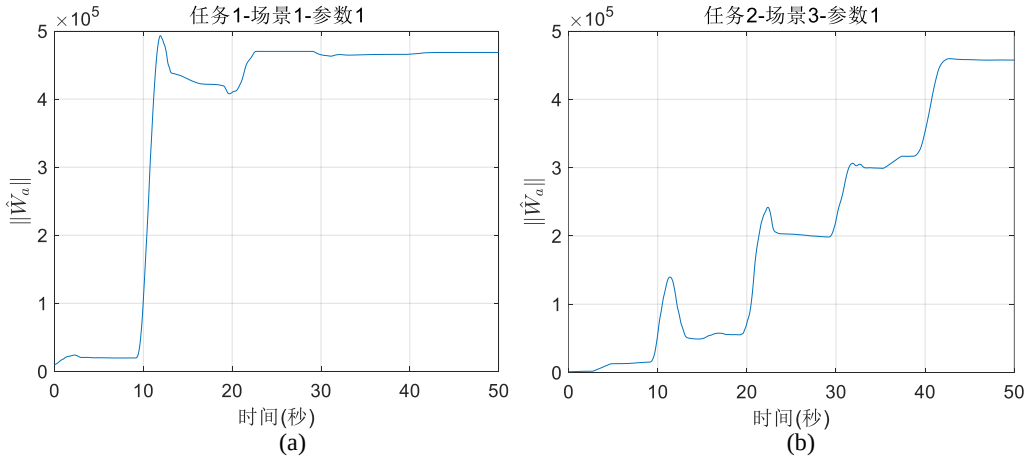
表 4-4 任务二中跟踪误差的 RMS(10^{-3}rad^2)
Table4-4 RMS tracking error of task 2 (10^{-3}rad^2)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
SPRL	0.600	0.600	0.529	0.720	0.692	0.640	-	0.998	0.870
RS-TSMC	0.518	0.479	0.499	0.696	0.698	0.695	0.880	0.942	0.832
ξ	13.7%	20.2%	5.7%	3.3%	-0.9%	-8.6%	-	5.6%	4.37%



(a) (b)

图 4-2 横滚角跟踪误差随时间的变化
Fig.4-2 Variation of roll angle tracking error with time



(a) (b)

图 4-3 RS-TSMC 网络权重的变化
Fig.4-3 Weights respect to the time under RS-TSMC

图4-3展示了 RS-TSMC 策略网络权重范数随时间的变化。在图4-3(a) 中，策略网络权重的范数在 20 秒左右趋于定值，表明策略网络训练趋于稳定。在图4-3(b) 中，范数的变化与外部阶跃扰动施加的时间相一致，表明 RS-TSMC 算法在在线学习过程中表现出对扰动的适应能力。综上所述，仿真测试结果表明了本章所提出

中国知网 https://www.cnki.net

RS-TSMC 算法的有效性。本章提出的算法相比于第三章中所提出的串并联强化学习算法，不仅得到了在线学习过程的稳定性保障，提升了平衡控制的鲁棒性，而且进一步提升了反作用轮无人自行车的平衡控制性能。

（2）对比 RS-TSMC 与 S-TSMC 和 R-TSMC

为验证本章所提出的 RS-TSMC 控制器的有效性，在第二章建立的仿真测试环境及路径跟随的基础上，参考文献 [69] 设计两个测试案例，并将其与文献 [69] 中构建的 S-TSMC 算法和文献 [67] 中提出的 R-TSMC 算法进行比较。

在测试案例 1 中，设置在无人自行车质心处的横滚扰动为，

$$d_{l2} = 0.02 \sum_{j} \sin(jt) \tag{4-27}$$

其中，$j = [1, 3, 7, 11, 13, 15]$。

在测试案例 2 中，设置在无人自行车质心处的横滚扰动为，

$$d_{l2} = 0.02 \sum_{j} \sin(jt) + \begin{cases} 0.2, t \in [10, 12) \cup t \in [30, 32) \\ -0.2, t \in [20, 22) \cup t \in [40, 42) \\ 0, else \end{cases} \tag{4-28}$$

采用优化目标中的代价函数 V_c 作为控制性能指标的度量，仿真测试结果如表4-5所示。从表4-5可以看出，RS-TSMC 算法在测试案例 1 中相较于 TSMC 算法，代价函数累计减少了 39.79%，显著优于 R-TSMC 的 7.73% 和 S-TSMC 的 6.41%。在测试案例 2 中，RS-TSMC 算法相较于 TSMC 算法减少了 15.91%，同样优于 R-TSMC 的 11.59% 和 S-TSMC 的 2.42%。

表 4-5 不同测试案例下的控制性能评估

Table4-5 Assessment of control performance under different cases

	RS-TSMC	TSMC	R-TSMC[119]	S-TSMC[118]
测试案例 1	9.11	15.13	13.96	14.16
ξ	39.79%	-	7.73%	6.41%
测试案例 2	48.99	58.26	51.51	56.85
ξ	15.91%	-	11.59%	2.42%

图4-4展示了仿真测试案例 1 中四种控制算法下，状态、控制器输出及代价函数随时间的变化情况。从图4-4可以看出，本文提出的 RS-TSMC 算法对应的 V_c 始终小于其他对比算法。状态和控制器输出的曲线进一步表明，所提出的算法在控制性能上优于其他三种算法。

图4-5则展示了 RS-TSMC 算法下 $\|\hat{W}_c\|$ 和 $\|\hat{W}_a\|$ 随时间的变化情况。根据图4-5，$\|\hat{W}_c\|$ 在约 12 秒时收敛，而 $\|\hat{W}_a\|$ 在约 20 秒时收敛。

中国知网 https://www.cnki.net

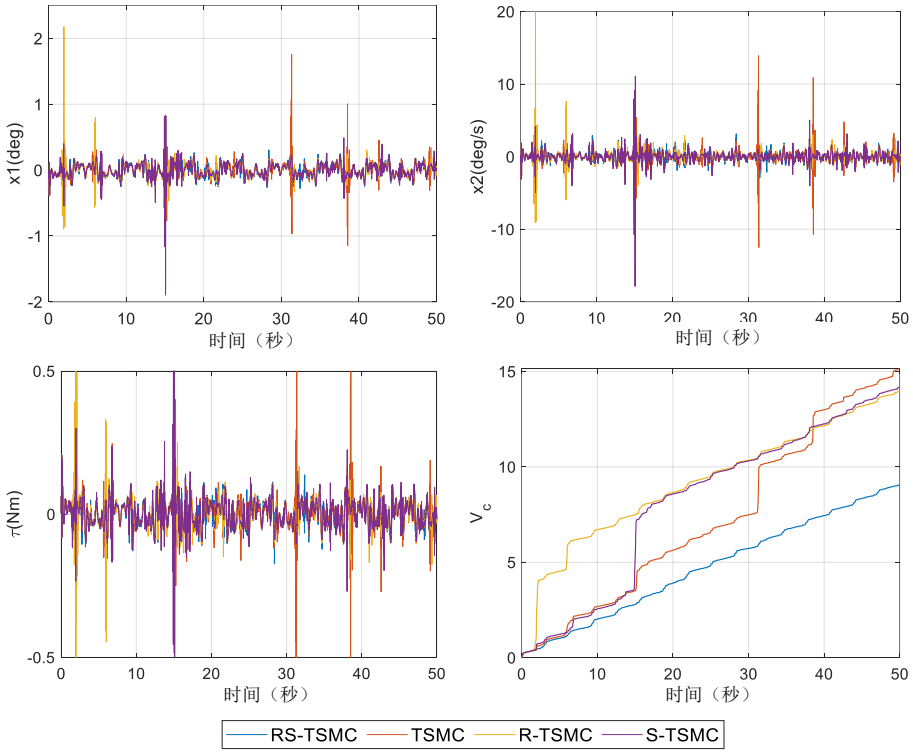


图 4-4 测试案例 1 中四种不同算法下状态随时间的变化

Fig.4-4 States with respect to the time under four different algorithms in case 1

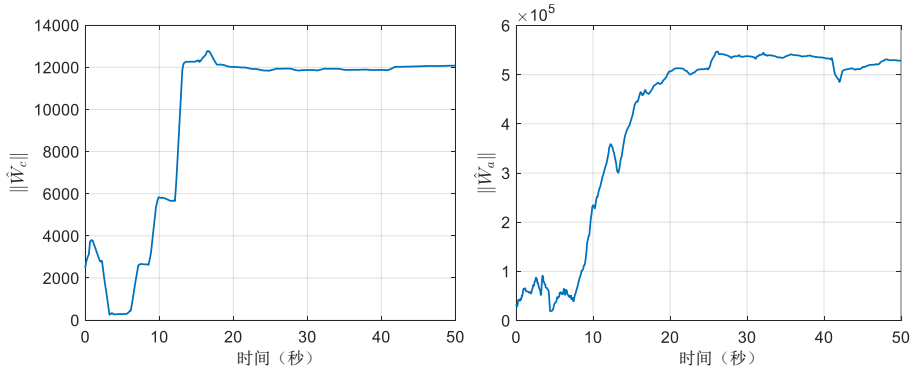


图 4-5 测试案例 1 中 RS-TSMC 网络权重的变化

Fig.4-5 Weights respect to the time under RS-TSMC in case 1

仿真测试案例 2 的结果见图4-6和图4-7。图4-6中展示的状态、系统输出及代价函数随时间变化的曲线。从图4-6中可以看到，RS-TSMC 算法下横滚角跟踪误差显著小于 TSMC、R-TSMC 和 S-TSMC 算法下的横滚角跟踪误差。并且 RS-TSMC 算法下控制器输出也小于其他三种对比算法。因此，本章提出的 RS-TSMC 算法具有更好的控制性能。代价函数随时间的变化曲线也验证了该结论。从图4-7可以观察到，在 10 秒后脉冲扰动对 $\|\hat{W}_c\|$ 产生了显著影响，进而导致 $\|\hat{W}_a\|$ 随着脉冲扰动呈现出规律性的变化。这表明在线学习算法对扰动有一定的在线适应能力。综上

中国知网 https://www.cnki.net

所述，从两个仿真测试案例中可以看出，本章提出的 RS-TSMC 相较于 R-TSMC 和 S-TSMC 能够实现更优的横滚角跟踪控制性能。

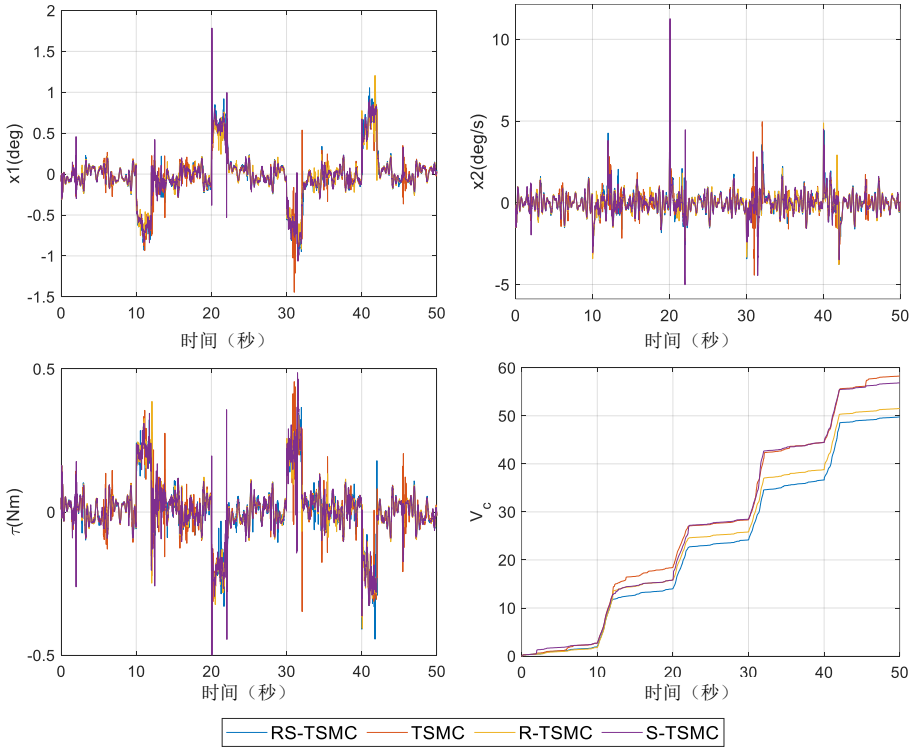


图 4-6 测试案例 2 中四种不同算法下状态随时间的变化

Fig.4-6 States with respect to the time under four different algorithms in case 2

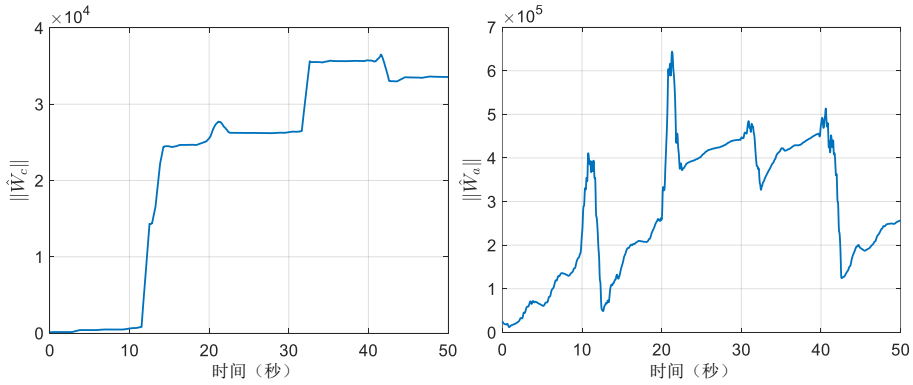


图 4-7 测试案例 2 中 RS-TSMC 网络权重的变化

Fig.4-7 Weights respect to the time under RS-TSMC in case 2

4.5 鲁棒在线自学习无人自行车平衡控制实物实验

（1）对比 RS-TSMC 和 SPRL

在路径跟随实验中，对 RS-TSMC 算法和 SPRL 算法的平衡控制性能进行对

中国知网 https://www.cnki.net

比。图4-8呈现了在扰动幅值为 2.0V 时，RS-TSMC 算法下反作用轮无人自行车样机实验的视频截图。图4-9(a) 呈现了 SPRL 和 RS-TSMC 下横滚角跟踪误差随时间的变化，从该图中可以看出 RS-TSMC 最大跟踪误差显著小于 SPRL。跟踪误差均方值方面，两者相差不大。图4-9(b) 为横滚角跟踪误差的箱形图，更清晰地呈现了该结论。计算 RS-TSMC 横滚角跟踪误差的均方值为 $2.65\times10^{-4}\text{rad}^2$，SPRL 下横滚角跟踪误差的均方值为 $2.93\times10^{-4}\text{rad}^2$，则 RS-TSMC 相较于 SPRL 的横滚角跟踪误差均方值减少了 9.6%。



图 4-8 路径跟随下的样机实验

Fig.4-8 The path following prototype experiment

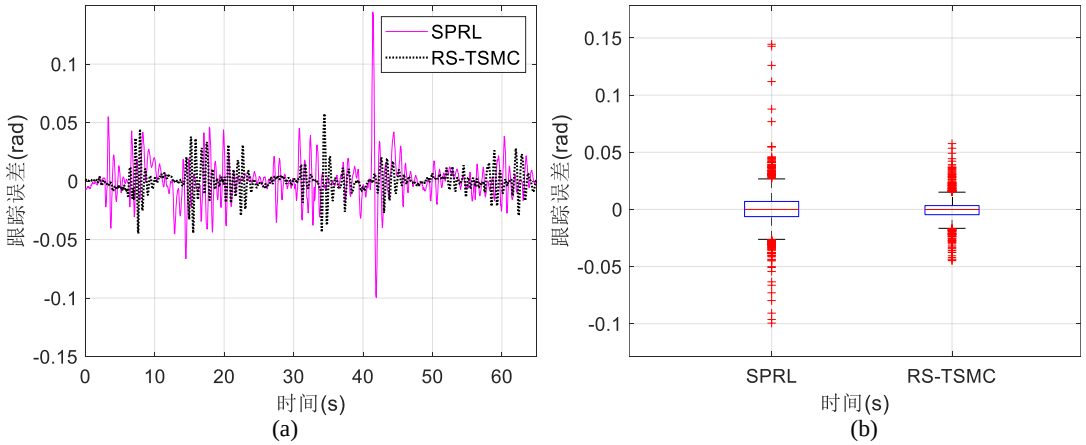


图 4-9 横滚角跟踪误差随时间的变化及其分布情况

Fig.4-9 Variation of roll angle tracking error with time and distribution

RS-TSMC 相较于 SPRL 减小了跟踪误差的最大值，其原因可能是，RS-TSMC 通过其鲁棒自适应动态规划机制能够更准确地逼近系统的动态特性，这使得控制策略更加贴合实际系统的需求，进而减少跟踪误差。而 SPRL 虽然也通过深度学习来近似控制策略，但可能不如 RS-TSMC 在处理系统动态特性时那样精确。

（2）对比 RS-TSMC 与 S-TSMC 和 R-TSMC

本节对比 S-TSMC 算法、R-TSMC 算法和本章提出的 RS-TSMC 算法下，反作用轮无人自行车在直线行驶任务中的表现。该任务通过车把的正弦摆动引入了对横滚角的扰动。RS-TSMC 算法下的实验视频截图见图4-10。

中国知网 https://www.cnki.net

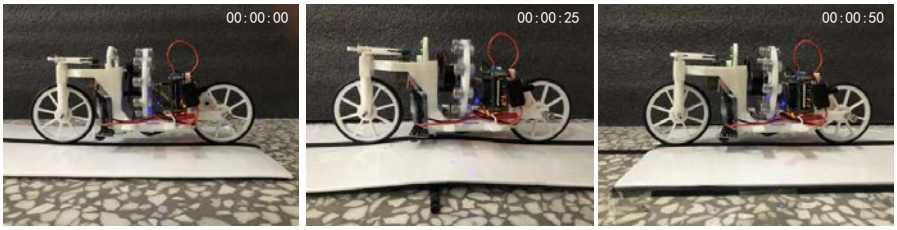


图 4-10 曲面路面直线行驶下的样机实验

Fig.4-10 Prototype experiment under straight-line driving on a curved road surface

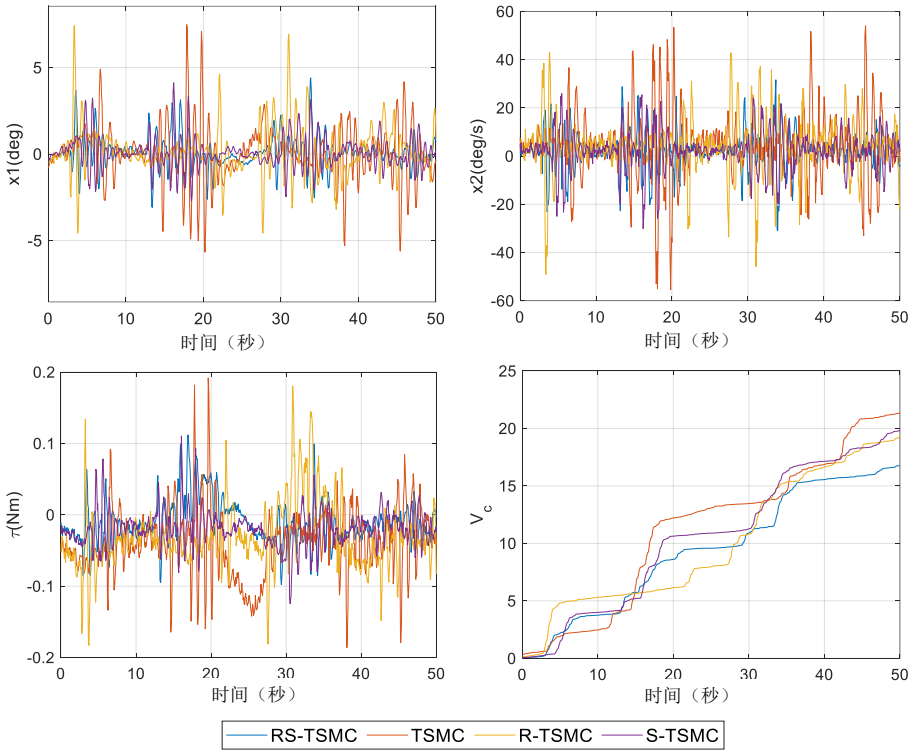


图 4-11 实验中状态随时间的变化

Fig.4-11 States with respect to the time in experiment

图4-11展示了在不同算法下，横滚角跟踪误差、横滚角跟踪误差的变化率、控制器输出以及代价函数随时间的变化情况。从图4-11可以观察到，在前 10 秒内，三种优化算法的控制效果与 TSMC 滑模算法相比，差异并不显著。这一现象可能由两个因素造成：首先，反作用轮无人自行车在不同算法实验中的初始横滚角及横滚角速度引入的干扰；其次，由于硬件计算资源的限制，优化算法的更新频率仍然会低于 TSMC 的控制频率。随着优化算法的迭代进行，在 20 秒后，三种优化算法的控制效果逐渐优于 TSMC。在 50 秒时，RS-TSMC 算法下的 V_c 为 14.19，TSMC 为 21.41，R-TSMC 为 19.44，S-TSMC 为 19.80，则 RS-TSMC 相较于 TSMC 的累计代价降低了 33.72%，而 R-TSMC 和 T-TSMC 相较于 TSMC 的降低幅度均为 9.20% 和 7.52%。此外，值得注意的是，在整个实验过程中，RS-TSMC 的跟踪误差和代

中国知网 https://www.cnki.net

价函数始终小于其他两种优化算法。图4-12绘制了误差分布的箱形图，可以看到 RS-TSMC 的跟踪误差更集中于原点，验证了上述分析。

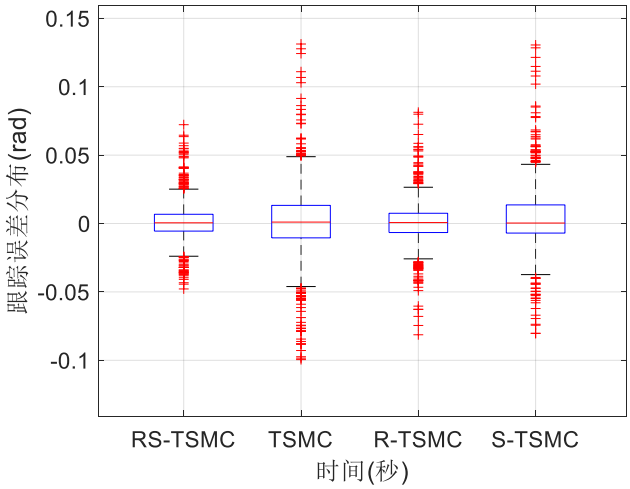


图 4-12 跟踪误差的分布情况
Fig.4-12 Distribution of tracking error

表 4-6 实验中 V_c 随时间的变化
Table4-6 The V_c with respect to the time in experiment

	RS-TSMC	TSMC	R-TSMC[119]	S-TSMC[118]
	14.19	21.41	19.44	19.80
ξ_{TSMC}	33.72%	-	9.20%	7.52%

综上所述，反作用轮无人自行车的平衡控制实验结果验证了所提出的 RS-TSMC 算法的有效性。

4.6 本章小结

针对串并联在线强化学习滑模控制算法缺乏稳定性保障的问题，本章提出了鲁棒自适应动态规划无人自行车平衡控制算法。该算法基于自适应动态规划算法，引入了鲁棒自适应动态规划机制，削弱自适应动态规划对精确系统模型的依赖，并在滑模控制器参数许用调节范围已知的假设条件下，构建了输出饱和约束，得到了强化学习算法在线训练的稳定性保障。

通过两个仿真测试案例对比了本章所提出的 RS-TSMC 算法与相关文献中提出的 R-TSMC 和 S-TSMC，本章算法在测试案例上相较于 TSMC 的横滚角跟踪误差分别减小了 39.79% 和 15.91%，现有相关算法仅减小了 7.7%、11.59% 和 6.41%、2.42%。展示了本章所提出在线学习算法的优势。通过对比 RS-TSMC 和第三章中提出的 SPRL，RS-TSMC 完成了所有 18 个仿真测试任务，而 SPRL 完成了 17 个。

中国知网 https://www.cnki.net

说明具有稳定性保障的 RS-TSMC 在仿真测试中具有更强的鲁棒性。此外，在所有仿真测试中 RS-TSMC 相较于 SPRL 的横滚角跟踪误差平均减少了 22.9%。在 RS-TSMC 算法与 R-TSMC 和 S-TSMC 对比的实物实验中，RS-TSMC 相较于 TSMC 的横滚角跟踪误差减少了 33.72%，而 R-TSMC 和 S-TSMC 相对于滑模控制的横滚角跟踪误差减少了约 10%。在 RS-TSMC 算法与 SPRL 的实物实验对比中，跟踪误差均方值减少了 9.6%。上述仿真和实验展现了本章提出的 RS-TSMC 算法在反作用轮无人自行车平衡控制上的有效性。

中国知网 https://www.cnki.net

第 5 章 概率安全保障的在线强化学习无人自行车平衡控制

5.1 引言

第四章提出了鲁棒自适应动态规划稳定性保障的无人自行车平衡控制算法，并对控制性能进行了对比分析。尽管该方法能够为在线训练过程提供稳定性证明，并在滑模控制的基础上显著提升了平衡控制性能，但该算法仍存在如下的局限性。首先，鲁棒自适应动态规划稳定性保障的无人自行车平衡控制算法的稳定性保障受限于特定的学习算法。其次，该算法的稳定性分析依赖于对滑模控制器参数可调范围已知的假设条件。

本章提出概率安全保障的在线强化学习无人自行车平衡控制算法，该算法基于系统不确定性符合高斯分布的假设条件，综合考虑不确定性概率预测对系统安全性及在线学习的影响，进一步提升反作用轮无人自行车平衡控制在线学习过程的安全性。

5.2 问题描述

为了提升强化学习在线训练过程的鲁棒性，第四章提出了鲁棒自适应动态规划稳定性保障的无人自行车平衡控制算法。然而该算法仍然需要依赖于滑模控制器参数可调范围已知的假设条件。这在实际应用中，通常通过人为设定一个相对保守的调节范围来满足这一假设条件。不合理的调节范围可能影响平衡控制的在线优化，进而影响控制性能。为解决上述问题，本章引入安全强化学习的相关概念及研究成果，为强化学习在线训练提供安全性保障。

安全强化学习这一概念最早出现在文献 [70] 中。其主要目标是学习一种策略，以最大化预期回报，同时确保满足给定的安全约束。安全约束通常以状态空间前向不变集的形式给出。通过前文绪论中对相关研究现状的分析，可以看到，控制障碍函数（CBFs）是实现安全在线强化学习的少数有效手段之一。

控制障碍函数通常通过系统模型和系统前向不变集，将在状态约束条件下的控制器输出求解转化为在线二次规划问题。该方法旨在求解出与原始控制输出范数距离最小的控制输出，同时确保系统状态不违反安全约束。CBFs 的一个显著缺陷在于其对动态系统精确数学模型的依赖。尽管将控制障碍函数与高斯过程回归相结合为不确定性下系统的安全性保障提供了新的思路，但现有研究较少同时考

中国知网 https://www.cnki.net

虑系统不确定性对安全约束及强化学习探索优化过程的综合影响。在存在系统不确定性的情况下，确保反作用轮无人自行车平衡控制在线强化学习的安全性仍然是一个未得到充分研究的问题。

对安全在线强化学习问题进行一般性描述。

$$\boldsymbol{x}_{k+1} = f(\boldsymbol{x}_k) + g(\boldsymbol{x}_k)\boldsymbol{u}_k + \boldsymbol{d}_k \tag{5-1}$$

其中，$\boldsymbol{x}_k \in \mathcal{X} \subseteq \mathbb{R}^n$ 表示系统的状态，$d_k \subseteq \mathbb{R}^n$ 表示由未建模动态和扰动引起的系统不确定性，$\boldsymbol{u}_k \in \mathcal{U} \subseteq \mathbb{R}^m$ 表示时间步 k 时的控制器输出，$\boldsymbol{u}_k$ 的初始值 $\boldsymbol{u}_k^*$ 由本文前述章节中在线强化学习与滑模控制结合得到，$\mathcal{U}$ 表示控制器许用输出，$f(\cdot)$ 和 $g(\cdot)$ 由采样时间对系统标称模型离散得到。

假设存在光滑函数 $B: \mathcal{X} \to R$ 将系统状态映射到实数域，则安全集合 $\mathcal{S}$ 定义如下，

$$\mathcal{S} = \{\boldsymbol{x}_k \in \mathcal{X} | B(\boldsymbol{x}_k) \geq 0\} \tag{5-2}$$

安全在线强化学习的目标在于确定控制变量 u_k，以确保系统 (5-1) 能够满足约束条件 (5-2) 和 (5-3)，并在此约束中实现控制性能的在线优化。

$$\min_{u_k \in \mathcal{U}} \left\| u_k - u_k^* \right\|^2 \tag{5-3}$$

此外，本研究还考虑了传统离线强化学习与在线强化学习的探索噪声在训练过程影响方面的差异。在传统的离线强化学习中，策略优化需要在探索与利用之间进行权衡，这通常通过逐步减小探索噪声来实现。通常来说，传统离线强化学习训练中探索噪声的设置，并不会对策略的迁移产生直接的影响。然而，在在线强化学习中，不当的探索噪声不仅会影响学习效率，还可能导致系统发散，从而使得探索噪声的设置变得更加复杂。如何合理设置在线强化学习中的探索噪声仍需进一步探讨。

5.3 无人自行车概率安全保障的在线强化学习平衡控制算法

本章提出一种具有概率安全保障的在线强化学习算法，称为具有概率保障的安全在线强化学习（Safe Online Reinforcement Learning with Probabilistic Guarantees, SRLP）。该算法将探索噪声匹配（Exploration Noise Matching, ENM）与高斯控制障碍函数（Gaussian Control Barrier Function, GCBF）相结合。ENM 通过高斯过程回归（GPR）对系统的不确定性进行预测，并在线调整强化学习中的探索噪声，以避免因不当的探索噪声导致系统的发散。GCBF 则基于 GPR 构建高斯障碍函数，并根据不确定性预测实时调整约束，从而实现概率安全保障。

中国知网 https://www.cnki.net

SRLP 算法的框图见图5-1，其主要由以下三个部分组成：用于反作用轮无人自行车不确定性预测的高斯过程回归，基于高斯过程回归的探索噪声匹配机制，以及基于高斯过程回归的高斯控制障碍函数。SRLP 算法的伪代码见表5-1。

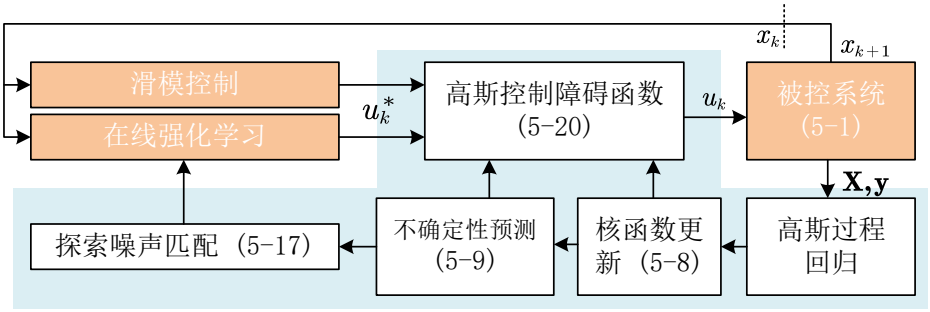


图 5-1 SRLP 算法框图
Fig.5-1 Schematic of SRLP algorithm

表 5-1 SRLP 算法伪代码
Table5-1 Pseudo code of SRLP algorithm

SRLP 算法
定义高斯过程回归采样窗口宽度 N，定义系统安全集合； 初始化在线强化学习经验池 $\mathcal{B}$ 循环： 　计算 u_k^* 　构建高斯过程回归训练样本中的训练输入 $\mathbf{X}$ 和训练目标 $\mathbf{y}$ 直到 $\mathcal{B}$ 中的样本数量大于 N 循环： 　计算 u_k^* 　构建高斯过程回归训练样本中的训练输入 $\mathbf{X}$ 和训练目标 $\mathbf{y}$ 　利用公式 (5-7) 更新高斯过程回归模型 　基于公式 (5-9) 预测下一时刻系统状态的不确定性 　通过公式 (5-17) 计算在线强化学习探索噪声 　求解优化问题 (5-21)，得到 u_k

5.3.1 高斯过程回归

高斯过程回归是一种广泛应用于机器学习领域的技术，尤其适合处理复杂的非线性关系及不确定性建模问题。在利用高斯过程回归进行不确定性预测时，首先需要通过数据样本对高斯回归模型进行拟合。随后，利用已拟合的模型对新的未知数据点进行预测。该预测结果不仅提供了点估计，还包括用于表征预测结果不确定性的置信区间。

为了预测反作用轮无人自行车系统的不确定性，构建在时间步 k 时的高斯过程回归训练样本，包含训练输入 x_k 和训练目标 y_k。

中国知网 https://www.cnki.net

$$\begin{aligned} \mathrm{x}_k &:= \left[q_1(k-1)\ \ \dot{q}_1(k-1)\ \ \dot{q}_2(k-1)\ \ \tau(k-1)\right]^{\mathrm{T}} \\ y_k &:= \triangle_k = q_1(k) - q_1(k-1) \end{aligned} \tag{5-4}$$

其中，q_1 表示无人自行车横滚角、$\dot{q}_1$ 表示横滚角速度、$\dot{q}_2$ 表示反作用轮角速度、τ 为反作用轮控制力矩。

在对非线性模型进行拟合的过程中，高斯过程回归通常依赖于核函数的选择。本文选用一种通用性较强的高斯核函数：

$$k\left(\mathrm{x}_p, \mathrm{x}_q\right) = \sigma_s^2 \exp\left(-\frac{1}{2}\left(\mathrm{x}_p - \mathrm{x}_q\right)^T \mathbf{\Lambda}^{-1}\left(\mathrm{x}_p - \mathrm{x}_q\right)\right) + \sigma_k^2 \delta_{pq} \tag{5-5}$$

在此，x_p 和 x_q 分别代表时刻 p 和 q 的高斯过程回归训练输入，σ_s^2 表示潜在函数的方差，而 σ_k^2 则表示噪声的先验方差。符号 $\mathbf{\Lambda} := \mathrm{diag}\left(\left[\ell_1^2, \cdots, \ell_4^2\right]\right)$ 用于表示特征长度。上述变量构成了高斯过程回归模型的超参数，记作 $\Theta = [\sigma_s, \mathbf{\Lambda}, \sigma_k]$。此外，$\delta_{pq}$ 的定义如下：

$$\delta_{pq} = \begin{cases} 1, p = q \\ 0, p \neq q \end{cases} \tag{5-6}$$

当采集到长度为 N 的数据样本时，$\mathbf{X} = [\mathrm{x}_1, \cdots, \mathrm{x}_N]$，$\mathbf{y} = [y_1, \cdots, y_N]$。可以得到对数似然，

$$\log p\left(\mathbf{y}|\mathbf{X}, \Theta\right) = -\frac{1}{2}\left(N \log(2\pi) + \log\left|K_y\right| + \mathbf{y} K_y^{-1} \mathbf{y}\right) \tag{5-7}$$

其中，$K_y = \mathbf{K} + \sigma_k^2 \mathbf{I}$。$\mathbf{K}$ 为 Gram 矩阵，其元素为 $k_{ij} = k\left(\mathrm{x}_i, \mathrm{x}_j\right)$，$i$ 和 j 分别为行号和列号。

通过最大化对数似然函数可以对高斯过程回归模型超参数进行求解。根据式(5-7)，对高斯过程回归模型的超参数进行求导，可以得到如下结果。

$$\frac{\partial}{\partial \theta_j} \log p(\cdot) = \frac{1}{2} tr\left(\left(K_y^{-1} \mathbf{y}\mathbf{y}^{\mathrm{T}} K_y^{-\mathrm{T}} - K_y^{-\mathrm{T}}\right) \frac{\partial K_y}{\partial \theta_j}\right) \tag{5-8}$$

其中，θ_j 表示 Θ 中的第 j 个元素。通过梯度下降法来优化高斯过程回归模型的超参数 Θ，从而可以获得高斯过程回归模型。

接下来，基于所拟合的高斯过程回归模型以及在时间步 k 时的状态和动作，对下一时刻的状态均值及其不确定性进行预测。该预测结果遵循以下高斯分布：

$$p\left(\hat{q}_{1,k+1} | q_{1,k}, \tau_k\right) = \mathcal{N}\left(\hat{q}_{1,k+1} | \mu_{k+1}, \Sigma_{k+1}\right) \tag{5-9}$$

其中，$\hat{q}_{1,k+1}$ 表示在时刻 $k+1$ 时反作用轮无人自行车的横滚角估计值。后文将采用这种方式简化对状态对应时刻的表述。

中国知网 https://www.cnki.net

可以得到公式 (5-9) 中的均值和方差如下，

$$\begin{aligned} \mu_{k+1} &= \mathbb{E}\left[\triangle_{k+1}\right] + q_{1,k} \\ \Sigma_{k+1} &= var\left[\triangle_{k+1}\right] \end{aligned} \tag{5-10}$$

其中，

$$\begin{aligned} \mathbb{E}\left[\triangle_{k+1}\right] &= \mathbf{k}_{k+1}^{T} K_y^{-1} \mathbf{y} \\ var\left[\triangle_{k+1}\right] &= k_{k+1,k+1} - \mathbf{k}_{k+1}^{T} K_y^{-1} \mathbf{k}_{k+1} \end{aligned} \tag{5-11}$$

上式中，$\mathbf{k}_{k+1} := k\left(\mathbf{X}, \mathrm{x}_{k+1}\right)$，$k_{k+1,k+1} = k\left(\mathrm{x}_{k+1}, \mathrm{x}_{k+1}\right)$，$\mathrm{x}_{k+1} = \left[q_{1,k}\ \dot{q}_{1,k}\ \dot{q}_{2,k}\ \tau_k\right]^{\mathrm{T}}$。公式 (5-12) 以概率 $1-\delta$ 成立，

$$\left|\hat{q}_{1,k+1} - q_{1,k+1}^{*}\right| \leqslant k_\delta \Sigma_{k+1} \tag{5-12}$$

在此，$q_{1,k+1}^{*}$ 表示在时刻 $k+1$ 时反作用轮无人自行车的横滚角的真实值，而 k_δ 则是一个由参数 δ 所决定的设计参数。例如，当 $\delta = 0.03$ 时，k_δ 的值为 3。k_δ 的计算，可参考 [132, 133]。

本文并不基于所有采样数据进行高斯过程回归模型的拟合，而是采用固定长度窗口的采样数据，其中 N 为设定的常数。采用这种方法主要有两个方面的原因：首先，高斯过程回归的计算复杂度为 $O\left(N^3\right)$，滑动窗口的采样方式能够有效避免随着采样点数量的增加而导致的计算量剧增。其次，考虑到本文所探讨的是在线学习问题，滑动窗口的采样方式能够动态调整训练数据集，从而保持模型对最新采样数据的拟合，进而提升在线学习算法的性能与适应性。

5.3.2 探索噪声匹配机制

强化学习中的策略优化依赖于所收集的交互采样数据，因此在交互学习过程中，如何平衡现有策略的应用和状态-动作对的探索显得尤为重要。强化学习探索算法是实现其探索的具体计算方法，指的是智能体在学习过程中如何选择动作以进行探索，从而发现未知的状态-动作对，以便更好地理解环境并学习最优控制策略。利用机制则是指智能体基于已有的知识和经验，在当前状态下选择其认为最优的动作，以最大化累积奖励的期望值。

强化学习中常用的探索算法，包括 ϵ-贪婪探索[102]、玻尔兹曼探索[134]、置信区间上界[135] 以及噪声扰动探索[136]。这些探索算法最初是为了解决有限状态动作空间中的探索与利用问题而提出的。随着强化学习领域的发展，从有限状态动作空间扩展到连续状态动作空间，上述算法在众多连续状态动作空间的强化学习问

中国知网 https://www.cnki.net

题中得到了广泛应用，并展现出良好的适用性，因此被广泛用作基线方法。以下对 ϵ-贪婪探索和噪声扰动探索进行简要介绍。

ϵ-贪婪探索是一种对贪婪策略的改进。贪婪策略是在状态 $\boldsymbol{x}$ 下直接选择使得 Q 值最大的动作，即 $u = \arg\max_u Q(\boldsymbol{x}, u)$。然而，由于 Q 函数的估计可能并不准确，贪婪策略往往会导致算法收敛于局部最优策略。因此，为了在强化学习算法的训练过程中保持探索与利用之间的平衡，提出了一种直观的改进方法——ϵ-贪婪探索。该方法以 $1-\epsilon$ 的概率选择使得 Q 值最大的动作，而以 ϵ 的概率在动作空间中随机选择动作，见公式 (5-13)。ϵ-贪婪探索主要适用于离散动作空间的任务，例如在 Q 学习算法和深度 Q 网络（DQN）算法中得到了应用。

$$u = \begin{cases} \arg\max_u Q(\boldsymbol{x}, u), & 1-\epsilon \\ \mathrm{Unif}(\mathcal{U}), & \epsilon \end{cases} \tag{5-13}$$

噪声扰动的探索方法通常应用于连续动作空间的强化学习算法。该方法通过在智能体的目标策略生成的动作上添加高斯噪声，使得智能体能够对当前选择动作邻域内的动作值进行探索。本文中所选用的 TD3 强化学习算法采用了噪声扰动的探索策略，即在强化学习策略网络的输出上叠加方差逐渐衰减的高斯噪声，具体表达式见公式 (5-14)。随着强化学习训练的不断进行，σ_d 的值逐渐减小，从而使得智能体在探索和利用之间的选择上，愈加倾向于利用已获得的“经验”。

$$u = \pi(\boldsymbol{x}) + \mathcal{N}\left(0, \sigma_d(t)^2\right) \tag{5-14}$$

式中 σ_d———随时间变化的高斯噪声方差，量纲与策略输出相同；

在传统的强化学习框架中，智能体在初始交互阶段通常会选择较高的噪声水平，以便充分探索环境。随着时间的推移，智能体会逐步降低探索噪声水平，从而实现对已训练得到策略的利用。公式 (5-15) 展示 TD3 算法所采用的噪声方差。

$$\sigma_n = \max\left(a\sigma_0^{bk}, \sigma_{sat}\right) \tag{5-15}$$

式中 a、b———给定超参数（无量纲常数）；

k———强化学习训练的时间步（无量纲变量）；

σ_0———初始策略噪声，量纲与策略输出相同；

σ_{sat}———最小策略噪声，量纲与策略输出相同；

由于在 $k < N$ 时，尚未进行高斯过程的拟合与预测，因此本节采用式 (5-16) 中所示的噪声方差，以便于与基于高斯过程回归的噪声匹配进行比较。

$$\sigma_n' = \begin{cases} 0, k < N \\ \max\left(a\sigma_0^{b(k-N)}, \sigma_{sat}\right), k \geqslant N \end{cases} \tag{5-16}$$

中国知网 https://www.cnki.net

本节提出一种基于不确定性预测的噪声匹配方法，该方法在高斯过程回归预测的基础上，结合预测的不确定性方差对强化学习中的噪声方差进行适当调整。当不确定性方差较大时，噪声方差会适度减小；而当不确定性方差较小时，则适度增加噪声方差。本文设计的噪声匹配下的方差计算如公式 (5-17) 所示。

$$\sigma_{an}=\begin{cases}0, t<N\\ \max\left(\frac{1}{e^{c\sigma_N-d}}a\sigma_0^{b(t-N)}, \sigma_{sat}\right), t\geqslant N\end{cases} \tag{5-17}$$

式中 c、d———给定超参数（无量纲常数）；

N———给定高斯过程回归中的窗口长度（无量纲常数）；

σ_N———高斯回归给出的无人自行车模型预测方差，量纲为所预测的状态量纲；

当 σ_N 值较大时，$\frac{1}{e^{c\sigma_N-d}}<1$，这导致自适应探索方差 σ_{an} 小于原始探索方差。相反，当 σ_N 值较小时，$\frac{1}{e^{c\sigma_N-d}}>1$，从而使得自适应探索方差 σ_{an} 大于原始探索方差。

5.3.3 高斯控制障碍函数

本小节首先介绍传统的离散时间指数控制障碍函数，接着创新性地提出高斯控制障碍函数。

（1）离散时间指数控制障碍函数

根据文献 [81, 137] 的定义，当系统轨迹上的不变集 $\mathcal{S}$ 满足映射 $B:\mathcal{S}\rightarrow R$ 并符合式 (5-18) 时，B 被称为离散时间指数障碍函数。

$$\begin{cases}B\left(x_0\right)\geq 0\\ \triangle B\left(x_{k+1}, x_k\right):=B\left(x_{k+1}\right)-B\left(x_k\right)\geq -\lambda B\left(x_k\right)\end{cases} \tag{5-18}$$

其中，$0<\lambda\leqslant 1$ 用于调节障碍函数约束的强度。当 $\lambda=1$ 时，指数控制障碍函数退化为标准控制障碍函数的形式。相应地，当存在控制输入 u_k 满足式 (5-19) 时，B 被定义为离散时间指数控制障碍函数。

$$\begin{cases}B\left(x_0\right)\geq 0\\ \triangle B\left(x_k, u_k\right)\geq -\lambda B\left(x_k\right)\end{cases} \tag{5-19}$$

通过对约束条件式 (5-19) 下的二次规划问题 (5-3) 进行求解，可以获得所需的控制器输出。相关的证明详见文献 [81]。然而，由于式 (5-19) 依赖于精确的系统模型，因此模型的不确定性及外部扰动等因素会对控制障碍函数（CBF）的求解产生显著影响。

中国知网 https://www.cnki.net

（2）高斯控制障碍函数

本文基于离散时间指数控制障碍函数，结合高斯过程回归预测，设计了高斯控制障碍函数。该高斯控制障碍函数由两部分组成：第一部分是基于高斯核函数更新的障碍函数；第二部分是基于不确定性预测构建的安全集。

从 5.3.1 节的分析可知，系统的不确定性以超参数的形式被编码在高斯核函数中。并且，高斯核函数是一种具有正定性的光滑函数。因此可以用其构建障碍函数 B。

$$B_k := \sigma_s^2 \left(\frac{\exp\left(-\frac{1}{2}\tilde{x}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1}\tilde{x}\right)}{\exp\left(-\frac{1}{2}\tilde{F}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1}\tilde{F}\right)} - 1 \right) \tag{5-20}$$

其中，$\tilde{x} = x_k - x_{target}$，$\tilde{F} = F - x_{target}$，$x_{target}$ 代表目标状态，F 表示状态的安全约束。超参数 σ_s^2 和 $\boldsymbol{\Lambda}$ 由高斯过程回归的在线更新得到。

以一个简单的一维情形为例，设定 $x_{target} = 0$，$F = 1$。不同超参数下的障碍函数 B 如图5-2所示。从该图中可以观察到，超参数的变化会导致障碍函数 B 的曲率和形状变化，但不会对安全集构成影响。

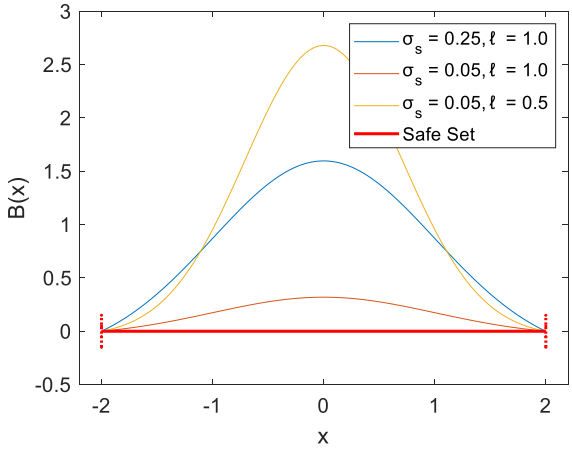


图 5-2 一维情况下基于高斯核的障碍函数

Fig.5-2 Barrier function with Gaussian kernel in 1-dimension

构建相应的序列二次规划问题，

$$\begin{aligned} &\min_{u_k \in \mathcal{U}} \left\| u_k - u_k^* \right\|^2 \\ &s.t. B\left(\mu_{k+1}, \Sigma_{k+1} | \Theta\right) - B\left(x_k | \Theta\right) \geq -\lambda B\left(x_k | \Theta\right) \end{aligned} \tag{5-21}$$

其中，

$$B\left(\mu_{k+1}, \Sigma_{k+1} | \Theta\right) = \sigma_s^2 \left(\frac{\exp\left(-\frac{1}{2}\tilde{x}_{k+1}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1}\tilde{x}_{k+1}\right)}{\exp\left(-\frac{1}{2}\tilde{F}_{k+1}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1}\tilde{F}_{k+1}\right)} - 1 \right) \tag{5-22}$$

中国知网 https://www.cnki.net

其中，$\tilde{x}_{k+1}=\mu_{k+1}-x_{target}$，$\tilde{F}_{k+1}=F-k_{\delta}\Sigma_{k+1}^{1/2}-x_{target}$。当求解出 u_k 满足式 (5-20) 时，系统能够在概率意义下确保前向不变集 $\mathcal{S}$ 成立。

本节所提出的高斯控制障碍函数与现有相关研究的差异在于，文献 [85] 在预测状态均值和方差时，未考虑不同控制器输入对高斯过程回归模型下一时刻预测方差的影响。而文献 [86] 则仅关注高斯过程回归预测对安全集的影响，忽视了不确定性对障碍函数特性的影响。由于系统的不确定性不仅需要在安全集和障碍函数中体现，而且不同的控制策略也会导致高斯预测均值和方差的相对变化。因此，本文所提出的算法综合考虑了上述因素的影响。

5.4 概率安全保障下的无人自行车平衡控制仿真测试

5.4.1 反作用轮无人自行车高斯过程回归仿真测试

本小节采用前文所设计的全局终端快速滑模控制，作为反作用轮无人自行车的平衡控制器。同时，对 5.3.1 节中基于滑动窗口高斯过程回归所建立的反作用轮无人自行车模型的预测性能进行评估，并与标称模型的计算结果和仿真中的实际采样值进行比较。

根据第二章推导的反作用轮无人自行车动力学模型，可以得到无人自行车内环的离散时间状态更新方程 $\boldsymbol{q}(k+1)=f(\boldsymbol{q}(k),\tau(k))$，具体如下：

$$\boldsymbol{q}(k+1)=\boldsymbol{q}(k)+\Delta t\cdot\begin{bmatrix}\dot{q}\\ \frac{\bar{m}g'I_2\sin(q_1)-I_2\tau(k)}{JI_2-I_2^2}\\ \frac{-\bar{m}g'I_2\sin(q_1)+J\tau(k)}{JI_2-I_2^2}\end{bmatrix} \tag{5-23}$$

其中，Δt 代表时间步长。

无人自行车标称动力学模型所计算的横滚角单步值记为 $q_{1,norm}$，而仿真中实际采样的值记为 $q_{1,real}$，高斯过程回归的预测值则记为 $\hat{q}_{1,gp}$。为了便于呈现高斯过程回归预测的效果，定义 e_{norm} 为仿真中横滚角实际采样值与动力学模型计算值之间差异的绝对值累积，e_{gp} 则表示仿真中横滚角实际采样值与高斯预测值之间差异的绝对值累积。

e_{norm} 和 e_{gp} 的计算方法见公式 (5-24)。

$$\begin{aligned}e_{norm}&=\sum_{k=1}^{T}\left|q_{1,real}(k)-q_{1,norm}(k)\right|\\ e_{gp}&=\sum_{k=1}^{T}\left|q_{1,real}(k)-\hat{q}_{1,gp}(k)\right|\end{aligned} \tag{5-24}$$

中国知网 https://www.cnki.net

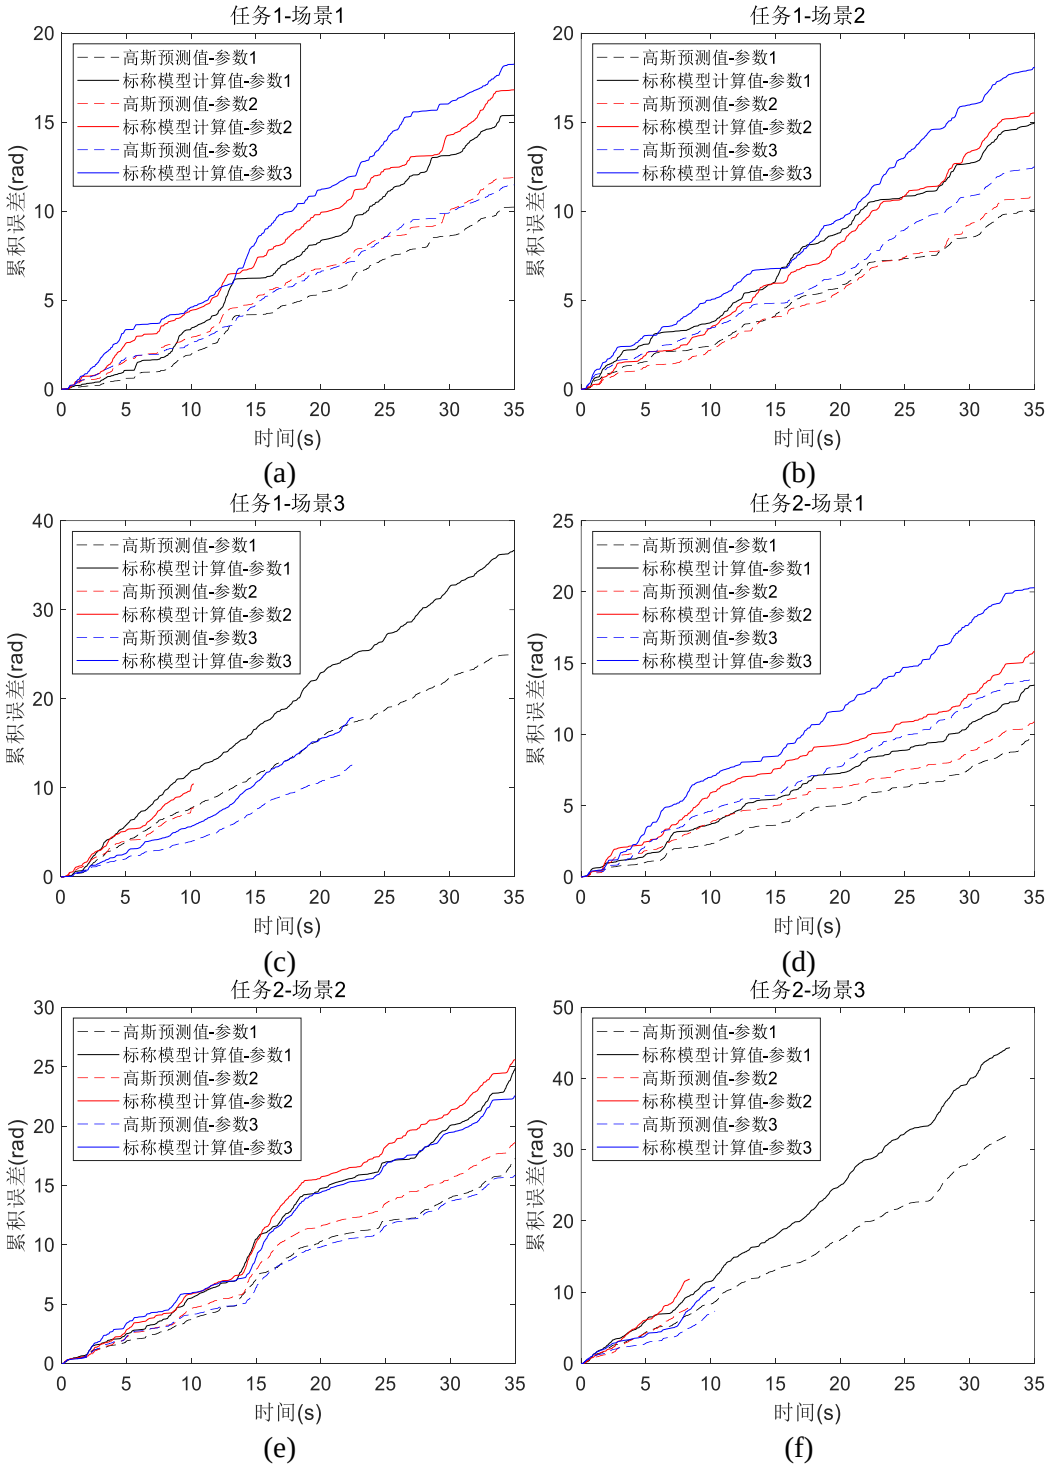


图 5-3 误差随时间的变化

Fig. 5-3 Error variation with time

图5-3呈现了 e_{norm} 与 e_{gp} 随时间的变化趋势。结果表明，在所有的仿真测试

中国知网 https://www.cnki.net

中，横滚角的实际采样值与高斯预测值之间差值的绝对值累积 e_{gp} 始终小于横滚角的实际采样值与动力学模型计算值之间差值的绝对值累积 e_{norm}。这一结果表明，本章所采用的滑动窗口高斯过程回归方法能够有效地从在线数据中拟合反作用轮无人自行车的系统模型并预测无人自行车的状态不确定性。

从每个任务的场景中选取一组参数，分析横滚角随时间的变化，并在图5-4中绘制高斯回归预测的无人自行车横滚角均值及其相应的预测区间。从图5-4可以看到，横滚角的实际采样值几乎完全落在拟合得到的高斯回归模型的预测区间内。这表明本章提出的滑动窗口高斯过程回归能够有效地从数据中预测反作用轮无人自行车横滚角随时间的变化。

图5-5展示了与图5-4相对应的不确定性方差随时间的变化趋势。可以看到，在任务 1 的 10 秒、20 秒、30 秒和 40 秒时，不确定性方差显著增加，这与本文在仿真环境中设定的外部扰动施加时间相符。而在任务 2 中，由于路径跟随与地形的综合影响，不确定性方差的变化趋势不如在任务 1 中明显。总体而言，图5-5反映了本章所提出算法在不确定性预测方面的有效性。

为了更清晰地展示高斯回归的预测效果，对高斯回归模型在横滚角预测误差方面相较于动力学模型的横滚角估计误差进行定量比较。依据公式 (5-25) 对上述差异 ξ_{imp} 进行计算。同时，依据公式 (5-26) 计算高斯过程回归预测中 $\pm 3\sigma$ 预测区间与仿真实际采样值的覆盖率 ξ_{cov}，σ 为预测方差。相关计算结果在表5-2和表5-3中列出。

$$\xi_{imp} = \frac{e_{norm} - e_{gp}}{e_{norm}} \tag{5-25}$$

$$\xi_{cov} = 1 - \frac{\sum_{i=1}^{M} \Theta\left(q_{1,real}(i) - q_{1,gp}(i)\right)}{M} \tag{5-26}$$

其中，$\Theta\left(q_{1,real}(i) - q_{1,gp}(i)\right) = \begin{cases} 1, \left|q_{1,real}(i) - q_{1,gp}(i)\right| \geqslant 3\sigma(i) \\ 0, \left|q_{1,real}(i) - q_{1,gp}(i)\right| < 3\sigma(i) \end{cases}$。

从表5-2和表5-3中可以观察到，本文所进行的所有仿真实验中，高斯过程回归的预测区间对实际采样值的覆盖率 ξ_{cov} 均维持在约 95% 的水平。此外，e_{gp} 相较于 e_{norm} 在每个仿真实验中都减少了约 30%。

上述结果表明，本节提出的基于滑动窗口的高斯过程回归模型在预测无人自行车动力学数据的特征及不确定性方面，相较于第二章中推导的动力学模型更有效。因此，后文中可以利用该拟合得到的高斯过程模型构建高斯障碍函数，以及用于在线调节强化学习的探索噪声方差。

中国知网 https://www.cnki.net

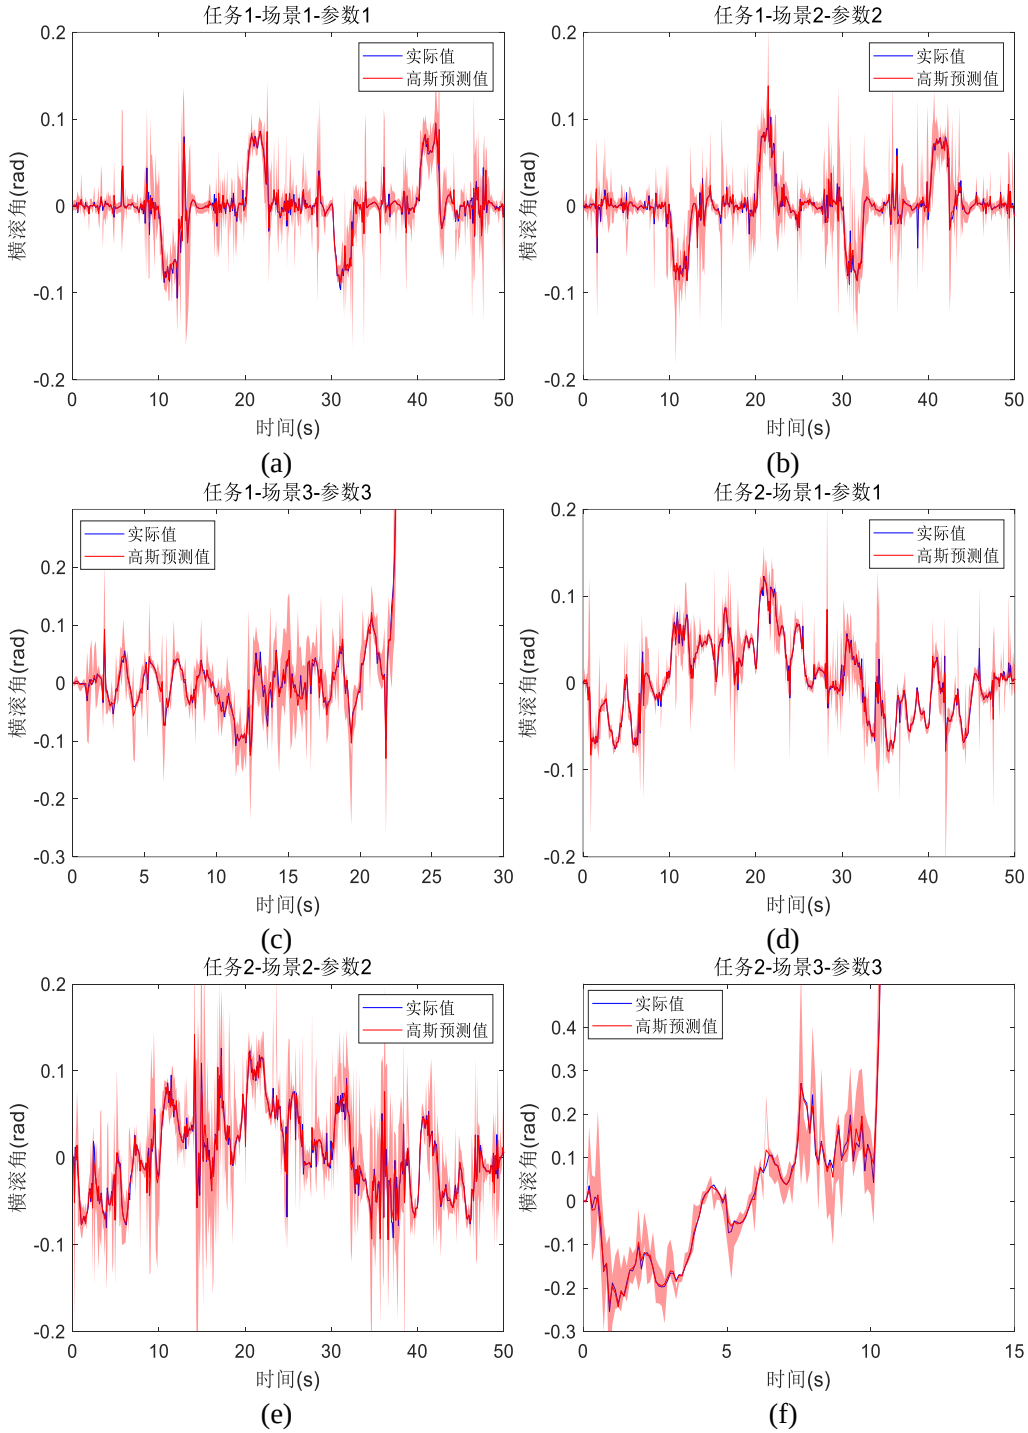


图 5-4 高斯过程回归预测随时间的变化

Fig.5-4 Gaussian process regression prediction variation with time

5.4.2 高斯障碍函数仿真测试

为了验证本文所提出的高斯障碍函数 GCBF 的有效性，本小节首先将其与

中国知网 https://www.cnki.net

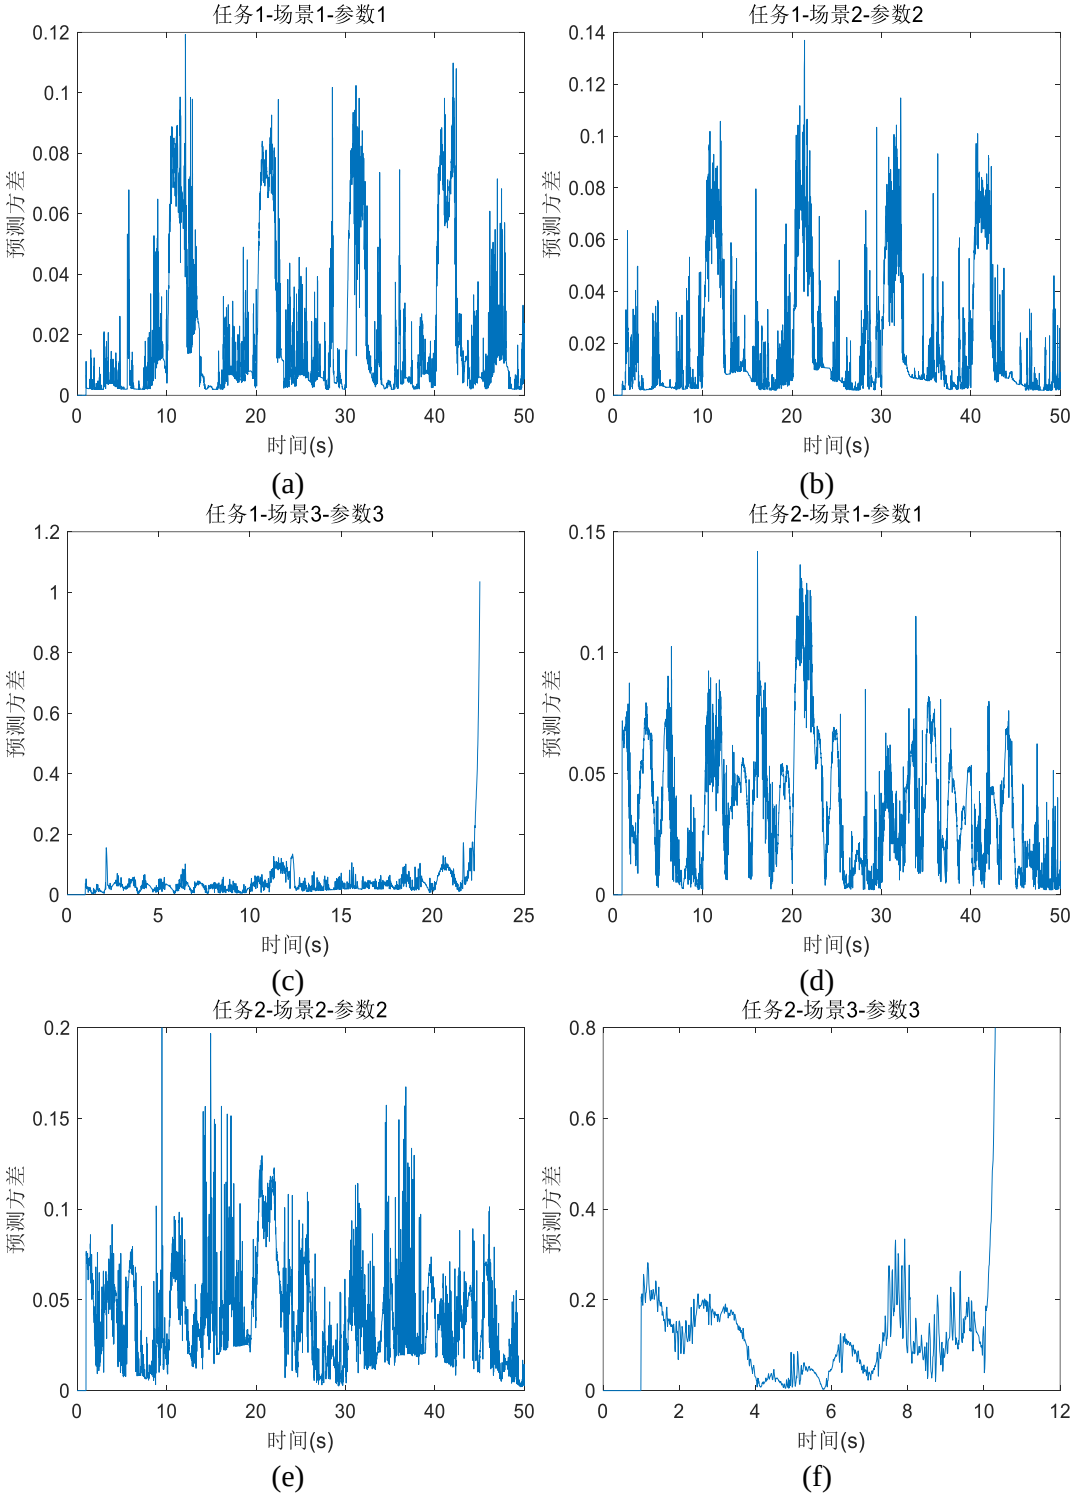


图 5-5 预测方差随时间的变化

Fig. 5-5 Prediction variance with time

文献 [81] 中的控制障碍函数（CBF）以及文献 [138] 中的高斯过程控制障碍函数（CBF-GP）进行比较。随后将其应用于反作用轮无人自行车的平衡控制。

中国知网 https://www.cnki.net

表 5-2 任务一中高斯过程回归的相关变量
Table5-2 Correlated variables for Gaussian process regression of task 1

变量	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
e_{norm}	22.35	24.42	26.73	19.41	21.14	23.81	42.83	10.44	17.90
e_{gp}	14.86	16.91	17.09	13.02	15.02	16.68	29.55	7.77	12.71
ξ_{imp}	33.5%	30.8%	36.1%	32.9%	29.0%	29.9%	31.0%	25.6%	29.0%
ξ_{cov}	95.4%	94.9%	94.8%	95.2%	95.7%	95.0%	93.4%	94.1%	94.3%

表 5-3 任务二中高斯过程回归的相关变量
Table5-3 Correlated variables for Gaussian process regression of task 2

变量	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
e_{norm}	18.02	24.10	26.50	35.15	37.04	32.83	44.32	11.82	10.71
e_{gp}	12.88	16.04	18.01	24.89	26.73	23.43	32.16	7.96	7.36
ξ_{imp}	28.5%	33.4%	32.0%	29.2%	27.9%	28.6%	27.4%	32.6%	31.3%
ξ_{cov}	95.4%	95.3%	95.8%	94.7%	95.2%	95.1%	93.6%	95.4%	94.6%

（1）GCBF 与 CBF 和 CBF-GP 的对比

基于文献 [81] 中的一维跟踪控制实例，构建本小节的测试用例。测试用例的系统方程如下：

$$x_{k+1} = (1 - T_s)\, x_k + T_s \left(1 + x_k^2\right) u_k + d_k \tag{5-27}$$

其中，$T_s = 0.01$。所采用的控制器为比例微分控制器，旨在跟踪正弦目标轨迹，同时需满足约束条件 $-1 < x_k < 1$。

系统所受的扰动如下：

$$d_k = \begin{cases} 3 + \mathcal{N}(0, 0.2), k \in [6,7] \cup [16,17] \\ -3 + \mathcal{N}(0, 0.2), k \in [5,6] \cup [15,16] \\ \mathcal{N}(0, 0.2), else \end{cases} \tag{5-28}$$

首先设定比例微分跟踪控制，其中 $k_p = 3$ 和 $k_d = 0.1$。随后，设置高斯障碍函数的相关参数，$F = \pm 1$，$k_\delta = 2$，$N = 100$。

仿真测试结果如图5-6所示。从图5-6可以看出，在算法 CBF 和 CBF-GP 下，系统状态并未完成被限定在安全约束内。而本文提出的 GCBF 算法在扰动情况下有效地实现了安全控制。说明本章所提出算法 GCBF 综合考虑系统不确定性对安全集和障碍函数的影响，有利于保障系统跟踪控制的安全性。

（2）GCBF 应用于反作用轮无人自行车

中国知网 https://www.cnki.net

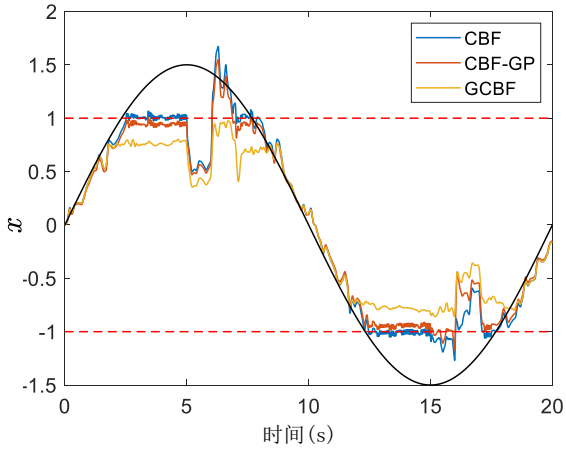


图 5-6 GCBF 安全控制与 CBF 和 CBF-GP 的对比
Fig.5-6 Safe control using GCBF compared to CBF and CBF-GP

在任务 1、场景 3、参数 3 的仿真测试任务中，对 GCBF 应用于反作用轮无人自行车的平衡控制进行测试，见图5-7所示，其中，$F = \pm 0.1$。从 SPRL 和 SPRL-GCBF 的对比可以看出，本章提出的 GCBF 算法能够有效地将被控系统状态约束在安全集内。

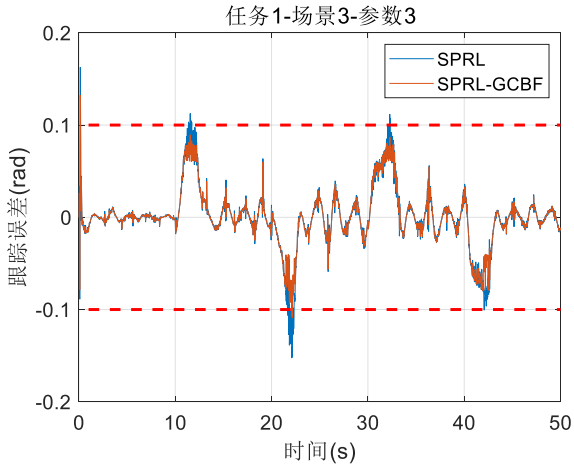


图 5-7 GCBF 用于 RWBR
Fig.5-7 GCBF is used for RWBR

5.4.3 反作用轮无人自行车安全在线强化学习仿真测试

为了验证本章所提出算法的有效性，本节对本章提出的 SRLP 算法和第三章提出的 SPRL 算法进行比较，并与无在线探索噪声的 SPRL 算法进行比较。为便于对三种算法进行区分，下文中将 SRLP 记为 SPRL-AN，其中 AN 表示自适应探索噪声机制；将原始的 SPRL 记为 SPRL-N；将无在线探索噪声的 SPRL 算法记为 SPRL-ZN。相较于第三章中的仿真测试环境，本章在原有阶跃扰动的基础上，额

中国知网 https://www.cnki.net

外添加了公式 (5-29) 所示的持续扰动。此外，在 SPRL-AN 算法中，令 $F = \pm 0.15$。

$$d = 0.02 \sum_{j} \sin(jt) \tag{5-29}$$

其中，$j = [1, 3, 7, 11, 13, 15]$。

表5-4对仿真完成情况进行统计，由于上述算法都完成了场景 1 和场景 2 下的仿真测试任务，表5-4中仅给出场景 3 的仿真测试任务的完成情况。从表5-4可以看出，在 18 个仿真测试中，SPRL-AN 完成了所有 18 个仿真测试任务。SPRL-ZN 仅完成了 14 个仿真测试任务。说明强化学习在线训练中，添加探索噪声是必要的。无探索噪声，可能会导致策略过早的陷入局部最优。

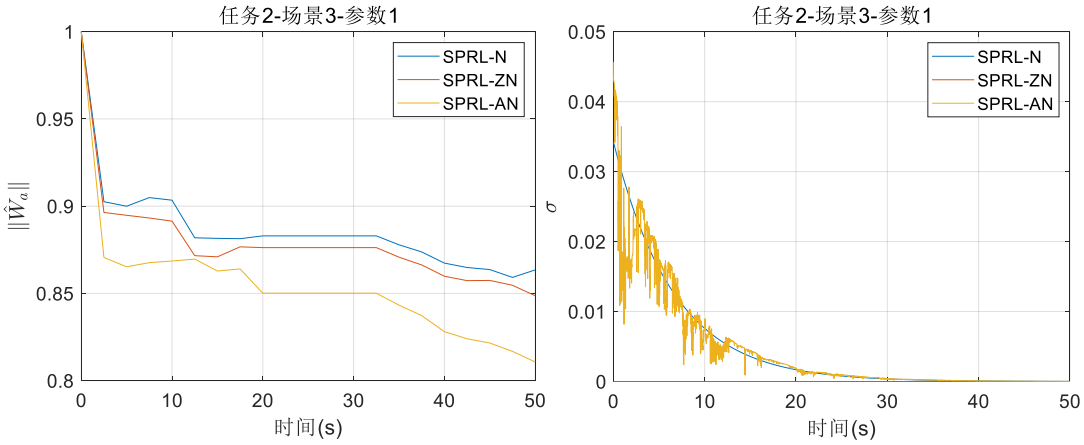
表 5-4 仿真测试完成情况 (秒)
Table5-4 Simulation test completion status(s)

任务/算法	场景 3		
	参数 1	参数 2	参数 3
1/SPRL-N	-	-	-
1/SPRL-ZN	-	22.6	22.7
1/SPRL-AN	-	-	-
2/SPRL-N	-	-	-
2/SPRL-ZN	-	10.7	16.9
2/SPRL-AN	-	-	-

图5-8(a) 给出了任务 2、场景 3、参数 1 下三种算法策略网络权重范数随时间的变化，从该图可以看出，SPRL-AN 权重范数变化率比 SPRL-N 和 SPRL-ZN 大。从图5-8(b) 可以看到，在 10 秒处，阶跃扰动出现时，SPRL-AN 的探索噪声方差小于 SPRL-N。在其他时间段，SPRL-AN 的探索噪声方差大于 SPRL-N。符合本章算法设计的预期目标。图5-9绘制了横滚角跟踪误差随时间的变化。在图5-9(a) 中绘制了任务 1、场景 1 下的横滚角跟踪误差，在该图中三种算法下的横滚角跟踪误差随时间的变化差异并不显著。说明在直线行驶的平衡控制中，控制器能够抑制探索噪声的不利影响。在图5-9(b) 中绘制了任务 2、场景 3 下的横滚角跟踪误差，在该图中 SPRL-ZN 未能完成仿真测试，SPRL-AN 的跟踪误差在 10 秒后显著小于 SPRL-N 都说明本章所提出的算法的有效性。图5-10为横滚角跟踪误差分布的箱形图，该图进一步表明，SPRL-AN 在跟踪误差分布上的表现优于 SPRL-N 和 SPRL-ZN。

表5-5、表5-6和表5-7分别列出了 SPRL-N、SPRL-ZN 和 SPRL-AN 在反作用轮无人自行车平衡控制中的跟踪误差最大值、均方根误差（RMS）和控制力矩绝对值的累积情况。具体而言，表5-5显示 SPRL-AN 的跟踪误差最大值比 SPRL-N 小

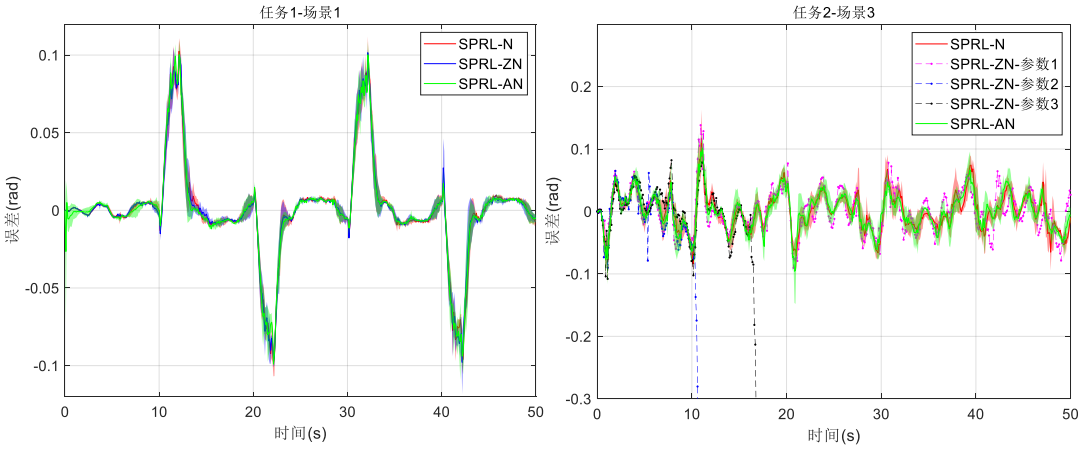
中国知网 https://www.cnki.net



(a) (b)

图 5-8 策略网络权重范数 $\|\hat{W}_a\|$ 和探索噪声方差 σ 随时间的变化

Fig.5-8 Policy network weight norm $\|\hat{W}_a\|$and exploration noise variance σover time



(a) (b)

图 5-9 横滚角跟踪误差随时间的变化

Fig.5-9 Roll angle tracking error variation with time

1.23%，比 SPRL-ZN 小 0.82%；表5-6中，SPRL-AN 的跟踪误差均方值比 SPRL-N 最多减少了 5.41%，在所有测试场景中平均减少了 0.48%，比 SPRL-ZN 平均减少了 0.13%；表5-7则表明，SPRL-AN 的控制力矩绝对值累积比 SPRL-N 减少了 0.71%，约等于 SPRL-ZN。综上所述，SPRL-AN 在仿真完成情况、跟踪误差最大值和 RMS 方面均优于 SPRL-N 和 SPRL-ZN。由此可见，本章所提出的安全在线强化学习方法提升了反作用轮无人自行车在线强化学习算法在探索阶段的安全性以及平衡控制的效果。

5.5 概率安全保障下的无人自行车平衡控制实物实验

对反作用轮无人自行车样机在路径跟随任务中进行实验，并对实验结果进行

中国知网 https://www.cnki.net

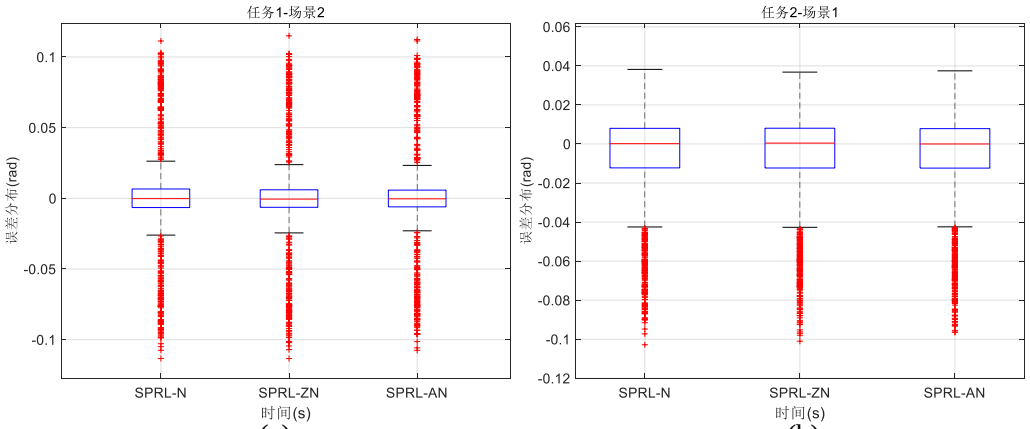


图 5-10 横滚角跟踪误差的分布

Fig.5-10 Roll angle tracking error distribution

表 5-5 跟踪误差的最大值 (10^{-1} rad)

Table5-5 Maximum tracking error (10^{-1} rad)

任务/算法	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1/SPRL-N	1.15	1.11	1.06	1.13	1.21	1.11	1.42	1.33	1.27
1/SPRL-ZN	1.08	1.21	1.07	1.18	1.13	1.09	1.67	-	-
1/SPRL-AN	1.13	1.08	1.09	1.12	1.04	1.08	1.52	1.50	1.17
ξ_N		0.22%			2.10%			-1.49%	
ξ_{ZN}		0.72%			1.58%			-	
2/SPRL-N	1.03	0.95	1.00	1.06	1.10	1.05	1.70	1.26	1.33
2/SPRL-ZN	1.03	1.06	0.98	1.07	1.04	0.99	1.77	-	-
2/SPRL-AN	0.97	1.03	0.98	1.02	1.04	1.04	1.49	1.15	0.94
ξ_N		0.00%			1.15%			5.41%	
ξ_{ZN}		0.99%			0.00%			-	

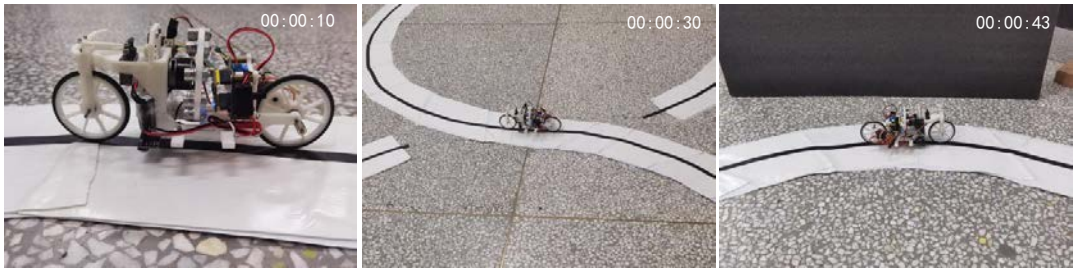


图 5-11 “8 字”路径跟随 SPRL-ZN 的样机实验

Fig.5-11 The ”8-shape” path following prototype experiment of SPRL-ZN

分析。图5-11展示了在扰动为 1.0V 时，SPRL-ZN 的实验视频截图。实验中，扰动 d_{gp} 分别设置为 0.0V 和 1.0V，并添加了公式 (5-29) 所示的持续扰动，对 SPRL-N、SPRL-ZN 和 SPRL-AN 进行实验。表5-5总结了实验的完成情况及在 65 秒实验中跟踪误差的均方值。当 d_{gp} 为 0.0V 时，SPRL-N、SPRL-ZN 和 SPRL-AN 均成功完

中国知网 https://www.cnki.net

表 5-6 跟踪误差的 RMS(10^{-3} rad^2)
Table 5-6 RMS tracking error (10^{-3} rad^2)

任务/算法	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1/SPRL-N	1.02	1.00	0.84	1.02	1.00	0.88	1.50	1.33	1.08
1/SPRL-ZN	1.01	1.02	0.86	1.02	0.99	0.89	1.35	-	-
1/SPRL-AN	1.00	1.00	0.88	1.01	1.00	0.88	1.33	1.26	
ξ_N		-0.16%			0.12%			1.27%	
ξ_{ZN}		0.16%			0.11%			-	
2/SPRL-N	0.80	0.79	0.70	0.90	0.93	0.80	1.11	0.93	1.13
2/SPRL-ZN	0.77	0.78	0.70	0.87	0.90	0.81	1.14	-	-
2/SPRL-AN	0.77	0.79	0.69	0.87	0.89	0.80	1.05	1.00	1.12
ξ_N		0.59%			0.92%			0.13%	
ξ_{ZN}		0.00%			0.26%			-	

表 5-7 控制力矩绝对值的累积 (10^2 Nm)
Table 5-7 Accumulation of absolute control moment (10^2 Nm)

任务/算法	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
1/SPRL-N	2.13	2.29	2.46	2.24	2.37	2.72	4.22	4.32	4.09
1/SPRL-ZN	2.04	2.24	2.53	2.20	2.34	2.64	4.39	-	-
1/SPRL-AN	2.12	2.30	2.59	2.19	2.33	2.56	3.92	4.03	4.13
ξ_N		-0.68%			1.19%			1.48%	
ξ_{ZN}		-0.96%			0.49%			-	
2/SPRL-N	2.44	2.53	2.81	2.75	2.82	3.03	5.23	5.16	5.87
2/SPRL-ZN	2.40	2.47	2.70	2.58	2.68	2.99	5.31	-	-
2/SPRL-AN	2.43	2.49	2.64	2.57	2.77	2.96	5.23	5.35	5.64
ξ_N		0.99%			1.14%			0.14%	
ξ_{ZN}		0.00%			-0.18%			-	

成了曲面路面的路径跟随实验；而当 d_{gp} 为 1.0V 时，仅 SPRL-N 和 SPRL-AN 完成了实验。

从表5-8可以看出，在 d_{gp} 为 0.0V 和 1.0V 的情况下，SPRL-N 和 SPRL-AN 均能够顺利行驶完整个“8 字”形测试跑道；而 SPRL-ZN 仅在 d_{gp} 为 0.0V 时能够完成实验。无扰动情况下 SPRL-AN 相较于 SPRL-N 的跟踪误差减小了 9.03%，在有附加扰动情况下 SPRL-AN 相较于 SPRL-N 的跟踪误差减小了 6.17%，即平均减少了 7.6%。表明本章所提出算法提升了反作用轮无人自行车系统在线学习过程及平衡控制的安全性，并且提升了控制性能。

图5-12展示了在 d_{gp} 为 0.0V 和 1.0V 时，反作用轮无人自行车横滚角跟踪误差随时间变化的曲线。从图5-12 (a) 中可以观察到，在无扰动情况下，0s 到 15s 之

中国知网 https://www.cnki.net

表 5-8 跟踪误差均方值 (10^{-4}rad^2)

Table5-8 Statistics on the mean square of tracking error(10^{-4}rad^2)

算法	d_{gp} = 0.0	d_{gp} = 1.0
SPRL-N	1.44	1.62
SPRL-ZN	1.42	43s
SPRL-AN	1. 31	1.52
ξ_N	9.03%	6.17%

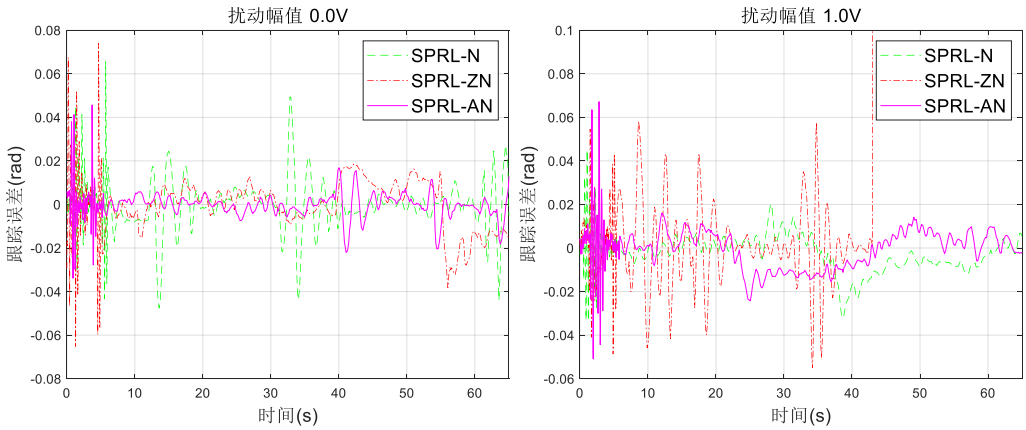


图 5-12 横滚角跟踪误差随时间的变化

Fig.5-12 Roll angle tracking error variation with time

间，受到在线强化学习叠加探索噪声的影响，SPRL-N 和 SPRL-AN 的横滚角度跟踪误差大于 SPRL-ZN。而在 40s 到 65s 之间，得益于在线强化学习的优化作用，SPRL-AN 的跟踪误差逐渐减小，并小于 SPRL-ZN。图5-12 (b) 中显示，有扰动情况下，SPRL-ZN 在 43 秒时，反作用轮无人自行车出现了失去平衡的情况。SPRL-AN 不仅完成了实验，并且在经过约 20s 的在线学习后，其跟踪误差显著小于 SPRL-N。表明本章所提出的算法有效提升了反作用轮无人自行车的平衡控制性能。

5.6 本章小结

本章提出了一种具有概率安全保障的在线强化学习框架，该框架基于高斯过程回归对系统不确定性进行概率建模，并结合了高斯控制障碍函数和探索噪声匹配机制为系统的在线学习提供安全性保障。

在仿真测试中，高斯过程回归模型对系统状态的预测比系统标称模型计算值和采样值的差值平均减小了 30%。此外，本章所提出的 GCBF 比相关文献中的算法更好地实现了系统不确定性下的安全保障。最后，本章所提出算法不仅完成了全部测试任务，而且相较于 SPRL 算法，在仿真测试中跟踪误差最多减小 5.4%，平均减小约 1%。在实物实验中最多减小 9.03%，平均减小约 7.6%。

中国知网 https://www.cnki.net

结 论

本文旨在研究崎岖路面环境及系统不确定性下，反作用轮无人自行车的平衡控制问题。为实现具有在线学习能力的反作用轮无人自行车平衡控制，本文首先分析了离线强化学习在无人自行车平衡控制中的局限性，进而提出了一种多智能体在线强化学习算法，该算法能够同时在线调整滑模控制器的参数并进行在线补偿，以实现平衡控制。针对该算法在稳定性理论分析及安全性保障方面的不足，本文进一步提出了鲁棒自适应动态规划的稳定性保障方法，以及基于概率安全保障的在线强化学习无人自行车平衡控制算法。

本文的主要研究工作如下：

（1）完成了反作用轮无人自行车样机的设计，推导了横滚角跟踪误差模型；构建了离线强化学习域随机化训练环境，设计了基于近端策略优化算法的无人自行车平衡控制器；设定了 18 个仿真测试任务。在仿真测试中，离线强化学习 PPO 算法下无人自行车平衡控制器完成了 14 个仿真测试任务。最后对仿真测试中的跟踪误差和控制器输出进行了统计。

（2）设计了同时调节滑模控制参数和输出补偿的在线强化学习平衡控制算法，利用强化学习与滑模控制的结合，解决了反作用轮无人自行车平衡控制中，在线强化学习对交互样本量需求较大的问题。仿真测试中，SPRL 完成了 18 个任务中的 17 个、完成率约 94%，显著优于其他对比算法。在跟踪误差均方值和控制器累计输出方面，SPRL 相较于 PPO 也分别减小了 15% 和 45%。实物实验中，SPRL 完成了所有测试任务，而 PPO 算法未能完成任何实物实验。SPRL 跟踪误差均方值相较于 TSMC、SRL 和 PRL 分别减小了约 20%、17% 和 32%。仿真和实验表明所提出的 SPRL 算法显著提升了任务完成情况和控制性能。

（3）建立了鲁棒自适应动态规划的无人自行车平衡控制算法，旨在保障强化学习在线训练的稳定性。通过引入鲁棒自适应动态规划机制，降低了对精确系统模型的依赖，并在已知滑模控制器参数允许调节范围的前提下，构建了输出饱和约束，从而为强化学习的在线训练提供了稳定性保障。该算法不仅成功完成了前述设计的 18 个仿真测试任务，而且在跟踪误差方面相较于现有相关研究减小了约 21%，与本文提出 SPRL 算法相比，在仿真测试中减小了约 20%，在实物实验中减小了约 10%。验证了所提出算法在反作用轮无人自行车平衡控制中的有效性。

（4）实现了概率安全保障的在线强化学习无人自行车平衡控制算法。该算法不局限于特定的强化学习算法与滑模控制的结合方式，且避免了滑模控制参数可调

中国知网 https://www.cnki.net

范围已知的前提条件。该算法利用高斯过程回归对系统状态的不确定性进行预测，并结合高斯控制障碍函数与在线强化学习探索噪声匹配机制，从而实现了概率意义下强化学习在线训练过程的安全保障。仿真测试结果表明，本文提出的滑动窗口高斯过程回归在系统不确定性预测方面，相较于标称系统动力学模型的预测误差降低了 30%。基于此构建的高斯控制障碍函数与探索噪声匹配机制，不仅实现了系统不确定性下概率意义的安全性保障。而且相较于 SPRL 算法，在不同的测试任务中，本章算法仿真测试的跟踪误差最多减小了 5.4%，平均减小约 1%。实物实验中最多减小了 9.03%，平均减小了约 7.6%。

本文主要取得了如下创新性成果：

（1）提出了强化学习对滑模控制同时在线调节和输出补偿的反作用轮无人自行车平衡控制算法。通过融合滑模控制的强鲁棒性和强化学习的自适应学习能力，解决了强化学习在线应用交互样本量需求较大的问题，克服了传统滑模控制匹配条件的约束，弥补了传统自适应滑模控制仅能调整趋近律参数的局限性。仿真和实验结果表明，该算法在提升测试任务完成率和减小跟踪误差方面，显著优于其他对比算法。

（2）提出了将鲁棒自适应动态规划与滑模控制相结合的反作用轮无人自行车平衡控制算法。该算法基于鲁棒自适应动态规划技术，并考虑滑模控制器参数可调节范围已知的输出饱和约束，实现了系统不确定性下具备稳定性保障的在线强化学习平衡控制。通过对现有相关研究及前述算法的仿真和实验进行比较，结果表明该算法在测试任务完成率和跟踪误差方面更具优势。

（3）提出了具有概率安全保障的在线强化学习框架。该框架通过高斯过程回归对系统不确定性进行预测，并综合考虑了不确定性对系统安全性和在线学习的影响。相较于现有相关研究及前述算法，该框架不仅减少了对滑模控制参数可调范围已知假设条件的依赖，提供了概率意义下的系统安全性保障，并且减小了自行车横滚角跟踪误差，提升了平衡控制性能。

本文重点研究了反作用轮无人自行车平衡控制中的在线学习问题，提出了强化学习在线调节滑模控制器参数和输出补偿的控制算法，探索了强化学习在线训练的稳定性和安全性保障，为实现反作用轮无人自行车平衡控制的在线学习提供了有效的途径和理论支持。在本文目前研究的基础上，后续还可以从以下方面开展更加深入的研究：

（1）本文仅考虑了崎岖路面和系统不确定性下的平衡控制问题，后续可以研究反作用轮无人自行车的高机动运动策略，进一步挖掘反作用轮无人自行车在崎岖地形下的应用潜力。

（2）本文仅考虑了路径跟随控制下的反作用轮无人自行车的平衡控制问题，尚未结合无人系统的路径规划、避障控制等，后续可围绕崎岖地形下的反作用轮无人自行车感知与规划进行无人系统的自主导航研究。

中国知网 https://www.cnki.net

参考文献

[1] APPELL P. Traité De Mécanique Rationelle: Dynamique Des Systèmes. Mcanique Analytique[M]. Creative Media Partners, LLC, 1896.

[2] KLEIN F S A. Über die Theorie des Kreisels[M]. BG Teubner, 1915.

[3] KREISEL G R D. Seine Theorie und Seine Anwendungen[M]. Springer, 1920.

[4] JONES D E H. The stability of the bicycle[J]. Physics Today, 1970, 23(4): 34-40.

[5] KOOIJMAN J D G, MEIJAARD J P, J M PAPADOPOULOS A R, et al. A Bicycle Can Be Self-Stable Without Gyroscopic or Caster Effects [J]. Science, 2011, 332(6027): 339-342.

[6] 刘延柱. 自稳定的无人自行车[J]. 力学与实践, 2015, 37: 146-148.

[7] WHIPPLE F J W. The stability of the motion of a bicycle[J]. Quarterly Journal of Pure and Applied Mathematics, 1899, 30: 312-348.

[8] HAND R S. Comparisons and stability analysis of linearized equations of motion for a basic bicycle model[D]. Cornell University, 1988.

[9] MEIJAARD J P, PAPADOPOULOS J M, A RUINA E A. Linearized dynamics equations for the balance and steer of a bicycle: a benchmark and review[J]. Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences, 2007, 463(2084): 1955-1982.

[10] 王囡囡, 熊佳铭, 刘才山. 自行车动力学建模及稳定性分析研究综述[J]. 力学学报, 2020, 52(4): 11.

[11] GETZ N H M J E. Control for an autonomous bicycle[C]. IEEE International Conference on Robotics and Automation, Aichi, Japan, 1995: 1397-1402.

[12] YI J G, SONG D Z, LEVANDOWSKI A, et al. Trajectory tracking and balance stabilization control of autonomous motorcycles[C]. IEEE International Conference on Robotics and Automation, Florida, USA, 2006: 2583-2589.

[13] 黄用华. 前轮驱动自行车机器人建模与几种平衡运动控制研究[D]. 北京邮电大学, 2011.

[14] 黄用华, 廖启征, 魏世民. 45°车把转角下前轮驱动自行车机器人的定车运动[J]. 机械工程学报, 2012, 48(7): 16-22.

中国知网 https://www.cnki.net

[15] ARAKI M, AKIMOTO K, TAKENAKA T. Study of Riding Assist Control Enabling Self-Standing in Stationary State[J]. SAE International Journal of Vehicle Dynamics Stability and NVH, 2015, 3(1): 47-56.

[16] HE J R, ZHAO M G, STASINOPOULOS S. Constant-Velocity Steering Control Design for Unmanned Bicycles[C]. IEEE International Conference on Robotics and Biomimetics, Zhuhai, China, 2015: 428-433.

[17] PEI J, DENG L, SONG S, et al. Towards artificial general intelligence with hybrid Tianjic chip architecture[J]. Nature, 2019, 572(7767): 106.

[18] BEZNOS A V, FORMAL' SKY A M, GURFINKEL E V, et al. Control of autonomous motion of two-wheel bicycle with gyroscopic stabilisation[C]. IEEE International Conference on Robotics and Automation, Zhuhai, China, 1998: 2670-2075.

[19] LAM P Y. Design and Development of a self-Balancing Bicycle Using Control Moment Gyro[D]. National University of Singapore, 2012.

[20] CHEN C K, CHU T D, ZHANG X D. Modeling and Control of an Active Stabilizing Assistant System for a Bicycle[J]. Sensors, 2019, 19(2): 248.

[21] ZHENG X D, ZHU X J, Z CHEN Y Y S, et al. Dynamic modeling of an unmanned motorcycle and combined balance control with both steering and double CMGs[J]. Mechanism and Machine Theory, 2022, 169: 104643.

[22] IGARASHI Y, YAMAKITA M. Autonomous Bike System for Acrobatic Motions[C]. Proceedings of the 57th Annual Conference of the Society of Instrument and Control Engineers of Japan, Nara, Japan, 2015: 723-728.

[23] YAVIN Y. Stabilization and control of the motion of an autonomous bicycle by using a rotor for the tilting moment[J]. Computer Methods in Applied Mechanics Engineering, 1999, 178(3-4): 233-243.

[24] KEO L, YAMAKITA M. Controller Design of an Autonomous Bicycle with Both Steering and Balancer Controls[C]. 2009 IEEE International Conference on Control Applications/International Symposium on Intelligent Control, Saint Petersburg, Russia, 2009: 1294-1299.

[25] KEO L, YAMAKITA M. Controlling Balancer and Steering for Bicycle Stabilization[C]. 2009 IEEE/RSJ International Conference on Intelligent Robots and Systems, Saint Petersburg, Russia, 2009: 4541-4546.

[26] HE K H, DENG Y, WANG G H, et al. Learning-Based Trajectory Tracking and Balance Control for Bicycle Robots with a Pendulum: A Gaussian Process Approach[J]. IEEE-ASME Transactions on Mechatronics, 2022, 27(2): 634-644.

中国知网 https://www.cnki.net

[27] 毛海燕. “村田顽童”：多重技术的结晶体[J]. 压电与声光, 2011, 33: 52.

[28] KANJANAWANISHKUL K. LQR and MPC controller design and comparison for a stationary self-balancing bicycle robot with a reaction wheel[J]. Kybernetika, 2015, 51(1): 173-191.

[29] WANG S, CUI L L, LAI J, et al. Gain Scheduled Controller Design for Balancing an Autonomous Bicycle[C]. 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems, Las Vegas, USA, 2020: 7595-7600.

[30] CUI L L, WANG S, LAI J, et al. Nonlinear Balance Control of an Unmanned Bicycle: Design and Experiments[C]. 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems, Las Vegas, USA, 2020: 7279-7284.

[31] CHEN L, LIU J, WANG H, et al. Robust control of reaction wheel bicycle robot via adaptive integral terminal sliding mode[J]. Nonlinear Dynamics, 2021, 104(3): 2291-2302.

[32] SHARP R S, LIMEBEER D J N. A Motorcycle Model for Stability and Control Analysis[J]. Multibody System Dynamics, 2001, 6(2): 123-142.

[33] WILLIAMS R. On the use of back propagation in associative reinforcement learning[C]. 1988 IEEE International Conference on Neural Networks, CA, USA, 1988: 7279-7284.

[34] WILLIAMS R. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256.

[35] SUTTON R S, BARTO A G. A temporal-difference model of classical conditioning[C]. Proceedings of the Annual Meeting of the Cognitive Science Society, Washington, USA, 1987: 355-378.

[36] WATKINS C, DAYAN P. Q-Learning[J]. Machine Learning, 1992, 8(3-4): 279-292.

[37] RUMMERY G A, NIRANJAN M. On-line Q-learning using connectionist systems[M]. University of Cambridge, 1994.

[38] KONDA V R, TSITSIKLIS J N. Actor-critic algorithms[C]. Proceedings of the 13th Annual Conference on Neural Information Processing Systems, MA, USA, 1999: 1008-1014.

[39] HAYES A T, MARTINOLI A, GOODMAN R M. Swarm robotic odor localization: Off-line optimization and validation with real robots[J]. Robotica, 2003, 21: 427-441.

中国知网 https://www.cnki.net

[40] KOBER J, PETERS J. Learning Motor Primitives for Robotics[C]. IEEE International Conference on Robotics and Automation, Kobe, Japan, 2009: 2509-2515.

[41] FINNSSON H, BJORNSSON Y. Learning Simulation Control in General Game Playing Agents[C]. 2010 AAAI Conference on Artificial Intelligence, Georgia, USA, 2010: 954-959.

[42] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level Control through Deep Reinforcement Learning[J]. Nature, 2015, 518: 529-533.

[43] SCHULMAN J, LEVINE S, MORITZ P, et al. Trust Region Policy Optimization[C]. Proceedings of the 32nd International Conference on Machine Learning, Lille, France, 2015: 1889-1897.

[44] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[C]. 4th International Conference on Learning Representations, San Juan, USA, 2016: 1-14.

[45] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J/OL]. 2017. ArXiv, abs/1707.06347.

[46] FUJIMOTO S, HOOF H, MEGER D. Addressing function approximation error in actor-critic methods[C]. International conference on machine learning, Vienna, Austria, 2018: 1587-1596.

[47] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C]. Proceedings of the 35th International Conference on Machine Learning, Stockholm, Sweden, 2018: 1861-1870.

[48] ARULKUMARAN K, DEISENROTH M P, BRUNDAGE M, et al. Deep Reinforcement Learning: A Brief Survey[J]. IEEE Signal Processing Magazine, 2017, 34(6): 26-38.

[49] LIU D, XUE S, ZHAO B. Adaptive dynamic programming for control: A survey and recent advances[J]. IEEE Transactions on Systems Man Cybernetics systems, 2021, 51(1): 142 – 160.

[50] JI J, KHAJEPOUR A, MELEK W M, et al. Path Planning and Tracking for Vehicle Collision Avoidance Based on Model Predictive Control with Multiconstraints[J]. IEEE Transactions on Vehicular Technology, 2017, 66(2): 952-964.

[51] DEISENROTH M P, RASMUSSEN C E. PILCO: a model-based and data efficient approach to policy search[C]. Proceedings of the 28th

中国知网 https://www.cnki.net

International Conference on International Conference on Machine Learning, WI, USA, 2011: 465-472.

[52] SUTTON R S, BARTO A G. Reinforcement learning: An introduction (2nd ed.) [M]. The MIT Press, 2018.

[53] SUTTON R S, MCALLESTER D, SINGH S, et al. Policy gradient methods for reinforcement learning with function approximation[C]. Proceedings of the 13th Annual Conference on Neural Information Processing Systems, MA, USA, 1999: 1057-1063.

[54] HOLZLEITNER M, GRUBER L, ARJONA-MEDINA J, et al. Convergence proof for actor-critic methods applied to PPO and RUDDER[J/OL]. 2012. ArXiv:2012.01399

[55] ANDRYCHOWICZ M, BAKER B, CHOCIEJ M. Learning dexterous in-hand manipulation[J]. International Journal of Robotics Research, 2020, 39(1): 3-20.

[56] LEE J, HWANGBO J, WELLHAUSEN L, et al. Learning quadrupedal locomotion over challenging terrain[J]. Science robotics, 2020, 5(47): eabc5986.

[57] JOHANNINK T, BAHL S, NAIR A, et al. Residual Reinforcement Learning for Robot Control[C]. 2019 IEEE International Conference on Robotics and Automation, QC, Canada, 2019: 6023-6029.

[58] GUAN Z, YAMAMOTO T. Design of a Reinforcement Learning PID controller[C]. 2020 International Joint Conference on Neural Networks, Glasgow, UK, 2020: 1-6.

[59] GRONAUER S, DIEPOLD K. Multi-agent deep reinforcement learning: a survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.

[60] WANG C, PéREZ-D ’ ARPINO C, XU D. Co-GAIL: Learning diverse strategies for human-robot collaboration[C]. Conference on Robot Learning, Auckland, New Zealand, 2022: 1297-1290.

[61] AMRI W Z E, HERMES L, SCHILLING M. Hierarchical Decentralized Deep Reinforcement Learning Architecture for a Simulated Four-Legged Agent[C]. Proceedings of the 8th Annual International Conference on Machine Learning, Optimization and Data science, Certosa di Pontignano, Italy, 2020: 265-280.

[62] BELLMAN R. Dynamic Programming [J/OL]. Science, 1957, 153: 34-37. https://api.semanticscholar.org/CorpusID:274137570.

[63] WANG F Y, ZHANG H G, LIU D R. Adaptive Dynamic Programming: An Introduction[J/OL]. IEEE Computational Intelligence Magazine, 2009, 4(2):

中国知网 https://www.cnki.net

39-47. http://dx.doi.org/10.1109/MCI.2009.932261.

[64] ZHANG H G, LIU D R, WANG Y H L A D. Adaptive dynamic programming for control[M]. Springer, 2013.

[65] VAMVOUDAKIS K G, LEWIS F L. Online actor-critic algorithm to solve the continuous-time infinite horizon optimal control problem[J]. Automatica, 2010, 46(5): 878-888.

[66] BHASIN S, KAMALAPURKAR R, JOHNSON M, et al. A novel actor-critic identifier architecture for approximate optimal control of uncertain nonlinear systems[J]. Automatica, 2013, 49(1): 82-92.

[67] ZHU Y, ZHAO D. Comprehensive comparison of online adp algorithms for continuous-time optimal control[J]. Artificial Intelligence Review, 2018, 49(4): 531-547.

[68] GUO L, LIN H, JIANG J. Combined control algorithm based on synchronous reinforcement learning for a self-balancing bicycle robot[J]. ISA Transactions, 2024, 145: 479-492.

[69] MA Q, ZHANG X, XU X, et al. Self-learning sliding mode control based on adaptive dynamic programming for nonholonomic mobile robots[J]. ISA Transactions, 2023, 142: 136-147.

[70] GARCIA J, FERNANDEZ F. A comprehensive survey on safe reinforcement learning[J]. Journal of Machine Learning Research, 2015, 16: 1437-1480.

[71] OSBORNE M, SHIN H-S, TSOURDOS A. A Review of Safe Online Learning for Nonlinear Control Systems[C]. 2021 International Conference on Unmanned Aircraft Systems, Athens, Greece, 2021: 794-803.

[72] KALAGARLA K, JAIN R, NUZZO P. Safe Posterior Sampling for Constrained MDPs with Bounded Constraint Violation[J/OL]. 2023. ArXiv.2301.11547.

[73] LUO X, HAO T, LI S. Platoon Control of Connected Vehicles via Safe Reinforcement Learning Based on Lyapunov Based Soft Actor Critic Algorithm[C]. Proceedings of 36th Chinese Control and Decision Conference, Xi’ an, China, 2024: 896-901.

[74] KAMALAPURKAR R, WALTERS P, ROSENFELD J, et al. Reinforcement Learning for Optimal Feedback Control: A Lyapunov-Based Approach[M]. Springer, 2018.

[75] METELLI A M, PIROTTA M, CALANDRIELLO D, et al. Safe Policy Iteration: A Monotonically Improving Approximate Policy Iteration Approach[J]. Journal of Machine Learning Research, 2021, 22:1-83.

中国知网 https://www.cnki.net

[76] KöNIGHOFER B, RUDOLF J, PALMISANO A, et al. Online shielding for reinforcement learning[J]. Innovations in System and Software Engineering, 2023, 19: 379-394.

[77] LUO W, SUN W, KAPOOR A. Sample-Efficient Safe Learning for Online Nonlinear Control with Control Barrier Functions[C]. 15th Workshop on the Algorithmic Foundations of Robotics, Maryland, USA, 2022: 419-435.

[78] GARCIA J, SHAFIE D. Teaching a humanoid robot to walk faster through Safe Reinforcement Learning[J]. Engineering Applications of Artificial Intelligence, 2020, 88: 0952-1976.

[79] WANG X. Ensuring Safety of Learning-Based Motion Planners Using Control Barrier Functions[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 4773-4780.

[80] AGRAWAL A, SREENATH K. Discrete Control Barrier Functions for Safety Critical Control of Discrete Systems with Application to Bipedal Robot Navigation[C]. Proceedings of 13th Conference on Robotics-Science and Systems, Massachusetts, USA, 2017: 1-10.

[81] KHAN M, CHATTERJEE A. Gaussian Control Barrier Functions: Safe Learning and Control[C]. Proceedings of 59th IEEE Conference on Decision and Control, Jeju, Korea (South), 2020: 3316-3322.

[82] TAYLOR A J, AMES A D. Adaptive Safety with Control Barrier Functions[C]. 2020 American Control Conference, CO, USA, 2020: 1399-1405.

[83] LI Z, TIAN B, ZHANG X. Adaptive prescribed performance sliding mode control based on time-varying barrier function[J]. Asian Journal of Control, 2024, 26(3): 1528-1539.

[84] BRUGGEMANN S, STEEVES D, KRSTIC M. Simultaneous Lane-Keeping and Obstacle Avoidance by Combining Model Predictive Control and Control Barrier Functions[C]. Proceedings of IEEE 61st Conference on Decision and Control, Cancun, Mexico, 2022: 5285-5290.

[85] JAGTAP P, PAPPAS G J, ZAMANI M. Control Barrier Functions for Unknown Nonlinear Systems using Gaussian Processes[C]. Proceedings of 59th IEEE Conference on Decision and Control, Jeju, Korea (South), 2020: 3699-3704.

[86] HU Y, FU J, WEN G. Safe Reinforcement Learning for Model-Reference Trajectory Tracking of Uncertain Autonomous Vehicles With Model-Based Acceleration[J]. IEEE Transactions on Intelligent Vehicles, 2023, 8(3):

中国知网 https://www.cnki.net

2332-2344.

[87] RANDLøV J A P. Learning to Drive a Bicycle Using Reinforcement Learning and Shaping[C]. The Fifteenth International Conference on Machine Learning, Wisconsin, USA, 1998: 463-471.

[88] RANDLøV J. Shaping in Reinforcement Learning by Changing the Physics of the Problem[C]. The Seventeenth International Conference on Machine Learning, CA, USA, 2000: 767-774.

[89] COOK M. It Takes Two Neurons To Ride a Bicycle[J]. Demonstration at nips, 2004, 4.

[90] CHUNG T. Controlling bicycle using deep deterministic policy gradient algorithm[C]. 2017 14th International Conference on Ubiquitous Robots and Ambient Intelligence, Jeju, South Korea, 2017: 413-417.

[91] CHOI S Y, LE T P, NGUYEN Q D, et al. Toward Self-Driving Bicycles Using State-of-the-Art Deep Reinforcement Learning Algorithms[J]. Symmetry Basel, 2019, 11(2): 290.

[92] ZHENG Q Y, WANG D, CHEN Z, et al. Continuous reinforcement learning based ramp jump control for single-track two-wheeled robots[J]. Transactions of the Institute of Measurement and Control, 2022, 44(4): 892-904.

[93] MüLLER P C, MAGNUS K. A pioneer of multibody system dynamics[J]. Multibody System Dynamics, 2013, 30(2): 199-207.

[94] NEWTON I, MOTTE T B. The Mathematical Principles of Natural Philosophy[M]. University of California Press, 2014.

[95] 张元波, 张奇志, 周亚丽. 基于虚拟重力的双足机器人迭代学习控制[J]. 北京信息科技大学学报(自然科学版), 2009, 24(04): 21-24.

[96] ZHANG F, YU Y, WANG Q. A terrain-adaptive robot prototype designed for bumpy-surface exploration[J]. Mechanism and Machine Theory, 2019, 141: 213-225.

[97] DOMINGUEZ S, ALI A, GARCIA G, et al. Comparison of lateral controllers for autonomous vehicle: experimental results[C]. 2016 IEEE International Conference on Intelligent Transportation Systems, Rio de Janeiro, Brazil, 2016: 1418-1423.

[98] Montemerlo M THRUN S D H E A. Stanley: The robot that won the DARPA Grand Challenge[J]. Journal of Field Robotics, 2006, 23(9): 661-692.

[99] BLOCH A M, KRISHNAPRASAD P S, MARSDEN J E. Nonholonomic mechanical systems with symmetry[J]. Archive for Rational Mechanics and Analysis, 1996, 136(1): 21-99.

中国知网 https://www.cnki.net

[100] OLFATI-SABER R. Nonlinear control of underactuated mechanical systems with application to robotics and aerospace vehicles[J]. IEEE Transactions on Automatic Control, 2002, 47(2): 305-308.

[101] SPONG M W, CORKE P, LOZANO R. Nonlinear control of the Reaction Wheel Pendulum[J]. Automatica, 2001, 37(1): 1845-1851.

[102] WATKINS C. Learning from delayed rewards[D]. Cambridge University, 1989.

[103] ZHAO W S, QUERALTA J P, WESTERLUND T. Sim-to-Real Transfer in Deep Reinforcement Learning for Robotics: A Survey[C]. 2020 IEEE Symposium Series on Computational Intelligence, ACT, Australia, 2020: 737-744.

[104] PENG X B, ANDRYCHOWICZ M, ZAREMBA W, et al. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[C]. 2018 IEEE International Conference on Robotics and Automation, Brisbane, Australia, 2018: 3803-3810.

[105] CARLSON A, SKINNER K A, VASUDEVAN R, et al. Sensor Transfer: Learning Optimal Sensor Effect Image Augmentation for Sim-to-Real Domain Adaptation[J]. IEEE Robotics and Automation Letters, 2019, 4(3): 2431-2438.

[106] SINGH S, JAAKKOLA T, LITTMAN M L, et al. Convergence results for single-step on-policy reinforcement-learning algorithms[J]. Machine Learning, 2000, 38(3): 287-308.

[107] LAGOUDAKIS M G, PARR R. Least-squares policy iteration[J]. Journal of Machine Learning Research, 2004, 4(6): 1107-1149.

[108] SCHULMAN J, MORITZ P, LEVINE S, et al. High-dimensional continuous control using generalized advantage estimation[J]. CoRR, 2015.

[109] CONN A R, GOULD N I, TOINT P L. Trust region methods[M]. SIAM, 2000.

[110] KULLBACK S, LEIBLER R A. On information and sufficiency[J]. The Annals of Mathematical Statistics, 1951, 22(1): 79-86.

[111] CHOI H H. LMI-Based Sliding Surface Design for Integral Sliding Mode Control of Mismatched Uncertain Systems[J]. IEEE Transactions on Automatic Control, 2007, 52(4): 736-742.

[112] 刘金琨. 滑模变结构控制 MATLAB 仿真基本理论与设计方法[M]. 北京: 清华大学出版社, 2019.

[113] YU X H, MAN Z H. Fast terminal sliding-mode control design for nonlinear

中国知网 https://www.cnki.net

dynamical systems[J]. IEEE Transactions on Circuits and Systems I-Regular Papers, 2002, 49(2): 261-264.

[114] YU S H, YU X H, MAN Z H, et al. Robust global terminal sliding mode control of SISO nonlinear uncertain systems[C]. Proceedings of the 39th IEEE Conference on Decision and Control, NSW, Australia, 2000: 2198-2203.

[115] SAM J M. A class of proportional-integral sliding mode control with application to active suspension system[J]. Systems Control Letters, 2004, 51(3-4): 217-223.

[116] LIU S, LIN S. LMI-based robust sliding control for mismatched uncertain nonlinear systems using fuzzy models[J]. International Journal of Robust and Nonlinear Control, 2012, 22.

[117] MATTHEWS G P, DECARLO R A. Decentralized tracking for a class of interconnected nonlinear-systems using variable structure control[J]. Automatica, 1988, 24(2): 187-193.

[118] UTKIN V, SHI J X. Integral sliding mode in systems operating under uncertainty conditions[C]. Proceedings of the 35th IEEE Conference on Decision and Control, Kobe, Japan, 1996: 4591-4596.

[119] WEI X, GUO L. Composite disturbance-observer-based control and terminal sliding mode control for non-linear systems with disturbances[J]. International Journal of Control, 2009, 82(6): 1082-1098.

[120] LU Y S, CHIU C W. A Stability-Guaranteed Integral Sliding Disturbance Observer for Systems Suffering from Disturbances with Bounded First Time Derivatives[J]. International Journal of Control Automation and Systems, 2011, 9(2): 402-409.

[121] Kamal S CHALANGA A F L M E A. Implementation of Super-Twisting Control: Super-Twisting and Higher Order Sliding-Mode Observer-Based Approaches[J]. IEEE Transactions on Industrial Electronics, 2016, 63(6): 3677-3685.

[122] SHTESSEL Y, EDWARDS C, FRIDMAN L, et al. Sliding Mode Control and Observation[M]. Birkhäuser New York, NY, 2014.

[123] SHAO K, ZHENG J, WANG H, XU F, WANG X, LIANG B. Recursive sliding mode control with adaptive disturbance observer for a linear motor positioner[J]. Mechanical Systems and Signal Processing, 2021, 146, 107014.

[124] 郭瑛, 艾渤, 钟章队. 重要性采样研究进展[J]. 信息与电子工程, 2011, 9(05): 604-609.

中国知网 https://www.cnki.net

[125] GUO L, LIAO Q, WEI S. Design of fuzzy sliding-mode controller for bicycle robot nonlinear system[C]. IEEE International Conference on Robotics and Biomimetics, Kunming, China, 2006: 176-180.

[126] CHEN L, LIU J, WANG H, et al. Robust control of reaction wheel bicycle robot via adaptive integral terminal sliding mode[J]. Nonlinear Dynamics, 2021, 104(3): 2291-2302.

[127] ZHU X J, DENG Y, ZHENG X D, et al. Online reinforcement-learning based adaptive terminal sliding mode control for disturbed bicycle robots on a curved pavement[J]. Electronics, 2022, 11(21): 3495-3512.

[128] ZHU X J, DENG Y, ZHENG X D, et al. Online series-parallel reinforcement learning-based balancing control for reaction wheel bicycle robots on a curved pavement[J]. IEEE Access, 2023, 11: 3495-3512.

[129] HUO B, YU L, LIU Y, et al. Reinforcement learning based path tracking control method for unmanned bicycle on complex terrain[C]. IECON 2023 49th Annual Conference of the IEEE Industrial Electronics Society, Singapore, Singapore, 2023: 1-6.

[130] FRANCOIS-LAVET V, HENDERSON P, ISLAM R, et al. An Introduction to Deep Reinforcement Learning[J]. Foundations and Trends® in Machine Learning, 2023, 11(3-4): 219-354.

[131] YU S H, YU X H, ZHIHONG M. Robust global terminal sliding mode control of SISO nonlinear uncertain systems[C]. Proceedings of the 39th IEEE Conference on Decision and Control, NSW, Australia, 2000: 2198-2203.

[132] SRINIVAS N, KRAUSE A, KAKADE S M, et al. Information- theoretic regret bounds for gaussian process optimization in the bandit setting[J]. IEEE Transactions on Information Theory, 2012, 58(5): 3250 – 3265.

[133] LEDERER A, UMLAUFT J, HIRCHE S. Uniform error bounds for gaussian process regression with application to safe control[J]. Neural Information Processing Systems, 2019.

[134] CESA-BIANCHI N, GENTILE C, LUGOSI G. Boltzmann Exploration Done Right[C]. Proceedings of the 31st Annual Conference on Neural Information Processing Systems, NY, USA, 2017: 6287-6296.

[135] AUER P, CESA-BIANCHI N, FISCHER P. Finite-time analysis of the multi armed bandit problem[J]. Machine Learning, 2002, 47(2-3): 235-256.

[136] FORTUNATO M, AZAR M G, PIOT B, et al. Noisy networks for exploration[J/OL]. 2017. ArXiv.1706.10295.

中国知网 https://www.cnki.net

[137] FREIRE V, NICOTRA M M. Systematic Design of Discrete-Time Control Barrier Functions Using Maximal Output Admissible Sets[J]. IEEE Control Systems Letters, 2023, 7: 1891-1896.

[138] CLARK A. Verification and Synthesis of Control Barrier Functions[C]. 2021 60th IEEE Conference on Decision and Control, TX, USA, 2021: 6105-6112.

中国知网 https://www.cnki.net

附录 A 在线强化学习与滑模结合的仿真测试结果

为了支持第三章的相关分析及统计结果，附录 A 提供了在线强化学习与滑模控制相结合的仿真测试中所有测试案例的跟踪误差曲线随时间变化的情况。此外，相关定量分析指标的统计结果原始数据也已在表格中列出。

表 A-1 任务一的仿真测试完成情况 (秒)
Table A-1 Simulation test completion status of task 1 (s)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	-	-	-	-	-	-	40.4	10.3	22.6
ATSMC	-	-	-	-	-	-	-	-	-
OTSMC	-	-	-	-	-	-	-	12.6	-
SRL	-	-	-	-	-	-	-	-	22.7
PRL	-	-	-	-	-	-	-	-	-
SPRL	-	-	-	-	-	-	-	-	-

表 A-2 任务二的仿真测试完成情况 (秒)
Table A-2 Simulation test completion status of task 2 (s)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	-	-	-	-	-	-	33.1	8.38	10.3
ATSMC	-	-	-	36.0	-	-	9.01	8.20	3.74
OTSMC	-	-	-	-	-	-	-	11.1	-
SRL	-	-	-	-	-	-	1.32	8.08	1.26
PRL	-	-	-	-	-	-	10.6	43.1	30.9
SPRL	-	-	-	-	-	-	45.6	-	-

表 A-3 任务一中跟踪误差的最大值 (10^{-1}rad)
Table A-3 Maximum tracking error of task 1 (10^{-1}rad)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	1.15	1.19	0.952	1.20	1.36	1.13	-	-	-
ATSMC	1.02	1.01	1.22	1.22	1.07	1.08	1.39	1.34	1.57
OTSMC	1.03	0.987	0.984	1.12	1.09	1.07	1.77	-	1.36
SRL	1.09	0.984	1.03	1.02	1.01	0.998	1.42	1.61	-
PRL	1.13	1.14	1.12	1.27	1.17	1.28	1.72	2.15	1.34
SPRL	1.06	1.05	0.975	1.05	1.06	1.15	1.78	1.67	1.62

中国知网 https://www.cnki.net

表 A-4 任务二中跟踪误差的最大值 (10^{-1}rad)
Table A-4 Maximum tracking error of task 2 (10^{-1}rad)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	0.993	1.01	1.11	1.55	1.29	1.20	-	-	-
ATSMC	1.29	1.14	1.42	-	1.87	2.06	-	-	-
OTSMC	0.386	0.405	0.347	0.353	0.412	0.406	1.26	-	1.30
SRL	1.06	1.32	0.971	0.952	1.02	0.881	-	-	-
PRL	1.05	1.13	1.05	1.49	1.22	1.27	-	-	-
SPRL	0.955	0.968	0.862	1.21	0.917	0.913	-	1.52	1.24

表 A-5 任务一中跟踪误差的 RMS(10^{-3}rad^2)
Table A-5 RMS tracking error of task 1 (10^{-3}rad^2)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	1.03	1.02	0.916	0.968	0.992	0.934	-	-	-
ATSMC	0.925	0.923	0.872	0.934	0.912	0.833	1.06	1.10	1.10
OTSMC	0.979	0.944	0.816	1.05	0.962	0.824	1.45	-	1.06
SRL	0.954	0.920	0.853	0.925	0.926	0.843	1.58	1.46	-
PRL	1.05	1.05	0.933	1.03	0.975	0.971	1.66	1.87	1.45
SPRL	0.953	0.925	0.806	0.943	0.930	0.811	1.29	1.22	1.07

表 A-6 任务二中跟踪误差的 RMS(10^{-3}rad^2)
Table A-6 RMS tracking error of task 2 (10^{-3}rad^2)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	0.667	0.712	0.665	1.18	1.12	0.931	-	-	-
ATSMC	0.758	0.757	0.755	-	1.18	1.18	-	-	-
OTSMC	0.827	0.827	0.745	0.955	0.992	0.892	0.920	-	1.49
SRL	0.703	0.689	0.589	0.891	0.768	0.663	-	-	-
PRL	0.671	0.763	0.637	1.04	0.943	0.840	-	-	-
SPRL	0.600	0.600	0.529	0.720	0.692	0.640	-	0.998	0.870

表 A-7: 任务一中控制力矩绝对值的累加 (10^2Nm)
Table A-7: Accumulation of control moment of task 1 (10^2Nm)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	6.62	7.24	7.90	6.22	6.80	7.67	-	-	-
ATSMC	2.83	3.23	3.22	2.95	3.12	3.03	3.47	4.02	4.55
OTSMC	0.338	0.346	0.378	0.477	0.378	0.405	0.917	-	0.746
SRL	3.08	3.62	3.97	3.22	3.48	3.58	7.90	7.09	-

中国知网 https://www.cnki.net

表 A-7（续表）

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
PRL	1.45	1.70	1.54	1.36	1.32	1.27	2.41	2.70	2.24
SPRL	1.92	1.98	2.29	1.98	2.09	2.22	4.31	3.87	3.98

表 A-8 任务二中控制力矩绝对值的累加 (10^2Nm)

Table A-8 Accumulation of absolute control moment of task 2 (10^2Nm)

任务	场景 1			场景 2			场景 3		
	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3	参数 1	参数 2	参数 3
TSMC	5.45	6.99	7.51	9.64	10.0	9.28	-	-	-
ATSMC	8.47	8.79	9.55	-	11.2	12.2	-	-	-
OTSMC	0.490	0.500	0.565	0.504	0.551	0.614	1.01	-	1.38
SRL	3.43	3.20	3.48	4.03	4.05	4.10	-	-	-
PRL	1.00	1.51	1.33	1.77	1.72	1.63	-	-	-
SPRL	2.18	2.20	2.37	2.51	2.47	2.83	-	5.88	6.31

中国知网 https://www.cnki.net